LAPORAN TUGAS AKHIR

KLASTERISASI PROFIL PASIEN RAWAT INAP MENGGUNAKAN ALGORITMA K-MEANS PADA RUMAH SAKIT ISLAM FATIMAH CILACAP

Diajukan sebagai Pedoman Pelaksanaan Penelitian Tugas Akhir

Jurusan Informatika Fakultas Teknik

Universitas Jenderal Soedirman

Oleh:

SUFYAN ABDUR ROFIQ

H1D022004

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
UNIVERSITAS JENDERAL SOEDIRMAN
FAKULTAS TEKNIK
JURUSAN INFORMATIKA
PURWOKERTO

2026

LEMBAR PENGESAHAN

Tugas Akhir dengan judul:

KLASTERISASI PROFIL PASIEN RAWAT INAP MENGGUNAKAN ALGORITMA K-MEANS PADA RUMAH SAKIT ISLAM FATIMAH CILACAP

Disusun oleh:

SUFYAN ABDUR ROFIQ

H1D022004

Diajukan untuk memenuhi salah satu persyaratan memperoleh gelar Sarjana Komputer pada Jurusan/Program Studi Informatika Fakultas Teknik Universitas Jenderal Soedirman

Disetujui dan disahkan

Pada Tanggal: : 5 Mei 2026

Dosen Pembimbing I	**Dosen Pembimbing II**
Ir. Nofiyati, S.Kom., M.Kom., IPM	**Ir. Nur Alfi Ekowati, S.Kom., M.Sc**
NIP. 198108192024212012	**NIP. 199001302025062006**

Mengetahui,
Dekan Fakultas Teknik

Prof. Dr. Eng. Ir. Agus Maryoto, ST., M.T., IPU., ASEAN Eng.
NIP. 197109202006041001

HALAMAN PERNYATAAN KEASLIAN SKRIPSI

Saya yang bertanda tangan di bawah ini:

Nama : Sufyan Abdur Rofiq

NIM : H1D022004

Program Studi : Informatika

Dengan ini menyatakan bahwa skripsi yang saya buat dengan judul:

KLASTERISASI PROFIL PASIEN RAWAT INAP MENGGUNAKAN ALGORITMA K-MEANS PADA RUMAH SAKIT ISLAM FATIMAH CILACAP

adalah hasil karya asli saya dan belum pernah diajukan untuk memperoleh gelar kesarjanaan di perguruan tinggi manapun. Sepanjang pengetahuan saya, tidak terdapat karya atau pendapat yang ditulis atau diterbitkan oleh orang lain, kecuali yang secara tertulis diacu dalam naskah ini dan disebutkan dalam daftar pustaka.

Demikian pernyataan ini saya buat dengan sebenar-benarnya tanpa ada paksaan dari pihak manapun. Apabila dikemudian hari terbukti bahwa saya memberikan pernyataan palsu, maka saya bersedia menerima sanksi yang telah ditetapkan.

Purbalingga, 30 April 2026



Sufyan Abdur Rofiq

HALAMAN PERSEMBAHAN

Tiada lembar yang paling indah dalam laporan tugas akhir ini kecuali lembar persembahan. Dengan mengucap syukur atas Rahmat Allah SWT, tugas ini saya persembahkan sebagai tanda bukti kepada:

1. Kedua orang tua tercinta, Umi dan Abi. Terima kasih atas segala cinta, doa, dan kepercayaan yang senantiasa kalian berikan tanpa henti. Terima kasih karena selalu mendukung setiap langkah dan keputusan hidup saya dengan penuh ketulusan. Semoga Allah selalu melimpahkan kebahagiaan, kesehatan, dan perlindungan kepada Umi dan Abi. Saya sangat bersyukur dan bangga memiliki orang tua seperti kalian.
2. Adik tersayang, Zahrotun Nida Al Mubarokah. Terima kasih atas dukungan dan semangat yang selalu kamu berikan selama perjalanan ini. Kehadiranmu menjadi motivasi bagi saya untuk terus berjuang, bukan hanya demi diri sendiri, tetapi juga untuk menjadi teladan dan sumber inspirasi bagimu. Semoga kita senantiasa saling menguatkan, berkembang bersama, dan menjadi kebanggaan bagi keluarga.
3. Muhammad Galih, sahabat yang selalu setia mendampingi sejak awal perkuliahan hingga terselesaikannya tugas akhir ini. Terima kasih atas dukungan, semangat, dan kebersamaan yang penuh makna. Kehadiranmu menjadi bagian berharga dalam setiap proses dan perjuangan yang telah dilalui.
4. Teman-teman Kost Blater 34, yang selalu menghadirkan kebersamaan dan semangat selama masa perkuliahan. Terutama kepada Heri Pebrianto, terima kasih atas dorongan dan motivasi yang diberikan kepada saya untuk berani

memulai proses pengajuan hingga pengerjaan tugas akhir ini. Dukungan kalian menjadi salah satu penyemangat dalam menyelesaikan perjalanan ini.

5. Kepada diri saya, Sufyan Abdur Rofiq. Sebuah penghargaan atas keteguhan hati dalam menapaki perjalanan panjang ini hingga selesai. Tidak sedikit rintangan, rasa lelah, dan keraguan yang menyertai, namun kamu tetap berkomitmen untuk menuntaskan apa yang telah dimulai. Dengan kesabaran, usaha yang konsisten, dan doa yang tak terputus, akhirnya tahap ini dapat dilewati dengan baik. Semoga pencapaian ini menjadi awal dari langkah-langkah besar berikutnya dan pengingat bahwa setiap perjuangan selalu memiliki makna.

HALAMAN MOTTO

“Sesungguhnya bersama kesulitan ada kemudahan”

(QS. Al-Insyirah: 6)

“Allah tidak membebani seseorang melainkan sesuai dengan kesanggupannya”

(QS. Al-Baqarah: 286)

“Cukuplah Allah menjadi penolong kami dan Dia sebaik-baik pelindung”

(QS. Al-Imran: 173)

KATA PENGANTAR

Puji syukur ke hadirat Tuhan Yang Maha Esa atas rahmat dan karunia- Nya, sehingga saya dapat menyusun dan menyelesaikan penelitian dengan judul "Klasterisasi Profil Pasien Rawat Inap menggunakan Algoritma K-Means pada Rumah Sakit Islam Fatimah Cilacap" sebagai salah satu persyaratan memperoleh gelar Sarjana Komputer di Jurusan Informatika Universitas Jenderal Soedirman.

Dalam proses penyusunan penelitian ini, saya mendapatkan berbagai dukungan, arahan, serta masukan dari banyak pihak. Oleh karena itu, dengan penuh hormat dan rasa syukur, saya menyampaikan terima kasih kepada:

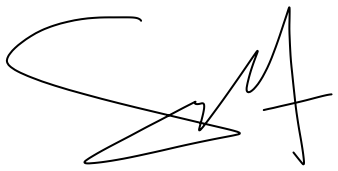
1. Allah SWT yang telah melimpahkan rahmat dan karunia-Nya kepada saya sehingga saya diberikan kemudahan dalam menyusun laporan tugas akhir ini.
2. Bapak Prof. Dr. Eng. Ir. Agus Maryoto, S.T., M.T., IPU., ASEAN.Eng., selaku Dekan Fakultas Teknik, Universitas Jenderal Soedirman.
3. Bapak Dr. Ir. Lasmedi Afuan, S.T., M.Cs., IPM., selaku Ketua Jurusan Informatika, Fakultas Teknik, Universitas Jenderal Soedirman.
4. Bapak Ir. Bangun Wijayanto, S.T., M.Cs., IPM., selaku Dosen Pembimbing Akademik, yang selama ini telah memberikan bimbingan, nasihat, dan dukungan selama perjalanan akademik saya.
5. Ibu Ir. Nofiyati, S.Kom., M.Kom., IPM., selaku Dosen Pembimbing I dan Ibu Ir. Nur Alfi Ekowati, S.Kom., M.Sc., selaku Dosen Pembimbing II yang dengan penuh perhatian telah memberikan arahan, bimbingan, serta masukan berharga selama proses penelitian berlangsung.
6. Bapak dr. H. Nono Rasino, Sp.OG(K)FER., selaku Direktur Utama Rumah

Sakit Islam Fatimah Cilacap yang telah mengizinkan untuk melakukan penelitian dan pengambilan data pasien.

7. Ibu Rini Andriyani selaku Staf Bagian Sumber Daya Insani dan Dakwah Rumah Sakit Islam Fatimah Cilacap yang telah membantu dalam proses perizinan.
8. Ibu dr. Betaningrum selaku Kepala Instalasi Rekam Medis Rumah Sakit Islam Fatimah Cilacap yang telah membantu dalam proses pengambilan data pasien.
9. Bapak Dedi Mulyana selaku Kepala Instalasi PDE (IT) Rumah Sakit Islam Fatimah Cilacap yang telah membantu dalam proses pengembangan aplikasi.
10. Orang tua dan keluarga tercinta atas doa, semangat, serta dukungan.
11. Rekan-rekan seperjuangan di Jurusan Informatika angkatan 2022, serta seluruh pihak yang telah memberikan dukungan dan masukan.

Dengan disusunnya laporan tugas akhir ini, saya berharap penelitian ini dapat memberikan manfaat serta menjadi inspirasi bagi para pembaca. Saya menyadari bahwa dalam proses penyusunannya masih terdapat kekurangan dan belum mencapai kesempurnaan. Oleh karena itu, saya mengharapkan kritik dan saran yang membangun sebagai bahan perbaikan dan penyempurnaan penelitian ini.

Purbalingga, 30 April 2026



Sufyan Abdur Rofiq

DAFTAR ISI

LEMBAR PENGESAHAN ii
HALAMAN PERNYATAAN KEASLIAN SKRIPSI iii
HALAMAN PERSEMBAHAN iv
HALAMAN MOTTO vi
KATA PENGANTAR vii
DAFTAR ISI ix
DAFTAR GAMBAR xi
DAFTAR TABEL xiii
DAFTAR *LISTING PROGRAM* xiv
ABSTRAK xv
ABSTRACT xvi
BAB I PENDAHULUAN 1
1.1. Latar Belakang 1
1.2. Rumusan Masalah 3
1.3. Batasan Masalah 3
1.4. Tujuan Penelitian 5
1.5. Manfaat Penelitian 5
BAB II TINJAUAN PUSTAKA 7
2.1. *Data Mining* 7
2.2. Klasterisasi /*Clustering* 7
2.3. Profil 8
2.4. Pasien Rawat Inap 9
2.5. Mekanisme Rawat Inap 10
2.6. Algoritma 11
2.7. Algoritma K-Means 12
2.8. Metode *Elbow* 14
2.9. *Silhouette Score* 15
2.10. *Davies-Bouldin Index* (DBI) 16
2.11. *Python* 17
2.12. PHP 18
2.13. *Laravel* 19
2.14. Metode Pengembangan Sistem *Waterfall* 19
2.15. Penelitian Sejenis 22
BAB III METODOLOGI PENELITIAN 26
3.1. Waktu dan Tempat Penelitian 26
3.2. Alat dan Data Penelitian 26
3.2.1. Alat Penelitian 26
3.2.2. Data Penelitian 26
3.3. Mekanisme Penelitian 27
3.3.1. Pengumpulan Data 27
3.3.2. *Data Preprocessing* 29
3.3.3. Proses Klasterisasi 33
3.3.4. Evaluasi 35

3.3.5. Pengembangan *Website* 37
BAB IV HASIL DAN PEMBAHASAN 40
4.1. Pengumpulan Data 40
4.2. *Data Preprocessing* 43
4.2.1. *Data Selection* 43
4.2.2. *Data Cleaning* 44
4.2.3. *Data Transformation* 46
4.2.4. *Data Reduction* 55
4.3. Proses Klasterisasi 57
4.4. Evaluasi 69
4.5. Pengembangan *Website* 79
4.5.1. Analisis Kebutuhan 80
4.5.2. Desain Sistem 83
4.5.3. Implementasi 88
4.5.4. Pengujian 141
4.5.5. Pemeliharaan 146
BAB V PENUTUP 147
5.1. Kesimpulan 147
5.2. Saran 149
DAFTAR PUSTAKA 150
LAMPIRAN 153

DAFTAR GAMBAR

Gambar 1. Mekanisme Penelitian 27
Gambar 2. *Data Preprocessing* 29
Gambar 3. Alur K-Means 35
Gambar 4. Metode *Waterfall* 38
Gambar 5. *Missing Values* 44
Gambar 6. Pemeriksaan Data Duplikat 45
Gambar 7. Pengecekan Data Tidak Valid 46
Gambar 8. Hasil *Feature Engineering* 48
Gambar 9. Data Sebelum Standarisasi 49
Gambar 10. Data Setelah Standarisasi 53
Gambar 11. Hasil *One-Hot Encoding* 55
Gambar 12. Dimensi Data Sebelum PCA 56
Gambar 13. Dimensi Data Setelah PCA 57
Gambar 14. Grafik *Elbow Method* 60
Gambar 15. Grafik *Silhouette Score* 61
Gambar 16. Grafik *Davies-Bouldin Index* (DBI) 62
Gambar 17. Perbandingan Nilai *Elbow Method* 71
Gambar 18. Perbandingan Nilai *Silhouette Score* 74
Gambar 19. Perbandingan Nilai *Davies-Bouldin Index* (DBI) 77
Gambar 20. *Use Case Diagram* Admin 84
Gambar 21. *Use Case Diagram* Tenaga Medis 85
Gambar 22. *Activity Diagram* Admin 87
Gambar 23. *Activity Diagram* Tenaga Medis 88
Gambar 24. Halaman *Login* Admin 90
Gambar 25. Halaman *Dashboard* Admin 92
Gambar 26. Halaman *Upload Dataset* Admin 93
Gambar 27. Halaman *Upload Dataset* Ketika *Dataset* Berhasil Di-*Upload* 94
Gambar 28. Halaman *Upload Dataset* Ketika Ada Kesalahan Format 95
Gambar 29. Halaman Edit Data *Dataset* Admin 96
Gambar 30. Halaman Proses Klasterisasi Admin 97
Gambar 31. Halaman Proses Klasterisasi Ketika Berhasil Dijalankan 98
Gambar 32. Halaman Laporan Hasil Admin 99
Gambar 33. Halaman Detail Hasil Klasterisasi Admin - Informasi 100
Gambar 34. Halaman Detail Hasil Klasterisasi Admin - Interpretasi 101
Gambar 35. Halaman Detail Hasil Klasterisasi Admin - Evaluasi 102
Gambar 36. Halaman Detail Hasil Klasterisasi Admin - Data Pasien 103
Gambar 37. Halaman Visualisasi Klaster Admin 104
Gambar 38. Halaman Detail Visualisasi Klaster Admin 105
Gambar 39. Grafik Distribusi Klaster Admin 106
Gambar 40. Grafik Rata-Rata Lama Rawat per Klaster Admin 107
Gambar 41. Grafik Distribusi Jumlah Pasien per Klaster Admin 108
Gambar 42. Grafik Distribusi Atribut Numerik per Klaster Admin 109
Gambar 43. Grafik Distribusi Atribut Kategorikal per Klaster Admin 110

Gambar 44. *Heatmap* Sebaran Kelompok Diagnosis - Tindakan Admin.....112
Gambar 45. *Box Plot* Distribusi Umur dan Lama Rawat per Klaster Admin.....113
Gambar 46. Grafik Profil dan Rata-Rata Diagnosis serta Tindakan Admin.....115
Gambar 47. Grafik Komposisi Jenis Kelamin dan Keadaan Keluar Admin 116
Gambar 48. Halaman Manajemen *User* Admin 117
Gambar 49. Halaman Tambah *User* Baru Admin.....118
Gambar 50. Halaman Edit Akun Pengguna Admin.....119
Gambar 51. Halaman *Login* Tenaga Medis 121
Gambar 52. Halaman *Dashboard* Tenaga Medis..... 122
Gambar 53. Halaman Laporan Hasil Tenaga Medis..... 124
Gambar 54. Halaman Detail Hasil Klasterisasi Tenaga Medis - Informasi..... 125
Gambar 55. Halaman Detail Hasil Klasterisasi Tenaga Medis - Interpretasi 126
Gambar 56. Halaman Detail Hasil Klasterisasi Tenaga Medis - Evaluasi 127
Gambar 57. Halaman Detail Hasil Klasterisasi Tenaga Medis - Data Pasien ... 128
Gambar 58. Halaman Visualisasi Klaster Tenaga Medis..... 129
Gambar 59. Halaman Detail Visualisasi Klaster Tenaga Medis 130
Gambar 60. Grafik Distribusi Klaster Tenaga Medis 132
Gambar 61. Grafik Rata-Rata Lama Rawat per Klaster Tenaga Medis 133
Gambar 62. Grafik Distribusi Jumlah Pasien per Klaster Tenaga Medis 134
Gambar 63. Grafik Distribusi Atribut Numerik per Klaster Tenaga Medis 135
Gambar 64. Grafik Distribusi Atribut Kategorikal per Klaster Tenaga Medis.. 136
Gambar 65. *Heatmap* Sebaran Kelompok Diagnosis - Tindakan Tenaga Medis137
Gambar 66. *Box Plot* Distribusi Umur dan Lama Rawat Tenaga Medis..... 138
Gambar 67. Grafik Profil dan Rata-Rata Diagnosis - Tindakan Tenaga Medis 140
Gambar 68. Grafik Jenis Kelamin dan Keadaan Keluar Tenaga Medis 141

DAFTAR TABEL

Tabel 1. Penelitian Sejenis 22
Tabel 2. *Dataset* Pasien Rawat Inap 41
Tabel 3. Perhitungan Jarak Titik Data dengan *Centroid* 65
Tabel 4. Nilai a(i), b(i), dan s(i) untuk 5 Data Pertama 73
Tabel 5. Nilai *Silhouette Score* per Klaster 73
Tabel 6. Rekapitulasi Nilai Metrik Evaluasi dan Jumlah Pasien per Klaster 79
Tabel 7. Analisis Kebutuhan Pengguna 80
Tabel 8. Hasil *Black Box Testing* 141

DAFTAR *LISTING PROGRAM*

Listing Program 1. *Z-Score Standardization*..... 49
Listing Program 2. *One-Hot Encoding*..... 54
Listing Program 3. *Elbow Method*..... 58
Listing Program 4. *Silhouette Score*..... 59
Listing Program 5. *Davies-Bouldin Index* (DBI)..... 59
Listing Program 6. Klasterisasi Menggunakan Algoritma K-Means..... 62

KLASTERISASI PROFIL PASIEN RAWAT INAP MENGGUNAKAN ALGORITMA K-MEANS PADA RUMAH SAKIT ISLAM FATIMAH CILACAP

SUFYAN ABDUR ROFIQ
H1D022004

ABSTRAK

Berdasarkan data pasien rawat inap di Rumah Sakit Islam Fatimah Cilacap pada tahun 2025, terdapat 13.024 data pasien dengan karakteristik medis dan pelayanan yang beragam. Permasalahan yang dihadapi adalah belum adanya pengelompokan pasien secara sistematis, sehingga pihak rumah sakit mengalami kesulitan dalam mengidentifikasi pola karakteristik pasien guna mendukung pengelolaan pelayanan rawat inap yang optimal. Penelitian ini bertujuan untuk menerapkan algoritma K-Means dalam proses klasterisasi profil pasien rawat inap berdasarkan karakteristik medis dan pelayanan, serta menentukan jumlah klaster optimal menggunakan metode *Elbow*, *Silhouette Score*, dan *Davies-Bouldin Index* (DBI). Hasil evaluasi menunjukkan jumlah klaster optimal pada k = 3 dengan nilai *Elbow* (WCSS) sebesar 49.148,10, *Silhouette Score* sebesar 0,2215 dan *Davies-Bouldin Index* (DBI) sebesar 1,5231. Klaster 0 terdiri dari 1.756 pasien (15,5%) yaitu kelompok pasien dengan diagnosis dominan Kehamilan dan Persalinan serta pelayanan medis Spesialis Kebidanan dan Kandungan. Klaster 1 terdiri dari 4.779 pasien (42,2%) yaitu kelompok pasien dengan diagnosis dominan Infeksi Bakteri dan Parasit serta pelayanan medis Spesialis Anak Anak. Sementara itu, Klaster 2 terdiri dari 4.794 pasien (42,3%) yaitu kelompok pasien dengan diagnosis dominan Infeksi Bakteri dan Parasit serta pelayanan medis Spesialis Penyakit Dalam. Hasil penelitian menunjukkan bahwa klasterisasi profil pasien rawat inap terdiri dari 3 klaster. Hasil klasterisasi ini telah berhasil diterapkan dalam sebuah aplikasi berbasis *website* yang menyediakan fitur analisis dan visualisasi data interaktif, sehingga dapat mendukung pihak rumah sakit dalam mengidentifikasi pola karakteristik pasien guna pengelolaan pelayanan rawat inap yang lebih optimal.

Kata kunci: *Davies-Bouldin Index, Elbow Method, Klasterisasi, K-Means, Pasien Rawat Inap, Silhouette Score, Website*

INPATIENT PROFILE CLUSTERING USING K-MEANS ALGORITHM AT FATIMAH ISLAMIC HOSPITAL CILACAP

SUFYAN ABDUR ROFIQ
H1D022004

ABSTRACT

Based on inpatient data at Fatimah Cilacap Islamic Hospital in 2025, there were 13,024 patient records with diverse medical and service characteristics. The primary challenge identified was the absence of systematic patient grouping, which hindered the hospital's ability to recognize characteristic patterns necessary for optimizing inpatient service management. This study aims to implement the K-Means algorithm to cluster inpatient profiles based on medical and service characteristics, while determining the optimal number of clusters using the Elbow method, Silhouette Score, and Davies-Bouldin Index (DBI). The evaluation results identified the optimal number of clusters at k = 3, with an Elbow (WCSS) value of 49,148.10, a Silhouette Score of 0.2215, and a Davies-Bouldin Index (DBI) of 1.5231. Cluster 0 consists of 1,756 patients (15.5%), representing a group with a dominant diagnosis of "Pregnancy and Childbirth" within Obstetrics and Gynecology services. Cluster 1 comprises 4,779 patients (42.2%), characterized by a dominant diagnosis of "Bacterial and Parasitic Infections" within Pediatric services. Meanwhile, Cluster 2 includes 4,794 patients (42.3%), featuring a dominant diagnosis of "Bacterial and Parasitic Infections" within Internal Medicine services. The study concludes that inpatient profiles are effectively categorized into three distinct clusters. These clustering results have been successfully implemented into a web-based application providing interactive data analysis and visualization features, thereby supporting the hospital in identifying patient patterns for more optimal inpatient service management.

Keywords: *Clustering, Davies-Bouldin Index, Elbow Method, Inpatient, K-Means, Silhouette Score, Website*

BAB I
PENDAHULUAN

1.1. Latar Belakang

Pemanfaatan teknologi informasi dalam bidang kesehatan terus mengalami perkembangan yang pesat, khususnya dalam pengelolaan data pelayanan rumah sakit. Setiap kegiatan pelayanan kesehatan menghasilkan data dalam jumlah besar, terutama pada pelayanan rawat inap yang mencakup data pasien, kondisi medis, serta pelayanan yang diberikan selama masa perawatan. Data tersebut memiliki potensi untuk diolah dan dianalisis guna memperoleh informasi yang bermanfaat dalam mendukung peningkatan kualitas pelayanan dan pengambilan keputusan di rumah sakit (Rusli, 2022).

Permasalahan yang sering dihadapi dalam pengelolaan data pasien rawat inap adalah belum adanya pengelompokan pasien berdasarkan karakteristik yang dimiliki. Pasien rawat inap memiliki perbedaan karakteristik dari berbagai aspek, seperti jenis kelamin, umur, lama rawat, kelas, penjamin, staf medis fungsional (SMF), keadaan keluar, ICD-10, diagnosis, ICD-9 CM dan tindakan. Perbedaan karakteristik tersebut menyebabkan kebutuhan pelayanan pasien menjadi beragam. Namun, tanpa adanya proses analisis data yang sistematis, pihak rumah sakit mengalami kesulitan dalam mengidentifikasi pola dan kesamaan karakteristik pasien secara menyeluruh (Maryati dkk., 2022).

Dampak dari kondisi tersebut adalah kurang optimalnya pengelolaan pelayanan rawat inap di rumah sakit. Rumah sakit dapat mengalami ketidakseimbangan dalam penggunaan ruang perawatan, perbedaan beban

pelayanan antar kelas perawatan, serta kesulitan dalam melakukan evaluasi terhadap lama rawat inap pasien. Selain itu, pengambilan keputusan yang berkaitan dengan perencanaan fasilitas, tenaga medis, dan pelayanan kesehatan masih belum sepenuhnya didukung oleh hasil analisis data yang objektif dan terstruktur (Ratman dkk., 2025).

Beberapa penelitian sebelumnya telah menerapkan teknik *data mining*, khususnya metode klasterisasi, untuk menganalisis data di bidang kesehatan. Metode klasterisasi digunakan untuk mengelompokkan data pasien berdasarkan tingkat kemiripan karakteristik tertentu. Namun, sebagian besar penelitian tersebut masih berfokus pada karakteristik medis saja dan belum banyak yang mengombinasikan karakteristik medis dan pelayanan secara bersamaan. Selain itu, penentuan jumlah klaster pada penelitian sebelumnya umumnya masih menggunakan satu metode evaluasi, sehingga kualitas klaster yang dihasilkan belum tentu optimal (Masruriyah dkk., 2025).

Untuk mengatasi permasalahan tersebut, penelitian ini mengimplementasikan algoritma K-Means dalam proses klasterisasi profil pasien rawat inap di Rumah Sakit Islam Fatimah Cilacap. Algoritma K-Means dipilih karena mampu mengelompokkan data berdasarkan tingkat kemiripan antar pasien tanpa memerlukan label awal. Melalui analisis terhadap variabel medis dan pelayanan yang digunakan, algoritma ini diharapkan dapat membentuk kelompok pasien rawat inap yang memiliki karakteristik serupa (Sjamsuddin dkk., 2025).

Selain itu, penelitian ini bertujuan menentukan jumlah klaster yang optimal agar hasil klasterisasi memiliki kualitas yang baik. Penentuan jumlah klaster

dilakukan dengan mengombinasikan metode *elbow*, *silhouette score*, dan *davies-bouldin index* (DBI) sebagai metode evaluasi klaster (Hardiansyah dkk., 2025). Penggunaan beberapa metode evaluasi tersebut bertujuan menghasilkan jumlah klaster yang lebih representatif, sehingga hasil klasterisasi dapat dimanfaatkan sebagai dasar pendukung pengambilan keputusan dalam pengelolaan pelayanan rawat inap di Rumah Sakit Islam Fatimah Cilacap.

1.2. Rumusan Masalah

Berdasarkan latar belakang dan identifikasi permasalahan yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

a. Bagaimana menerapkan algoritma K-Means dalam melakukan klasterisasi profil pasien rawat inap di Rumah Sakit Islam Fatimah Cilacap berdasarkan karakteristik medis dan pelayanan?
b. Bagaimana menentukan jumlah klaster yang optimal dan evaluasi kualitas hasil klasterisasi profil pasien rawat inap menggunakan metode *elbow*, *silhouette score*, dan *davies-bouldin index* (DBI)?

1.3. Batasan Masalah

Untuk menjaga dan membatasi pembahasan masalah yang terlalu luas dan agar penelitian tetap terfokus pada tujuan, maka batasan masalahnya ditetapkan sebagai berikut:

a. Data yang digunakan dalam penelitian ini adalah data pasien rawat inap Rumah Sakit Islam Fatimah Cilacap periode Januari hingga Desember 2025. Data tersebut diperoleh dari Instalasi Rekam Medis dan bersumber langsung dari

Sistem Informasi Manajemen Rumah Sakit (SIMRS), dengan total sebanyak 13.024 data pasien.

b. Penelitian ini hanya membahas klasterisasi profil pasien rawat inap menggunakan algoritma K-Means, dengan memanfaatkan variabel medis dan pelayanan seperti jenis kelamin, umur, lama rawat, kelas, penjamin, staf medis fungsional (SMF), keadaan keluar, ICD-10, diagnosis, ICD-9 CM dan tindakan, tanpa mencakup analisis prediksi, klasifikasi, maupun analisis kausal.

c. Penentuan jumlah klaster optimal dan evaluasi kualitas klaster dilakukan menggunalkan metode *elbow*, *silhouette score*, dan *davies-bouldin index* (DBI), serta hasil penelitian dibatasi pada analisis karakteristik setiap klaster yang terbentuk.

d. Penyajian hasil klasterisasi dilakukan melalui media berbasis *website* yang dikembangkan menggunakan bahasa pemrograman *python* dan PHP dengan memanfaatkan *framework laravel*, yang dirancang agar dapat digunakan secara berkelanjutan untuk mengolah dan menganalisis *dataset* pasien rawat inap yang baru.

e. Luaran penelitian ini berupa model klasterisasi profil pasien rawat inap dan aplikasi berbasis *website* yang menampilkan hasil klasterisasi serta visualisasi klaster. Aplikasi tersebut dapat digunakan oleh pihak rumah sakit sebagai media analisis dan pendukung dalam pengelolaan pelayanan rawat inap, serta dapat diakses oleh dua jenis pengguna (*user*), yaitu admin dan tenaga medis (dokter/perawat), sesuai dengan kebutuhan penggunaan sistem.

1.4. Tujuan Penelitian

Berdasarkan rumusan masalah di atas, maka tujuan dari penelitian ini adalah sebagai berikut:

a. Menerapkan algoritma K-Means untuk melakukan klasterisasi profil pasien rawat inap di Rumah Sakit Islam Fatimah Cilacap berdasarkan karakteristik medis dan pelayanan.
b. Menentukan jumlah klaster yang optimal dan evaluasi kualitas klaster menggunakan metode *elbow*, *silhouette score*, dan *davies-bouldin index* (DBI) agar klaster yang dihasilkan bersifat representatif dan valid.
c. Menyajikan dan menganalisis hasil klasterisasi profil pasien rawat inap melalui media berbasis *website* interaktif, sehingga hasilnya dapat dimanfaatkan sebagai informasi pendukung dalam pengelolaan pelayanan rawat inap di Rumah Sakit Islam Fatimah Cilacap.

1.5. Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Penelitian ini diharapkan dapat meningkatkan pemahaman peneliti dalam menerapkan algoritma K-Means pada proses klasterisasi data pasien rawat inap berdasarkan karakteristik medis dan pelayanan, serta mengembangkan kemampuan dalam pengolahan data, evaluasi hasil klasterisasi, dan perancangan media berbasis *website* untuk penyajian hasil secara interaktif.
2. Penelitian ini diharapkan dapat memberikan informasi kepada pihak rumah sakit mengenai pengelompokan pasien rawat inap berdasarkan kemiripan karakteristik medis dan pelayanan. Hasil klasterisasi tersebut dapat

dimanfaatkan sebagai bahan pendukung dalam evaluasi dan perencanaan pelayanan, serta membantu analisis data pasien melalui media berbasis *website* yang terstruktur dan visual.

3. Penelitian ini diharapkan dapat memberikan pemahaman kepada pembaca mengenai penerapan teknik *data mining*, khususnya metode K-Means, pada data kesehatan. Selain itu, penelitian ini dapat dijadikan referensi dalam memahami proses pengelompokan data berdasarkan karakteristik tertentu serta pemanfaatan teknologi informasi dalam mendukung pengelolaan layanan rumah sakit.
4. Penelitian ini diharapkan dapat menambah referensi ilmiah bagi perguruan tinggi di bidang *data mining* dan sistem informasi kesehatan, serta menjadi bahan ajar atau studi kasus pada mata kuliah terkait. Selain itu, hasil penelitian ini diharapkan dapat mendorong pengembangan penelitian lanjutan yang relevan dengan pemanfaatan data medis dan pelayanan.

BAB II
TINJAUAN PUSTAKA

2.1. *Data Mining*

Data mining merupakan proses analisis data dari berbagai sudut pandang untuk menghasilkan informasi yang bernilai dan dapat dimanfaatkan dalam pengambilan keputusan, seperti meningkatkan keuntungan, menekan biaya operasional, atau mencapai keduanya secara bersamaan. Secara teknis, *data mining* dapat didefinisikan sebagai proses untuk menemukan pola, hubungan, atau korelasi dari ratusan hingga ribuan atribut yang tersimpan dalam basis data relasional berukuran besar, sehingga memungkinkan penggalian informasi bisnis yang penting dan tersembunyi dari kumpulan data yang sangat besar guna mendukung perencanaan dan strategi organisasi (Mabrur & Lubis, 2012).

Data mining merupakan bidang ilmu yang berfokus pada penemuan pengetahuan, wawasan, serta pola dari sekumpulan data. Fungsi utama *data mining* adalah mengekstraksi pola-pola yang bermanfaat dari data yang telah terorganisir. Pola yang dihasilkan harus bersifat valid, memiliki unsur kebaruan, berpotensi memberikan manfaat, serta mudah dipahami. Secara sederhana, *data mining* digunakan untuk memproyeksikan kondisi di masa depan berdasarkan data masa lalu. Beberapa tugas utama dalam *data mining* meliputi klasifikasi, klasterisasi, prediksi, asosiasi, dan estimasi (Sapuan dkk., 2022).

2.2. Klasterisasi /*Clustering*

Klasterisasi merupakan salah satu teknik *unsupervised learning* yang tidak memerlukan proses pelatihan model karena tidak adanya fase pembelajaran

(*learning*) menggunakan data berlabel. Teknik ini digunakan untuk mengelompokkan data ke dalam beberapa kelas atau klaster berdasarkan tingkat kemiripan atau karakteristik tertentu. Data yang memiliki kesamaan karakteristik akan ditempatkan dalam klaster yang sama, sedangkan data dengan karakteristik yang berbeda akan dikelompokkan ke dalam klaster yang berbeda. Dengan demikian, tujuan utama klasterisasi adalah membagi data atau objek ke dalam kelompok-kelompok yang setiap anggotanya memiliki tingkat kemiripan yang tinggi (Nugroho dkk., 2022).

Clustering atau pengklasteran adalah sebuah teknik fundamental dalam *data mining* yang berperan untuk mengelompokkan data secara otomatis menjadi *subset-subset* logis yang disebut klaster. Tujuan utama dari teknik ini adalah untuk memastikan bahwa objek-objek dalam satu klaster memiliki tingkat kesamaan (keterhubungan) yang sangat tinggi, sedangkan objek-objek di antara klaster yang berbeda memiliki kesamaan yang rendah. Terdapat dua pendekatan utama dalam pengklasteran: *Hierarchical Clustering*, yang membangun pengelompokan secara bertingkat (dari yang paling mirip hingga yang paling tidak mirip) hingga membentuk struktur hierarkis; dan *Non Hierarchical Clustering*, yang memulai prosesnya dengan menentukan jumlah klaster yang diinginkan di awal dan mengelompokkan data tanpa mengikuti struktur hierarki (Ma'rifatin, 2020).

2.3. Profil

Profil dapat diartikan sebagai uraian atau gambaran menyeluruh yang merepresentasikan suatu objek, individu, kelompok, atau fenomena tertentu. Gambaran ini disusun berdasarkan berbagai karakteristik, ciri khas, maupun atribut

yang melekat, sehingga mampu memberikan pemahaman yang lebih jelas mengenai identitas, kondisi, dan sifat utama dari objek yang dikaji. Dengan adanya profil, informasi yang awalnya bersifat terpisah dan beragam dapat disatukan menjadi deskripsi yang utuh, sehingga memudahkan pembaca dalam mengenali dan memahami objek tersebut secara umum (Kristanto, 2019).

Dalam konteks analisis dan penelitian, profil memiliki peran penting sebagai dasar untuk menginterpretasikan data dan menarik kesimpulan. Profil tidak hanya berfungsi sebagai alat pengenalan, tetapi juga sebagai sarana untuk mengelompokkan, membandingkan, serta mengevaluasi suatu objek berdasarkan karakteristik tertentu. Oleh karena itu, penyusunan profil yang sistematis dan akurat sangat diperlukan agar informasi yang disajikan bersifat informatif, relevan, dan dapat mendukung proses pengambilan keputusan maupun pengembangan kajian lebih lanjut.

2.4. Pasien Rawat Inap

Pasien merupakan individu yang membutuhkan, mencari, atau sedang menerima pelayanan kesehatan dari tenaga medis maupun fasilitas kesehatan. Kondisi ini dapat disebabkan oleh gangguan kesehatan, penyakit, cedera, atau keperluan tertentu yang mengharuskan seseorang mendapatkan pemeriksaan, pengobatan, serta pemantauan medis guna menjaga atau memulihkan kesehatannya (Sophian dkk., 2023).

Pasien rawat inap adalah pasien yang berdasarkan pertimbangan medis diwajibkan menjalani perawatan di rumah sakit dengan cara menginap dalam jangka waktu tertentu. Perawatan ini dilakukan karena kondisi kesehatan pasien

memerlukan pengawasan intensif, tindakan medis berkelanjutan, atau penggunaan fasilitas khusus yang tidak dapat dilakukan secara rawat jalan. Dengan sistem rawat inap, tenaga medis dapat memberikan pelayanan yang lebih terkontrol, menyeluruh, dan berkesinambungan sesuai dengan kebutuhan pasien.

2.5. Mekanisme Rawat Inap

Pelayanan rawat inap di Rumah Sakit Islam Fatimah Cilacap diberikan kepada pasien yang memerlukan perawatan dan pengawasan medis secara berkelanjutan berdasarkan hasil pemeriksaan dokter. Proses rawat inap diawali dengan pemeriksaan awal di unit pelayanan, seperti Instalasi Gawat Darurat atau Poliklinik, untuk menentukan kondisi klinis pasien dan kebutuhan perawatan lanjutan. Apabila pasien dinyatakan perlu menjalani rawat inap, maka dilakukan proses administrasi dan penempatan pasien pada ruang perawatan yang sesuai dengan tingkat keparahan penyakit, kelas perawatan, serta penjamin biaya yang digunakan.

Selama menjalani rawat inap, pasien mendapatkan pelayanan medis dan keperawatan sesuai dengan diagnosis dan rencana terapi yang telah ditetapkan. Setiap tindakan medis, hasil pemeriksaan, serta perkembangan kondisi pasien dicatat secara sistematis dalam rekam medik. Informasi yang dicatat meliputi data identitas pasien, diagnosis utama, lama perawatan, ruang dan kelas perawatan, serta bentuk pelayanan yang diberikan. Seluruh data tersebut dikelola oleh Instalasi Rekam Medis dan tersimpan dalam Sistem Informasi Manajemen Rumah Sakit (SIMRS) sebagai bagian dari dokumentasi pelayanan kesehatan dan sumber data untuk analisis lebih lanjut (Sifa dkk., 2024).

2.6. Algoritma

Algoritma merupakan rangkaian langkah yang logis dan sistematis untuk menyelesaikan suatu permasalahan atau mencapai tujuan tertentu, khususnya dalam proses pengembangan perangkat lunak. Sistem komputer bekerja melalui keterpaduan antara perangkat keras, perangkat lunak, dan pengguna, namun pembahasan lebih difokuskan pada perangkat lunak yang dibangun dari susunan program serta aturan penulisan sintaks. Penyusunan program memerlukan tahapan yang terstruktur dan masuk akal agar tujuan pengembangan dapat tercapai dengan baik, sehingga algoritma memiliki peran penting sebagai dasar perancangan alur pemecahan masalah. Dalam bidang komputasi, algoritma menjadi komponen utama dalam pembangunan perangkat lunak, dan dalam kehidupan sehari-hari konsep algoritma juga sering diterapkan tanpa disadari melalui berbagai aktivitas yang memiliki urutan langkah tertentu (Maulana, 2017).

Algoritma merupakan rangkaian langkah atau operasi yang logis dan sistematis untuk menyelesaikan suatu masalah hingga mencapai tujuan tertentu. Langkah-langkah dalam algoritma harus disusun secara runtut dan jelas agar dapat dijalankan dengan benar, khususnya dalam pemrograman komputer. Berbagai pendapat ahli menegaskan bahwa algoritma berfungsi sebagai metode terstruktur yang memuat aturan dan tahapan operasional dalam memecahkan masalah, sehingga dapat diterapkan secara efektif untuk menghasilkan solusi yang tepat (Anggreani & Yahfizham, 2024).

2.7. Algoritma K-Means

K-Means merupakan algoritma klasterisasi yang digunakan untuk mengelompokkan data ke dalam sejumlah klaster berdasarkan tingkat kemiripan, di mana setiap klaster direpresentasikan oleh pusat klaster (*centroid*). Proses K-Means diawali dengan menentukan jumlah klaster serta menetapkan *centroid* awal, kemudian setiap data dikelompokkan ke dalam klaster dengan jarak terdekat terhadap *centroid* tersebut. Selanjutnya, algoritma melakukan proses iterasi untuk memperbarui posisi *centroid* berdasarkan nilai rata-rata data pada masing-masing klaster hingga posisi *centroid* dan keanggotaan klaster menjadi stabil, sehingga hasil pengelompokan dapat digunakan untuk menganalisis pola dan karakteristik data secara lebih terstruktur (Sucipto, 2019).

Algoritma K-Means merupakan metode pengelompokan data yang membagi data ke dalam beberapa klaster berdasarkan tingkat kemiripan, sehingga data yang memiliki karakteristik serupa berada dalam klaster yang sama, sedangkan data yang berbeda dikelompokkan ke klaster lain (Rohmawati dkk., 2015). Secara lebih rinci, tahapan kerja algoritma K-Means dapat dijelaskan sebagai berikut:

1. Menentukan jumlah klaster yang diinginkan sebagai nilai k.
2. Menentukan pusat klaster awal (*centroid*) secara acak sesuai dengan jumlah k.
3. Menghitung jarak antara setiap data masukan dengan masing-masing *centroid* menggunakan rumus jarak *euclidean* (*euclidean distance*) untuk menentukan *centroid* yang memiliki jarak terdekat terhadap setiap data. Berikut ini merupakan persamaan *euclidean distance* pada rumus (1).

$$d(xi, \mu j) = \sqrt{\sum_{k=1}^{n} (x_{ik} - \mu_{jk})^2} \quad (1)$$

Keterangan:

$d(xi, \mu j)$= Jarak antara data ke-i dengan pusat klaster (*centroid*) ke-j

xi = Data ke-i atau vektor data ke-i yang akan dihitung jaraknya

μj = *Centroid* klaster ke-j, yaitu nilai rata-rata dari seluruh data

n = Jumlah atribut yang digunakan dalam proses klasterisasi

4. Mengelompokkan setiap data ke dalam klaster berdasarkan jarak terdekat terhadap *centroid*.
5. Melakukan pembaruan *centroid* dengan menentukan nilai pusat klaster baru berdasarkan rata-rata data yang tergabung dalam klaster yang bersangkutan menggunakan rumus (2).

$$\mu j(t+1) = \frac{1}{N_{sj}} \sum_{i \epsilon sj} xj \quad (2)$$

Keterangan:

$\mu j(t+1)$= *Centroid* klaster ke-j pada iterasi ke-(t+1)

N_{sj} = Jumlah data yang berada dalam klaster ke-j

$\sum i \epsilon sj$ = Penjumlahan seluruh data yang menjadi anggota klaster ke-j

x_j = Nilai data yang termasuk ke dalam klaster ke-j

6. Mengulangi langkah ke-2 sampai ke-5 hingga tidak terjadi lagi perubahan keanggotaan data pada setiap klaster.

Apabila langkah ke-6 telah terpenuhi, maka nilai pusat klaster (μ_j) pada iterasi terakhir digunakan sebagai parameter dalam menentukan pengelompokkan data.

2.8. Metode *Elbow*

Metode *elbow* adalah teknik yang digunakan untuk menentukan jumlah *cluster* (c) yang paling optimal dengan menghitung nilai *sum of square error* (SSE) pada setiap variasi jumlah klaster. Metode ini bekerja dengan mengamati penurunan nilai SSE seiring bertambahnya jumlah klaster, di mana perbedaan SSE yang paling signifikan antara dua klaster berturut-turut akan membentuk titik menyerupai sudut siku (*elbow*) pada grafik. Dalam kombinasi dengan algoritma K-Means, grafik *elbow* merepresentasikan hubungan antara jumlah klaster dan pengurangan tingkat kesalahan, yang awalnya menurun tajam lalu melandai hingga mencapai kondisi stabil. Nilai c yang berada pada titik sudut paling tajam tersebut dianggap sebagai jumlah klaster terbaik karena menunjukkan keseimbangan antara kompleksitas model dan minimnya error (Sanjaya dkk., 2024).

Metode *elbow* merupakan salah satu pendekatan yang digunakan untuk menentukan jumlah klaster yang paling optimal dengan mengamati perubahan persentase tiap klaster yang membentuk pola menyerupai siku pada titik tertentu. Metode ini umumnya disajikan dalam bentuk grafik agar titik siku yang terbentuk dapat terlihat dengan lebih jelas. Tujuan penggunaan metode *elbow* adalah memilih nilai k yang relatif kecil namun tetap menghasilkan nilai *withinss* yang rendah. Dalam penerapannya bersama algoritma K-Means, nilai k ditentukan berdasarkan grafik hubungan antara jumlah klaster dan penurunan nilai error. Jumlah klaster yang diperoleh kemudian dievaluasi menggunakan teknik SSE (*Sum of Square Error*), yaitu ukuran yang digunakan untuk mengetahui perbedaan antara data dan pusat klasternya (Maori, 2023). Adapun persamaan yang digunakan dalam metode

elbow adalah perhitungan nilai total WCSS (*Within Cluster Sum of Squares*) yang juga dikenal sebagai SSE (*Sum of Square Error*), dengan menggunakan rumus (3).

$$SSE = \sum_{k=1}^{k} \sum_{x_i \in Ck} (x_i - \varphi_k)^2 \quad (3)$$

Keterangan:

$C_k C_k$ = K klaster yang terbentuk

$k\ k$ = Banyaknya klaster

$x_i x_i$ = Data x pada fitur ke-i

$\varphi_k \varphi_k$ = Rata-rata K klaster pada nilai k (k=1,2,3,...,K)

2.9. *Silhouette Score*

Silhouette score merupakan salah satu metrik evaluasi yang digunakan untuk menilai kualitas hasil *clustering*. Metrik ini mengukur sejauh mana suatu titik data lebih sesuai berada dalam klaster-nya sendiri dibandingkan dengan klaster lainnya. Nilai *silhouette score* berada pada rentang -1 hingga 1, di mana nilai yang mendekati 1 menunjukkan bahwa data terkelompok dengan sangat baik serta memiliki pemisahan yang jelas dari klaster lain. Nilai yang mendekati 0 menandakan bahwa data berada di batas antara dua klaster, sedangkan nilai yang mendekati -1 mengindikasikan kemungkinan kesalahan dalam proses pengelompokan. Melalui penggunaan metrik ini, kualitas *clustering* dapat dievaluasi untuk berbagai nilai k, sehingga dapat dipilih nilai k yang menghasilkan *silhouette score* tertinggi sebagai jumlah cluster dengan tingkat kohesi dan pemisahan terbaik (Putra dkk., 2025).

Silhouette score merupakan metrik yang digunakan untuk mengevaluasi tingkat kemiripan data dalam suatu klaster dibandingkan dengan klaster lainnya. Nilai *silhouette score* yang mendekati 1 menunjukkan bahwa hasil *clustering* yang diperoleh semakin optimal. Metrik ini sangat bermanfaat untuk menilai kualitas pengelompokan secara objektif tanpa memerlukan informasi label data yang sebenarnya (Ubaidillah dkk., 2025). Adapun perhitungan *silhouette score* menggunakan rumus (4).

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \tag{4}$$

Keterangan:

$a(i)$ = Selisih jarak rata-rata data terhadap seluruh titik dalam klaster yang sama

$b(i)$ = Jarak rata-rata terdekat data terhadap cluster lain yang paling dekat

2.10. *Davies-Bouldin Index* (DBI)

Davies-Bouldin Index (DBI) merupakan metrik evaluasi internal yang digunakan untuk menilai kualitas hasil *clustering*, khususnya pada algoritma K-Means. Nilai DBI dihitung berdasarkan rasio antara jarak antar klaster dan tingkat kepadatan di dalam klaster. Metrik ini mengukur sejauh mana setiap klaster dapat terpisah dengan baik dari klaster lainnya melalui evaluasi parameter kepadatan dan jarak antar klaster. Semakin kecil nilai DBI yang dihasilkan, semakin baik kualitas *clustering* karena menunjukkan bahwa klaster-klaster terbentuk secara jelas dan tidak saling tumpang tindih. Sebaliknya, nilai DBI yang tinggi mengindikasikan bahwa pemisahan antar klaster kurang optimal, sehingga hasil *clustering* dianggap kurang efektif (Yolandari dkk., 2025).

Davies-Bouldin Index (DBI) merupakan metrik evaluasi yang digunakan untuk mengukur perbandingan antara jarak dalam klaster dan jarak antar klaster. Nilai DBI yang semakin kecil menunjukkan kualitas klaster yang semakin baik (Setyani dkk., 2025). Adapun perhitungan DBI menggunakan rumus (5).

$$DBI = \frac{1}{k}\sum_{i=1}^{k}\max_{j \neq i}\left(\frac{S_i + S_j}{d(c_i, c_j)}\right) \quad (5)$$

Keterangan:

k = Jumlah klaster yang terbentuk

i, j = Menunjukkan indeks klaster, dengan syarat j ≠ i

S_i = Ketidakkompakan klaster ke-i (rata-rata jarak titik ke pusat klaster)

S_j = Ketidakkompakan klaster ke-j

$d(c_i, c_j)$= Jarak *euclidean* antara pusat klaster i dan j

$\max_{j \neq i}$ = Untuk tiap klaster i, dipilih pasangan klaster j yang paling mirip

2.11. *Python*

*Pytho*n merupakan bahasa pemrograman tingkat tinggi yang dikembangkan oleh Guido van Rossum pada tahun 1991 dengan tujuan menghadirkan sintaksis yang sederhana dan mudah dipahami, sehingga dapat digunakan oleh pemula maupun pengembang berpengalaman. Bahasa ini mendukung berbagai paradigma pemrograman, seperti berorientasi objek, imperatif, dan fungsional, serta memiliki ekosistem pustaka dan *framework* yang sangat luas, antara lain *numpy*, *pandas*, dan *matplotlib*, yang banyak dimanfaatkan dalam bidang analisis data, pembelajaran mesin, dan pengembangan *web*. Sebagai bahasa pemrograman *open-source, python* terus berkembang berkat dukungan komunitas yang aktif dan memiliki

kompatibilitas lintas platform, termasuk windows, macos, dan linux. Kemudahan instalasi serta fleksibilitas penggunaannya menjadikan *python* banyak digunakan dalam dunia pendidikan dan penelitian, karena mampu membantu pengguna memahami logika pemrograman yang dapat diterapkan pada bahasa pemrograman lainnya (Rasyida dkk., 2025).

Python merupakan bahasa pemrograman yang banyak digunakan dalam pengolahan dan analisis data, khususnya pada bidang *data mining* dan pembelajaran mesin. Keunggulan *python* terletak pada sintaks yang sederhana serta dukungan pustaka yang lengkap untuk pengolahan data dan visualisasi. Beberapa pustaka yang umum digunakan antara lain *numpy* untuk komputasi numerik dan pengolahan data berbasis array, *pandas* untuk manipulasi dan analisis data terstruktur, serta *matplotlib* untuk menyajikan hasil analisis dalam bentuk visualisasi grafik. Kombinasi pustaka tersebut menjadikan *python* sangat sesuai digunakan dalam proses pengolahan data rekam medis, penerapan algoritma klasterisasi seperti K-Means, serta penyajian hasil analisis secara informatif dan mudah dipahami (Anggraini dkk., 2025).

2.12. PHP

PHP adalah bahasa pemrograman *server-side open source* yang diciptakan oleh Rasmus Lerdorf pada tahun 1994, dirancang khusus untuk pengembangan *web* namun juga dapat digunakan secara umum. PHP tersedia secara gratis di bawah lisensi PHP *license* dan menggunakan nama rekursif "PHP: *Hypertext Preprocessor*" (Noviana, 2022).

PHP (*Hypertext Preprocessor*) adalah bahasa pemrograman berbasis server yang dieksekusi di sisi server sebelum hasilnya dikirimkan ke browser pengguna, memungkinkan konten halaman *web* bersifat dinamis seperti menampilkan tanggal secara otomatis. Sesuai dengan karakteristiknya tersebut, PHP banyak digunakan sebagai bahasa pemrograman utama dalam pengembangan aplikasi berbasis *web* (Rubiati & Harahap, 2019).

2.13. *Laravel*

Laravel adalah *framework* PHP *open source* karya Taylor Otwell yang menggabungkan berbagai keunggulan dari *framework* populer lainnya seperti *codeIgniter, ruby on rails,* dan ASP.NET MVC. *Framework* ini dilengkapi dengan fitur-fitur canggih seperti *blade templating*, konsep HMVC, migrasi *database*, serta artisan CLI, sehingga mampu mempercepat proses pengembangan *web* sekaligus menjamin keamanan dan stabilitas aplikasi yang dibangun (Handika & Purbasari, 2018).

Laravel merupakan *framework* PHP yang dirancang dengan mengutamakan kemudahan dan fleksibilitas, dirilis di bawah lisensi MIT melalui platform *Github* sebagai wadah berbagi kode. Seperti *framework* PHP pada umumnya, *laravel* dibangun berbasis arsitektur MVC (*Model View Controller*) dan dilengkapi dengan *tool* berbasis *command line* bernama "Artisan" yang berfungsi untuk mengelola *packaging bundle* serta proses instalasinya (Kansha dkk., 2023).

2.14. Metode Pengembangan Sistem *Waterfall*

Metode *waterfall* merupakan salah satu model dalam SDLC (*System Development Life Cycle)* yang digunakan dalam pengembangan sistem informasi

atau perangkat lunak dengan pendekatan linear dan terstruktur. Proses pengembangannya dilakukan secara berurutan, dimulai dari tahap analisis kebutuhan, perancangan sistem, implementasi atau pengkodean, pengujian, hingga pemeliharaan. Setiap tahapan harus diselesaikan secara menyeluruh sebelum melanjutkan ke tahap berikutnya, sehingga model ini menekankan perencanaan yang matang dan dokumentasi yang lengkap. Dengan alur kerja yang sistematis dan jelas, model *waterfall* memberikan kerangka pengembangan yang terorganisasi serta memudahkan pengendalian dan evaluasi pada setiap tahap pengembangan perangkat lunak (Risdiansyah & Fitriana, 2025).

Metode *waterfall* merupakan pendekatan pengembangan perangkat lunak yang dilakukan secara berurutan dan bertahap, di mana setiap tahap harus diselesaikan terlebih dahulu sebelum melanjutkan ke tahap berikutnya dan tidak memungkinkan untuk kembali ke tahap sebelumnya. Proses pengembangan dimulai dari analisis kebutuhan, perencanaan, perancangan sistem, implementasi, pengujian, hingga pemeliharaan. Dengan alur yang terstruktur dan jelas, metode ini membantu mengendalikan serta mengelola risiko pengembangan perangkat lunak melalui pembagian tahapan yang terdefinisi dengan baik. Selain itu, pendekatan *waterfall* memudahkan penjadwalan proyek dan memungkinkan pihak manajemen untuk memantau progres pengembangan secara sistematis (Ningki & Noviyanti.P, 2023). Tahapan dalam metode *waterfall* dijelaskan secara rinci sebagai berikut:

a. Analisis Kebutuhan (*Requirements Analysis*)

Tahap awal berfokus pada proses mengidentifikasi serta memahami kebutuhan pengguna dan pihak terkait terhadap sistem yang akan

dikembangkan. Pada tahap ini pengumpulan dan analisis kebutuhan fungsional maupun nonfungsional dilakukan melalui komunikasi dengan pengguna. Hasil dari tahap ini berupa dokumen kebutuhan yang menjadi acuan dalam menentukan tujuan, fungsi, dan fitur sistem.

b. Desain Sistem (*Design*)

Tahap perancangan merupakan proses penyusunan rancangan sistem berdasarkan dokumen kebutuhan, yang mencakup arsitektur sistem, antarmuka pengguna, basis data, dan modul sistem sebagai acuan pengembangan.

c. Implementasi (*Implementation*)

Setelah tahap perancangan selesai, pengembang mulai menerapkan desain ke dalam bentuk kode program. Proses ini mencakup pengkodean dan integrasi komponen hingga sistem dapat berjalan sesuai dengan rancangan yang telah ditetapkan.

d. Pengujian (*Testing*)

Pada tahap ini, sistem yang telah dikembangkan diuji untuk memastikan seluruh fungsi berjalan sesuai kebutuhan. Pengujian dilakukan untuk menemukan dan memperbaiki kesalahan sehingga kualitas dan keandalan sistem dapat terjamin sebelum digunakan.

e. Pemeliharaan (*Maintenance*)

Pada tahap pemeliharaan, sistem yang telah digunakan dipantau dan diperbaiki secara berkala. Kegiatan ini mencakup perbaikan kesalahan, peningkatan fungsi, serta penyesuaian terhadap kebutuhan pengguna agar sistem tetap berjalan optimal dan andal dalam jangka panjang.

2.15. Penelitian Sejenis

Beberapa penelitian sebelumnya telah dilakukan terkait dengan penerapan metode klasterisasi menggunakan algoritma K-Means di bidang kesehatan. Meskipun penelitian-penelitian tersebut menggunakan pendekatan yang serupa dalam mengelompokkan data pasien, terdapat perbedaan signifikan dalam hal cakupan variabel yang diangkat serta metode evaluasi yang digunakan. Adapun rincian lebih lanjut mengenai penelitian-penelitian tersebut dapat dilihat pada Tabel 1.

Tabel 1. Penelitian Sejenis

No.	Peneliti	Judul	Metode	Hasil	Perbedaan
1	Eriana Asep Herdiaman, Aso Sudiarjo, dan Missi Hikmatyar (2024)	Klasterisasi Pasien pada RSUD Ciamis Mengguna-kan Metode K-Means	K-Means	Hasil penelitian menunjukkan bahwa algoritma K-Means mampu mengelompok-kan 2.420 data pasien rawat inap menjadi tiga klaster dengan karakteristik penyakit yang berbeda, dengan nilai *davies-bouldin index* (DBI) sebesar 0,406 sebagai kualitas klaster terbaik.	Penelitian ini hanya menggunakan data pasien rawat inap selama satu bulan dengan evaluasi klasterisasi menggunakan *davies-bouldin index* (DBI) saja.

2	Harfina Dilawati, Heru Widianto, dan Agustinus Kuswiadji (2024)	Klasterisasi Data Rekam Medis Pasien Menggunakan Metode *K-Means Clustering* di Rumah Sakit Widodo Ngawi	K-Means	Hasil penelitian menunjukkan bahwa algoritma K-Means mampu mengelompokkan 3.171 data pasien rawat inap menjadi empat klaster dengan pola penyakit dominan seperti demam, stroke, dan penyakit degeneratif berdasarkan karakteristik penyakit, dan metode pembayaran pasien.	Penelitian ini hanya menggunakan data rawat inap selama tiga bulan tanpa metode evaluasi klaster, dan penelitian ini menggunakan aplikasi rstudio.
3	Yandiko Saputra Sy (2023)	Klasterisasi Pasien Rawat Inap Peserta BPJS Berdasarkan Jenis Penyakit Menggunakan Algoritma K-Means	K-Means	Penelitian ini berhasil mengelompokkan 80 pasien BPJS rawat inap menjadi tiga klaster, di mana setiap klaster menunjukkan dominasi jenis penyakit tertentu, seperti kanker payudara, limfoma non-hodgkin, fraktur leher femur, dan demam berdarah.	Penelitian ini hanya menggunakan data pasien BPJS rawat inap dengan jumlah yang terbatas tanpa metode evaluasi klaster, dan penelitian ini menggunakan algoritma K-Means dan melakukan pengujian secara manual menggunakan aplikasi rapidminer.

4	Amir Ali dan Lilis Masyfufah (2021)	Klasterisasi Pasien BPJS dengan Metode *K-Means Clustering* guna Menunjang Program Jaminan Kesehatan Nasional di Rumah Sakit Anwar Medika Balong bendo Sidoarjo	K-Means	Penelitian ini berhasil mengelompok-kan 180 data pasien BPJS rawat inap ke dalam tiga klaster yang terdiri dari 91 pasien perempuan (51%), 26 pasien Perempuan (14%), dan 63 pasien laki-laki (35%).	Penelitian ini hanya menggunakan data pasien BPJS rawat inap dengan jumlah dan periode data yang terbatas tanpa metode evaluasi klaster, dan penelitian ini melakukan visualisasi proses *clustering* menggunakan *tools* WEKA.
5	Jeri Wandana, Sarjon Defit, dan Sumijan (2020)	Klasterisasi Data Rekam Medis Pasien Pengguna Layanan BPJS Kesehatan Mengguna-kan Metode K-Means	K-Means	Penelitian ini berhasil mengelompok-kan 13 data pasien BPJS rawat inap ke dalam tiga klaster yang terdiri 3 pasien yang didominasi penyakit A09.9 (diare/disentri) , 5 pasien dengan jenis penyakit yang lebih beragam, dan 5 pasien yang didominasi penyakit K30 (dyspepsia).	Penelitian ini hanya menggunakan data pasien BPJS rawat inap dengan jumlah yang sangat terbatas dengan periode tiga bulan tanpa metode evaluasi klaster, dan penelitian ini melakukan klasterisasi secara manual menggunakan microsoft excel.

6	Sufyan Abdur Rofiq (2026)	Klasterisasi Profil Pasien Rawat Inap Mengguna-kan Algoritma K-Means pada Rumah Sakit Islam Fatimah Cilacap	K-Means	Penelitian ini diharapkan dapat menghasilkan klasterisasi profil pasien rawat inap di Rumah Sakit Islam Fatimah Cilacap menggunakan algoritma K-Means untuk mengelompok-kan 13.024 data pasien berdasarkan karakteristik medis dan pelayanan secara efektif. Proses klasterisasi tersebut dievaluasi menggunakan metode *elbow*, *silhouette score*, dan *davies-bouldin index* (DBI) guna memperoleh jumlah klaster yang optimal, sehingga klaster yang dihasilkan mampu merepresentasi-kan perbedaan profil pasien rawat inap secara jelas, terstruktur, dan sistematis.	Penelitian ini menggunakan data pasien rawat inap selama satu tahun dengan jumlah data yang lebih besar serta mengombinasi-kan metode *elbow*, *silhouette score*, dan *davies-bouldin index* (DBI) dalam menentukan jumlah klaster yang optimal guna meningkatkan kualitas klasterisasi. Implementasi algoritma K-Means dilakukan menggunakan bahasa pemrograman *python*, sementara hasil klasterisasi divisualisasi-kan melalui *website* berbasis *laravel* yang bersifat interaktif.

BAB III
METODOLOGI PENELITIAN

3.1. Waktu dan Tempat Penelitian

Penelitian ini berlangsung selama empat bulan pada periode Januari hingga April 2026, dengan lokasi penelitian di Rumah Sakit Islam Fatimah Cilacap.

3.2. Alat dan Data Penelitian

Alat dan data yang mendukung penelitian ini adalah sebagai berikut.

3.2.1. Alat Penelitian

Untuk melaksanakan penelitian ini, dibutuhkan beberapa alat yang berupa perangkat keras dan perangkat lunak. Alat-alat ini digunakan untuk mendukung proses pengolahan data dan perancangan *website*. Perangkat keras yang digunakan untuk menjalankan perangkat lunak yang dibutuhkan selama penelitian ini adalah laptop Lenovo IdeaPad Slim 3 14IAH8. Adapun perangkat lunak yang digunakan untuk menunjang penelitian adalah sebagai berikut:

a. Visual Studio Code
b. *Laravel*
c. Draw.io
d. Microsoft Word 2021
e. Microsoft Excel 2021

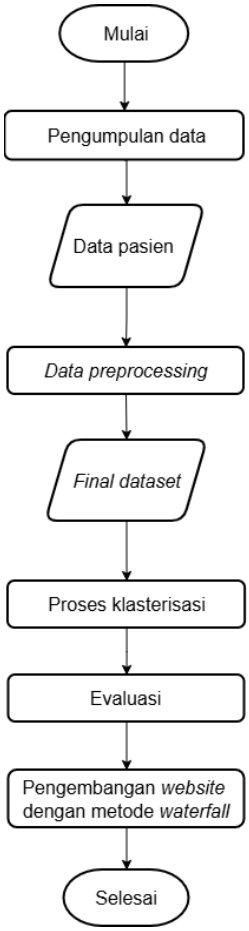
3.2.2. Data Penelitian

Data yang digunakan dalam penelitian ini adalah data pasien rawat inap periode Januari hingga Desember 2025 yang diperoleh dari Instalasi Rekam

Medis Rumah Sakit Islam Fatimah Cilacap dan bersumber dari Sistem Informasi Manajemen Rumah Sakit (SIMRS) melalui izin instansi terkait dengan total sebanyak 13.024 data pasien.

3.3. Mekanisme Penelitian

Penelitian ini akan melalui berbagai proses, yaitu pengumpulan data, *data preprocessing*, proses klasterisasi, evaluasi, dan pengembangan *website*. Berikut ini adalah mekanisme penelitian yang digambarkan pada Gambar 1.



Gambar 1. Mekanisme Penelitian

3.3.1. Pengumpulan Data

Pada tahap ini pengumpulan data dilakukan sebagai landasan utama dalam pelaksanaan penelitian. Proses pengumpulan data bertujuan untuk

memperoleh informasi yang diperlukan sebelum memasuki tahap pengolahan dan analisis data. Metode yang digunakan dalam pengumpulan data meliputi metode dokumentasi dan studi literatur.

a. Dokumentasi

Metode dokumentasi dalam penelitian ini dilakukan dengan mengambil data pasien rawat inap yang diperoleh dari Instalasi Rekam Medis dan bersumber langsung dari Sistem Informasi Manajemen Rumah Sakit (SIMRS) Rumah Sakit Islam Fatimah Cilacap. Proses pengambilan data dilakukan dengan mengekspor data pasien rawat inap dari sistem secara bulanan pada periode Januari hingga Desember 2025, yang selanjutnya digabungkan menjadi satu *dataset* dan disimpan dalam format microsoft excel (.xlsx) untuk digunakan sebagai bahan penelitian.

Data yang diperoleh mencakup sejumlah variabel yang relevan dengan tujuan penelitian, seperti jenis kelamin, umur, lama rawat, kelas, penjamin, staf medis fungsional (SMF), keadaan keluar, ICD-10, diagnosis, ICD-9 CM dan tindakan.

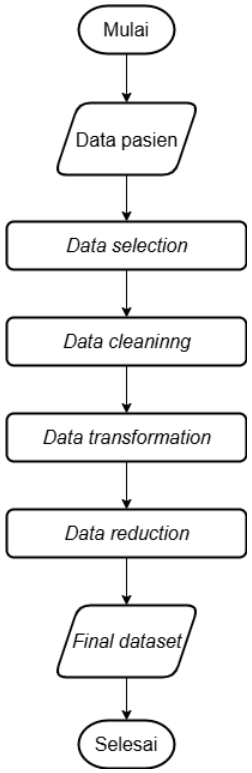
b. Studi Literatur

Metode studi literatur dilakukan dengan mengumpulkan dan menelaah berbagai referensi yang relevan, seperti buku, jurnal ilmiah, dan penelitian terdahulu yang berkaitan dengan klasterisasi data pasien dan penerapan algoritma K-Means. Studi literatur ini bertujuan untuk memperoleh landasan teori yang kuat mengenai konsep klasterisasi, prinsip kerja algoritma K-Means, serta metode evaluasi klaster yang

digunakan, yaitu *elbow method*, *silhouette score*, dan *davies-bouldin index* (DBI). Melalui kajian pustaka ini, peneliti memahami dasar pemilihan metode, tahapan analisis yang tepat, serta membandingkan hasil penelitian sebelumnya yang sejenis. Hasil studi literatur ini digunakan sebagai acuan dalam perancangan metode penelitian, proses analisis data, dan interpretasi hasil klasterisasi profil pasien rawat inap.

3.3.2. *Data Preprocessing*

Pada tahap ini dilakukan proses *preprocessing* data yang bertujuan untuk membersihkan dan menyiapkan data sebelum dilakukan analisis lebih lanjut. Proses *preprocessing* meliputi empat tahapan utama, yaitu *data selection*, *data cleaning*, *data transformation*, dan *data reduction*. Rangkaian tahapan *preprocessing* data tersebut ditunjukkan pada Gambar 2.



Gambar 2. *Data Preprocessing*

a. *Data Selection*

Tahap ini merupakan langkah awal dalam *preprocessing* yang bertujuan untuk memilih atribut atau variabel yang relevan dengan tujuan klasterisasi pasien rawat inap. Proses seleksi data dilakukan dengan menentukan atribut medis dan pelayanan yang berpengaruh terhadap pembentukan klaster, sehingga data yang digunakan lebih fokus, representatif, dan sesuai dengan tujuan penelitian. Melalui tahapan ini, atribut yang tidak memberikan kontribusi informasi terhadap pengelompokan akan dihilangkan agar hasil pengelompokan yang terbentuk lebih optimal.

b. *Data Cleaning*

Tahap ini dilakukan untuk membersihkan data pasien rawat inap yang diperoleh dari Rumah Sakit Islam Fatimah Cilacap. Pada tahap ini dilakukan pemeriksaan terhadap data yang tidak lengkap (*missing values*), data duplikat, serta data yang tidak konsisten atau tidak valid. Data yang bermasalah tersebut kemudian diperbaiki atau dihapus agar kualitas data tetap terjaga dan layak digunakan dalam proses klasterisasi.

c. *Data Transformation*

Pada tahap ini proses transformasi data dilakukan untuk menyesuaikan format data agar siap digunakan dalam proses klasterisasi menggunakan algoritma K-Means. Transformasi data bertujuan untuk menyamakan skala antar atribut sehingga tidak terjadi dominasi atribut tertentu dalam perhitungan jarak.

Atribut numerik, seperti umur dan lama rawat, distandarisasi menggunakan teknik *z-score standardization*. Teknik ini mengubah nilai data sehingga memiliki nilai rata-rata (μ) sebesar 0 dan standar deviasi (σ) sebesar 1, sehingga perbedaan skala antar atribut numerik tidak memengaruhi hasil klasterisasi. Secara matematis, perhitungan *z-score* ditunjukkan pada Persamaan (1).

$$Z = \frac{(X - \mu)}{\sigma} \quad (1)$$

Keterangan:

X = Nilai asli

μ = Rata-rata data

σ = Standar deviasi

Sementara itu, atribut kategorikal seperti jenis kelamin, kelas, penjamin, staf medis fungsional (SMF), keadaan keluar, diagnosis, dan tindakan ditransformasikan menggunakan teknik *one-hot encoding*. Teknik ini mengubah setiap kategori menjadi representasi biner dalam bentuk beberapa atribut baru dengan nilai 0 atau 1. Penggunaan *one-hot encoding* bertujuan untuk menghindari terbentuknya hubungan ordinal semu antar kategori, sehingga perhitungan jarak menggunakan *euclidean distance* pada algoritma K-Means dapat dilakukan secara lebih akurat dan sesuai dengan karakteristik data kategorikal. Melalui proses transformasi ini, seluruh atribut baik numerik maupun kategorikal berada dalam bentuk numerik yang kompatibel dengan algoritma K-Means, sehingga proses

klasterisasi dapat menghasilkan kelompok pasien rawat inap yang lebih representatif dan bermakna.

Selain itu, pada tahap transformasi juga dilakukan *feature engineering* (ekstraksi fitur baru), yaitu proses pembentukan fitur baru dari atribut yang telah tersedia untuk memperoleh informasi yang lebih representatif dalam proses analisis. *Feature engineering* dilakukan dengan mengekstrak informasi dari atribut ICD-10 dan ICD-9 CM pada data yang telah dibersihkan.

Dari atribut ICD-10, dibentuk dua fitur baru yaitu kelompok diagnosis dan jumlah diagnosis. Fitur kelompok diagnosis menunjukkan kategori penyakit berdasarkan kode ICD-10 dan termasuk dalam tipe data kategorikal, sehingga selanjutnya ditransformasikan menggunakan *teknik one-hot encoding*. Sementara itu, fitur jumlah diagnosis menunjukkan banyaknya diagnosis yang tercatat pada setiap pasien dan termasuk dalam tipe data numerik, sehingga dilakukan proses standarisasi *z-score.*

Selanjutnya, dari atribut ICD-9 CM dibentuk dua fitur baru yaitu kelompok tindakan dan jumlah tindakan. Fitur kelompok tindakan merepresentasikan kategori prosedur atau tindakan medis yang dilakukan terhadap pasien dan ditransformasikan menggunakan *teknik one-hot encoding*. Adapun fitur jumlah tindakan menunjukkan jumlah tindakan medis yang diterima oleh pasien selama masa perawatan dan termasuk dalam tipe data numerik sehingga dilakukan standarisasi *z-score*.

d. Data Reduction

Tahap ini bertujuan untuk mengurangi kompleksitas data tanpa menghilangkan informasi penting yang berpengaruh terhadap proses klasterisasi. Proses reduksi data dilakukan dengan menerapkan reduksi dimensi menggunakan metode *principal component analysis* (PCA). Teknik ini digunakan karena proses *one-hot encoding* pada atribut kategorikal menghasilkan jumlah fitur yang cukup banyak sehingga meningkatkan dimensi data.

Melalui PCA, data direduksi ke dalam sejumlah komponen utama yang mampu merepresentasikan sebagian besar informasi dari *dataset*. Pada penelitian ini, jumlah komponen utama dipilih berdasarkan komponen yang mampu menjelaskan minimal 80% dari total *variance* pada data. Dengan demikian, dimensi data dapat dikurangi tanpa kehilangan informasi yang signifikan, sehingga proses klasterisasi menjadi lebih efisien dan mampu menghasilkan klaster yang lebih optimal.

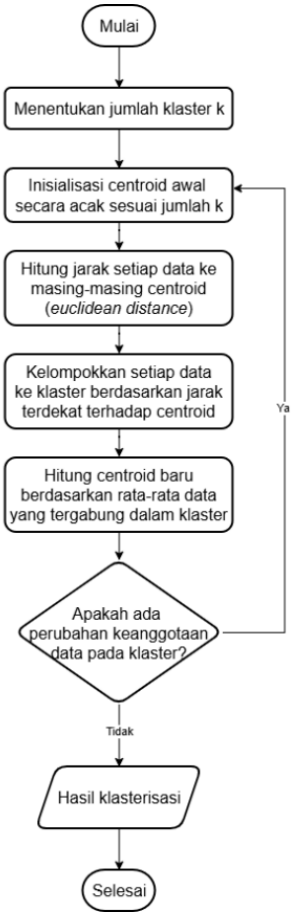
3.3.3. Proses Klasterisasi

Pada tahap ini, proses klasterisasi dilakukan dengan mengimplementasikan algoritma K-Means untuk mengelompokkan data pasien rawat inap berdasarkan tingkat kemiripan karakteristik medis dan pelayanan. Algoritma K-Means termasuk dalam metode *unsupervised learning* (pembelajaran tanpa pengawasan), karena proses pengelompokan dilakukan tanpa menggunakan label kelas, sehingga klaster terbentuk berdasarkan pola alami yang terdapat dalam data.

Proses klasterisasi diawali dengan menentukan jumlah klaster (k) yang akan digunakan. Penentuan nilai k dilakukan berdasarkan hasil evaluasi menggunakan metode *elbow*, *silhouette score*, dan *davies-bouldin index* (DBI) agar jumlah klaster yang dipilih bersifat optimal. Setelah nilai k ditentukan, algoritma melakukan inisialisasi pusat klaster (*centroid*) awal secara acak sesuai dengan jumlah klaster yang telah ditetapkan.

Setiap data pasien kemudian dihitung jaraknya terhadap masing-masing *centroid* menggunakan *euclidean distance* (jarak *Euclidean*). Berdasarkan hasil perhitungan jarak tersebut, setiap data pasien ditempatkan ke dalam klaster dengan jarak terdekat. Tahap ini bertujuan untuk memastikan bahwa data yang berada dalam satu klaster memiliki tingkat kemiripan yang lebih tinggi dibandingkan dengan data pada klaster lainnya.

Tahap berikutnya adalah memperbarui posisi *centroid* dengan menghitung nilai rata-rata dari seluruh data yang tergabung dalam masing-masing klaster. Proses perhitungan jarak dan pembaruan *centroid* dilakukan secara iteratif hingga posisi *centroid* menjadi stabil dan tidak terjadi perubahan keanggotaan klaster. Hasil akhir dari proses ini berupa kelompok pasien rawat inap yang memiliki tingkat kemiripan tinggi dalam satu klaster dan perbedaan yang jelas antar klaster, sehingga dapat digunakan untuk menganalisis pola serta karakteristik pasien rawat inap secara lebih terstruktur. Tahapan proses klasterisasi menggunakan algoritma K-Means disajikan pada Gambar 3.



Gambar 3. Alur K-Means

3.3.4. Evaluasi

Evaluasi hasil klasterisasi dilakukan untuk menilai kualitas klaster yang terbentuk serta menentukan jumlah klaster yang paling optimal pada algoritma K-Means. Proses evaluasi ini penting karena K-Means memerlukan penentuan jumlah klaster (k) di awal, sehingga diperlukan metode pendukung untuk memilih nilai k yang paling representatif. Dalam penelitian ini, evaluasi klaster dilakukan menggunakan tiga metode, yaitu *elbow method*, *silhouette score*, dan *davies-bouldin index* (DBI), agar hasil klasterisasi tidak hanya bergantung pada satu indikator penilaian.

Elbow method digunakan pada tahap awal, sebelum proses klasterisasi final ditetapkan, untuk menentukan jumlah klaster optimal dengan menganalisis nilai WCSS (*Within-Cluster Sum of Squares)* atau SSE (*Sum of Squared Error)* pada berbagai nilai k. Nilai SSE akan terus menurun seiring bertambahnya jumlah klaster, namun penurunan tersebut akan melambat pada titik tertentu. Titik perlambatan yang membentuk sudut seperti siku (*elbow*) menunjukkan jumlah klaster yang dianggap paling optimal karena mampu memberikan keseimbangan antara jumlah klaster dan tingkat homogenitas data dalam klaster.

Setelah diperoleh beberapa kandidat nilai k dari *elbow method*, *silhouette score* digunakan setelah proses klasterisasi dilakukan untuk mengevaluasi kualitas pengelompokan data. Metode ini mengukur tingkat kedekatan data dalam klaster yang sama dan tingkat keterpisahan antar klaster yang berbeda. Nilai *silhouette* berada pada rentang -1 hingga 1, di mana nilai yang mendekati 1 menunjukkan bahwa data berada pada klaster yang tepat, nilai mendekati 0 menunjukkan adanya tumpang tindih antar klaster, sedangkan nilai negatif menunjukkan kemungkinan data salah terklasterisasi. Dalam penelitian ini, *silhouette score* digunakan untuk membandingkan kualitas hasil klasterisasi pada beberapa nilai k.

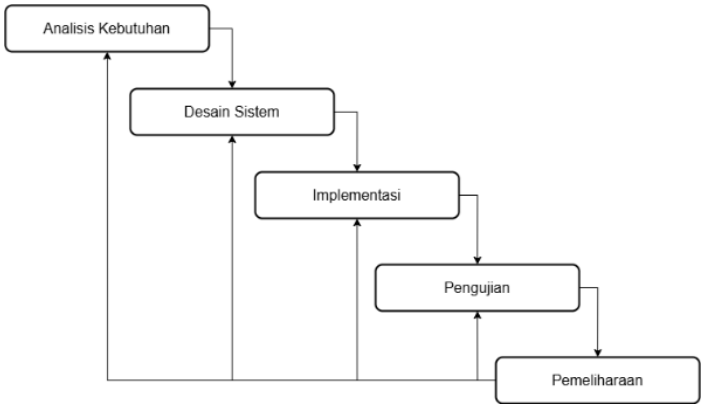
Selanjutnya, *davies-bouldin index* (DBI) digunakan setelah proses klasterisasi sebagai ukuran tambahan untuk menilai kualitas klaster berdasarkan rasio jarak dalam klaster terhadap jarak antar klaster. Semakin kecil nilai DBI, semakin baik kualitas klaster yang dihasilkan karena

menunjukkan bahwa data dalam satu klaster semakin kompak dan jarak antar klaster semakin terpisah. Penggunaan kombinasi *elbow method*, *silhouette score*, dan *davies-bouldin index* (DBI) dalam penelitian ini bertujuan untuk memperoleh jumlah klaster yang lebih optimal dan hasil klasterisasi yang lebih valid serta representatif dalam memetakan profil pasien rawat inap.

3.3.5. Pengembangan *Website*

Tahap pengembangan *website* pada penelitian ini dilakukan dengan menerapkan metode *waterfall*. Metode ini dipilih karena proses pengembangan sistem dilakukan secara terstruktur dan kebutuhan fungsional telah ditetapkan sejak awal penelitian. Setiap tahapan dikerjakan secara berurutan, di mana satu tahap harus diselesaikan terlebih dahulu sebelum melanjutkan ke tahap berikutnya, sehingga memudahkan pengendalian proses pengembangan. Pendekatan ini sesuai dengan karakteristik penelitian yang memiliki alur kerja yang jelas dan terdefinisi sejak awal.

Secara operasional, rangkaian proses ini dimulai dari analisis kebutuhan untuk mendefinisikan fitur sistem, yang kemudian diterjemahkan ke dalam rancangan desain arsitektur dan antarmuka pengguna. Setelah desain disetujui, tahap implementasi dilakukan dengan mengonversi rancangan tersebut ke dalam baris kode program hingga sistem siap diuji secara fungsional. Seluruh alur diakhiri dengan tahap pemeliharaan untuk memastikan aplikasi tetap berjalan optimal dan mampu menangani kebutuhan data secara berkelanjutan. Tahapan pengembangan *website* menggunakan metode *waterfall* tersebut ditunjukkan pada Gambar 4.



Gambar 4. Metode *Waterfall*

Adapun uraian dari setiap tahapan yang terdapat dalam metode *waterfall* dapat dijelaskan sebagai berikut:

a. Analisis Kebutuhan (*Requirements Analysis*)

Pada tahap ini analisis kebutuhan dilakukan dengan mengidentifikasi kebutuhan sistem klasterisasi pasien rawat inap berbasis *website* yang akan dikembangkan. Proses analisis mencakup pengumpulan informasi terkait data yang akan diolah, fungsi sistem yang diperlukan, serta kebutuhan pengguna dalam melakukan proses klasterisasi dan visualisasi hasil. Hasil dari tahap ini menjadi acuan dalam perancangan dan pengembangan sistem agar aplikasi yang dibangun selaras dengan tujuan penelitian serta dapat mendukung proses analisis klasterisasi menggunakan algoritma K-Means secara optimal.

b. Desain Sistem (*Design*)

Pada tahap ini perancangan sistem dilakukan dengan menyusun desain aplikasi berdasarkan kebutuhan yang telah dianalisis sebelumnya. Kegiatan utama pada tahap ini meliputi pembuatan *flowchart* dan *use case diagram* untuk memodelkan alur proses serta interaksi antara pengguna

dengan sistem klasterisasi yang dikembangkan. Hasil perancangan ini selanjutnya digunakan sebagai pedoman pada tahap implementasi agar sistem yang dibangun sesuai dengan rancangan yang telah ditetapkan.

c. Implementasi (*Implementation*)

Pada tahap implementasi, sistem dikembangkan melalui proses pengkodean dengan memanfaatkan *framework laravel* untuk membangun *website* yang interaktif. Bahasa pemrograman yang digunakan adalah PHP sebagai bahasa utama dalam pengembangan aplikasi, dan *python* yang mendukung proses pengolahan data dan penerapan algoritma K-Means dalam sistem yang dibangun.

d. Pengujian (*Testing*)

Pada tahap ini pengujian aplikasi dilakukan untuk memastikan seluruh fitur dan fungsi sistem berjalan sesuai dengan spesifikasi yang telah ditetapkan. Metode pengujian yang digunakan adalah *black box testing*, yaitu dengan menguji respons sistem terhadap berbagai masukan serta memverifikasi bahwa keluaran yang dihasilkan telah sesuai dengan hasil yang diharapkan.

e. Pemeliharaan (*Maintenance*)

Pada tahap pemeliharaan, dilakukan kegiatan pemantauan dan perbaikan terhadap kesalahan yang masih ditemukan setelah sistem digunakan. Tahap ini juga mencakup pengembangan lanjutan serta penyesuaian fitur agar aplikasi tetap berjalan optimal dan sesuai dengan kebutuhan pengguna yang berkembang.

BAB IV
HASIL DAN PEMBAHASAN

4.1. Pengumpulan Data

Penelitian ini menggunakan data sekunder yang diperoleh dari Instalasi Rekam Medis Rumah Sakit Islam Fatimah Cilacap yang bersumber dari Sistem Informasi Manajemen Rumah Sakit (SIMRS). Data yang digunakan berupa data pasien rawat inap periode januari hingga desember 2025 yang mencakup variabel no, no reg, no MR, nama pasien, JK (Jenis Kelamin), umur, tgl. masuk, jam masuk, tgl. keluar, jam keluar, lama rawat, ruang rawat, kelas, penjamin, dokter yang merawat, SMF, keadaan keluar, cara keluar, ICD 10, diagnosis, ICD 9 CM, dan tindakan. Secara keseluruhan, terdapat 13.024 data pasien yang terdokumentasi dalam bentuk *file* Excel.

Dataset yang digunakan dalam penelitian ini terdiri dari atribut yang menggambarkan karakteristik pasien serta pelayanan yang diterima selama perawatan. Atribut tersebut meliputi jenis kelamin, umur, tanggal dan waktu masuk serta keluar, lama rawat, ruang rawat, kelas, penjamin, dokter yang merawat, SMF, keadaan keluar, cara keluar, serta informasi medis berupa ICD 10, diagnosis, ICD 9 CM, dan tindakan. Seluruh atribut tersebut memberikan gambaran menyeluruh mengenai kondisi pasien dan layanan yang diterima selama rawat inap. Dengan jumlah data yang cukup besar, *dataset* ini dinilai representatif untuk digunakan dalam proses klasterisasi guna mengelompokkan pasien berdasarkan kemiripan karakteristik medis dan pelayanan yang dimiliki. Data pasien rawat inap ditunjukkan pada Tabel 2.

Tabel 2. *Dataset* Pasien Rawat Inap

No.	No. Reg	No. MR	Nama Pasien	JK	Umur	Tgl. Masuk	Jam Masuk	Tgl. Keluar	Jam Keluar	Lama Rawat	Ruang Rawat	Kelas	Penjamin	Dokter Yang Merawat	SMF	Keadaan Keluar	Cara Keluar	ICD 10	Diagnosa	ICD 9 CM	Tindakan
1	2412300244	00-39-50-92	ANNISA' ROFIFAH WAROHIDAH	P	26	30 Des 2024	14:09	01 Jan 2025	10:36	2	ARAFAH 3 Dewasa	KELAS 2	BPJS KESEHATAN	dr. Rahmi Ilmiya Ramli, Sp.OG	Spesialis Kebidanan dan Kandungan	sembuh	sembuh	O36.5 O41.0 O83.8 O70.1 Z37.0	Maternal care for poor fetal growth Oligohydramnios Other specified assisted single delivery Second degree perineal laceration Single live birth	73.59 73.4 73.6 90.59 99.18 99.29 75.32 88.78	Other manually assisted delivery Medical induction of labor Episiotomy Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance Fetal EKG Diagnostic ultrasound of gravid uterus
2	2412310073	00-39-51-99	NY. HETI MUJIANINGSIH	L	0	31 Des 2024	08:40	01 Jan 2025	17:10	1	BOX BAYI ARAFAH 3	KELAS BAYI (SEHAT)	BPJS KESEHATAN	dr. Galih Akbar Pinandhito, Sp.A	Spesialis Anak Anak	sembuh	sembuh	P03.4 Z38.0	Fetus and newborn affected by caesarean delivery Singleton, born in hospital	90.59 99.29	Microscopic examination of blood Injection or infusion of therapeutic substance
3	2412310123	00-39-52-10	NY. ALIFAH ISTIKOMAH	P	0	31 Des 2024	10:49	01 Jan 2025	18:47	1	BOX BAYI ARAFAH 3	KELAS BAYI (SEHAT)	BPJS KESEHATAN	dr. Galih Akbar Pinandhito, Sp.A	Spesialis Anak Anak	sembuh	sembuh	P03.4 Z38.0	Fetus and newborn affected by caesarean delivery Singleton, born in hospital	90.59 99.29	Microscopic examination of blood Injection or infusion of therapeutic substance
4	2412280215	00-31-95-50	KASILEM	P	52	28 Des 2024	23:22	01 Jan 2025	22:59	4	AL-KAUTSAR E2	KELAS 3	BPJS KESEHATAN	dr. Agus Susanto, Sp.PD	Spesialis Penyakit Dalam	sembuh	sembuh	A01.0 E11.9	Typhoid fever Non-insulin-dependent diabetes mellitus: Without complications	90.59 99.18 99.29 89.52	Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance Electrocardiogram
5	2412300275	00-38-54-47	HETI MUJIANINGSIH	P	34	30 Des 2024	14:28	01 Jan 2025	17:12	2	ARAFAH 3 Dewasa	KELAS 3	BPJS KESEHATAN	dr. Nono Rasino, Sp.OG (K) FER	Spesialis Kebidanan dan Kandungan	sembuh	sembuh	O33.9 O34.2 O82.0 Z37.0	Maternal care for disproportion Maternal care due to uterine scar Delivery by elective caesarean section Single live birth	74.4 90.59 99.18 99.29	Cesarean section Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance
6	2412280174	00-19-94-32	AISYAH FATHINAH	P	10	28 Des 2024	17:04	01 Jan 2025	12:34	4	ARAFAH 4 Isolasi 463	VIP - ISOLASI	UMUM	dr. Galih Akbar Pinandhito, Sp.A	Spesialis Anak Anak	sembuh	sembuh	A90	Dengue fever [classical dengue]	90.59 99.18 99.29	Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance
7	2412310163	00-39-52-24	DIARRA ALTYN UMAIZA	P	0	31 Des 2024	13:37	01 Jan 2025	15:31	1	BOX BAYI ARAFAH 3	KELAS BAYI (SEHAT)	UMUM	dr. Galih Akbar Pinandhito, Sp.A	Spesialis Anak Anak	sembuh	sembuh	Z38.0	Singleton, born in hospital	99.29 90.59	Injection or infusion of therapeutic substance Microscopic examination of blood
8	2412310049	00-39-51-94	NY. PRISCILA MARSELINAELTIN, S.PI	L	0	31 Des 2024	08:23	01 Jan 2025	16:55	1	BOX BAYI ARAFAH 3	KELAS BAYI (SEHAT)	BPJS KESEHATAN	dr. Galih Akbar Pinandhito, Sp.A	Spesialis Anak Anak	sembuh	sembuh	Z38.0	Singleton, born in hospital	90.59 99.29 93.96	Microscopic examination of blood Injection or infusion of therapeutic substance Other oxygen enrichment
9	2412300382	00-39-51-85	NY. YULIANI	L	0	30 Des 2024	22:51	01 Jan 2025	07:11	2	BOX BAYI ARAFAH 3	KELAS BAYI (SEHAT)	BPJS KESEHATAN	dr. Galih Akbar Pinandhito, Sp.A	Spesialis Anak Anak			Z38.0	Singleton, born in hospital	90.59 99.29	Microscopic examination of blood Injection or infusion of therapeutic substance
10	2412300101	00-39-51-27	FATHAN ARDIANSYAH ILYAS	L	0	30 Des 2024	09:24	01 Jan 2025	20:29	2	ARAFAH 3 Dewasa	VIP	BPJS KESEHATAN	dr. Galih Akbar Pinandhito, Sp.A	Spesialis Anak Anak	sembuh	sembuh	A09.9 J06.9 E86	Gastroenteritis and colitis Acute upper respiratory infection Volume depletion	90.59 99.18 99.29	Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
13016	2512280074	00-40-71-70	ALIFAH PUTRI RAMADHANI	P	2	28 Des 2025	17:58	31 Des 2025	15:35	3	MUZDALIFAH 2 B	KELAS 3	BPJS KESEHATAN	dr. Galih Akbar Pinandhito, Sp.A	Spesialis Anak Anak	sembuh	sembuh	E86 J20.9	Volume depletion Acute bronchitis, unspecified	90.59 99.18 99.29 93.94	Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance Respiratory medication by nebulizer
13017	2512290039	00-41-12-18	RIZKY RAHMADHAN	L	21	29 Des 2025	07:49	31 Des 2025	20:15	2	MUZDALIFAH 4 B	KELAS 3	BPJS KESEHATAN	dr. Agus Susanto, Sp.PD	Spesialis Penyakit Dalam	sembuh	sembuh	A90 E86	Dengue fever [classical dengue] Volume depletion	90.59 99.18 99.29	Microscopic examination of blood Injection or infusion of electrolytes

No.	No. Reg	No. MR	Nama Pasien	JK	Umur	Tgl. Masuk	Jam Masuk	Tgl. Keluar	Jam Keluar	Lama Rawat	Ruang Rawat	Kelas	Penjamin	Dokter Yang Merawat	SMF	Keadaan Keluar	Cara Keluar	ICD 10	Diagnosa	ICD 9 CM	Tindakan
																					Injection or infusion of therapeutic substance
13018	2512290271	00-40-30-71	RASIMUN	L	67	29 Des 2025	15:23	31 Des 2025	13:44	2	MUZDALIFAH 3 B	KELAS 2	BPJS KESEHATAN	dr. Hanum Faeni, Sp.B	Spesialis Bedah	sembuh	sembuh	E11.9 C50.9	Non-insulin-dependent diabetes mellitus Malignant neoplasm: Breast, unspecified	85.21 91.66 90.59 99.18 99.29 89.52 87.44	Local excision of lesion of breast Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance Electrocardiogram Routine chest x-ray
13019	2512280071	00-15-86-79	SATINEM	P	61	28 Des 2025	17:30	31 Des 2025	20:05	3	MUZDALIFAH 3 B	KELAS 3	BPJS KESEHATAN	dr. Lia Amalia, Sp.N	Spesialis Saraf	sembuh	sembuh	I63.5 J15.9 E78.2	Cerebral infarction due to unspecified occlusion Bacterial pneumonia Mixed hyperlipidaemia	87.03 90.59 99.18 99.29 89.52 87.44 93.94 93.96	CT scan of head Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance Electrocardiogram Routine chest x-ray Respiratory medication by nebulizer Other oxygen enrichment
13020	2512240331	00-41-10-93	TUMIRAH	P	81	24 Des 2025	20:11	31 Des 2025	17:20	7	ARAFAH 2 Dewasa dan Anak	KELAS 1 - ISOLASI	BPJS KESEHATAN	dr. Agus Susanto, Sp.PD	Spesialis Penyakit Dalam	sembuh	sembuh	K30 E86	Dyspepsia Volume depletion	90.59 99.18 99.29 89.52	Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance Electrocardiogram
13021	2512280025	00-39-61-68	HAMDAN MUAZZAM ZAKI	L	0	28 Des 2025	09:43	31 Des 2025	09:51	3	ARAFAH 3	VIP	BPJS KESEHATAN	dr. Galih Akbar Pinandhito, Sp.A	Spesialis Anak Anak	sembuh	sembuh	J18.0	Bronchopneumonia, unspecified	90.59 99.18 99.29 87.44 93.94	Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance Routine chest x-ray Respiratory medication by nebulizer
13022	2512280061	00-41-10-60	REGINA GANES ZULEIKA	P	16	28 Des 2025	15:02	31 Des 2025	20:09	3	MUZDALIFAH 3 C	KELAS 3	BPJS KESEHATAN	dr. Husnul Author, Sp.B.	Spesialis Bedah	sembuh	sembuh	K40.9	Unilateral or unspecified inguinal hernia, without obstruction or gangrene	53.04 90.59 99.18 99.29	Other and open repair of indirect inguinal hernia Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance
13023	2512280010	00-12-46-31	SUTIMAH	P	83	28 Des 2025	05:59	31 Des 2025	17:22	3	MUZDALIFAH 3 A	KELAS 2	BPJS KESEHATAN	dr. Agus Susanto, Sp.PD	Spesialis Penyakit Dalam	sembuh	sembuh	J40 E86	Bronchitis, not specified as acute or chronic Volume depletion	90.59 99.18 99.29 89.52	Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance Electrocardiogram
13024	2512250082	00-40-67-34	NGAINAH	P	64	25 Des 2025	17:17	31 Des 2025	20:38	6	MUZDALIFAH 4 C	KELAS 3	BPJS KESEHATAN	dr. Agus Susanto, Sp.PD	Spesialis Penyakit Dalam	dead	dead	K81.8 D64.9 I95.9	Other cholecystitis Anaemia, unspecified Hypotension, unspecified	99.04 90.59 99.18 99.29 89.52 87.44 88.76 99.60	Transfusion of packed cells Microscopic examination of blood Injection or infusion of electrolytes Injection or infusion of therapeutic substance Electrocardiogram Routine chest x-ray Diagnostic ultrasound of abdomen Cardiopulmonary resuscitation

4.2. *Data Preprocessing*

Tahap *data preprocessing* merupakan proses pemilihan, pembersihan, dan persiapan data sebelum dilakukan proses analisis. Pada penelitian ini, tahapan *preprocessing* meliputi *data selection*, *data cleaning*, *data transformation*, dan *data reduction* yang akan dijelaskan di bawah ini.

4.2.1. *Data Selection*

Tahap ini merupakan langkah awal dalam proses *preprocessing* yang bertujuan untuk memilih atribut atau variabel yang relevan dengan tujuan klasterisasi pasien rawat inap. Proses seleksi data dilakukan dengan menentukan atribut yang berkaitan dengan karakteristik medis dan pelayanan pasien sehingga data yang digunakan menjadi lebih fokus dan representatif terhadap tujuan penelitian.

Berdasarkan hasil proses *data selection*, jumlah atribut pada *dataset* berkurang dari 22 atribut menjadi 11 atribut yang digunakan dalam proses analisis. Atribut yang dipilih meliputi umur, lama rawat, jenis kelamin (JK), kelas, penjamin, staf medis fungsional (SMF), keadaan keluar, ICD-10, diagnosis, ICD-9 CM, dan tindakan, seperti yang disajikan pada Gambar 5.

Atribut ICD-10 dan ICD-9 CM selanjutnya tidak digunakan secara langsung dalam proses klasterisasi, tetapi akan diolah lebih lanjut pada tahap *feature engineering* (ekstraksi fitur baru) pada proses *data transformation* untuk menghasilkan fitur baru yang lebih representatif dalam menggambarkan karakteristik diagnosis dan tindakan medis pasien. Dengan demikian, kualitas dan relevansi fitur yang digunakan lebih terjamin.

4.2.2. *Data Cleaning*

Pada tahap ini pemeriksaan dan pengolahan data dilakukan untuk memastikan bahwa data memiliki tingkat integritas, kelengkapan, dan validitas yang baik.

a) Missing Values

Pada *dataset* pasien rawat inap yang telah dikumpulkan, ditemukan beberapa data yang tidak memiliki nilai pada atribut tertentu sehingga berpotensi memengaruhi proses klasterisasi yang akan dilakukan. Oleh karena itu, data yang memiliki nilai kosong (*missing values*) perlu ditangani dengan cara menghapus atau menghilangkan baris data yang tidak lengkap. *Missing values* pada *dataset* ini ditemukan pada beberapa atribut yang digunakan dalam penelitian, seperti umur, lama rawat, keadaan keluar, diagnosis, tindakan, ICD-10, dan ICD-9 CM, seperti yang disajikan pada Gambar 5.

```
Missing values per kolom:
Umur                 1
Lama Rawat           1
JK                   0
Kelas                0
Penjamin             0
SMF                  0
Keadaan Keluar    1201
Diagnosa            23
Tindakan            53
ICD 10              23
ICD 9 CM            53
dtype: int64

Total missing values: 1355

Jumlah baris sebelum cleaning: 13024
Jumlah baris setelah hapus missing values: 11779
Baris yang dihapus: 1245
```

Gambar 5. *Missing Values*

Setelah *missing values* dihapus dari *dataset*, jumlah data berkurang dari 13.024 menjadi 11.779, menunjukkan adanya 1.245 baris data yang dihapus karena tidak memiliki nilai lengkap.

b) Data Duplikat

Pada tahap ini dilakukan pemeriksaan terhadap kemungkinan adanya data duplikat, yaitu baris data yang memiliki isi yang sama pada seluruh atribut. Berdasarkan hasil pemeriksaan, ditemukan sebanyak 450 baris data duplikat pada *dataset*. Dalam proses pembersihan data, hanya baris duplikat kedua dan seterusnya yang dihapus, sedangkan baris pertama tetap dipertahankan sebagai data asli. Setelah proses penghapusan data duplikat dilakukan, jumlah data yang tersisa dalam *dataset* menjadi 11.329 baris. Hasil pemeriksaan data duplikat disajikan pada Gambar 6.

```
Jumlah data duplikat: 450
Jumlah baris setelah menghapus duplikat: 11329
```

Gambar 6. Pemeriksaan Data Duplikat

c) Data Tidak Valid

Pada tahap pengecekan data tidak valid yang telah dilakukan, diperoleh hasil bahwa tidak ditemukan data yang berada di luar batas validitas yang telah ditentukan. Validasi dilakukan pada beberapa atribut, yaitu umur, lama rawat, dan jenis kelamin. Hasil pemeriksaan menunjukkan bahwa tidak terdapat nilai umur yang kurang dari 0 atau lebih dari 120 tahun, sehingga seluruh data umur dinyatakan valid. Selanjutnya, pada atribut lama rawat juga tidak ditemukan nilai yang kurang dari 0 hari maupun lebih dari 365 hari, sehingga data pada atribut

tersebut dinilai konsisten dan sesuai dengan batas yang telah ditetapkan. Selain itu, pada atribut jenis kelamin (JK) diperoleh dua nilai unik yaitu "P" dan "L", yang masing-masing merepresentasikan perempuan dan laki-laki. Hasil ini menunjukkan bahwa seluruh nilai pada atribut jenis kelamin telah sesuai dengan kategori yang diharapkan, sehingga tidak terdapat data tidak valid yang perlu dihapus pada tahap ini. Hasil pengecekan data tidak valid disajikan pada Gambar 7.

```
   a) Umur tidak valid (< 0 atau > 120 tahun): 0 baris

   b) Lama Rawat tidak valid (< 0 atau > 365 hari): 0 baris

   c) Validasi Jenis Kelamin (JK):
      Nilai unik: <StringArray>
['P', 'L']
Length: 2, dtype: str
      ✓ Semua nilai JK valid
```

Gambar 7. Pengecekan Data Tidak Valid

4.2.3. *Data Transformation*

Pada tahap ini proses transformasi data dilakukan untuk menyesuaikan format data agar siap digunakan dalam proses klasterisasi menggunakan algoritma K-Means.

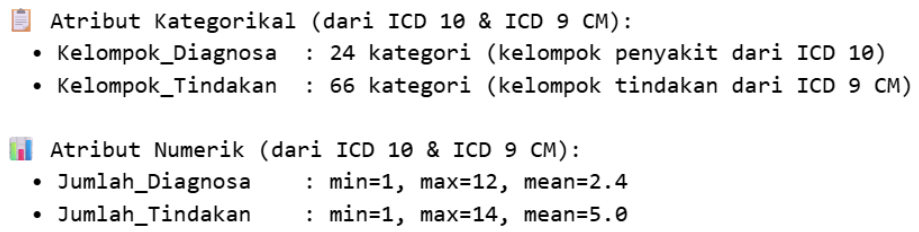
a) *Feature Engineering* (ekstraksi fitur baru)

Tahap pertama dalam proses ini adalah *feature engineering*. Pada tahap *feature engineering* (ekstraksi fitur baru) dilakukan proses pembentukan fitur baru dari atribut yang telah tersedia agar informasi yang digunakan dalam proses klasterisasi menjadi lebih representatif. Proses ini

memanfaatkan atribut ICD 10 dan ICD 9 CM yang berisi kode diagnosis dan tindakan medis pasien.

Dari atribut ICD 10, terlebih dahulu diekstrak kode diagnosis utama dari setiap pasien, kemudian kode tersebut dikelompokkan berdasarkan huruf pertama kode ICD 10 untuk membentuk fitur baru bernama kelompok diagnosis yang merepresentasikan kategori penyakit. Selain itu, dari atribut yang sama juga dihitung jumlah kode diagnosis yang dimiliki setiap pasien sehingga menghasilkan fitur numerik jumlah diagnosis yang menunjukkan banyaknya diagnosis yang tercatat.

Selanjutnya, pada atribut ICD 9 CM dilakukan proses serupa dengan mengekstrak kode tindakan utama dan mengelompokkannya berdasarkan dua digit pertama kode ICD 9 CM untuk membentuk fitur kelompok tindakan yang menggambarkan kategori prosedur atau tindakan medis yang diterima pasien. Selain itu, dihitung pula jumlah kode tindakan pada setiap pasien sehingga diperoleh fitur numerik jumlah tindakan. Dengan demikian, melalui *tahap feature engineering* ini dihasilkan empat fitur baru, yaitu kelompok diagnosis, kelompok tindakan, jumlah diagnosis, dan jumlah tindakan, yang selanjutnya digunakan dalam proses transformasi dan analisis klasterisasi. Proses *feature engineering* menghasilkan 24 kategori pada fitur kelompok diagnosis dan 66 kategori pada fitur kelompok tindakan. Keempat fitur baru tersebut menjadi representasi yang lebih terstruktur dalam mendukung proses klasterisasi selanjutnya. Hasil *feature engineering* disajikan pada Gambar 8.



Gambar 8. Hasil *Feature Engineering*

b) *Z-Score Standardization* (Standarisasi *Z-Score*)

Pada tahap ini dilakukan standardisasi terhadap atribut numerik agar data memiliki skala yang seragam sebelum digunakan dalam proses klasterisasi menggunakan algoritma K-Means. Atribut numerik yang digunakan dalam penelitian ini meliputi umur, lama rawat, jumlah diagnosis, dan jumlah tindakan. Atribut umur dan lama rawat merupakan atribut asli pada data pasien, sedangkan jumlah diagnosis dan jumlah tindakan merupakan atribut hasil dari proses *feature engineering* yang sebelumnya telah dilakukan.

Proses standardisasi dilakukan menggunakan metode *z-score* dengan bantuan *standardscaler*. Metode ini mengubah nilai setiap atribut numerik sehingga memiliki rata-rata (*mean*) mendekati 0 dan standar deviasi (std) mendekati 1. Tujuan dari standardisasi ini adalah untuk menyamakan skala antar atribut numerik sehingga tidak terjadi dominasi atribut tertentu dalam proses perhitungan jarak pada algoritma K-Means. Dengan standarisasi ini, setiap atribut berkontribusi secara proporsional dalam proses klasterisasi sehingga hasil pengelompokan yang diperoleh menjadi lebih akurat dan tidak bias terhadap atribut dengan skala nilai yang lebih besar. Data sebelum dilakukan standarisasi disajikan pada Gambar 9.

```
Statistik SEBELUM standardisasi:
                Umur    Lama Rawat  Jumlah_Diagnosa  Jumlah_Tindakan
count  11329.000000  11329.000000     11329.000000     11329.000000
mean      36.814370      3.129667         2.372584         4.990997
std       23.453793      1.728442         1.326485         1.721906
min        0.000000      1.000000         1.000000         1.000000
25%       19.000000      2.000000         1.000000         4.000000
50%       34.000000      3.000000         2.000000         5.000000
75%       57.000000      4.000000         3.000000         6.000000
max      102.000000     26.000000        12.000000        14.000000
```

Gambar 9. Data Sebelum Standarisasi

Adapun kode untuk melakukan standarisasi *z-score* ditunjukkan pada *Listing Program 1.*

```
numerical_features = ['Umur', 'Lama Rawat',
'Jumlah_Diagnosa', 'Jumlah_Tindakan']
scaler = StandardScaler()
df_numerical_scaled = pd.DataFrame(
    scaler.fit_transform(df_cleaned[numerical_features]),
    columns=numerical_features)
```

Listing Program 1. *Z-Score Standardization*

Adapun rumus untuk melakukan perhitungan *z-score* disajikan pada Persamaan 1.

$$Z = \frac{(X - \mu)}{\sigma} \tag{1}$$

Keterangan:

X = Nilai asli

μ = Rata-rata data

σ = Standar deviasi

Selanjutnya proses perhitungan *z-score* pada atribut umur pada data *indeks* ke-0. Langkah pertama yang dilakukan adalah menghitung nilai rata-rata (*mean*) dari seluruh data pada kolom umur. Nilai rata-rata

diperoleh dengan menjumlahkan seluruh nilai umur pasien kemudian dibagi dengan jumlah keseluruhan data.

$$\mu\ umur = \frac{26\ +\ 0\ +\ 0\ +\ 52\ +\ 34 + \ldots + 64}{11.329} = \frac{417.070}{11.329}$$

$$= 36{,}814370$$

Didapatkan bahwa hasil rata-rata pada atribut umur diperoleh 36,814370. Setelah mendapatkan nilai rata-rata, selanjutnya dilakukan perhitungan standar deviasi.

$\sigma\ umur$

$$= \sqrt{\frac{(26 - 36{,}81)^2 +\ (0 - 36{,}81)^2 +\ (0 - 36{,}81)^2 +\ \ldots\ +\ (64 - 36{,}81)^2}{11.329}}$$

$$= 23{,}452757$$

Didapatkan bahwa hasil standar deviasi pada kolom umur diperoleh 23,452757. Selanjutnya dilakukan perhitungan *z-score* pada kolom umur pada *index* 0 menggunakan Persamaan (1).

$$z - score = \frac{26\ -\ 36{,}814370}{23{,}452757} = \frac{-10{,}814370}{23{,}452757} = -0.461113$$

Didapatkan hasil *z-score* pada umur pada *index* 0 diperoleh -0.461113. Selanjutnya dilakukan perhitungan nilai rata-rata (*mean*) dari seluruh data pada kolom lama rawat.

$$\mu\ lama\ rawat = \frac{2\ +\ 1\ +\ 1\ +\ 4\ +\ 2 + \ldots + 6}{11.329} = \frac{35.456}{11.329}$$

$$= 3{,}129667$$

Didapatkan bahwa hasil rata-rata pada atribut lama rawat diperoleh 3,129667. Setelah mendapatkan nilai rata-rata, selanjutnya dilakukan perhitungan standar deviasi.

$\sigma\ lama\ rawat$

$$= \sqrt{\frac{(2-3{,}13)^2 + (1-3{,}13)^2 + (1-3{,}13)^2 + \ldots + (6-3{,}13)^2}{11.329}}$$

$$= 1{,}728365$$

Didapatkan bahwa hasil standar deviasi pada kolom lama rawat diperoleh 1,728365. Selanjutnya dilakukan perhitungan *z-score* pada kolom lama rawat pada *index* 0 menggunakan Persamaan (1).

$$z - score = \frac{2 - 3{,}129667}{1{,}728365} = \frac{-1{,}129667}{1{,}728365} = -0{,}653604$$

Didapatkan hasil *z-score* pada lama rawat pada *index* 0 diperoleh -0,653604. Selanjutnya dilakukan perhitungan nilai rata-rata (*mean*) dari seluruh data pada kolom jumlah diagnosis.

$$\mu\ jumlah\ diagnosis = \frac{5 + 2 + 2 + 2 + 4 + \ldots + 3}{11.329} = \frac{26.879}{11.329}$$

$$= 2{,}372584$$

Didapatkan bahwa hasil rata-rata pada atribut jumlah diagnosis diperoleh 2,372584. Setelah mendapatkan nilai rata-rata, selanjutnya dilakukan perhitungan standar deviasi.

$\sigma\ jumlah\ diagnosa$

$$= \sqrt{\frac{(5-2{,}37)^2 + (2-2{,}37)^2 + (2-2{,}37)^2 + \ldots + (3-2{,}37)^2}{11.329}}$$

$$= 1{,}326426$$

Didapatkan bahwa hasil standar deviasi pada kolom jumlah diagnosis diperoleh 1,326426. Selanjutnya dilakukan perhitungan *z-score* pada kolom jumlah diagnosis pada *index* 0 menggunakan Persamaan (1).

$$z - score = \frac{5 \ - \ 2{,}372584}{1{,}326426} = \frac{2{,}627416}{1{,}326426} = 1{,}980823$$

Didapatkan hasil *z-score* pada jumlah diagnosis pada *index* 0 diperoleh 1,980823. Selanjutnya dilakukan perhitungan nilai rata-rata (*mean*) dari seluruh data pada kolom jumlah tindakan.

$$\mu\ jumlah\ tindakan = \frac{8 \ + \ 2 \ + \ 2 \ + \ 4 \ + \ 4 + \ldots + 8}{11.329} = \frac{56.543}{11.329}$$

$$= \ 4{,}990997$$

Didapatkan bahwa hasil rata-rata pada atribut jumlah tindakan diperoleh 4,990997. Setelah mendapatkan nilai rata-rata, selanjutnya dilakukan perhitungan standar deviasi.

$$\sigma\ jumlah\ tindakan$$

$$= \sqrt{\frac{(8 - 4.99)^2 \ + \ (2 - 4.99)^2 \ + \ (2 - 4.99)^2 + \ldots + (8 - 4.99)^2}{11.329}}$$

$$= \ 1{,}721830$$

Didapatkan bahwa hasil standar deviasi pada kolom jumlah tindakan diperoleh 1,721830. Selanjutnya dilakukan perhitungan *z-score* pada kolom jumlah tindakan pada *index* 0 menggunakan Persamaan (1).

$$z - score = \frac{8 \ - \ 4{,}990997}{1{,}721830} = \frac{3{,}009003}{1{,}721830} = 1{,}747561$$

Didapatkan hasil *z-score* pada jumlah Tindakan pada *index* 0 diperoleh 1,747561. Proses ini menghasilkan seluruh data pada atribut

umur, lama rawat, jumlah diagnosis dan jumlah Tindakan yang telah di standarisasi. Adapun hasil standarisasi disajikan pada Gambar 10.

Statistik SETELAH standardisasi:

	Umur	Lama Rawat	Jumlah_Diagnosa	Jumlah_Tindakan
count	1.132900e+04	1.132900e+04	1.132900e+04	1.132900e+04
mean	-8.028023e-17	-3.574979e-17	3.010509e-17	8.028023e-17
std	1.000044e+00	1.000044e+00	1.000044e+00	1.000044e+00
min	-1.569725e+00	-1.232186e+00	-1.034798e+00	-2.317880e+00
25%	-7.595853e-01	-6.536044e-01	-1.034798e+00	-5.755483e-01
50%	-1.200017e-01	-7.502304e-02	-2.808928e-01	5.228995e-03
75%	8.606932e-01	5.035583e-01	4.730125e-01	5.860063e-01
max	2.779444e+00	1.323235e+01	7.258161e+00	5.232225e+00

Gambar 10. Data Setelah Standarisasi

c) One-Hot Encoding

Pada tahap ini dilakukan transformasi data kategorikal menggunakan metode *one-hot encoding*. Proses ini bertujuan untuk mengubah atribut yang bersifat kategorikal menjadi bentuk numerik sehingga dapat diproses oleh algoritma K-Means, karena algoritma tersebut hanya dapat mengolah data dalam bentuk angka.

One-Hot Encoding dilakukan pada seluruh atribut kategorikal, yaitu jk, kelas, penjamin, staf medis fungsional (SMF), keadaan keluar, kelompok diagnosis, dan kelompok tindakan. Setiap kategori pada atribut tersebut diubah menjadi kolom baru yang berisi nilai 0 atau 1, di mana nilai 1 menunjukkan bahwa data termasuk dalam kategori tersebut, sedangkan nilai 0 menunjukkan sebaliknya. Setelah proses *encoding* dilakukan, seluruh kolom hasil *encoding* kemudian dikonversi ke tipe data integer agar format data menjadi lebih konsisten. Proses ini memastikan seluruh atribut kategorikal dapat diolah secara numerik. Adapun kode untuk melakukan *one-hot encoding* ditunjukkan pada *Listing Program 2.*

```
categorical_features = ['JK', 'Kelas', 'Penjamin', 'SMF',
'Keadaan Keluar', 'Kelompok_Diagnosa', 'Kelompok_Tindakan']
df_categorical_encoded                                    =
pd.get_dummies(df_cleaned[categorical_features],
prefix=categorical_features, drop_first=False)
df_categorical_encoded = df_categorical_encoded.astype(int)
for feature in categorical_features:
    unique_count = df_cleaned[feature].nunique()
           encoded_cols    =    [col    for    col    in
df_categorical_encoded.columns if col.startswith(feature)]
      print(f"  -  {feature}:  {unique_count}  kategori  →
{len(encoded_cols)} kolom")
```

Listing Program 2. *One-Hot Encoding*

Hasil dari proses ini adalah bertambahnya jumlah atribut karena setiap kategori direpresentasikan sebagai kolom tersendiri. Proses *one-hot encoding* membentuk 173 atribut dengan 2 kategori pada atribut JK, 12 kategori pada atribut kelas, 51 kategori pada atribut penjamin, 12 kategori pada atribut SMF, 6 kategori pada atribut keadaan keluar, 24 kategori pada atribut kelompok diagnosis, dan 66 kategori pada atribut kelompok tindakan. Dimensi data yang menjadi lebih tinggi ini kemudian akan disederhanakan kembali pada tahap berikutnya menggunakan metode *principal component analysis* (PCA) untuk mengurangi jumlah fitur tanpa menghilangkan informasi penting yang terkandung dalam data. Meskipun jumlah atribut meningkat secara signifikan, representasi data yang dihasilkan menjadi lebih lengkap dan siap untuk diproses lebih lanjut pada tahap reduksi dimensi. Adapun hasil *one-hot encoding* disajikan pada Gambar 11.

```
Jumlah atribut kategorikal asli: 7
Jumlah atribut setelah one-hot encoding: 173

Detail encoding per atribut:
  - JK: 2 kategori → 2 kolom
  - Kelas: 12 kategori → 12 kolom
  - Penjamin: 51 kategori → 51 kolom
  - SMF: 12 kategori → 12 kolom
  - Keadaan Keluar: 6 kategori → 6 kolom
  - Kelompok_Diagnosa: 24 kategori → 24 kolom
  - Kelompok_Tindakan: 66 kategori → 66 kolom
```

Gambar 11. Hasil *One-Hot Encoding*

4.2.4. *Data Reduction*

Tahap ini merupakan proses reduksi dimensi menggunakan *metode principal component analysis* (PCA). Tujuan dari tahap ini adalah mengurangi jumlah atribut hasil transformasi sebelumnya tanpa menghilangkan informasi penting yang terkandung dalam data. Reduksi dimensi diperlukan karena setelah proses *one-hot encoding*, jumlah fitur menjadi cukup banyak sehingga dapat meningkatkan kompleksitas perhitungan pada proses klasterisasi menggunakan algoritma K-Means.

Pada tahap reduksi dimensi, data yang telah melalui proses standardisasi atribut numerik dan *one-hot encoding* pada atribut kategorikal digabungkan menjadi satu *dataset*. Hasil penggabungan tersebut menghasilkan data dengan 11.329 baris pasien dan 177 fitur, yang terdiri dari 4 fitur numerik yang telah distandarisasi yaitu umur, lama rawat, jumlah diagnosis, dan jumlah tindakan serta 173 fitur kategorikal hasil *encoding* dari atribut JK, kelas, penjamin, SMF, keadaan keluar, kelompok diagnosis, dan kelompok tindakan. Jumlah fitur yang cukup besar ini berpotensi

menimbulkan kompleksitas tinggi dalam proses analisis sehingga diperlukan teknik reduksi dimensi.

Oleh karena itu, reduksi dimensi menggunakan metode *principal component analysis* (PCA) dilakukan untuk menyederhanakan jumlah fitur tanpa menghilangkan informasi penting yang terdapat dalam data. Pada tahap awal, PCA dijalankan dengan seluruh komponen untuk mengetahui nilai *explained variance ratio* dari setiap komponen. Selanjutnya dihitung *cumulative explained variance* untuk menentukan jumlah komponen utama yang mampu menjelaskan minimal 80% dari total variasi data. Nilai tersebut digunakan sebagai dasar dalam menentukan jumlah komponen PCA yang optimal. Dimensi data sebelum dilakukan PCA dan proses analisis *explained variance* disajikan pada Gambar 12.

```
Dimensi data sebelum PCA: 177 fitur

Explained Variance Ratio per Komponen (Top 12 untuk ≥80% variance):
  PC1: 0.2442 (Kumulatif: 0.2442 = 24.4%)
  PC2: 0.1442 (Kumulatif: 0.3884 = 38.8%)
  PC3: 0.1304 (Kumulatif: 0.5188 = 51.9%)
  PC4: 0.0721 (Kumulatif: 0.5909 = 59.1%)
  PC5: 0.0564 (Kumulatif: 0.6473 = 64.7%)
  PC6: 0.0384 (Kumulatif: 0.6857 = 68.6%)
  PC7: 0.0302 (Kumulatif: 0.7159 = 71.6%)
  PC8: 0.0252 (Kumulatif: 0.7411 = 74.1%)
  PC9: 0.0204 (Kumulatif: 0.7615 = 76.2%)
  PC10: 0.0179 (Kumulatif: 0.7795 = 77.9%)
  PC11: 0.0176 (Kumulatif: 0.7971 = 79.7%)
  PC12: 0.0151 (Kumulatif: 0.8122 = 81.2%)

================================================================
✓ Jumlah komponen untuk ≥80% variance: 12
  Total variance yang dijelaskan: 81.22%
```

Gambar 12. Dimensi Data Sebelum PCA

Setelah jumlah komponen optimal diperoleh, dilakukan penerapan PCA kembali dengan jumlah komponen tersebut sehingga menghasilkan *dataset* baru yang terdiri dari beberapa komponen utama (PC1, PC2, dan seterusnya).

Setiap komponen merupakan kombinasi dari atribut-atribut sebelumnya yang merepresentasikan sebagian besar informasi dalam data. Proses ini menghasilkan *dataset* dengan jumlah fitur yang lebih sedikit namun tetap mempertahankan sebagian besar informasi penting. *Dataset* hasil reduksi dimensi inilah yang selanjutnya digunakan sebagai data akhir dalam proses klasterisasi. Adapun hasil *principal component analysis* (PCA) disajikan pada Gambar 13.

```
Dimensi sebelum PCA : 177 fitur
Dimensi setelah PCA : 12 komponen
Rasio reduksi       : 14.8x
Total variance      : 81.22%

============================================================
RINGKASAN DATA UNTUK CLUSTERING
============================================================
Jumlah data (baris) : 11329 pasien
Jumlah fitur (kolom): 12 komponen PCA

✓ Dataset final berisi 11329 data pasien dengan
  12 komponen PCA sebagai dasar pembentukan model klasterisasi.
```

Gambar 13. Dimensi Data Setelah PCA

4.3. Proses Klasterisasi

Sebelum membangun model klasterisasi, terlebih dahulu dilakukan penentuan jumlah klaster yang optimal. Pada penelitian ini, penentuan jumlah klaster dilakukan menggunakan tiga metode evaluasi, yaitu *elbow Method*, *silhouette score*, dan *davies–bouldin index* (DBI). Ketiga metode tersebut digunakan untuk memperoleh jumlah klaster yang paling sesuai dengan karakteristik data. Adapun kode program untuk menentukan jumlah klaster optimal menggunakan metode *elbow* ditunjukkan pada *Listing Program* 3.

```
wcss = []
K_range = range(2, 11)
```

```
for k in K_range:
kmeans = KMeans(n_clusters=k, init='random', random_state=42,
n_init=10)
kmeans.fit(df_final)
wcss.append(kmeans.inertia_)
print(f"K = {k}: WCSS = {kmeans.inertia_:.2f}")
penurunan = []
persen_penurunan = []
for i in range(len(wcss) - 1):
delta = wcss[i] - wcss[i + 1]
pct = (delta / wcss[i]) * 100
penurunan.append(delta)
persen_penurunan.append(pct)
print(f"    {list(K_range)[i]:>2}   →   {list(K_range)[i+1]:>2}   |
{delta:>15.2f} | {pct:>10.2f} %")
second_diff = []
for i in range(len(penurunan) - 1):
second_diff.append(penurunan[i] - penurunan[i + 1])
elbow_idx = second_diff.index(max(second_diff)) + 1  # +1 karena
elbow ada setelah penurunan terbesar
elbow_k = list(K_range)[elbow_idx]
print("\n" + "=" * 80)
```

Listing Program 3. *Elbow Method*

Adapun kode program untuk menentukan jumlah klaster optimal menggunakan metode *silhouette score* ditunjukkan pada *Listing Program 4*.

```
silhouette_scores = []
for k in K_range:
kmeans = KMeans(n_clusters=k, init='random', random_state=42,
n_init=10)
labels = kmeans.fit_predict(df_final)
score = silhouette_score(df_final, labels)
silhouette_scores.append(score)
```

```
print(f"K = {k}: Silhouette Score = {score:.4f}")
optimal_k_silhouette                                                    =
K_range[silhouette_scores.index(max(silhouette_scores))]
print("\n" + "=" * 80)
print(f"✓    Optimal    K    (berdasarkan    Silhouette    Score):
{optimal_k_silhouette}")
print(f"  Maximum Silhouette Score: {max(silhouette_scores):.4f}")
print("=" * 80)
```

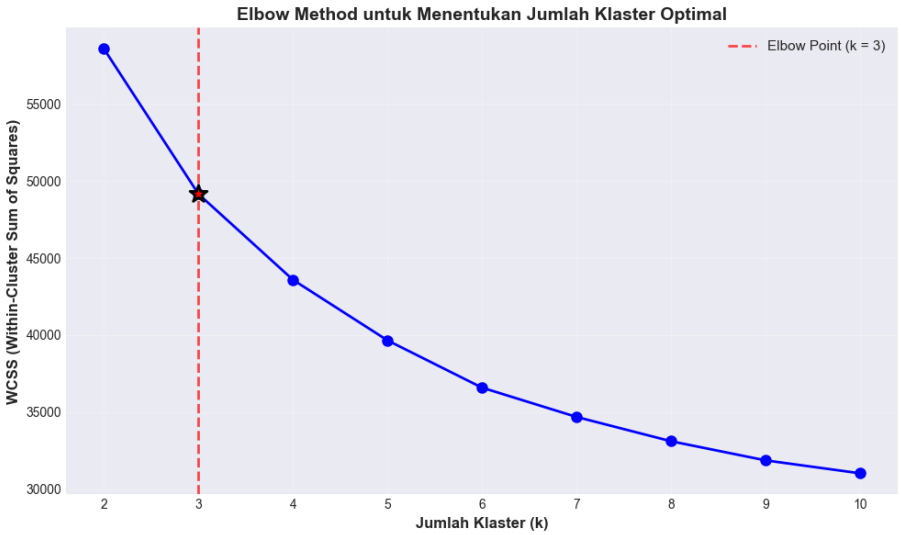
Listing Program 4. *Silhouette Score*

Adapun kode program untuk menentukan jumlah klaster optimal menggunakan metode *davies-bouldin index* (DBI) ditunjukkan pada *Listing Program 5*.

```
dbi_scores = []
for k in K_range:
kmeans  =  KMeans(n_clusters=k,  init='random',  random_state=42,
n_init=10)
labels = kmeans.fit_predict(df_final)
dbi = davies_bouldin_score(df_final, labels)
dbi_scores.append(dbi)
print(f"K = {k}: DBI = {dbi:.4f}")
optimal_k_dbi = K_range[dbi_scores.index(min(dbi_scores))]
print("\n" + "=" * 80)
print(f"✓ Optimal K (berdasarkan DBI): {optimal_k_dbi}")
print(f"  Minimum DBI Score: {min(dbi_scores):.4f}")
print("=" * 80)
dbi_final             =             davies_bouldin_score(df_final,
df_cleaned_final['Cluster'])
silhouette_final           =           silhouette_score(df_final,
df_cleaned_final['Cluster'])
```

Listing Program 5. *Davies-Bouldin Index (DBI)*

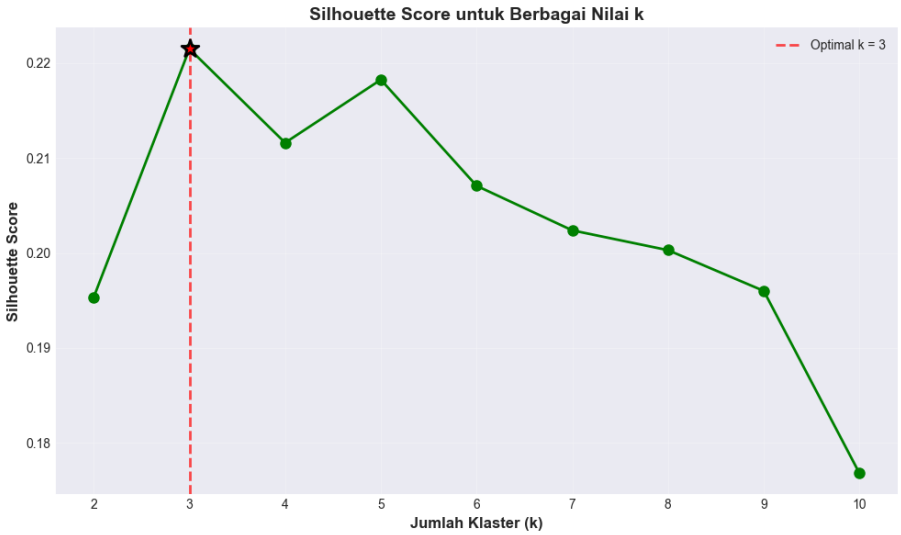
Berdasarkan *Listing Program 3*, variabel *k_range* digunakan untuk menentukan rentang nilai k yang akan diuji, yaitu dari k = 2 hingga k = 10. Pada setiap nilai k tersebut, algoritma K-Means dijalankan untuk membentuk klaster pada data. Selanjutnya, hasil klasterisasi dievaluasi menggunakan tiga metode, yaitu *elbow method*, *silhouette score*, dan *davies–bouldin index* (DBI) untuk menilai kualitas klaster yang dihasilkan. Berdasarkan hasil evaluasi dari ketiga metode tersebut diperoleh jumlah klaster optimal yaitu k = 3. Adapun grafik dari *elbow method* disajikan pada Gambar 14.



Gambar 14. Grafik *Elbow Method*

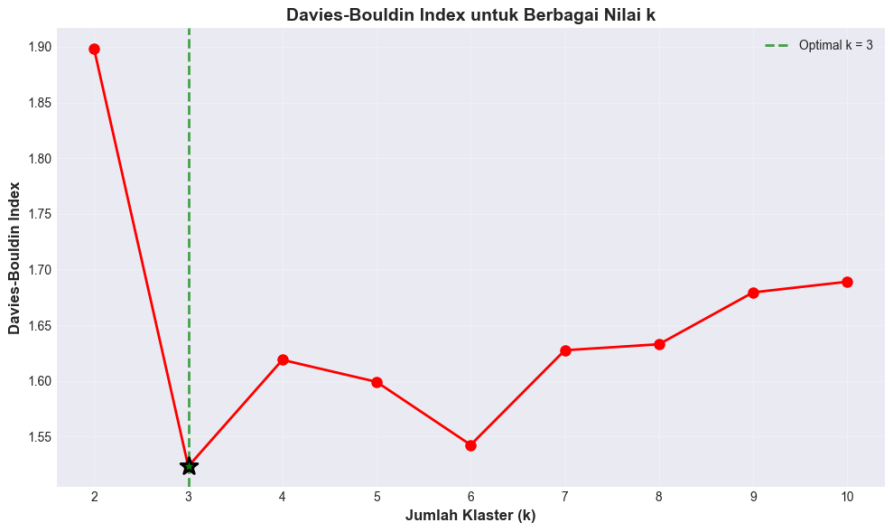
Grafik metode *elbow* menunjukkan hubungan antara jumlah klaster (k) dengan nilai WCSS (*Within Cluster Sum of Squares*) pada rentang pengujian k = 2 hingga k = 10. Berdasarkan grafik tersebut, penurunan nilai WCSS yang paling tajam terjadi dari k = 2 ke k = 3. Kemudian, laju penurunan mulai melandai secara perlahan pada k = 4 dan seterusnya, sehingga secara visual membentuk pola siku (*elbow*) tepat pada titik k = 3 dengan nilai WCSS sebesar 49.148,10. Hal ini menunjukkan secara jelas bahwa k = 3 merupakan jumlah klaster optimal

berdasarkan metode *elbow*. Adapun hasil evaluasi selanjutnya berupa grafik dari *silhouette score* disajikan pada Gambar 15.



Gambar 15. Grafik *Silhouette Score*

Grafik evaluasi *silhouette score* menunjukkan kualitas pemisahan klaster untuk setiap nilai k, di mana semakin tinggi nilainya maka semakin baik kualitas klasterisasi tersebut. Berdasarkan grafik pengujian tersebut, perolehan nilai *silhouette score* tertinggi dicapai pada titik k = 3 sebesar 0,2215. Setelah titik puncak tersebut, nilainya cenderung terus menurun pada nilai k yang lebih besar hingga mencapai angka 0,1770 pada batas k = 10. Penurunan nilai yang signifikan ini mengindikasikan bahwa penambahan jumlah kelompok justru meningkatkan risiko tumpah tindih (*overlap*) antar-klaster, sehingga struktur data menjadi kurang padat dan sulit dibedakan. Hasil evaluasi ini secara meyakinkan mengonfirmasi bahwa k = 3 menghasilkan pemisahan karakteristik antar klaster yang paling baik karena memiliki nilai koefisien yang paling mendekati angka satu dibandingkan pengujian lainnya. Adapun hasil pengujian terakhir berupa grafik dari *davies-bouldin index* (DBI) disajikan pada Gambar 16.



Gambar 16. Grafik *Davies-Bouldin Index* (DBI)

Grafik *davies-bouldin index* (DBI) menunjukkan rasio kekompakan dan pemisahan klaster untuk setiap nilai k, di mana semakin rendah nilainya maka semakin baik kualitas klasterisasi. Nilai DBI terendah dicapai pada k = 3 sebesar 1,5231, turun signifikan dari k = 2 sebesar 1,8979, kemudian meningkat kembali pada k = 4 dan seterusnya. Hasil ini memperkuat bahwa k = 3 merupakan jumlah klaster optimal dengan tingkat kekompakan dan pemisahan klaster terbaik.

Setelah diperoleh jumlah klaster yang optimal, langkah selanjutnya adalah membangun model klasterisasi menggunakan algoritma K-Means. Proses pembentukan klaster dilakukan dengan mengimplementasikan algoritma K-Means pada *dataset* yang telah melalui tahap *preprocessing* dan transformasi. Adapun kode program untuk melakukan proses klasterisasi menggunakan algoritma K-Means ditunjukkan pada *Listing Program 6.*

```
kmeans_final = KMeans(n_clusters=optimal_k, init='random',
                      random_state=42, n_init=10, max_iter=300)
df_cleaned_final['Cluster'] = kmeans_final.fit_predict(df_final)
```

Listing Program 6. Klasterisasi Menggunakan Algoritma K-Means

Listing Program 6 menunjukkan proses penerapan algoritma K-Means dengan jumlah klaster optimal yang telah ditentukan sebelumnya. Pada tahap ini, model K-Means diinisialisasi dengan jumlah klaster sebesar k = 3, dengan *centroid* awal dipilih secara acak dan proses inisialisasi dilakukan sebanyak 10 kali untuk memperoleh hasil klasterisasi terbaik. Selanjutnya, model dilatih menggunakan *dataset* hasil transformasi, kemudian setiap data diprediksi ke dalam klaster tertentu menggunakan fungsi *fit_predict()*. Hasil pengelompokan tersebut selanjutnya disimpan pada kolom *cluster* pada *dataset*. Adapun tahapan kerja dalam algoritma K-Means adalah sebagai berikut:

1) Menentukan Jumlah Klaster yang Diinginkan sebagai Nilai *k*

   Pada tahap pertama ditentukan jumlah klaster yang akan dibentuk. Penentuan jumlah klaster optimal dilakukan dengan menguji beberapa nilai k, yaitu dari k = 2 hingga k = 10. Nilai k dimulai dari 2 karena proses klasterisasi minimal harus membentuk lebih dari satu klaster agar perbandingan antar klaster dapat dilakukan. Rentang pengujian hingga k = 10 digunakan untuk melihat perubahan kualitas klaster pada beberapa jumlah klaster yang berbeda, sekaligus menjaga agar hasil klasterisasi tetap mudah dianalisis dan diinterpretasikan.

   Pada penelitian ini, evaluasi jumlah klaster dilakukan menggunakan tiga metode, yaitu *elbow method*, *silhouette score*, dan *davies–bouldin index* (DBI). Berdasarkan hasil pengujian menggunakan ketiga metode tersebut, diperoleh jumlah klaster yang paling optimal yaitu k = 3, sehingga proses klasterisasi pada penelitian ini menggunakan tiga klaster.

2) Menentukan Pusat Klaster Awal secara Acak Sesuai dengan Jumlah *k*

Pada tahap ini, algoritma K-Means menentukan tiga titik data secara acak sebagai pusat klaster awal (*centroid*). Ketiga *centroid* awal tersebut kemudian digunakan sebagai acuan dalam menghitung jarak setiap data pada iterasi pertama. Proses ini menggunakan *random_state* = 42 untuk memastikan hasil yang dapat direproduksi.

3) Menghitung Jarak antara Setiap Data dengan *Centroid* Menggunakan *Euclidean Distance*

Setelah *centroid* awal ditentukan, langkah berikutnya adalah menghitung jarak setiap titik data ke setiap *centroid* menggunakan rumus *euclidean distance*. Perhitungan ini bertujuan untuk menentukan klaster bagi masing-masing titik data berdasarkan kedekatannya dengan *centroid* tertentu. Proses perhitungan dilakukan terhadap seluruh data 11.329 pasien dikalikan dengan 3 klaster sehingga terbentuk 33.987 jarak yang dihitung secara serentak. Adapun rumus untuk melakukan perhitungan *euclidean distance* disajikan pada Persamaan 2.

$$d(xi, \mu j) = \sqrt{\sum_{k=1}^{n} (x_{ik} - \mu_{jk})^2} \quad (2)$$

Keterangan:

$d(xi, \mu j)$= Jarak antara data ke-i dengan pusat klaster (*centroid*) ke-j

xi = Data ke-i atau vektor data ke-i yang akan dihitung jaraknya

μj = *Centroid* klaster ke-j, yaitu nilai rata-rata dari seluruh data

n = Jumlah atribut yang digunakan dalam proses klasterisasi

Berikut ditampilkan contoh perhitungan jarak Euclidean untuk 5 data pertama terhadap ketiga *centroid* (μ_0, μ_1, μ_2):

$$d(x_1, \mu_0) = \sqrt{\sum (x_{1k} - \mu_{0k}{}^2)} = 3{,}490321$$

$$d(x_1, \mu_1) = \sqrt{\sum (x_{1k} - \mu_{1k}{}^2)} = 4{,}151262$$

$$d(x_1, \mu_2) = \sqrt{\sum (x_{1k} - \mu_{2k}{}^2)} = 2{,}039565$$

. . .

$$d(x_5, \mu_0) = \sqrt{\sum (x_{5k} - \mu_{0k}{}^2)} = 2{,}982986$$

$$d(x_5, \mu_1) = \sqrt{\sum (x_{5k} - \mu_{1k}{}^2)} = 2{,}836138$$

$$d(x_5, \mu_2) = \sqrt{\sum (x_{5k} - \mu_{2k}{}^2)} = 0{,}860794$$

Berdasarkan hasil perhitungan jarak, setiap data dilakukan penugasan atau pelabelan ke *centroid* terdekat. Pelabelan data ke *centroid* terdekat ditunjukkan pada Tabel 3.

Tabel 3. Perhitungan Jarak Titik Data dengan *Centroid*

Data ke-i	d(xi, μ0)	d(xi, μ1)	d(xi, μ2)	Jarak Terkecil	Klaster
1	3,490321	4,151262	2,039565	d(xi,μ2) = 2,039565	K2
2	4,187403	2,097506	3,697765	d(xi,μ1) = 2,097506	K1
3	4,169859	2,047827	3,411309	d(xi,μ1) = 2,047827	K1
4	1,973511	2,200792	3,192480	d(xi,μ0) = 1,973511	K0
5	2,982986	2,836138	0,860794	d(xi,μ2) = 0,860794	K2

Berdasarkan hasil perhitungan jarak yang ditunjukkan pada Tabel 3, setiap data ditetapkan ke dalam klaster dengan nilai jarak *euclidean* terkecil terhadap

centroid, sehingga data ke-1 dan ke-5 masuk ke klaster 2, data ke-2 dan ke-3 masuk ke klaster 1, serta data ke-4 masuk ke klaster 0.

4) Mengelompokkan Setiap Data ke dalam klaster berdasarkan jarak terdekat terhadap *centroid*

Setelah jarak setiap data ke masing-masing *centroid* dihitung, setiap data kemudian ditetapkan masuk ke dalam klaster yang memiliki *centroid* terdekat. Berdasarkan proses pengelompokan ini, diperoleh distribusi anggota klaster sebagai berikut:

Klaster 0 : 1.756 anggota

Klaster 1 : 4.779 anggota

Klaster 2 : 4.794 anggota

5) Melakukan Pembaruan *Centroid*

Setelah semua data ditetapkan ke klaster masing-masing, nilai *centroid* diperbarui dengan menghitung rata-rata seluruh data yang tergabung dalam klaster tersebut. Adapun rumus untuk melakukan pembaruan *centroid* disajikan pada Persamaan 3.

$$\mu j(t+1) = \frac{1}{N_{sj}} \sum_{i \epsilon sj} x_j \quad (3)$$

Keterangan:

$\mu j(t+1)$= *Centroid* klaster ke-j pada iterasi ke-(t+1)

N_{sj} = Jumlah data yang berada dalam klaster ke-j

$\sum i \epsilon sj$ = Penjumlahan seluruh data yang menjadi anggota klaster ke-j

x_j = Nilai data yang termasuk ke dalam klaster ke-j

Pembaruan *centroid* untuk klaster 0 (N_{s0}= 1.756 anggota):

$$\mu_0(t+1) = \frac{1}{N_{s0}} \times \sum_{i \in s0} x_i[PC1] = \frac{1}{1.756} \times 331{,}800947 = 0{,}188953$$

$$\mu_0(t+1) = \frac{1}{N_{s0}} \times \sum_{i \in s0} x_i[PC2] = \frac{1}{1.756} \times -3.043{,}036897 = -1{,}732937$$

Pembaruan *centroid* untuk klaster 1 (N_{s1} = 4.779 anggota):

$$\mu_1(t+1) = \frac{1}{N_{s1}} \times \sum_{i \in s1} x_i[PC1] = \frac{1}{4.779} \times -6.078{,}169273 = -1{,}271850$$

$$\mu_1(t+1) = \frac{1}{N_{s1}} \times \sum_{i \in s1} x_i[PC2] = \frac{1}{4.779} \times 1.581{,}422585 = 0{,}330911$$

Pembaruan *centroid* untuk klaster 2 (N_{s2} = 4.794 anggota):

$$\mu_2(t+1) = \frac{1}{N_{s2}} \times \sum_{i \in s2} x_i[PC1] = \frac{1}{4.794} \times 5.746{,}368327 = 1{,}198658$$

$$\mu_2(t+1) = \frac{1}{N_{s2}} \times \sum_{i \in s2} x_i[PC1] = \frac{1}{4.794} \times 1.461{,}614312 = 0{,}304884$$

Berdasarkan hasil perhitungan yang telah dilakukan, diperoleh nilai *centroid* baru untuk masing-masing klaster. *Centroid* klaster 0 memiliki nilai $\mu_0(t+1)$ = (0,188953; −1,732937), klaster 1 memiliki nilai $\mu_1(t+1)$ = (−1,271850; 0,330911), dan klaster 2 memiliki nilai $\mu_2(t+1)$ = (1,198658; 0,304884). Nilai *centroid* baru ini selanjutnya digunakan sebagai acuan dalam proses iterasi berikutnya.

6) Mengulangi Langkah Ke-2 sampai Ke-5 hingga Tidak Terjadi Perubahan Keanggotaan Klaster

Langkah ke-2 hingga ke-5 diulangi secara iteratif sampai kondisi konvergensi tercapai, yaitu ketika tidak ada lagi perubahan keanggotaan data

pada setiap klaster antara satu iterasi dengan iterasi berikutnya. Pada setiap iterasi, seluruh data dihitung ulang jaraknya terhadap *centroid* yang telah diperbarui, kemudian dialokasikan kembali ke klaster dengan jarak *euclidean* terkecil. Apabila hasil alokasi pada iterasi ke-t sama persis dengan hasil alokasi pada iterasi ke-(t−1), maka dapat disimpulkan bahwa *centroid* tidak lagi mengalami pergeseran dan algoritma dinyatakan telah konvergen.

Kondisi konvergensi ini terjadi karena pembaruan *centroid* yang dilakukan pada setiap iterasi secara bertahap menggerakkan pusat klaster menuju posisi yang paling representatif terhadap anggotanya. Semakin banyak iterasi yang dilakukan, semakin stabil posisi *centroid* hingga pada akhirnya tidak ada data yang berpindah klaster. Setelah kondisi tersebut terpenuhi, nilai *centroid* pada iterasi terakhir ditetapkan sebagai pusat klaster final yang merepresentasikan hasil pengelompokan data secara keseluruhan, dan label klaster yang diperoleh pada iterasi terakhir tersebut digunakan sebagai *output* akhir dari proses klasterisasi K-Means.

Penyajian nilai desimal dalam perhitungan ini sengaja dipertahankan dengan presisi yang tinggi (hingga enam angka di belakang koma) dan tidak dibulatkan menjadi dua angka saja. Hal ini dilakukan untuk menjaga tingkat akurasi perhitungan pada setiap iterasi algoritma K-Means. Mengingat proses klasterisasi sangat bergantung pada perbandingan jarak *euclidean* yang seringkali memiliki selisih sangat tipis antar data, pembulatan yang terlalu dini dikhawatirkan dapat menimbulkan akumulasi kesalahan (*rounding error*). Dengan mempertahankan presisi tersebut, posisi pusat klaster (*centroid*) dapat

ditentukan secara lebih akurat dan pergeseran keanggotaan data sekecil apa pun dapat terdeteksi guna memastikan algoritma mencapai titik konvergensi yang benar-benar stabil.

4.4. Evaluasi

Tahap evaluasi dilakukan untuk mengukur kualitas hasil klasterisasi yang dihasilkan oleh algoritma K-Means. Evaluasi ini diperlukan karena proses K-Means mengharuskan penentuan jumlah klaster (k) sebelum proses pengelompokan dilakukan. Oleh karena itu, digunakan beberapa metode evaluasi untuk membantu menentukan jumlah klaster yang paling sesuai. Pada penelitian ini, metode yang digunakan meliputi *elbow method*, *silhouette score*, dan *davies–bouldin index* (DBI) sehingga hasil klasterisasi dapat dinilai secara lebih objektif berdasarkan beberapa indikator kualitas klaster. Adapun penjelasan dari masing-masing metode evaluasi yang digunakan dalam penelitian ini adalah sebagai berikut:

1) *Elbow Method*

Metode *Elbow* digunakan untuk menentukan nilai k optimal dalam proses klasterisasi dengan cara menghitung nilai total WCSS (*Within Cluster Sum of Squares*) yang juga dikenal sebagai SSE (*Sum of Square Error*) pada berbagai nilai k. Nilai SSE diperoleh dengan menjumlahkan kuadrat jarak setiap titik data terhadap rata-rata klasternya masing-masing sesuai Persamaan 4. Semakin kecil nilai SSE, semakin kompak data dalam setiap klaster. Nilai k optimal ditentukan pada titik di mana penurunan SSE mulai melambat secara signifikan, yang divisualisasikan sebagai bentuk siku (*elbow*) pada grafik.

Untuk menghitung nilai SSE, digunakan dua komponen utama, yaitu xi dan μ̄k. Komponen xi menyatakan nilai data pada fitur ke-i, sedangkan μ̄k menyatakan nilai rata-rata k klaster pada nilai k tertentu. Penjumlahan dilakukan terhadap seluruh data yang tergabung dalam masing-masing klaster (xi ∈ Ck), kemudian diakumulasikan untuk seluruh k klaster yang terbentuk.

$$SSE = \sum_{k=1}^{k} \sum_{x_i \in Ck} (x_i - \varphi_k)^2 \quad (4)$$

Keterangan:

$C_k C_k$ = K klaster yang terbentuk

$k\ k$ = Banyaknya klaster

$x_i x_i$ = Data x pada fitur ke-i

$\varphi_k \varphi_k$ = Rata-Rata K klaster pada nilai k (k=1,2,3,...,K)

Berikut adalah contoh penerapan perhitungan SSE menggunakan Persamaan 4 untuk masing-masing klaster pada k = 3:

$SSE_0 = \sum_{xi \epsilon C0}(X_i - \mu_0)^2 = 3.913{,}314986$ (1.756 anggota)

$SSE_1 = \sum_{xi \epsilon C1}(X_i - \mu_1)^2 = 19.399{,}898540$ (4.779 anggota)

$SSE_2 = \sum_{xi \epsilon C2}(X_i - \mu_2)^2 = 25.834{,}885679$ (4.794 anggota)

SSE Total = 3.913,314986 + 19.399,898540 + 25.834,885679 = 49.148,099205

Berdasarkan hasil perhitungan menggunakan Persamaan 4, diperoleh nilai SSE untuk masing-masing klaster, yaitu SSE_0 = 3.913,314986, SSE_1 = 19.399,898540, dan SSE_2 = 25.834,885679, sehingga diperoleh total SSE

sebesar 49.148,099205. Nilai total SSE ini selanjutnya digunakan sebagai salah satu referensi dalam penentuan nilai k optimal melalui visualisasi metode *elbow*.

Sementara itu, perbandingan nilai hasil *elbow* untuk berbagai jumlah klaster dapat dilihat pada Gambar 17.

```
K = 2: WCSS = 58557.71
K = 3: WCSS = 49148.10
K = 4: WCSS = 43584.74
K = 5: WCSS = 39656.71
K = 6: WCSS = 36592.35
K = 7: WCSS = 34693.20
K = 8: WCSS = 33117.55
K = 9: WCSS = 31877.13
K = 10: WCSS = 31037.68

=========================================
ANALISIS PENURUNAN WCSS
=========================================
  K → K+1 |  Penurunan WCSS |  % Penurunan
-----------------------------------------
   2 →  3 |         9409.61 |      16.07 %
   3 →  4 |         5563.36 |      11.32 %
   4 →  5 |         3928.03 |       9.01 %
   5 →  6 |         3064.36 |       7.73 %
   6 →  7 |         1899.15 |       5.19 %
   7 →  8 |         1575.66 |       4.54 %
   8 →  9 |         1240.42 |       3.75 %
   9 → 10 |          839.44 |       2.63 %
```

Gambar 17. Perbandingan Nilai *Elbow Method*

Berdasarkan hasil analisis metode *elbow*, terlihat bahwa penurunan nilai WCSS terbesar terjadi dari k = 2 ke k = 3, yaitu sebesar 9.409,61 atau sekitar 16,07%. Setelah k = 3, penurunan WCSS mulai melambat secara signifikan, dari 11,32% menjadi 9,01% dan terus menurun hingga hanya 2,63% pada k = 10. Pola penurunan ini membentuk titik siku (*elbow*) pada k = 3, sehingga jumlah klaster optimal yang ditetapkan adalah tiga klaster.

Hasil klasterisasi menggunakan algoritma K-Means dengan jumlah klaster optimal sebanyak tiga klaster menghasilkan tiga kelompok data dengan

distribusi anggota yang berbeda, yaitu klaster 0 sebanyak 1.756 data, klaster 1 sebanyak 4.779 data, dan klaster 2 sebanyak 4.794 data. Perbedaan distribusi ini menunjukkan bahwa sebagian besar data terkonsentrasi pada klaster 1 dan klaster 2, sementara klaster 0 memiliki jumlah anggota yang lebih sedikit dan mencerminkan kelompok dengan karakteristik yang lebih spesifik.

2) *Silhouette Score*

Silhouette score adalah metrik yang digunakan untuk mengevaluasi kualitas klasterisasi dengan mengukur seberapa mirip suatu objek dengan klasternya sendiri dibandingkan dengan klaster lainnya. Nilai *silhouette score* berkisar antara -1 dan 1, dengan nilai yang lebih tinggi menunjukkan kualitas klaster yang lebih baik.

Untuk menghitung nilai *silhouette score*, digunakan dua komponen utama, yaitu a(i) dan b(i). Komponen a(i) menyatakan rata-rata jarak antara suatu data dengan seluruh data lain dalam klaster yang sama. Komponen b(i) menyatakan rata-rata jarak antara suatu data dengan seluruh data dalam klaster lain yang paling dekat. Perhitungan nilai a(i) dan b(i) dilakukan terhadap seluruh 11.329 data hasil klasterisasi, dengan menghitung rata-rata jarak setiap titik data terhadap seluruh titik data lain dalam klasternya maupun dalam klaster terdekat.

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (5)$$

Keterangan:

$a(i)$ = Selisih jarak rata-rata data terhadap seluruh titik dalam klaster yang sama

$b(i)$ = Jarak rata-rata terdekat data terhadap cluster lain yang paling dekat

Berikut ditampilkan contoh perhitungan s(i) untuk 5 data pertama menggunakan Persamaan 5.

$$s(1) = \frac{b(1) - a(1)}{max\{a(1),b(1)\}} = \frac{4{,}130223 - 2{,}443259}{4{,}130223} = 0{,}408444 \text{ (Klaster K2)}$$

$$s(2) = \frac{b(2) - a(2)}{max\{a(2),b(2)\}} = \frac{3{,}940712 - 2{,}820021}{3{,}940712} = 0{,}284388 \text{ (Klaster K1)}$$

$$s(3) = \frac{b(3) - a(3)}{max\{a(3),b(3)\}} = \frac{3{,}666143 - 2{,}792247}{3{,}666143} = 0{,}238369 \text{ (Klaster K1)}$$

$$s(4) = \frac{b(4) - a(4)}{max\{a(4),b(4)\}} = \frac{2{,}910935 - 2{,}859055}{2{,}910935} = 0{,}017822 \text{ (Klaster K0)}$$

$$s(5) = \frac{b(5) - a(5)}{max\{a(5),b(5)\}} = \frac{3{,}441672 - 1{,}559709}{3{,}441672} = 0{,}546816 \text{ (Klaster K2)}$$

Hasil perhitungan nilai a(i), b(i), dan s(i) untuk 5 data pertama secara lengkap ditunjukkan pada Tabel 4.

Tabel 4. Nilai a(i), b(i), dan s(i) untuk 5 Data Pertama

Data ke-i	Klaster	a(i)	b(i)	max{a,b}	b−a	s(i)
1	K2	2,443259	4,130223	4,130223	1,686964	0,408444
2	K1	2,820021	3,940712	3,940712	1,120691	0,284388
3	K1	2,792247	3,666143	3,666143	0,873896	0,238369
4	K0	2,859055	2,910935	2,910935	0,051880	0,017822
5	K2	1,559709	3,441672	3,441672	1,881963	0,546816

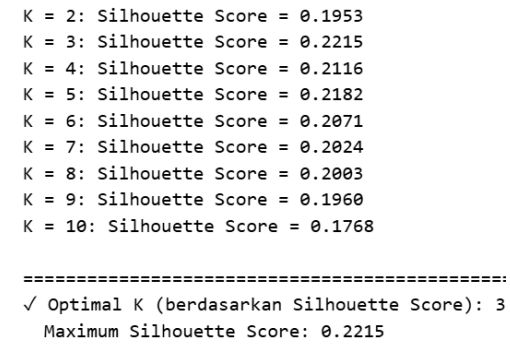
Nilai *silhouette score* per klaster dan rata-rata keseluruhan ditunjukkan pada Tabel 5.

Tabel 5. Nilai *Silhouette Score* per Klaster

Klaster	Jumlah	s (rata-rata)	s(i) minimum	s(i) maksimum
Klaster 0	1.756	0,454489	0,040060	0,589209
Klaster 1	4.779	0,214558	−0,133525	0,416662
Klaster 2	4.794	0,143027	−0,166090	0,357067
Rata-rata Keseluruhan	**0,221478**			

Berdasarkan hasil perhitungan di atas, nilai *silhouette score* rata-rata yang diperoleh adalah 0,221478. Nilai tersebut mengindikasikan bahwa klasterisasi yang dihasilkan memiliki struktur yang cukup terpisah antar klaster, meskipun masih terdapat tumpang tindih pada sebagian data. Nilai *silhouette score* ini selanjutnya digunakan sebagai salah satu dasar evaluasi kualitas klasterisasi pada k = 3.

Sementara itu, perbandingan nilai hasil *silhouette score* untuk berbagai jumlah klaster dapat dilihat pada Gambar 18.



Gambar 18. Perbandingan Nilai *Silhouette Score*

Berdasarkan hasil perhitungan *silhouette score* untuk setiap nilai k dari 2 hingga 10, diperoleh nilai tertinggi pada k = 3 dengan *silhouette score* sebesar 0,2215. Nilai ini lebih tinggi dibandingkan nilai k lainnya, di mana k = 4 menghasilkan nilai 0,2116, k = 5 sebesar 0,2182, dan terus menurun hingga k = 10 yang hanya menghasilkan nilai 0,1768. Hal ini menunjukkan bahwa pada k = 3, data dalam setiap klaster memiliki kemiripan yang lebih baik dibandingkan dengan klaster lainnya.

Hasil evaluasi menggunakan *silhouette score* ini sejalan dengan hasil analisis metode *elbow*, di mana keduanya menunjukkan bahwa k = 3 merupakan jumlah klaster yang paling optimal. Dengan demikian, penetapan k = 3 sebagai

jumlah klaster dalam proses klasterisasi menggunakan algoritma K-Means telah didukung oleh dua metode evaluasi yang berbeda, sehingga hasil klasterisasi yang diperoleh dapat dinyatakan lebih valid dan dapat dipertanggungjawabkan secara ilmiah.

3) *Davies-Bouldin Index* (DBI)

Davies-Bouldin Index (DBI) adalah metrik evaluasi klasterisasi yang mengukur rata-rata kemiripan antara setiap klaster dengan klaster yang paling mirip dengannya. Nilai DBI yang lebih rendah menunjukkan kualitas klasterisasi yang lebih baik karena mengindikasikan klaster yang lebih kompak dan terpisah dengan baik.

$$DBI = \frac{1}{k}\sum_{i=1}^{k}\max_{j \neq i}\left(\frac{S_i + S_j}{d(c_i, c_j)}\right) \quad (6)$$

Keterangan:

k = Jumlah klaster yang terbentuk

i, j = Menunjukkan indeks klaster, dengan syarat j ≠ i

S_i = Ketidakkompakan klaster ke-i (rata-rata jarak titik ke pusat klaster)

S_j = Ketidakkompakan klaster ke-j

$d(c_i, c_j)$= Jarak *euclidean* antara pusat klaster i dan j

$\max_{j \neq i}$ = Untuk tiap klaster i, dipilih pasangan klaster j yang paling mirip

Proses perhitungan nilai *davies-bouldin index* (DBI) dilakukan berdasarkan rumusan matematis yang merujuk pada Persamaan 6. Secara sistematis, tahapan untuk mendapatkan nilai tersebut diselesaikan melalui tiga langkah utama sebagai berikut:

a) Menghitung Ketidakkompakan Klaster (S_i)

Nilai S_i merupakan rata-rata jarak seluruh titik data dalam suatu klaster terhadap *centroid* klaster tersebut. Semakin kecil nilai S_i, semakin kompak klaster tersebut.

$$S_0 = \left(\frac{1}{1.756}\right) \times \sum d(x_i, c_0) = 2{,}176803$$

$$S_1 = \left(\frac{1}{4.779}\right) \times \sum d(x_i, c_1) = 1{,}977072$$

$$S_2 = \left(\frac{1}{4.794}\right) \times \sum d(x_i, c_2) = 1{,}360536$$

b) Menghitung Jarak *Euclidean* Antar-*centroid* ($d(c_i, c_1)$)

Jarak antar-*centroid* dihitung menggunakan rumus *euclidean distance* yang sama dengan Persamaan 2, namun diterapkan pada pasangan *centroid*.

$$d(c_0, c_1) = 2{,}533579$$

$$d(c_0, c_2) = 2{,}741538$$

$$d(c_0, c_3) = 2{,}755276$$

c) Menghitung Rasio dan Nilai Maksimum per Klaster

Untuk setiap klaster i, dihitung rasio ($\frac{(S_i+S_j)}{d(c_i,c_j)}$) terhadap semua klaster j ≠ i, kemudian dipilih nilai maksimumnya.

Klaster 0 vs Klaster 1: $\frac{(S_0+S_1)}{d(c_0,c_1)} = \frac{(2{,}1768 + 1{,}9771)}{2{,}5336} = 1{,}639528$

Klaster 0 vs Klaster 2: $\frac{(S_0+S_2)}{d(c_0,c_2)} = \frac{(2{,}1768 + 1{,}3605)}{2{,}7415} = 1{,}290275$

Klaster 0: $max = max(1{,}639528;\ 1{,}290275) = 1{,}639528$

Klaster 1 vs Klaster 0: $\frac{(S_1+S_0)}{d(c_1,c_0)} = \frac{(1{,}9771 + 2{,}1768)}{2{,}5336} = 1{,}639528$

Klaster 1 vs Klaster 2: $\frac{(S_1+S_2)}{d(c_1,c_2)} = \frac{(1{,}9771 + 1{,}3605)}{2{,}7553} = 1{,}211352$

Klaster 1: $max = max(1{,}639528;\ 1{,}211352) = 1{,}639528$

Klaster 2 vs Klaster 0: $\frac{(S_2+S_0)}{d(c_2,c_0)} = \frac{(1{,}3605 + 2{,}1768)}{2{,}7415} = 1{,}290275$

Klaster 2 vs Klaster 1: $\frac{(S_2+S_1)}{d(c_2,c_1)} = \frac{(1{,}3605 + 1{,}9771)}{2{,}7553} = 1{,}211352$

Klaster 2: $max = max(1{,}290275;\ 1{,}211352) = 1{,}290275$

Nilai DBI dihitung sebagai rata-rata dari seluruh nilai maksimum rasio yang diperoleh:

$$DBI = \frac{1}{3} \times (1{,}639528 + 1{,}639528 + 1{,}290275) = \frac{1}{3} \times 4{,}569331$$

$$= 1{,}523110$$

Berdasarkan hasil perhitungan menggunakan rumus DBI, diperoleh nilai 1,523110. Nilai DBI yang diperoleh mendekati 1, yang mengindikasikan bahwa klaster-klaster yang terbentuk memiliki tingkat separasi yang cukup baik. Semakin kecil nilai DBI, semakin baik kualitas pemisahan antar klaster yang dihasilkan oleh algoritma K-Means.

Sementara itu, perbandingan nilai hasil *davies-bouldin index* (DBI) untuk berbagai jumlah klaster dapat dilihat pada Gambar 19.

```
K = 2: DBI = 1.8980
K = 3: DBI = 1.5231
K = 4: DBI = 1.6188
K = 5: DBI = 1.5991
K = 6: DBI = 1.5424
K = 7: DBI = 1.6274
K = 8: DBI = 1.6328
K = 9: DBI = 1.6794
K = 10: DBI = 1.6890

================================
✓ Optimal K (berdasarkan DBI): 3
  Minimum DBI Score: 1.5231
```

Gambar 19. Perbandingan Nilai *Davies-Bouldin Index* (DBI)

Berdasarkan hasil perhitungan DBI untuk setiap nilai k dari 2 hingga 10, diperoleh nilai terkecil pada k = 3 dengan DBI sebesar 1,5231. Nilai ini lebih rendah dibandingkan nilai k lainnya, di mana k = 2 menghasilkan nilai 1,8980, k = 4 sebesar 1,6188, dan nilai DBI pada k selanjutnya cenderung berfluktuasi di atas 1,5231 hingga k = 10 yang menghasilkan nilai 1,6890. Semakin kecil nilai DBI, semakin baik kualitas pemisahan antar klaster yang terbentuk, sehingga k = 3 menunjukkan pemisahan klaster yang paling optimal dibandingkan nilai k lainnya.

Hasil evaluasi menggunakan DBI ini konsisten dengan hasil analisis metode *elbow* dan *silhouette score*, di mana ketiga metode evaluasi secara serentak menunjukkan bahwa k = 3 merupakan jumlah klaster yang paling optimal. Dengan terkonfirmasinya k = 3 sebagai nilai optimal berdasarkan DBI, maka ketiga metode evaluasi yang digunakan, yaitu metode *elbow*, *silhouette score*, dan *davies-bouldin index*, seluruhnya memberikan hasil yang konsisten. Konsistensi ini memperkuat keyakinan bahwa jumlah klaster sebanyak tiga merupakan pilihan yang tepat dalam proses klasterisasi data menggunakan algoritma K-Means pada penelitian ini.

Penyajian nilai pada metode *elbow*, *silhouette score*, dan *davies-bouldin index* (DBI) tetap menggunakan presisi tinggi (hingga enam angka di belakang koma) untuk menjamin keakuratan evaluasi. Hal ini sangat penting karena selisih nilai antar jumlah klaster (nilai k) seringkali sangat tipis. Dengan mempertahankan angka desimal yang detail, perbandingan kualitas antar klaster dapat dilakukan secara lebih objektif dan valid, sehingga penentuan k = 3 sebagai

jumlah klaster optimal didasarkan pada data yang presisi dan bebas dari bias akibat pembulatan.

Berdasarkan hasil evaluasi menggunakan tiga metode, yaitu *elbow method*, *silhouette score*, dan *davies-bouldin index* (DBI), ketiga metode secara konsisten menunjukkan bahwa jumlah klaster optimal adalah k = 3 dengan nilai *elbow* (WCSS) sebesar 49.148,10, *silhouette score* sebesar 0,2215, dan *davies-bouldin index* (DBI) sebesar 1,5231. Rekapitulasi nilai metrik evaluasi dan jumlah pasien pada masing-masing klaster ditunjukkan pada Tabel 6.

Tabel 6. Rekapitulasi Nilai Metrik Evaluasi dan Jumlah Pasien per Klaster

Komponen	Nilai
Metrik Evaluasi	
Elbow (WCSS)	49.148,10
Silhouette Score	0,2215
Davies-Bouldin Index (DBI)	1,5231
Jumlah Pasien per Klaster (Persentase)	
Klaster 0	1.756 (15,5%)
Klaster 1	4.779 (42,2%)
Klaster 2	4.794 (42,3%)
Total	**11.329 (100%)**

4.5. Pengembangan *Website*

Pengembangan *website* dalam penelitian ini dilakukan menggunakan metode *waterfall* sebagai pendekatan dalam proses pengembangan. Metode ini dipilih karena memiliki tahapan yang terstruktur dan sistematis sehingga memudahkan dalam proses perancangan hingga implementasi sistem. Dengan alur sekuensial, setiap fase mulai dari analisis hingga pengujian diselesaikan secara tuntas sebelum berlanjut ke tahap berikutnya, sehingga menjamin konsistensi fungsionalitas. Secara umum, proses pengembangan dilakukan melalui beberapa tahap, yaitu analisis kebutuhan, desain sistem, implementasi, pengujian dan pemeliharaan.

4.5.1. Analisis Kebutuhan

Pada tahap ini, analisis kebutuhan dilakukan untuk mengidentifikasi kebutuhan fungsional sistem klasterisasi profil pasien rawat inap berbasis *website* yang akan dikembangkan. Fokus utama dari tahap ini adalah menentukan fitur-fitur yang harus tersedia dalam aplikasi untuk mendukung pengguna, yaitu admin dan tenaga medis (dokter/perawat) di Rumah Sakit Islam Fatimah Cilacap, dalam mengelola data pelayanan secara efektif. Dengan adanya tahap ini, diharapkan sistem yang dikembangkan dapat berjalan sesuai dengan kebutuhan pengguna. Adapun analisis kebutuhan pengguna ditunjukkan pada Tabel 7.

Tabel 7. Analisis Kebutuhan Pengguna

Aktor	Kebutuhan	Nomor *Requirement*
Admin	***Login dan Logout***	
	Admin dapat mengakses aplikasi melalui proses *login* menggunakan email dan *password.*	UR.AKPPRI.A.01.001
	Admin dapat melakukan *logout* dari sistem.	UR.AKPPRI.A.01.002
	Dashboard	
	Admin dapat mengakses halaman *dashboard.*	UR.AKPPRI.A.02.001
	Sistem menampilkan menu panduan aplikasi, riwayat klasterisasi per tahun, dan laporan hasil klasterisasi terbaru pada halaman *dashboard.*	UR.AKPPRI.A.02.002
	Upload Dataset	
	Admin dapat mengakses halaman *upload dataset.*	UR.AKPPRI.A.03.001
	Admin dapat meng-*upload* data pasien rawat inap dan memilih tahun data (format CSV / Excel).	UR.AKPPRI.A.03.002
	Sistem memvalidasi format dan isi data yang di-*upload* dan menampilkan pesan kesalahan jika data tidak valid.	UR.AKPPRI.A.03.003

	Sistem menyimpan data ke *database* dan menampilkan hasil *upload dataset.*	UR.AKPPRI.A.03.004
	Daftar *Dataset*	
	Admin dapat mengakses menu daftar *dataset.*	UR.AKPPRI.A.04.001
	Admin dapat melakukan proses lihat, edit baris, hapus baris, tambah kolom, dan hapus kolom data pada menu daftar *dataset.*	UR.AKPPRI.A.04.002
	Admin dapat menghapus *dataset* yang telah di-*upload.*	UR.AKPPRI.A.04.003
	Proses Klasterisasi	
	Admin dapat mengakses halaman proses klasterisasi.	UR.AKPPRI.A.05.001
	Admin dapat memilih *dataset* dan jumlah klaster (k) untuk diproses.	UR.AKPPRI.A.05.002
	Admin dapat menjalankan proses klasterisasi K-Means.	UR.AKPPRI.A.05.003
	Sistem melakukan proses *preprocessing* data dan menghitung nilai *elbow*, *silhouette*, serta DBI untuk setiap klaster.	UR.AKPPRI.A.05.004
	Riwayat Klasterisasi	
	Admin dapat mengakses menu riwayat klasterisasi.	UR.AKPPRI.A.06.001
	Sistem menampilkan hasil klasterisasi pada menu riwayat klasterisasi dan menyimpan hasil klasterisasi ke *database.*	UR.AKPPRI.A.06.002
	Admin dapat melihat dan menghapus hasil klasterisasi pada menu riwayat klasterisasi.	UR.AKPPRI.A.06.003
	Laporan Hasil	
	Admin dapat mengakses halaman laporan hasil.	UR.AKPPRI.A.07.001
	Sistem menampilkan menu hasil klasterisasi dan admin dapat melakukan proses lihat detail dan hapus hasil klasterisasi.	UR.AKPPRI.A.07.002
	Admin dapat memilih dan melihat detail hasil klasterisasi pada menu interpretasi per klaster, metode evaluasi penentuan k optimal k=2-10, dan data pasien per klaster.	UR.AKPPRI.A.07.003

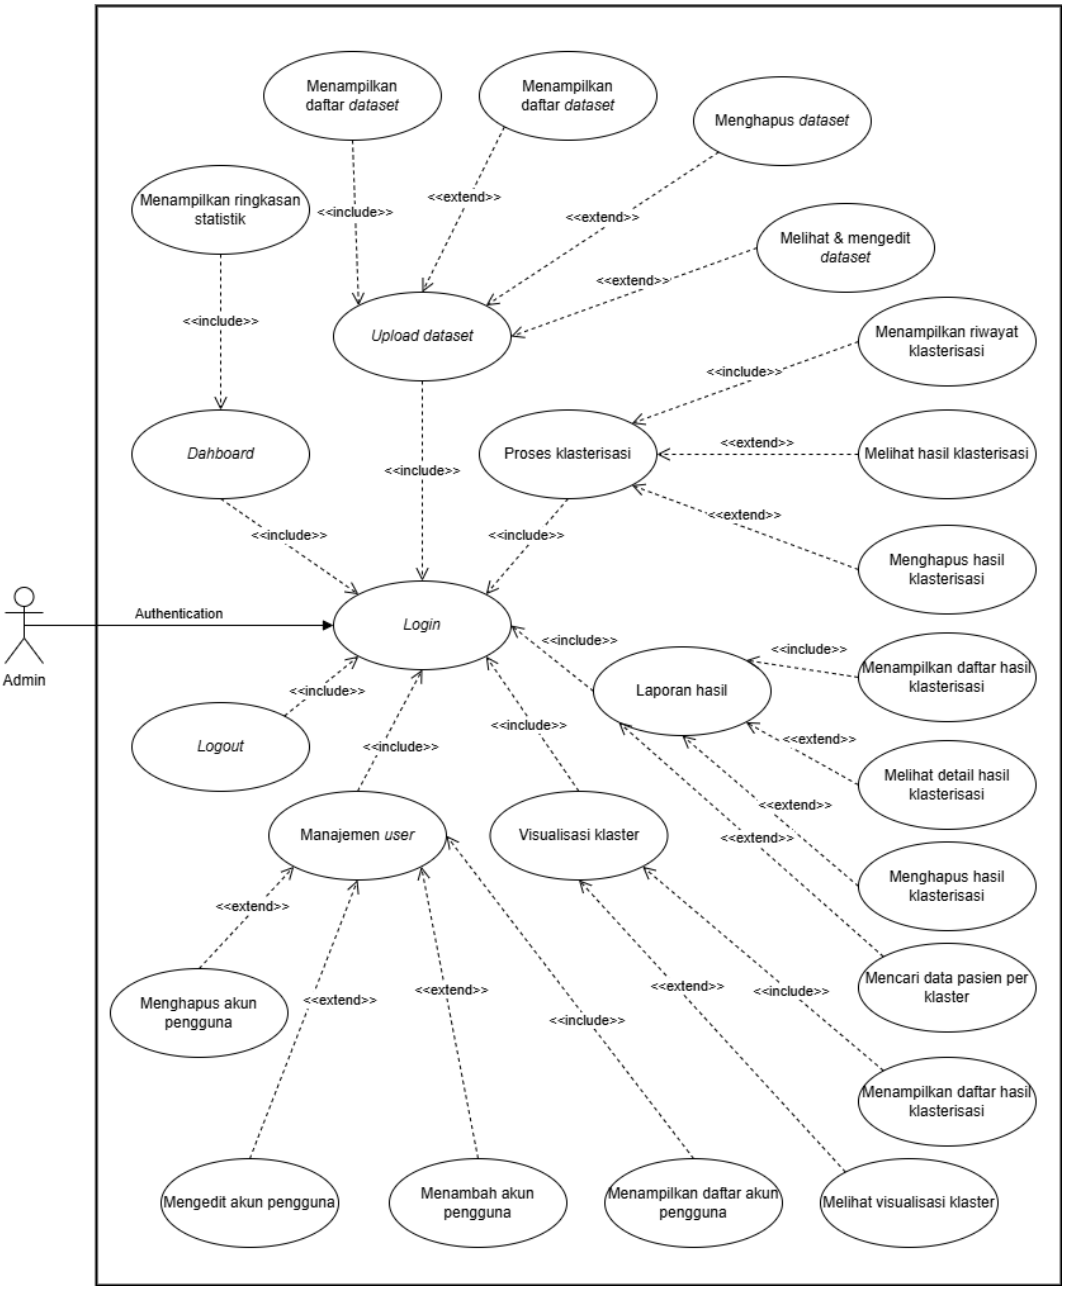
	Admin dapat mencari data pasien per klaster pada halaman detail hasil klasterisasi.	UR.AKPPRI.A.07.004
	Visualisasi Klaster	
	Admin dapat mengakses halaman visualisasi klaster.	UR.AKPPRI.A.08.001
	Sistem menampilkan menu visualisasi hasil klasterisasin dan admin dapat memilih dan melihat grafik visualisasi klaster.	UR.AKPPRI.A.08.002
	Manajemen *User*	
	Admin dapat mengakses halaman manajemen *user.*	UR.AKPPRI.A.09.001
	Sistem menampilkan menu daftar akun pengguna dan admin dapat melakukan proses tambah, edit, dan hapus akun pengguna.	UR.AKPPRI.A.09.002
	Admin dapat menambahkan akun pengguna baru.	UR.AKPPRI.A.09.003
	Admin dapat mengedit akun pengguna.	UR.AKPPRI.A.09.004
	Admin dapat menghapus akun pengguna.	UR.AKPPRI.A.09.005
Tenaga Medis	***Login dan Logout***	
	Tenaga medis dapat mengakses aplikasi melalui proses *login* menggunakan email dan *password.*	UR.AKPPRI.TM.01.001
	Tenaga medis dapat melakukan *logout* dari sistem.	UR.AKPPRI.TM.01.002
	Dashboard	
	Tenaga medis dapat mengakses halaman *dashboard.*	UR.AKPPRI.TM.02.001
	Sistem menampilkan menu buku panduan aplikasi, riwayat klasterisasi per tahun, dan laporan hasil klasterisasi terbaru pada halaman *dashboard.*	UR.AKPPRI.TM.02.002
	Laporan Hasil	
	Tenaga medis dapat mengakses halaman laporan hasil.	UR.AKPPRI.TM.03.001
	Sistem menampilkan menu hasil klasterisasi dan tenaga medis dapat melihat detail hasil klasterisasi.	UR.AKPPRI.TM.03.002
	Tenaga medis dapat memilih dan melihat detail hasil klasterisasi pada menu interpretasi per klaster, metode evaluasi	UR.AKPPRI.TM.03.003

	penentuan k optimal k=2-10, dan data pasien per klaster.	
	Tenaga medis dapat mencari data pasien per klaster pada halaman detail hasil klasterisasi.	UR.AKPPRI.TM.03.004
	Visualisasi Klaster	
	Tenaga medis dapat mengakses halaman visualisasi klaster.	UR.AKPPRI.TM.04.001
	Sistem menampilkan menu visualisasi hasil klasterisasi dan tenaga medis dapat memilih dan melihat grafik visualisasi klaster.	UR.AKPPRI.TM.04.002

4.5.2. Desain Sistem

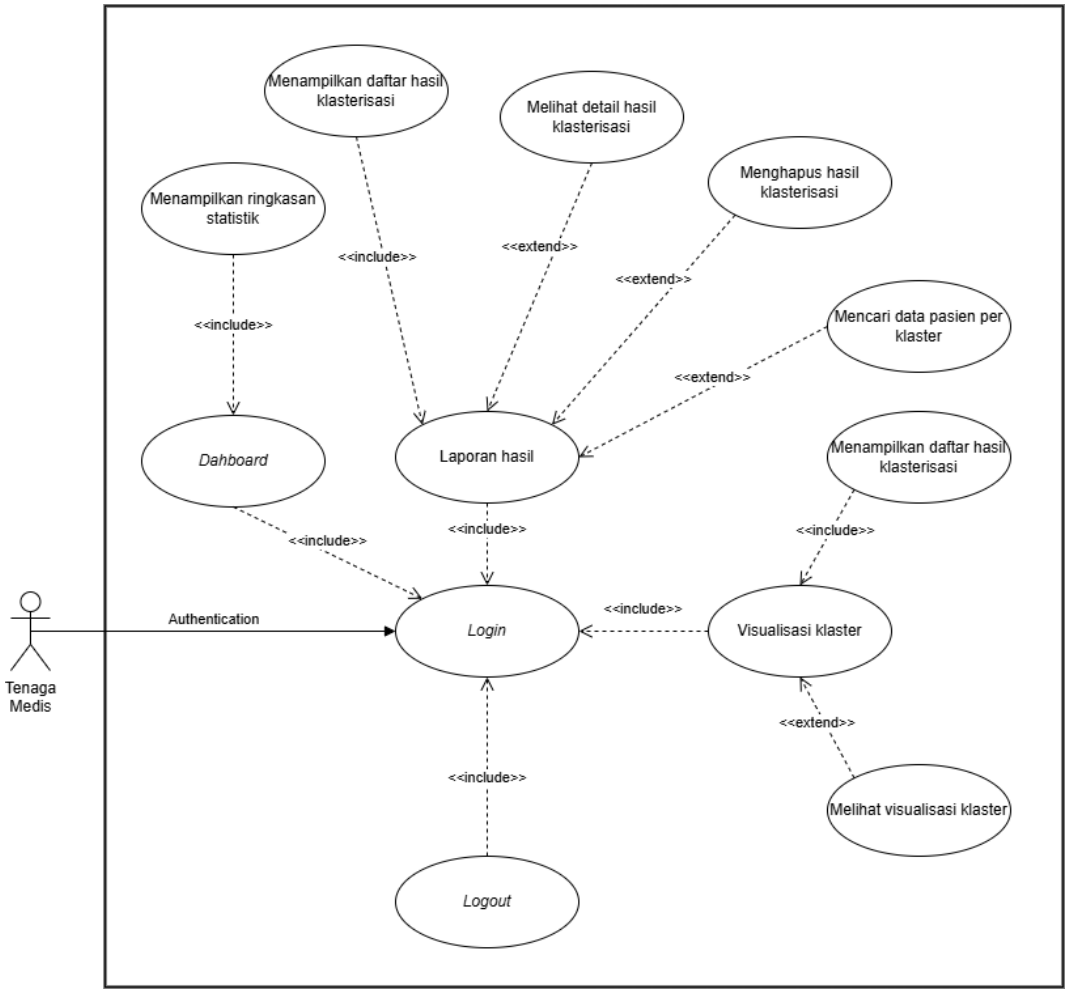
Tahapan desain sistem dilakukan dengan membuat *use case diagram* dan *activity diagram*. *Use case diagram* bertujuan untuk menggambarkan fungsionalitas sistem yang dapat digunakan oleh aktor yaitu admin dan tenaga medis (dokter/perawat) pada aplikasi klasterisasi profil pasien rawat inap, sedangkan *activity diagram* bertujuan untuk menggambarkan alur proses dan urutan aktivitas yang terjadi dalam setiap fungsionalitas sistem secara terstruktur.

Sebagai tindak lanjut dari perancangan diagram UML tersebut, pemetaan alur fungsionalitas ini kemudian dijadikan landasan utama dalam merancang konsep antarmuka pengguna (UI) dan pengalaman pengguna (UX) aplikasi. Rancangan UI/UX disusun secara sistematis untuk memastikan bahwa tata letak fitur dan visualisasi data hasil klasterisasi dapat diakses secara interaktif serta mudah dipahami oleh para aktor. Pendekatan desain antarmuka ini menjadi jembatan penting yang menghubungkan kompleksitas sistem klasterisasi di balik layar dengan kemudahan interaksi. Adapun *use case diagram* untuk admin disajikan pada Gambar 20.



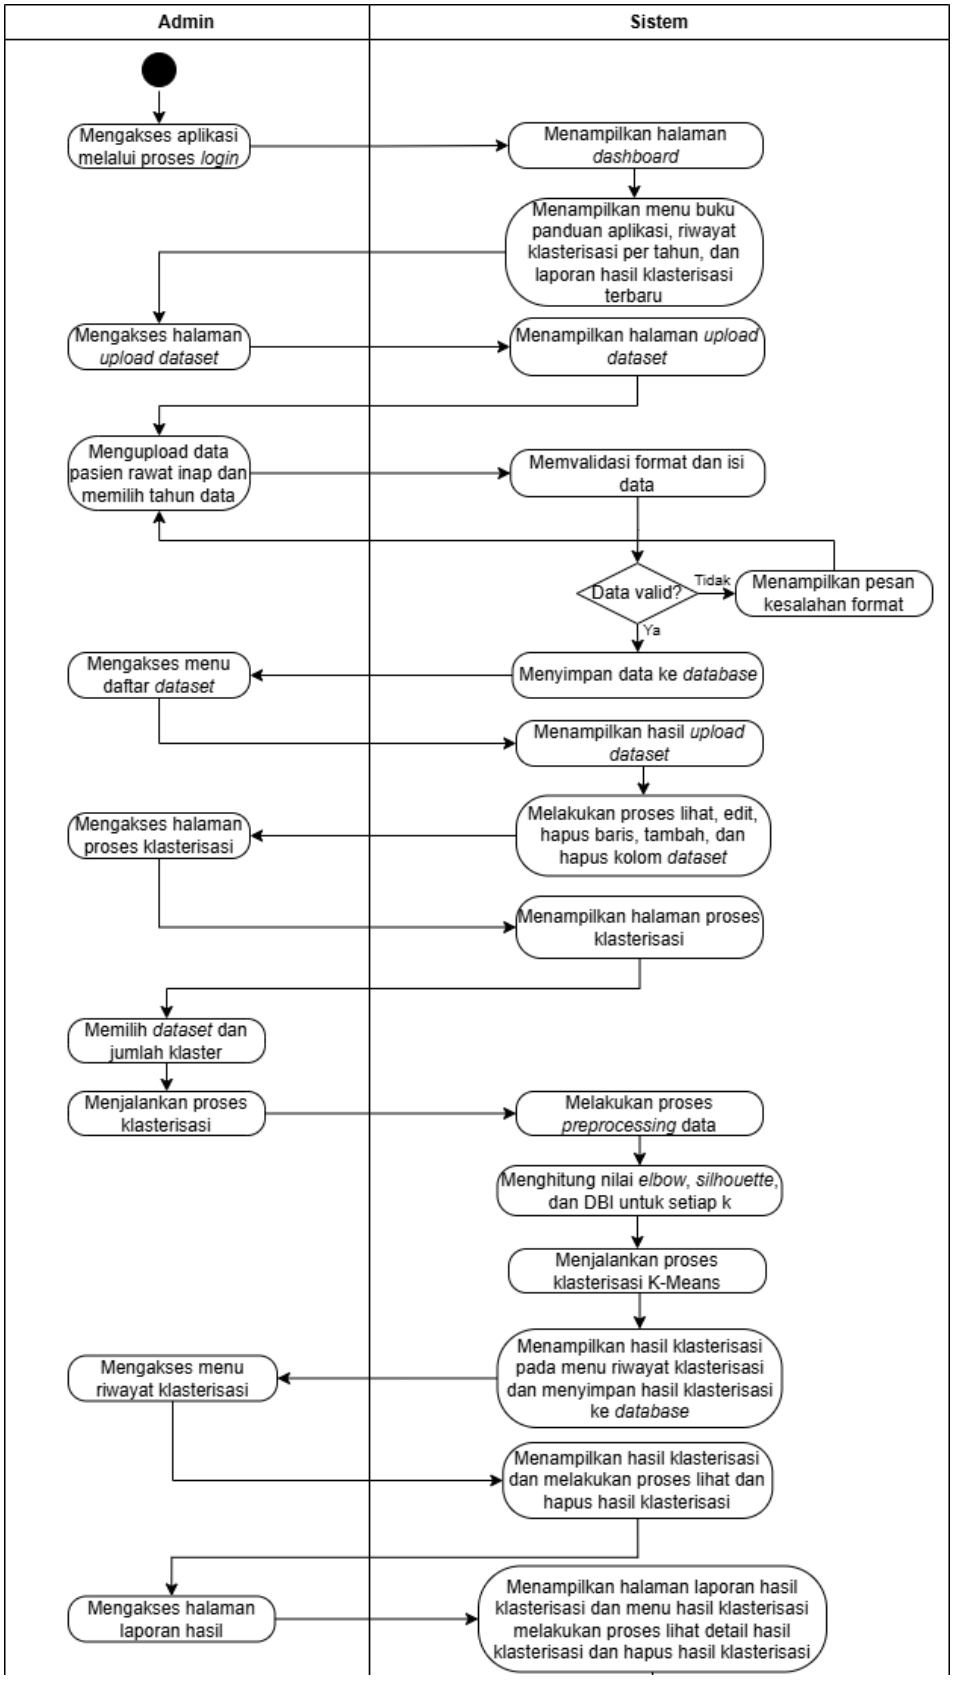
Gambar 20. *Use Case Diagram* Admin

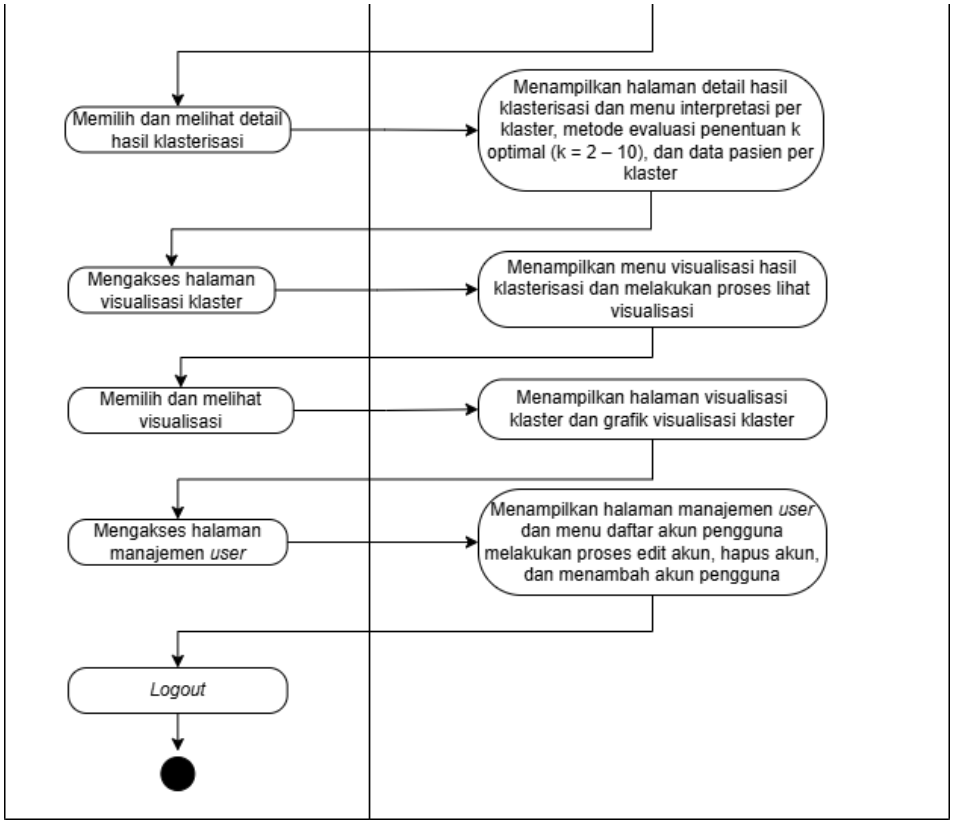
Selain untuk admin, sistem juga memfasilitasi interaksi bagi aktor tenaga medis (dokter/perawat). Fungsionalitas ini difokuskan pada pemanfaatan hasil analisis dan visualisasi data pasien guna mendukung pelayanan medis, yang rancangan *use case diagram*-nya disajikan secara rinci pada Gambar 21.



Gambar 21. *Use Case Diagram* Tenaga Medis

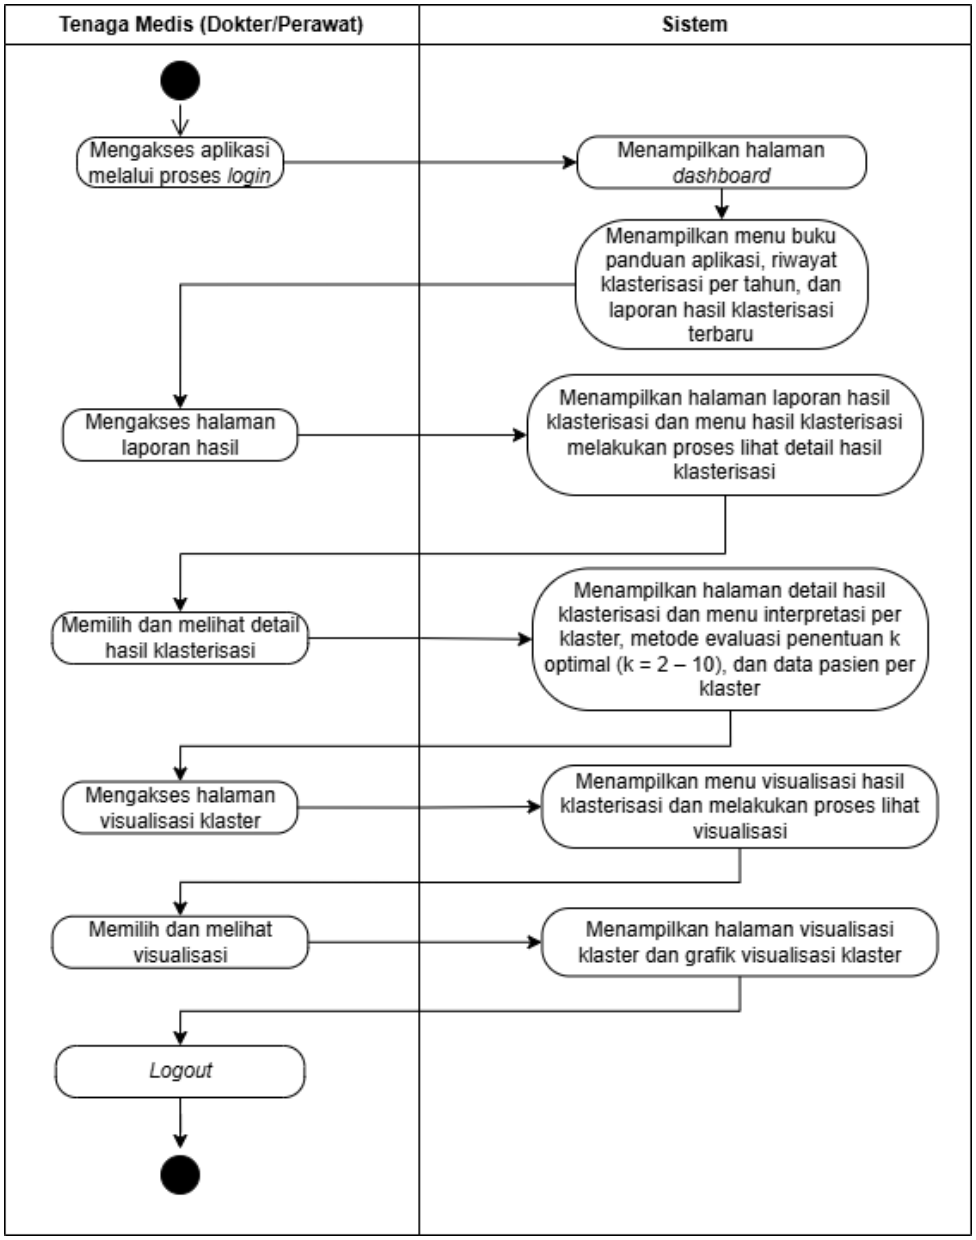
Sementara itu, guna memberikan gambaran yang lebih komprehensif mengenai alur kerja dan urutan aktivitas prosedural secara mendalam, disusunlah rancangan *activity diagram* khusus untuk aktor admin. Diagram ini memetakan secara kronologis setiap tahapan interaksi, mulai dari proses manajemen data pasien rawat inap, inisiasi parameter algoritma klasterisasi, hingga tahap akhir berupa pemrosesan laporan evaluasi dalam sistem. Seluruh rangkaian dinamika operasional yang dilakukan oleh admin tersebut disajikan secara sistematis pada Gambar 22.


Admin
Sistem
Mengakses aplikasi melalui proses *login*
Menampilkan halaman *dashboard*
Menampilkan menu buku panduan aplikasi, riwayat klasterisasi per tahun, dan laporan hasil klasterisasi terbaru
Mengakses halaman *upload dataset*
Menampilkan halaman *upload dataset*
Mengupload data pasien rawat inap dan memilih tahun data
Memvalidasi format dan isi data
Data valid?
Tidak
Menampilkan pesan kesalahan format
Ya
Mengakses menu daftar *dataset*
Menyimpan data ke *database*
Menampilkan hasil *upload dataset*
Mengakses halaman proses klasterisasi
Melakukan proses lihat, edit, hapus baris, tambah, dan hapus kolom *dataset*
Menampilkan halaman proses klasterisasi
Memilih *dataset* dan jumlah klaster
Menjalankan proses klasterisasi
Melakukan proses *preprocessing* data
Menghitung nilai *elbow*, *silhouette*, dan DBI untuk setiap k
Menjalankan proses klasterisasi K-Means
Mengakses menu riwayat klasterisasi
Menampilkan hasil klasterisasi pada menu riwayat klasterisasi dan menyimpan hasil klasterisasi ke *database*
Menampilkan hasil klasterisasi dan melakukan proses lihat dan hapus hasil klasterisasi
Mengakses halaman laporan hasil
Menampilkan halaman laporan hasil klasterisasi dan menu hasil klasterisasi melakukan proses lihat detail hasil klasterisasi dan hapus hasil klasterisasi



Gambar 22. *Activity Diagram* Admin

Sementara itu, guna memberikan pemahaman yang jelas mengenai prosedur interaksi aktor tenaga medis dalam memanfaatkan aplikasi, disusun pula rancangan *activity diagram* yang lebih spesifik. Diagram ini memetakan urutan aktivitas yang dilakukan oleh dokter maupun perawat, dimulai dari proses *login* hingga akses terhadap menu laporan hasil klasterisasi dan visualisasi hasil klasterisasi guna mendukung pengambilan keputusan klinis. Visualisasi alur ini sangat penting untuk memastikan bahwa navigasi sistem dalam menyajikan informasi klaster telah dirancang secara efisien guna menunjang produktivitas pelayanan medis. Seluruh rangkaian alur kerja yang menggambarkan bagaimana tenaga medis berinteraksi dengan fitur-fitur analisis tersebut disajikan secara komprehensif pada Gambar 23.



Gambar 23. *Activity Diagram* Tenaga Medis

4.5.3. Implementasi

Pada tahap implementasi, aplikasi klasterisasi profil pasien rawat inap berbasis *website* dibangun menggunakan *framework laravel*. Adapun hasil tampilan dari setiap halaman aplikasi sebagai representasi antarmuka pengguna akan diuraikan secara mendetail sebagai berikut:

1) Tampilan Admin

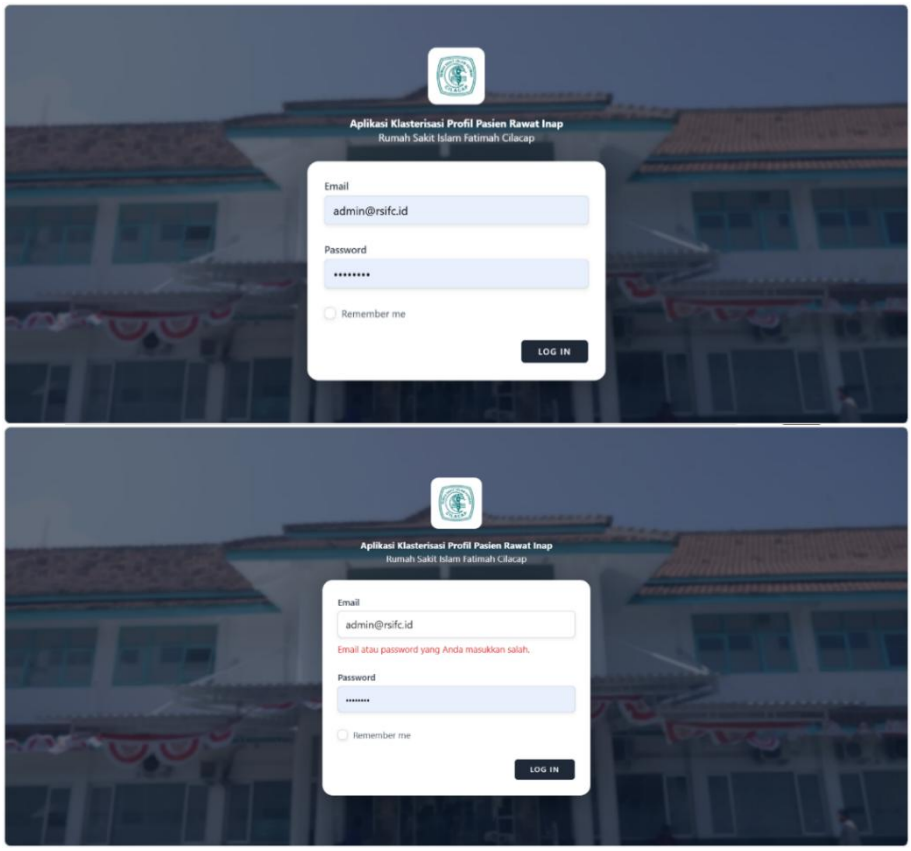
Tampilan admin merupakan representasi visual dari hak akses penuh dalam mengelola sistem klasterisasi profil pasien rawat inap. Rincian tampilan antarmuka dan fitur-fitur yang tersedia bagi admin dijelaskan secara mendetail di bawah ini.

a. Halaman *Login*

Halaman *login* merupakan antarmuka pertama yang ditampilkan saat pengguna mengakses aplikasi klasterisasi profil pasien rawat inap. Halaman ini berfungsi sebagai gerbang autentikasi untuk memastikan bahwa hanya pengguna dengan akun terdaftar yang dapat masuk ke dalam sistem guna menjaga keamanan data. Tampilan halaman dilengkapi dengan identitas visual berupa logo dan judul instansi Rumah Sakit Islam Fatimah Cilacap, serta latar belakang foto gedung rumah sakit yang dilapisi warna gelap transparan untuk menjamin keterbacaan elemen input di atasnya.

Formulir *login* ditempatkan secara terpusat pada kartu berwarna putih yang terdiri dari kolom input email, kata sandi, opsi *remember me*, dan tombol *login* untuk akses masuk. Sistem ini dilengkapi fitur validasi keamanan yang akan menampilkan pesan kesalahan berbunyi "Email atau *password* yang Anda masukkan salah" jika kredensial tidak sesuai. Seluruh pengelolaan akun dan pengaturan ulang kata sandi dilakukan secara terpusat oleh admin melalui menu manajemen *user*, di mana setelah autentikasi berhasil, akun admin akan diarahkan secara

otomatis menuju *dashboard* utama dengan hak akses manajerial penuh terhadap seluruh fitur dan pengolahan data aplikasi. Tampilan halaman *login* ditunjukkan pada Gambar 24.



Gambar 24. Halaman *Login* Admin

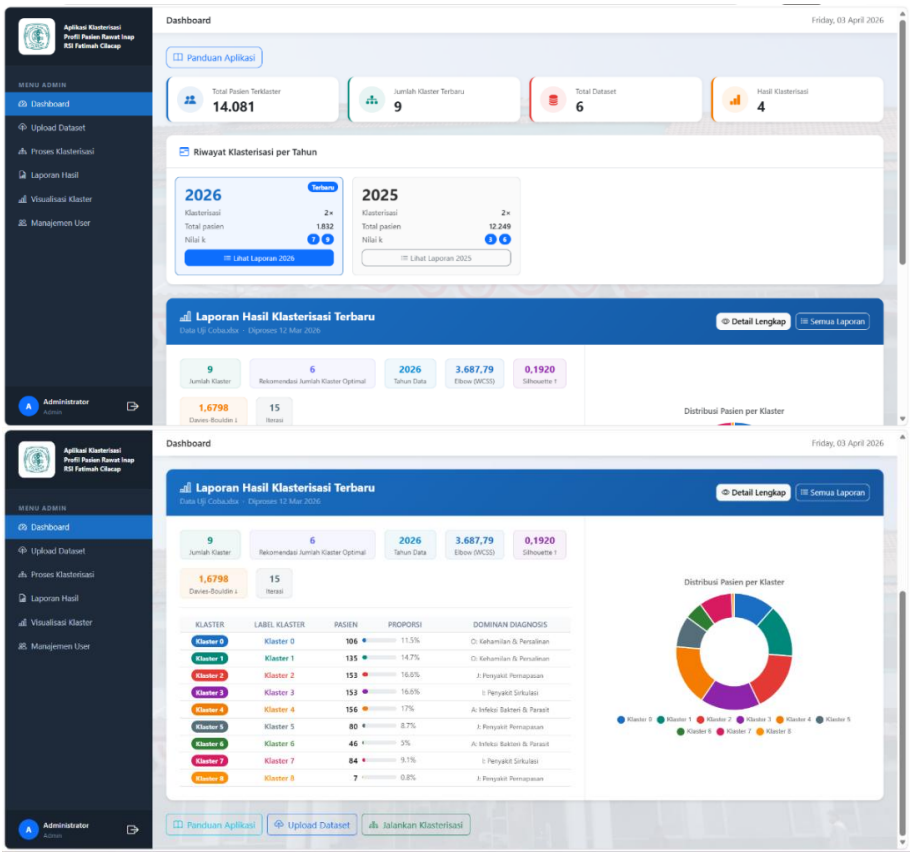
b. Halaman *Dashboard*

Halaman *dashboard* berfungsi sebagai pusat kendali utama yang menyajikan ringkasan data dan hasil klasterisasi secara komprehensif bagi pengguna dengan hak akses admin. Navigasi utama disediakan melalui *sidebar* di sisi kiri yang mencakup menu *dashboard*, *upload dataset*, proses klasterisasi, laporan hasil, visualisasi klaster, dan manajemen *user*, serta informasi sesi pengguna beserta tombol *logout*. Pada bagian atas halaman, tersedia tombol panduan aplikasi dalam

bentuk jendela modal dan empat kartu statistik utama yang menginformasikan total pasien terklaster, jumlah klaster terbaru, total *dataset*, serta akumulasi proses klasterisasi yang telah dilakukan di dalam sistem.

Dashboard ini juga memuat bagian riwayat klasterisasi per tahun yang menampilkan kartu ringkasan untuk setiap periode data, lengkap dengan label khusus untuk tahun terbaru dan akses cepat menuju laporan terkait. Pada bagian bawah, terdapat kartu laporan hasil klasterisasi terbaru yang memuat metadata *dataset* serta dilengkapi dua tombol aksi yaitu tombol detail lengkap untuk melihat rincian hasil klasterisasi dan tombol semua laporan untuk mengakses daftar seluruh laporan. Halaman ini juga menampilkan tujuh metrik evaluasi algoritma seperti *elbow* (WCSS), *silhouette score*, dan *davies-bouldin index* (DBI), serta visualisasi tabel proporsi pasien dan grafik donat untuk distribusi klaster. Di bagian akhir, tersedia kartu aksi cepat sebagai pintasan efisien bagi admin untuk mengunggah *dataset*, menjalankan proses klasterisasi, melihat seluruh laporan, maupun mengakses panduan aplikasi secara langsung. Keberadaan komponen-komponen tersebut dirancang sedemikian rupa untuk memberikan visibilitas data yang maksimal, sehingga admin dapat memahami pola pengelompokan pasien rawat inap tanpa harus membuka setiap menu secara terpisah. Integrasi seluruh informasi ini menjadikan *dashboard*

sebagai pusat kendali yang efektif. Tampilan halaman *dashboard* admin ditunjukkan pada Gambar 25.



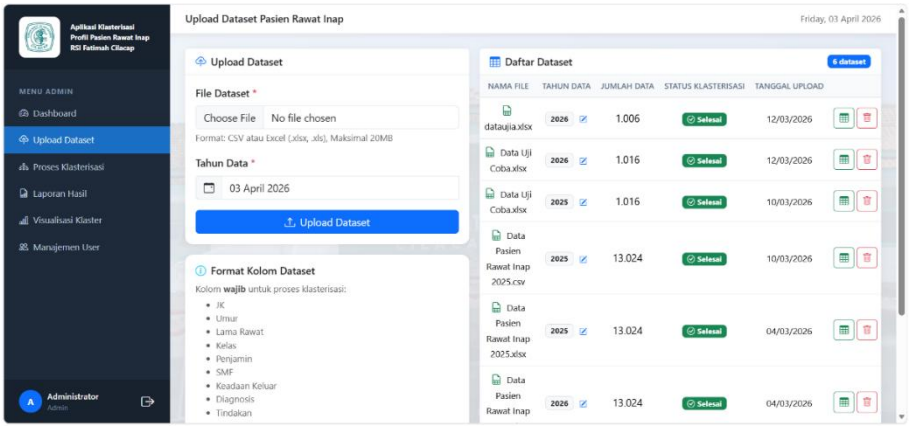
Gambar 25. Halaman *Dashboard* Admin

c. Halaman *Upload Dataset*

Halaman *upload dataset* berfungsi sebagai antarmuka bagi admin untuk mengunggah *file* data pasien rawat inap dalam format CSV atau Excel dengan batas ukuran maksimum 20MB. Antarmuka halaman ini terbagi menjadi dua bagian utama, yaitu formulir pengunggahan di sisi kiri dan tabel daftar dataset di sisi kanan. Formulir pengunggahan dilengkapi dengan fitur deteksi otomatis tahun data berdasarkan nama *file* atau melalui komponen *date picker*, serta menyediakan panduan format kolom *dataset* yang bersifat *case-insensitive*. Ketentuan struktur

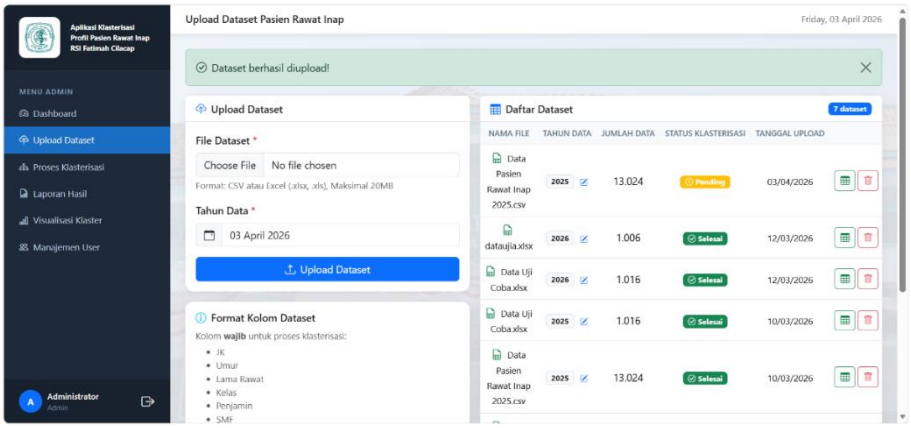
data mewajibkan beberapa parameter medis seperti jenis kelamin, umur, lama rawat, kelas, penjamin, SMF, keadaan keluar, diagnosis, tindakan hingga kode ICD 10 dan ICD 9 CM guna menjamin kelancaran proses klasterisasi.

Pada bagian kanan halaman, tabel daftar *dataset* menyajikan informasi komprehensif mengenai seluruh *file* yang telah berhasil diunggah, termasuk jumlah baris data, tanggal unggah, dan status klasterisasi yang ditandai dengan indikator warna *pending*, diproses, atau selesai. Tabel ini juga memfasilitasi admin untuk melakukan pembaruan tahun data melalui jendela modal tanpa perlu mengunggah ulang *file*. Selain itu, tersedia kolom aksi yang memungkinkan admin untuk melakukan pengelolaan isi *dataset* melalui fitur lihat dan edit data, serta fitur penghapusan *dataset* yang dilengkapi dengan dialog konfirmasi untuk menjaga integritas data di dalam sistem. Tampilan halaman *upload dataset* ditunjukkan pada Gambar 26.



Gambar 26. Halaman *Upload Dataset* Admin

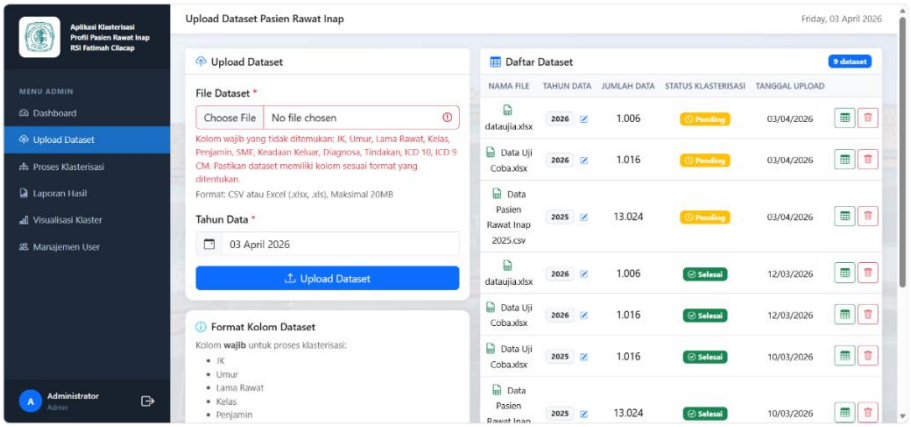
Setelah *file dataset* berhasil diunggah, aplikasi akan menampilkan notifikasi "Dataset berhasil diupload!" dan secara otomatis memperbarui tabel daftar *dataset* di sisi kanan halaman. Admin dapat memverifikasi informasi seperti nama *file*, tahun, jumlah baris, serta tanggal unggah dengan status klasterisasi awal bernilai *pending* yang menandakan data siap diproses lebih lanjut. Selain itu, tersedia fitur lihat dan edit data bagi admin untuk melakukan pengecekan detail isi *dataset* dan memastikan kesesuaian seluruh kolom wajib sebelum melanjutkan ke tahap klasterisasi, sebagaimana ditunjukkan pada Gambar 27.



Gambar 27. Halaman *Upload Dataset* Ketika *Dataset* Berhasil Di-*Upload*

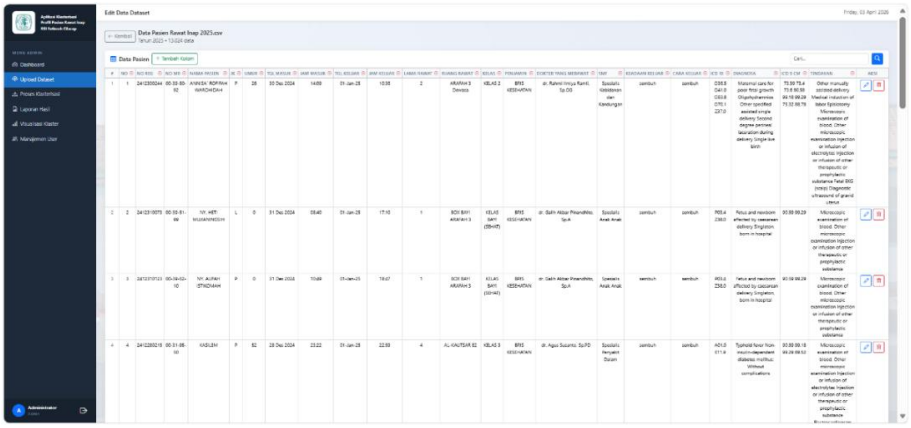
Apabila *file dataset* yang diunggah tidak memenuhi ketentuan format, aplikasi secara otomatis menolak proses tersebut dan menampilkan pesan kesalahan berwarna merah yang merinci daftar kolom wajib yang tidak ditemukan. Meskipun validasi nama kolom ini bersifat *case-insensitive*, admin tetap diwajibkan memperbaiki struktur *dataset* agar sesuai dengan parameter yang dibutuhkan guna mencegah

kegagalan pada tahap pemrosesan data selanjutnya. Fitur validasi ini memastikan integritas atribut data sebelum benar-benar masuk ke dalam sistem, sebagaimana ditunjukkan pada Gambar 28.



Gambar 28. Halaman *Upload Dataset* Ketika Ada Kesalahan Format

Halaman edit data *dataset* menyediakan antarmuka tabel interaktif bagi admin untuk mengelola dan memverifikasi isi *file* yang telah diunggah melalui menu lihat dan edit data. Halaman ini dilengkapi dengan fitur pencarian cepat, penambahan kolom baru, serta fungsi manipulasi data baik pada level kolom maupun baris melalui tombol aksi edit dan hapus. Sistem ini mendukung navigasi paginasi untuk efisiensi peninjauan data dalam jumlah besar sebelum melanjutkan ke tahap klasterisasi. Dengan adanya fitur-fitur tersebut, proses validasi dan pengelolaan data dapat dilakukan secara lebih sistematis dan terstruktur, sehingga membantu meminimalkan kesalahan serta memastikan data yang digunakan telah konsisten. Selain itu, antarmuka yang interaktif juga memudahkan pengguna dalam penyesuaian data secara cepat dan efisien, sebagaimana ditunjukkan pada Gambar 29.



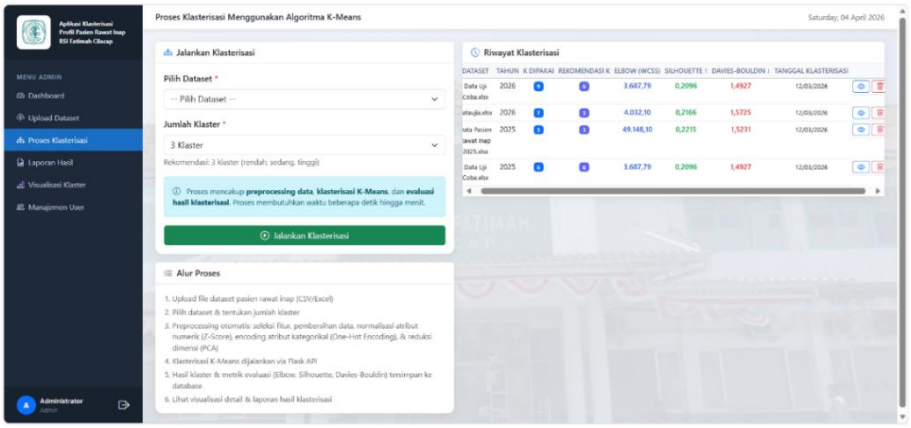
Gambar 29. Halaman Edit Data *Dataset* Admin

d. Halaman Proses Klasterisasi

Halaman proses klasterisasi berfungsi sebagai antarmuka utama bagi admin untuk melakukan pengelompokan data pasien menggunakan algoritma K-Means melalui penentuan parameter *dataset* dan jumlah klaster (k) antara 2 hingga 10. Sistem ini mengintegrasikan alur pemrosesan data yang komprehensif, dimulai dari tahap *preprocessing* yang meliputi seleksi fitur, pembersihan data, normalisasi *z-score*, *one-hot encoding*, hingga reduksi dimensi menggunakan *principal component analysis* (PCA). Eksekusi algoritma dijalankan melalui flask API dan diakhiri dengan evaluasi hasil menggunakan tiga metode utama, yaitu metode *elbow*, *silhouette score*, dan *davies-bouldin index* (DBI), didukung oleh kartu alur proses sebagai panduan visual bagi admin.

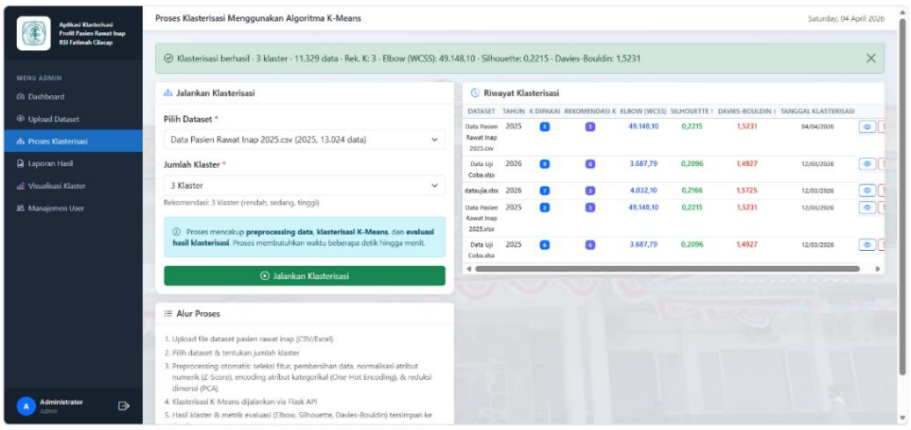
Pada bagian kanan halaman, tabel riwayat klasterisasi menyajikan informasi mendalam mengenai seluruh proses yang pernah dilakukan, termasuk jumlah klaster yang digunakan, rekomendasi k

optimal, serta nilai-nilai metrik evaluasi yang dihasilkan. Tabel ini memudahkan admin dalam memantau efektivitas hasil klasterisasi dan menyediakan akses cepat menuju laporan detail melalui tombol lihat. Selain itu, tersedia fitur hapus yang dilengkapi dengan jendela modal konfirmasi untuk mencegah penghapusan data pasien secara tidak sengaja, guna menjaga integritas riwayat pengolahan data di dalam sistem, sebagaimana ditunjukkan pada Gambar 30.



Gambar 30. Halaman Proses Klasterisasi Admin

Setelah proses klasterisasi berhasil dijalankan, aplikasi menampilkan notifikasi keberhasilan berwarna hijau yang menyajikan ringkasan hasil secara langsung. Notifikasi tersebut mencantumkan pesan detail seperti "Klasterisasi berhasil · 3 klaster · 11.329 data · Rek. K: 3 · *Elbow* (WCSS): 49.148,10 · *Silhouette*: 0,2215 · *Davies-Bouldin*: 1,5231". Hasil yang baru diproses ini secara otomatis ditambahkan ke dalam tabel riwayat klasterisasi di sisi kanan, sehingga admin dapat melihat hasil klasterisasi, sebagaimana ditunjukkan pada Gambar 31.



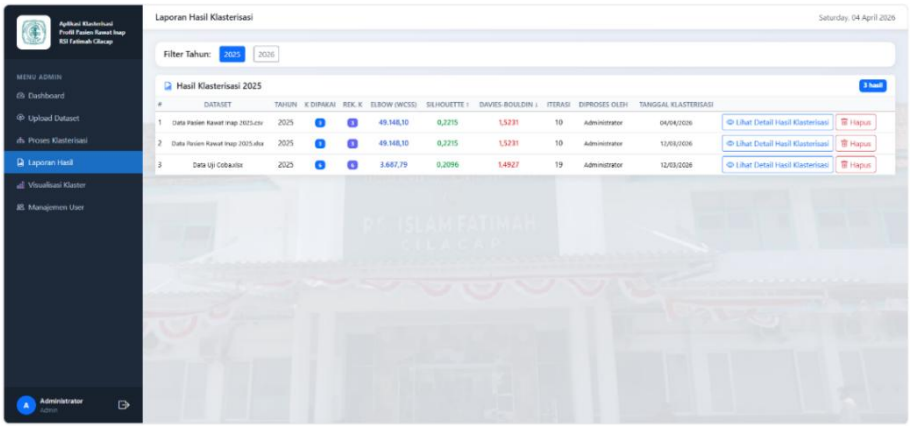
Gambar 31. Halaman Proses Klasterisasi Ketika Berhasil Dijalankan

e. Halaman Laporan Hasil

Halaman laporan hasil berfungsi sebagai pusat arsip digital yang menyajikan daftar seluruh hasil klasterisasi yang telah dilakukan oleh admin dalam sistem. Antarmuka halaman ini dilengkapi dengan fitur filter tahun di bagian atas untuk menyaring data berdasarkan periode tertentu, di mana tombol tahun yang aktif ditandai dengan warna kontras untuk memudahkan navigasi. Tabel utama pada halaman ini menyajikan informasi komprehensif pada setiap barisnya, mulai dari nama *dataset*, jumlah klaster (k), rekomendasi k optimal, hingga nilai iterasi algoritma saat mencapai konvergensi.

Selain data administratif, tabel ini memuat metrik evaluasi teknis yang mendalam, meliputi nilai *elbow* (WCSS), *silhouette score*, dan *davies-bouldin index* (DBI). Admin dapat mengelola setiap hasil melalui dua tombol aksi utama, yaitu tombol lihat detail hasil klasterisasi untuk meninjau interpretasi karakteristik dan grafik metrik, serta tombol hapus yang dilengkapi dialog konfirmasi keamanan.

Tersedia juga fitur navigasi paginasi untuk mempermudah akses terhadap catatan data dalam jumlah besar secara terstruktur. Sistem pengarsipan ini dirancang untuk memastikan seluruh riwayat pengolahan data tersimpan secara rapi, sehingga memudahkan admin dalam melakukan audit data maupun perbandingan performa algoritma antarperiode. Integrasi metrik memudahkan dalam validasi kualitas klaster secara objektif. Tampilan halaman laporan hasil sebagaimana ditunjukkan pada Gambar 32.

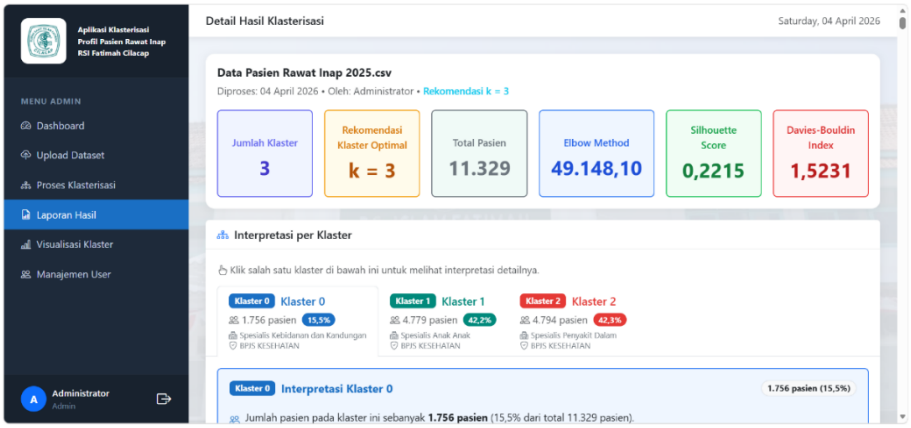


Gambar 32. Halaman Laporan Hasil Admin

Halaman detail hasil klasterisasi merupakan antarmuka komprehensif yang menyajikan informasi mendalam mengenai satu proses klasterisasi tertentu guna memberikan transparansi data serta validasi hasil bagi admin. Halaman ini dapat diakses secara fleksibel melalui tiga jalur navigasi utama, yaitu tombol lihat detail pada menu laporan hasil, tombol detail lengkap pada *dashboard* utama, serta ikon mata pada tabel riwayat di halaman proses klasterisasi. Seluruh jalur akses tersebut akan mengarahkan admin ke halaman yang terbagi

menjadi empat bagian utama, yakni informasi umum dan metrik, interpretasi per klaster, metode evaluasi penentuan k optimal (k = 2 - 10), dan data pasien per klaster.

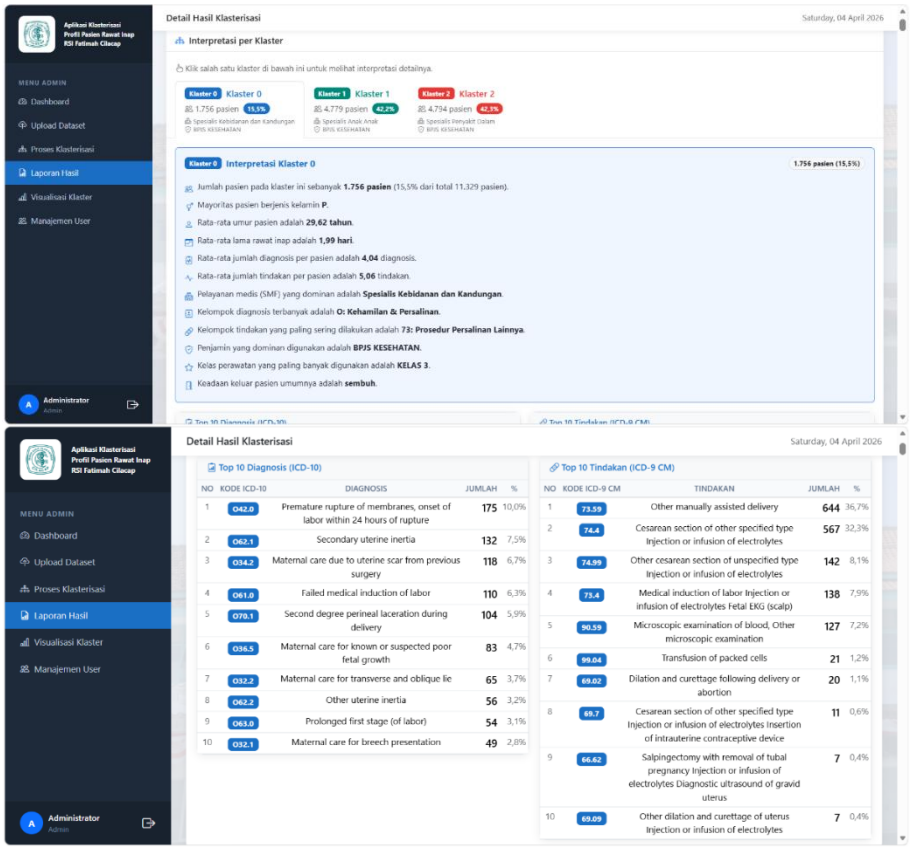
Pada bagian informasi umum dan metrik, terdapat *header card* yang menampilkan metadata administratif seperti nama *file dataset*, tanggal pemrosesan, identitas admin, serta rekomendasi jumlah klaster (k) optimal. Di bawah metadata tersebut, ditampilkan enam kartu statistik horizontal yang mencakup jumlah klaster aktif, rekomendasi klaster terbaik hasil konsensus, total pasien, serta nilai evaluasi *elbow*, *silhouette score*, dan DBI, sebagaimana ditunjukkan pada Gambar 33.



Gambar 33. Halaman Detail Hasil Klasterisasi Admin - Informasi

Bagian interpretasi per klaster menggunakan antarmuka tab navigasi untuk merinci karakteristik tiap kelompok melalui label interpretasi dan proporsi pasien. Saat tab dipilih, sistem menampilkan panel karakteristik mendalam yang mencakup mayoritas jenis kelamin, rata-rata umur, lama rawat, jumlah diagnosis dan tindakan, SMF dominan, kategori diagnosis dan tindakan terbanyak, penjamin, kelas

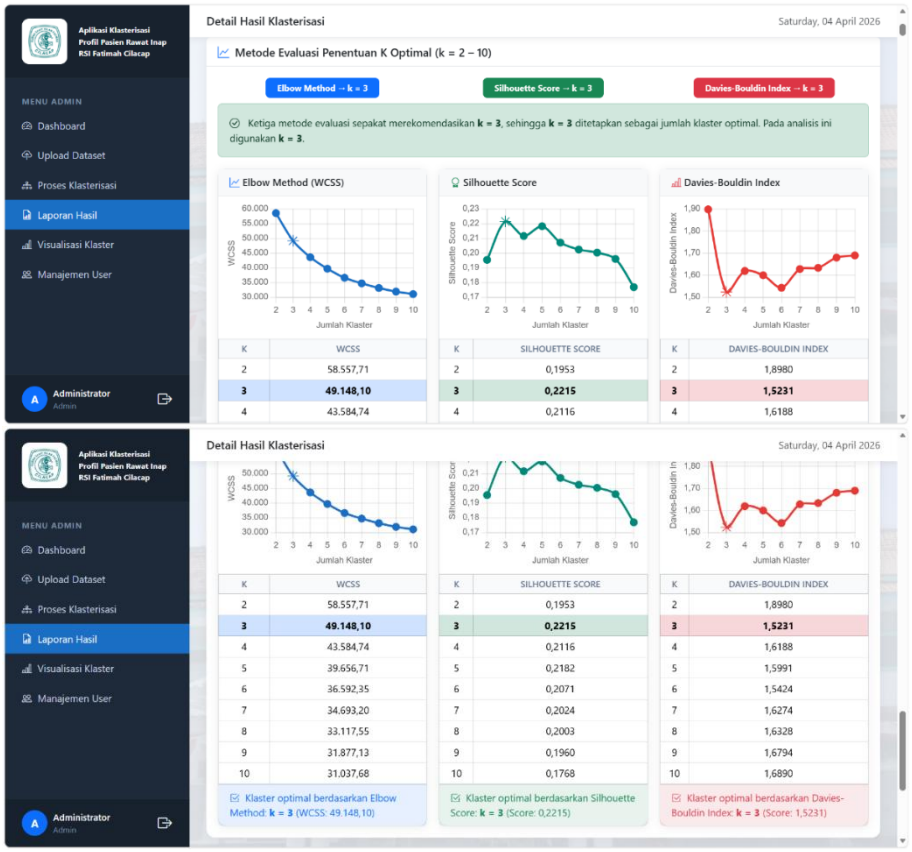
perawatan, hingga keadaan keluar pasien. Analisis ini diperdalam melalui dua tabel berdampingan berisi sepuluh besar kode ICD-10 (Diagnosis) dan ICD-9 CM (Tindakan) beserta frekuensi kemunculannya guna mengidentifikasi tren medis yang paling menonjol pada setiap kelompok. Integrasi antara data statistik karakteristik dan rincian kode medis ini dirancang untuk memudahkan pihak rumah sakit dalam memahami pola penanganan klinis secara lebih akurat dan komprehensif. Tampilan detail interpretasi karakteristik klaster ini ditunjukkan pada Gambar 34.



Gambar 34. Halaman Detail Hasil Klasterisasi Admin - Interpretasi

Bagian metode evaluasi penentuan k optimal (k=2-10) sebagai justifikasi ilmiah terhadap pemilihan jumlah kelompok melalui kotak

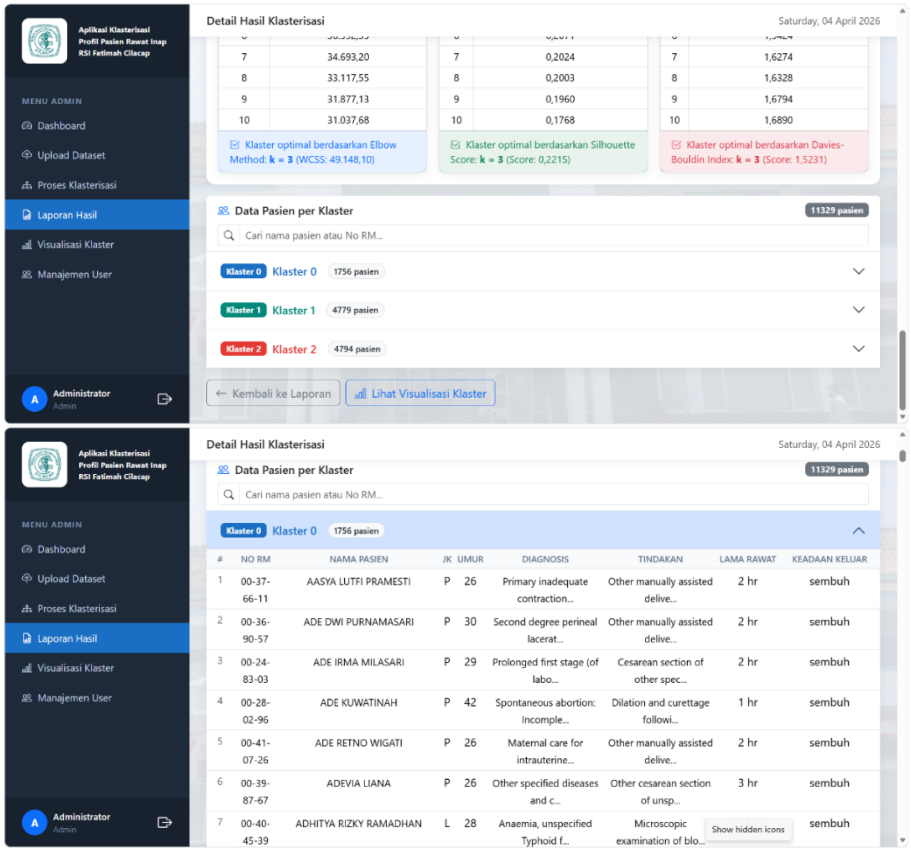
alert otomatis yang merangkum status konsensus antar-metode secara sistematis. Penjelasan teknis disajikan melalui tiga kartu grafik *line chart* untuk metode *elbow*, *silhouette*, dan DBI dengan penanda ikon bintang pada titik optimal, serta didampingi tabel nilai metrik yang diberi *highlight* pada baris paling optimal. Struktur ini dirancang untuk memberikan transparansi penuh terhadap proses pengambilan keputusan sistem dalam menentukan jumlah klaster terbaik berdasarkan landasan yang kuat, sebagaimana ditunjukkan pada Gambar 35.



Gambar 35. Halaman Detail Hasil Klasterisasi Admin - Evaluasi

Bagian data pasien per klaster menyediakan akses langsung ke data mentah yang telah terkelompok menggunakan komponen *accordion* yang efisien. Setiap panel klaster dapat diperluas untuk

menampilkan detail pasien secara mendalam, serta telah dilengkapi dengan fitur pencarian *real-time* berdasarkan nama atau nomor rekam medis untuk mempermudah verifikasi data tanpa perlu memuat ulang halaman. Halaman ini ditutup dengan dua opsi navigasi strategis, yaitu tombol untuk kembali ke daftar laporan utama atau tombol menuju visualisasi grafis guna melakukan analisis spasial hasil klasterisasi secara lebih mendalam, sebagaimana ditunjukkan pada Gambar 36.



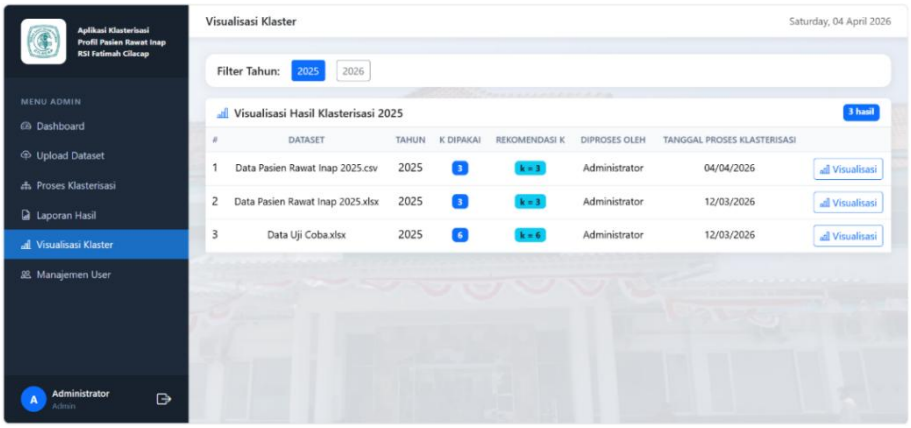
Gambar 36. Halaman Detail Hasil Klasterisasi Admin - Data Pasien

f. Halaman Visualisasi Klaster

Halaman visualisasi klaster berfungsi sebagai gerbang akses utama bagi admin untuk meninjau distribusi dan karakteristik pengelompokan data pasien dalam bentuk grafis interaktif. Antarmuka

halaman ini dilengkapi fitur filter tahun untuk menyaring daftar hasil klasterisasi berdasarkan periode tertentu, di mana tombol tahun yang aktif ditandai dengan warna biru. Tabel utama pada halaman ini menyajikan informasi administratif yang mencakup nama *dataset*, jumlah klaster (k), rekomendasi k optimal dalam bentuk *badge*, serta identitas admin dan tanggal pemrosesan data.

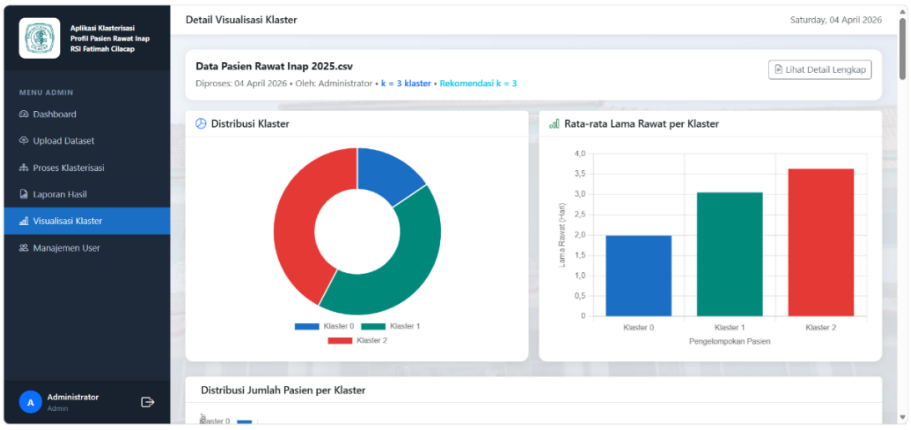
Setiap baris pada tabel dilengkapi tombol visualisasi yang mengarahkan admin ke halaman detail berisi berbagai grafik interaktif seperti distribusi pasien, *heatmap* sebaran klaster, *box plot*, hingga grafik radar profil klaster. Halaman detail tersebut juga menyajikan grafik distribusi atribut kategorikal per klaster dan fitur navigasi paginasi untuk memudahkan pengelolaan data dalam jumlah besar, sebagaimana ditunjukkan pada Gambar 37.



Gambar 37. Halaman Visualisasi Klaster Admin

Halaman detail visualisasi klaster menampilkan representasi data hasil klasterisasi melalui berbagai grafik interaktif untuk memudahkan admin dalam menganalisis distribusi dan karakteristik setiap kelompok

secara visual. Halaman ini dapat diakses melalui tombol visualisasi pada daftar utama atau tombol lihat visualisasi klaster di bagian bawah halaman detail hasil klasterisasi. Antarmuka halaman terbagi menjadi delapan bagian grafik utama yang menyajikan perspektif berbeda terhadap hasil pengelompokan data pasien. Pada bagian atas, terdapat *header card* yang memuat metadata administratif seperti nama *file*, tanggal proses, identitas admin, serta nilai k yang digunakan dan rekomendasi k optimal. Selain itu, tersedia tombol lihat detail lengkap yang memungkinkan admin berpindah secara cepat ke halaman detail hasil untuk meninjau interpretasi naratif dan data pasien, sebagaimana ditunjukkan pada Gambar 38.



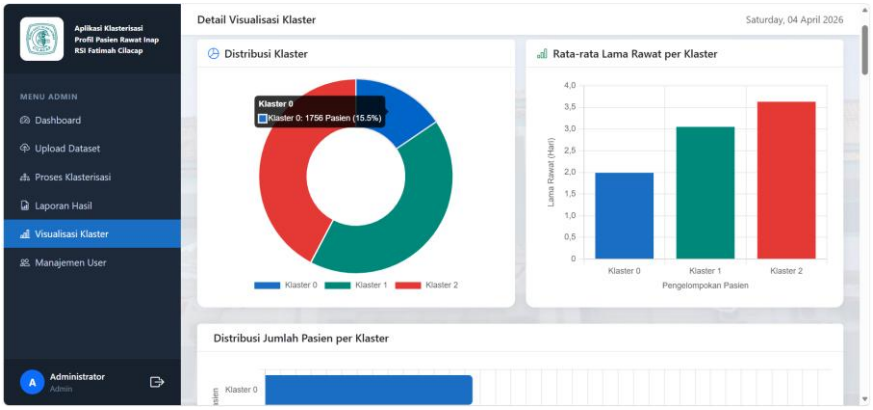
Gambar 38. Halaman Detail Visualisasi Klaster Admin

Beberapa jenis visualisasi yang disajikan pada halaman ini untuk mendukung analisis data pasien dapat dijelaskan sebagai berikut:

1) Grafik Distribusi Klaster

Grafik distribusi klaster disajikan dalam bentuk grafik donat (*doughnut chart*) untuk memvisualisasikan proporsi jumlah pasien

pada setiap klaster terhadap total keseluruhan data secara interaktif. Setiap potongan grafik menggunakan warna yang berbeda untuk merepresentasikan identitas tiap klaster, lengkap dengan legenda di bagian bawah yang memuat nama beserta warna indikatornya. Pengguna dapat mengarahkan kursor (*hover*) ke area potongan grafik untuk memunculkan *tooltip* yang menampilkan informasi mendetail yang menunjukkan klaster 0 dengan 1.756 pasien (15,5%), klaster 1 dengan 4.779 pasien (42,2%), serta klaster 2 sebagai kelompok dominan dengan 4.794 pasien (42,3%), sebagaimana ditunjukkan pada Gambar 39.

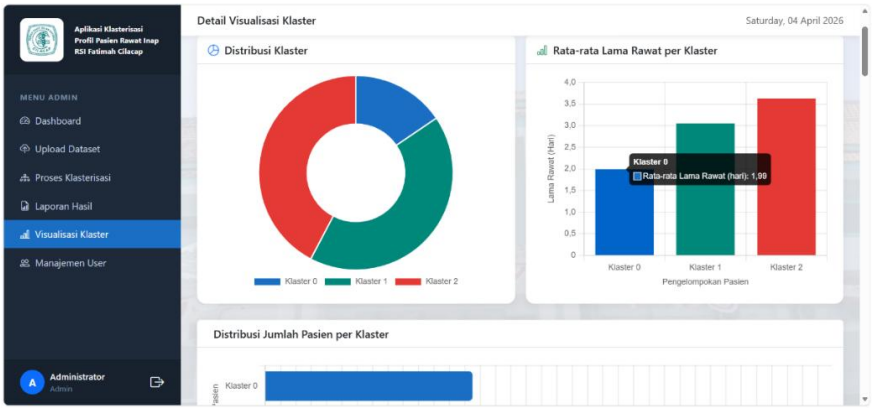


Gambar 39. Grafik Distribusi Klaster Admin

2) Grafik Rata-Rata Lama Rawat per Klaster

Di sebelah kanan grafik distribusi, ditampilkan grafik rata-rata lama rawat per klaster dalam bentuk grafik batang vertikal (*bar chart*). Sumbu x pada grafik ini merepresentasikan pengelompokan pasien berdasarkan nama klaster, sementara sumbu y menunjukkan nilai rata-rata durasi rawat inap dalam satuan hari. Setiap batang menggunakan warna identitas klaster untuk memudahkan admin

dalam membandingkan durasi perawatan antar-kelompok secara visual. Ketika kursor diarahkan ke setiap batang grafik, sistem akan menampilkan *tooltip* berisi nilai numerik yang presisi, di mana klaster 0 memiliki rata-rata lama rawat selama 1,99 hari, klaster 1 selama 3,05 hari, dan klaster 2 memiliki durasi rata-rata tertinggi yaitu 3,63 hari, sebagaimana ditunjukkan pada Gambar 40.

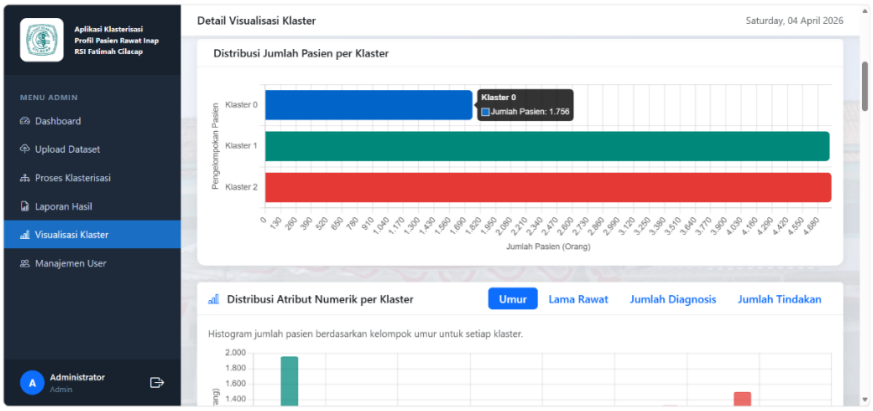


Gambar 40. Grafik Rata-Rata Lama Rawat per Klaster Admin

3) Grafik Distribusi Jumlah Pasien per Klaster

Selanjutnya, ditampilkan grafik distribusi jumlah pasien per klaster dalam bentuk grafik batang horizontal (*horizontal bar chart*) yang membentang penuh pada satu baris. Sumbu y pada grafik ini menampilkan nama masing-masing klaster sebagai pengelompokan pasien, sedangkan sumbu x menunjukkan kuantitas pasien dalam satuan orang. Grafik ini memungkinkan admin untuk melihat perbandingan ukuran serta volume data setiap klaster secara langsung dan proporsional melalui panjang batang yang berbeda. Berdasarkan interaksi pada gambar, sistem menyediakan *tooltip* yang menunjukkan jumlah eksklusif pasien pada tiap kelompok,

yaitu klaster 0 sebanyak 1.756 pasien, klaster 1 sebanyak 4.779 pasien, dan klaster 2 sebanyak 4.794 pasien. Visualisasi yang responsif ini dirancang untuk mempermudah admin dalam mengidentifikasi dominasi kelompok pasien secara cepat. Tampilan grafik distribusi jumlah pasien per klaster sebagaimana ditunjukkan pada Gambar 41.

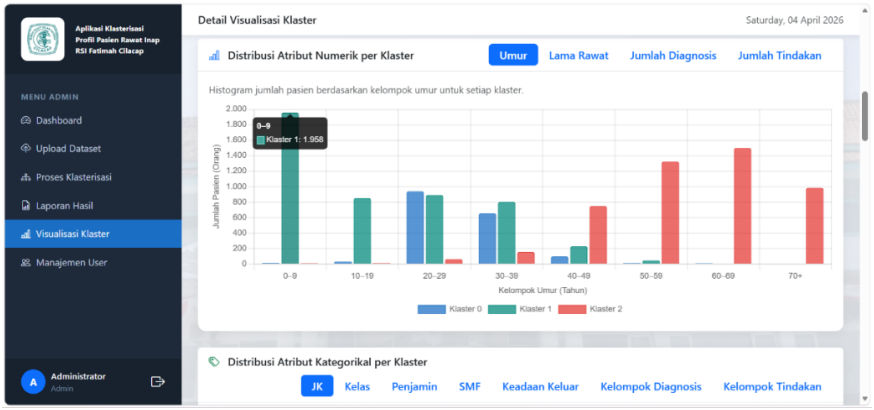


Gambar 41. Grafik Distribusi Jumlah Pasien per Klaster Admin

4) Grafik Distribusi Atribut Numerik per Klaster

Bagian ini menyajikan analisis distribusi data melalui empat histogram interaktif yang dapat diakses melalui tab navigasi: umur, lama rawat, jumlah diagnosis, dan jumlah Tindakan. Setiap histogram menggunakan grafik batang berkelompok (*grouped bar chart*) dengan warna identitas klaster untuk memudahkan perbandingan sebaran data antar-kelompok. Admin dapat beralih antar tab untuk melihat frekuensi pasien berdasarkan kategori tertentu, seperti kelompok umur (0-70+ tahun), durasi rawat inap, hingga intensitas beban medis (jumlah diagnosis dan tindakan).

Berdasarkan interaksi pada gambar, sistem menyediakan *tooltip* yang memberikan detail kuantitatif pada kategori tertentu. Sebagai contoh, pada tab umur, terlihat klaster 1 mendominasi kelompok usia 0-9 tahun dengan 1.958 pasien. Pada tab lama rawat, kelompok durasi 2 hari menjadi yang paling umum, di mana klaster 1 tercatat memiliki 341 pasien pada durasi 1 hari. Sementara itu, pada tab jumlah diagnosis dan jumlah tindakan, mayoritas pasien di klaster 1 memiliki 1 diagnosis dan 0 tindakan dengan jumlah masing-masing sebanyak 4.779 pasien, sebagaimana ditunjukkan pada Gambar 42.



Gambar 42. Grafik Distribusi Atribut Numerik per Klaster Admin

5) Grafik Distribusi Atribut Kategorikal per Klaster

Bagian ini menyajikan tujuh grafik batang berkelompok yang dapat diakses melalui tab navigasi untuk menganalisis distribusi atribut kualitatif pada setiap klaster. Tab yang tersedia meliputi JK (Jenis Kelamin), kelas (kelas perawatan), penjamin, SMF (Staf Medis Fungsional), keadaan keluar, serta kelompok diagnosis dan tindakan (Top 10). Setiap grafik memvisualisasikan jumlah pasien

per kategori dengan pewarnaan yang konsisten sesuai identitas klaster, dilengkapi petunjuk interaksi "Klik tab untuk mengganti atribut" guna memudahkan navigasi pengguna.

Berdasarkan interaksi pada rangkaian gambar, sistem menampilkan detail data yang spesifik melalui *tooltip* pada tiap tab. Sebagai contoh, pada tab JK, klaster 1 tercatat memiliki 2.194 pasien laki-laki (L). Pada tab kelas, mayoritas pasien klaster 1 berada di kelas 1 (920 pasien), sementara pada tab penjamin, BPJS kesehatan menjadi penanggung dominan untuk klaster 1 dengan 3.680 pasien. Informasi klinis juga terlihat pada tab SMF yang menunjukkan 1.056 pasien klaster 1 ditangani oleh spesialis penyakit dalam, dengan keadaan keluar didominasi status "sembuh" sebanyak 4.696 pasien. Lebih lanjut, kelompok diagnosis didominasi kategori "A: Infeksi Bakteri dan Parasit" (2.041 pasien) dan kelompok tindakan oleh kategori "90: Lab Mikroskopis" (3.350 pasien), sebagaimana ditunjukkan pada Gambar 43.



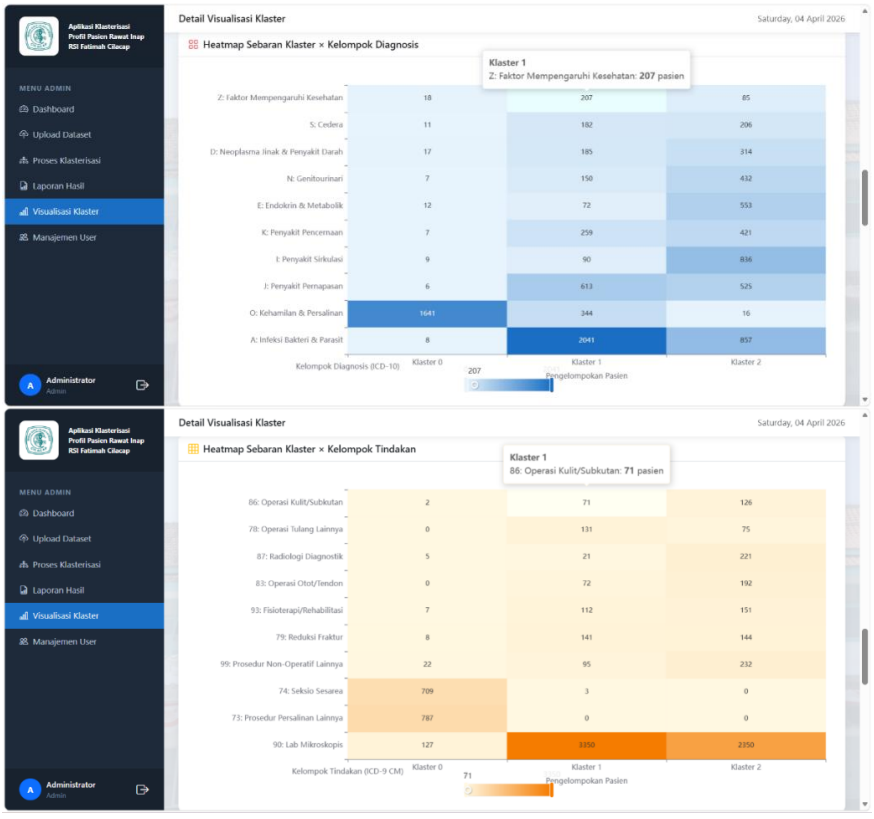
Gambar 43. Grafik Distribusi Atribut Kategorikal per Klaster Admin

6) *Heatmap* Sebaran Klaster Kelompok Diagnosis dan Kelompok Tindakan

Bagian ini menyajikan dua grafik *heatmap* interaktif untuk menganalisis kepadatan hubungan antara klaster dengan atribut klinis spesifik menggunakan *library echarts*. *Heatmap* pertama, *heatmap* sebaran klaster × kelompok diagnosis, memetakan matriks intensitas antara pengelompokan pasien (sumbu x) dengan kategori diagnosis ICD-10 (sumbu y). Sementara itu, *heatmap* kedua, *heatmap* sebaran klaster × kelompok tindakan, menunjukkan korelasi serupa terhadap kategori tindakan ICD-9 CM. Penggunaan gradasi warna dari terang ke gelap pada setiap sel berfungsi sebagai indikator visual kuantitas pasien, di mana warna yang lebih pekat menandakan populasi pasien yang lebih tinggi pada kombinasi tersebut.

Berdasarkan interaksi pada gambar, sistem menampilkan *tooltip* berisi informasi presisi saat kursor diarahkan ke sel tertentu. Pada *heatmap* diagnosis, terlihat klaster 1 memiliki konsentrasi sangat tinggi pada kategori "A: Infeksi Bakteri dan Parasit" dengan 2.041 pasien (warna biru pekat), sementara klaster 0 mendominasi kategori "O: Kehamilan dan Persalinan" dengan 1.641 pasien. Pada *heatmap* tindakan, klaster 1 menunjukkan pola dominansi yang kuat pada prosedur "90: Lab Mikroskopis" sebanyak 3.350 pasien (warna oranye pekat), sedangkan klaster 0 terfokus pada prosedur persalinan

(kode 73 dan 74). Kedua grafik ini juga dilengkapi dengan legenda rentang nilai di bagian bawah, visualisasi ini menjadi instrumen penting bagi pihak manajemen rumah sakit dalam memetakan beban kerja tenaga medis serta kebutuhan sumber daya klinis pada setiap kelompok profil pasien. Penyajian ini mempermudah konversi data kompleks menjadi aplikatif. Visualisasi korelasi mendalam ini ditunjukkan pada Gambar 44.



Gambar 44. *Heatmap* Sebaran Kelompok Diagnosis - Tindakan Admin

7) *Box Plot* Distribusi Umur dan Lama Rawat per Klaster

Bagian ini menyajikan dua grafik *box plot* yang disusun berdampingan untuk menganalisis sebaran statistik data numerik pada setiap klaster menggunakan *library echarts*. Grafik pertama,

distribusi umur per klaster, memvisualisasikan rentang usia pasien (sumbu y) dalam satuan tahun, sedangkan grafik kedua, distribusi lama rawat per klaster, menunjukkan sebaran durasi rawat inap dalam satuan hari. Melalui visualisasi ini, admin dapat mengidentifikasi nilai minimum, kuartil pertama (Q1), median, kuartil ketiga (Q3), hingga nilai maksimum secara cepat, sekaligus mendeteksi keberadaan pencilan (*outlier*) pada masing-masing klaster.

Berdasarkan interaksi pada gambar, sistem menyediakan *tooltip* berisi ringkasan statistik deskriptif saat kursor diarahkan ke area kotak. Sebagai contoh, pada grafik distribusi umur, klaster 1 menunjukkan profil pasien yang relatif muda dengan nilai median 26 tahun dan rentang usia antara 0 hingga 33 tahun. Sementara itu, pada grafik lama rawat, klaster 1 memiliki distribusi durasi perawatan yang sangat singkat, dengan median 2 hari dan batas maksimum pada 4 hari, sebagaimana ditunjukkan pada Gambar 45.

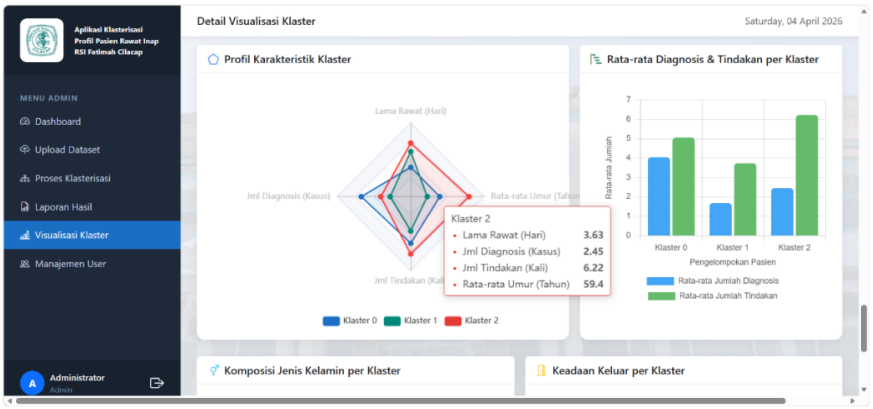


Gambar 45. *Box Plot* Distribusi Umur dan Lama Rawat per Klaster Admin

8) Grafik Profil Karakteristik Klaster dan Rata-Rata Diagnosis serta Tindakan

Bagian ini menyajikan dua grafik komplementer untuk menganalisis profil mendalam setiap kelompok pasien. Grafik pertama, profil karakteristik klaster, menggunakan grafik radar *(radar chart*) yang memetakan dimensi rata-rata umur, lama rawat, jumlah diagnosis, dan jumlah tindakan dalam satu kesatuan poligon berwarna. Visualisasi ini memungkinkan admin membandingkan karakteristik antar-klaster secara menyeluruh (holistik). Grafik kedua, rata-rata diagnosis dan tindakan per klaster, menyajikan data dalam bentuk grafik batang berkelompok (*grouped bar chart*) untuk memberikan perbandingan langsung antara intensitas diagnosis dan tindakan medis yang diterima pasien di setiap kelompok.

Berdasarkan interaksi pada gambar, sistem menampilkan *tooltip* berisi nilai numerik yang presisi. Sebagai contoh, pada grafik radar, klaster 2 teridentifikasi memiliki karakteristik dengan rata-rata umur tertua yaitu 59,4 tahun, lama rawat 3,63 hari, 2,45 diagnosis, dan 6,22 tindakan. Detail ini dikonfirmasi kembali pada grafik batang berdampingan, di mana klaster 2 secara visual menunjukkan beban tindakan medis tertinggi (6,22 kali) dibandingkan klaster lainnya, meskipun memiliki jumlah diagnosis yang relatif moderat (2,45 kasus), sebagaimana ditunjukkan pada Gambar 46.



Gambar 46. Grafik Profil dan Rata-Rata Diagnosis serta Tindakan Admin

9) Grafik Komposisi Jenis Kelamin dan Keadaan Keluar

Pada bagian terakhir, ditampilkan dua grafik batang bertumpuk (*stacked bar chart*) untuk menganalisis proporsi variabel kategorikal di setiap kelompok. Grafik pertama, komposisi jenis kelamin per klaster, menunjukkan perbandingan populasi laki-laki dan perempuan dalam satu batang utuh per klaster. Grafik kedua, keadaan keluar per klaster, memvisualisasikan distribusi status akhir pasien (seperti sembuh, rujuk, atau meninggal). Penggunaan model *stacked bar* ini memudahkan admin dalam mengidentifikasi pola yang mendominasi pada masing-masing klaster secara proporsional.

Berdasarkan interaksi pada gambar, sistem menyediakan informasi detail melalui *tooltip* untuk setiap segmen warna. Pada grafik jenis kelamin, klaster 2 menunjukkan komposisi yang cukup berimbang dengan 2.261 pasien laki-laki dan 2.533 pasien perempuan. Sementara pada grafik keadaan keluar, klaster 2 didominasi oleh pasien dengan status "sembuh" sebanyak 4.317 orang, namun juga mencatat angka "rujuk" sebanyak 123 pasien dan

status "*dead*" (meninggal) sebanyak 325 pasien. Setiap kategori pada grafik ini dibedakan melalui legenda warna yang kontras, sehingga perbedaan sebaran data antar-klaster dapat terlihat secara signifikan hanya dalam satu bidang pandang. Di bagian paling bawah halaman, terdapat tombol kembali ke visualisasi untuk mengarahkan admin kembali ke daftar utama, sebagaimana ditunjukkan pada Gambar 47.

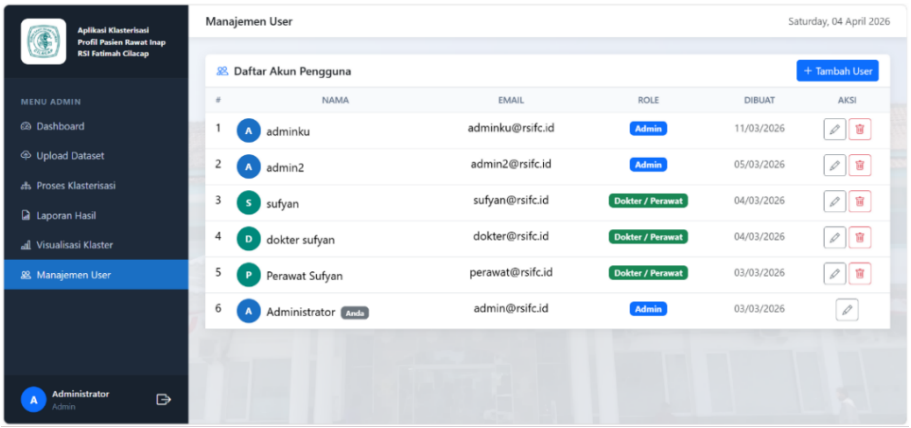


Gambar 47. Grafik Komposisi Jenis Kelamin dan Keadaan Keluar Admin

g. Halaman Manajemen *User*

Halaman manajemen *user* berfungsi sebagai pusat kendali bagi admin untuk mengelola seluruh akun pengguna melalui navigasi *sidebar*. Bagian atas halaman menampilkan kartu daftar akun pengguna yang dilengkapi tombol tambah *user* untuk pendaftaran akun baru. Tabel utama menyajikan informasi komprehensif mulai dari nama pengguna dengan ikon avatar, email, hingga peran (*role*) yang dibedakan melalui *badge* warna biru untuk admin dan hijau untuk tenaga medis (dokter/perawat). Setiap baris menyediakan kolom aksi berupa tombol edit dan hapus untuk pengelolaan akun secara individu.

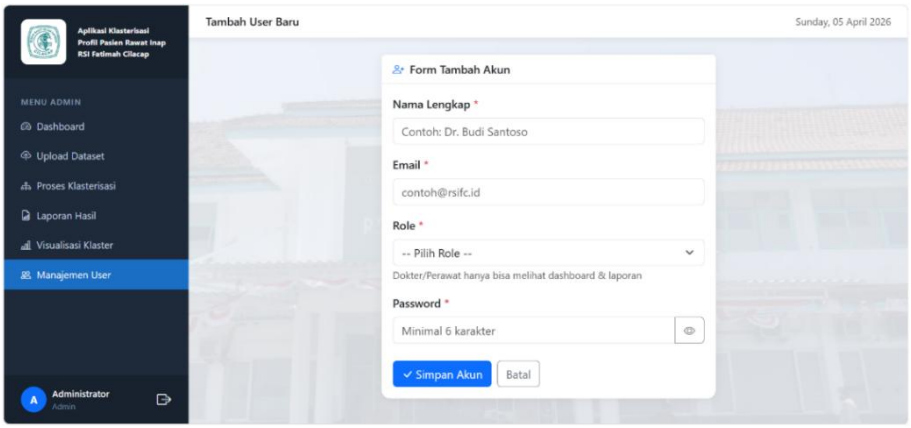
Sistem keamanan diterapkan dengan menyematkan penanda "Anda" serta menonaktifkan tombol hapus pada akun admin yang sedang *login* guna mencegah penghapusan diri sendiri. Selain itu, pada bagian bawah *sidebar* manajemen *user* terdapat informasi profil pengguna aktif yang dilengkapi tombol *logout* berupa ikon panah keluar. Fitur ini berfungsi untuk mengakhiri sesi secara instan dan mengarahkan kembali ke halaman *login*, yang tersedia secara konsisten di seluruh halaman aplikasi. Tampilan halaman manajemen *user* ditunjukkan pada Gambar 48.



Gambar 48. Halaman Manajemen *User* Admin

Halaman tambah *user* baru menyajikan formulir pendaftaran akun yang terdiri dari empat kolom input wajib, yaitu nama lengkap, email sebagai kredensial *login*, pilihan *role* (admin dan dokter/perawat), serta *password* dengan minimal enam karakter. Kolom kata sandi dilengkapi fitur visibilitas untuk menampilkan atau menyembunyikan teks guna memastikan akurasi *input*. Pada bagian bawah formulir, tersedia tombol simpan akun untuk memproses pendaftaran dan tombol

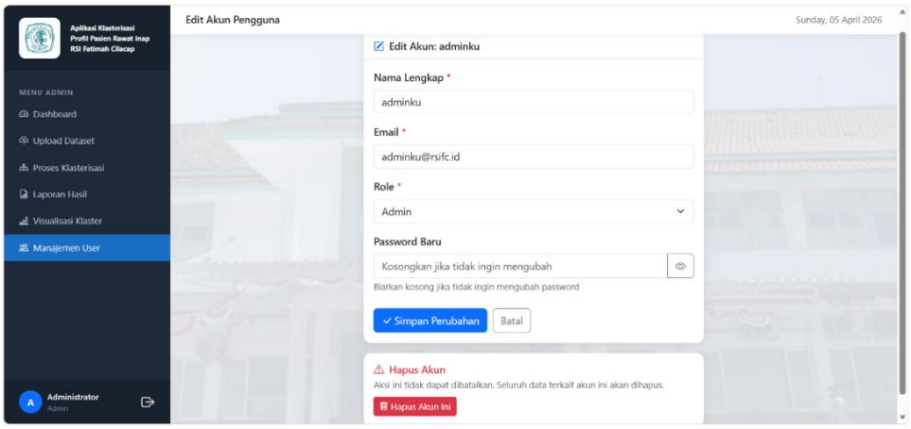
batal untuk kembali ke halaman manajemen utama tanpa menyimpan perubahan. Formulir ini dirancang dengan antarmuka yang bersih di dalam sebuah kotak putih simetris, lengkap dengan teks bantuan (*placeholder*) pada setiap kolomnya. Halaman dapat diakses melalui tombol tambah *user* di halaman manajemen *user*. Tampilan halaman tambah *user* baru ditunjukkan pada Gambar 49.



Gambar 49. Halaman Tambah *User* Baru Admin

Halaman edit akun pengguna dapat diakses melalui tombol edit bersimbol pensil pada tabel daftar akun pengguna. Halaman ini menyajikan formulir untuk memperbarui informasi pengguna yang mencakup modifikasi pada nama lengkap, email, dan pilihan *role*. kolom *password* baru bersifat opsional dan dapat dikosongkan jika admin tidak berniat melakukan perubahan kata sandi, lengkap dengan fitur visibilitas teks. Khusus untuk akun selain milik admin yang sedang *login*, halaman ini juga menyediakan panel hapus akun berwarna merah yang berisi peringatan permanensi tindakan beserta tombol hapus akun sebagai opsi alternatif pengelolaan. Di bagian bawah formulir, tersedia

tombol simpan perubahan untuk memvalidasi pembaruan data dan tombol batal untuk kembali ke halaman sebelumnya tanpa menyimpan modifikasi. Penempatan panel hapus akun secara terpisah di bagian bawah bertujuan untuk mencegah kesalahan penghapusan data secara tidak sengaja melalui penegasan visual yang kontras. Tampilan halaman edit akun pengguna ditunjukkan pada Gambar 50.



Gambar 50. Halaman Edit Akun Pengguna Admin

2) Tampilan Tenaga Medis (Dokter/Perawat)

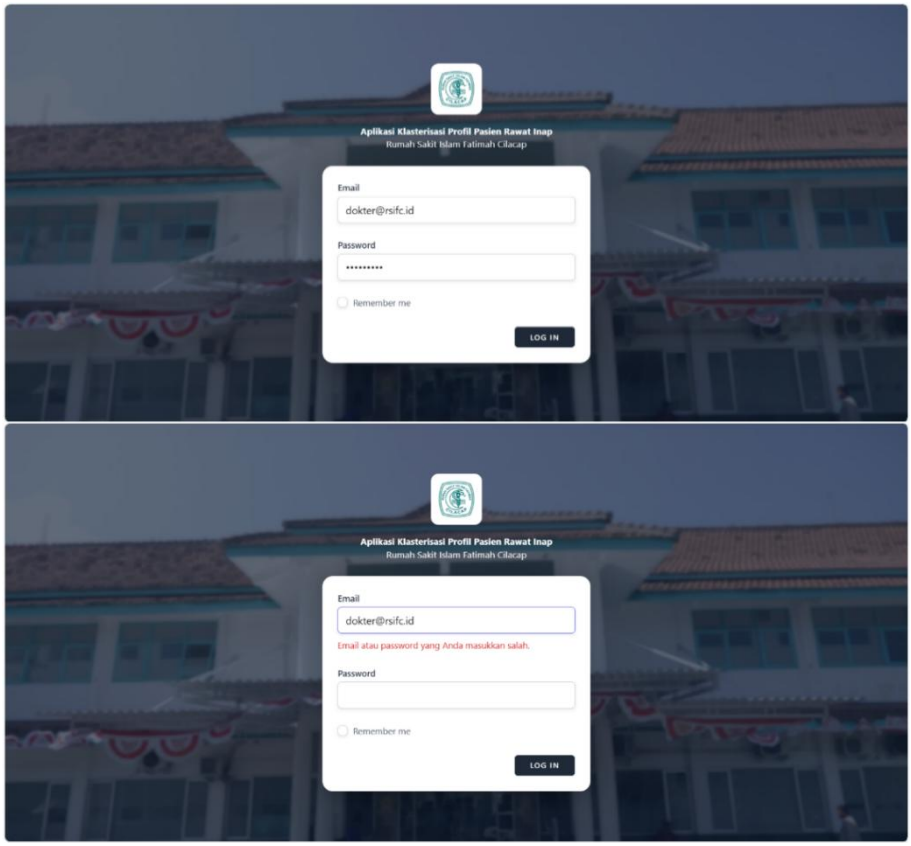
Tampilan tenaga medis merupakan representasi visual dari hak akses khusus yang berfokus pada peninjauan hasil analisis klasterisasi pasien. Berbeda dengan admin, aktor ini hanya diberikan akses pada fitur yang bersifat informatif guna mendukung pengambilan keputusan klinis. Rincian tampilan antarmuka dan fitur-fitur yang tersedia bagi tenaga medis dijelaskan secara mendetail di bawah ini.

a. Halaman *Login*

Halaman *login* tenaga medis (dokter/perawat) merupakan gerbang awal aplikasi yang menampilkan latar belakang foto gedung

RSI Fatimah Cilacap dengan formulir terpusat di tengah. Antarmuka ini memuat logo resmi rumah sakit serta kolom input email dan kata sandi sebagai kredensial utama. Fitur *remember me* disediakan di bawah kolom *password* untuk menyimpan sesi pengguna, sementara tombol *login* berfungsi untuk mengirimkan data verifikasi. Jika data yang dimasukkan valid, sistem akan mengarahkan pengguna secara otomatis ke halaman *dashboard* tenaga medis yang menyajikan ringkasan hasil analisis klasterisasi secara langsung.

Apabila kredensial yang dimasukkan tidak sesuai, sistem akan menampilkan pesan kesalahan berwarna merah bertuliskan "Email atau *password* yang Anda masukkan salah" di bawah kolom input. Demi alasan keamanan, aplikasi tidak menyediakan fitur reset *password* mandiri; pengguna yang mengalami kendala akses harus menghubungi admin untuk pembaruan kata sandi melalui menu manajemen *user*. Prosedur ini memastikan bahwa kendali akun tetap berada di bawah pengawasan administratif rumah sakit. Dengan demikian, halaman *login* tidak hanya berfungsi sebagai autentikasi pengguna, tetapi juga sebagai mekanisme awal dalam menjaga keamanan sistem serta memastikan bahwa akses terhadap data klasterisasi hanya dapat dilakukan oleh pengguna yang berwenang. Selain itu, validasi input yang diterapkan membantu mencegah kesalahan akses dan meningkatkan keandalan sistem dalam proses pengelolaan data, sebagaimana ditunjukkan pada Gambar 51.

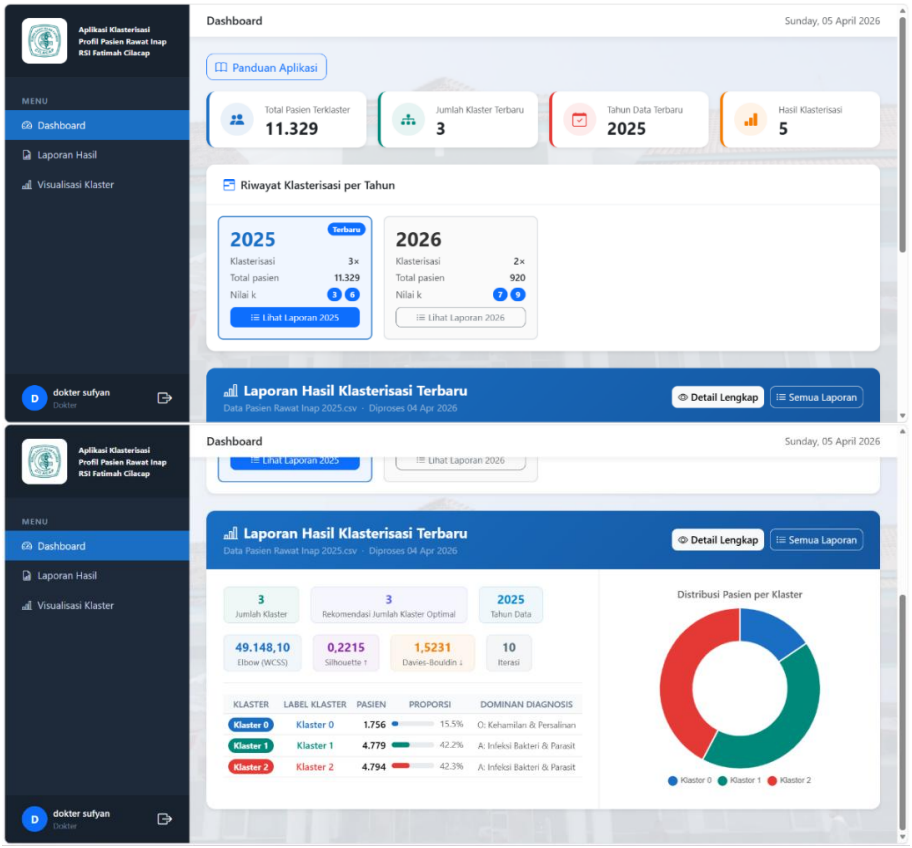


Gambar 51. Halaman *Login* Tenaga Medis

b. Halaman *Dashboard*

Halaman *dashboard* tenaga medis (dokter/perawat) berfungsi sebagai pusat informasi utama yang menyajikan ringkasan hasil analisis klasterisasi pasien rawat inap melalui navigasi *sidebar* yang telah disederhanakan. Bagian atas halaman dilengkapi tombol panduan aplikasi serta empat kartu statistik utama yang mencakup total pasien terklaster, jumlah klaster terbaru, tahun data terbaru, dan total proses klasterisasi. Selain itu, terdapat panel riwayat klasterisasi per tahun yang mengelompokkan data secara kronologis, di mana setiap kartu tahun menyediakan akses cepat ke laporan terkait melalui tombol lihat laporan.

Pada bagian bawah, terdapat kartu laporan hasil klasterisasi terbaru yang memuat metadata *dataset* serta dilengkapi dua tombol aksi yaitu tombol detail lengkap untuk melihat rincian hasil klasterisasi dan tombol semua laporan untuk mengakses daftar seluruh laporan. Halaman ini juga menampilkan tujuh metrik evaluasi algoritma seperti *elbow* (WCSS), *silhouette score*, dan *davies-bouldin index* (DBI), tabel ringkasan yang merinci label klaster beserta diagnosis dominan, serta grafik donat distribusi pasien. Penyajian seluruh elemen informasi ini dirancang secara terintegrasi untuk memberikan visibilitas data yang optimal. Tampilan halaman *dashboard* tenaga medis sebagaimana ditunjukkan pada Gambar 52.

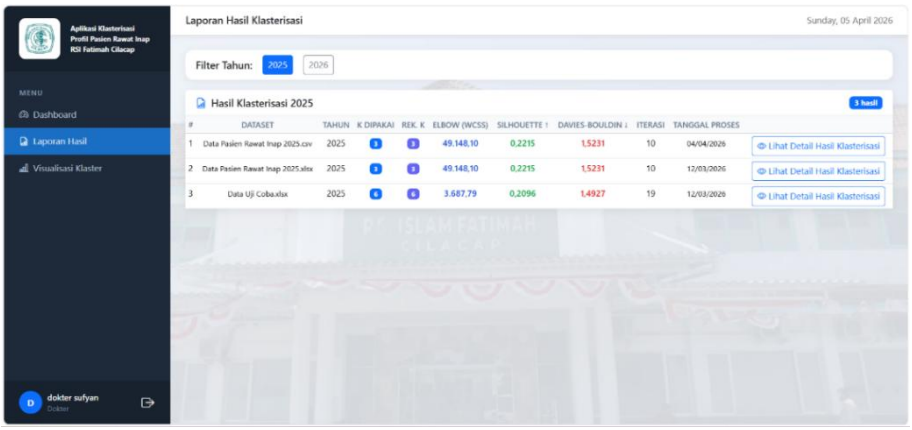


Gambar 52. Halaman *Dashboard* Tenaga Medis

c. Halaman Laporan Hasil

Halaman laporan hasil klasterisasi merupakan pusat peninjauan seluruh hasil analisis yang dapat diakses oleh tenaga medis (dokter/perawat) melalui navigasi *sidebar* maupun tombol pintasan di halaman *dashboard*. Antarmuka ini dilengkapi fitur filter tahun interaktif untuk menyaring data berdasarkan periode tertentu, di mana tahun yang aktif ditandai dengan warna biru solid. Tabel utama menyajikan informasi mendalam pada setiap baris, meliputi nama *dataset*, jumlah klaster (k) yang digunakan, rekomendasi k optimal, serta metrik evaluasi teknis seperti nilai *elbow* (WCSS), *silhouette score*, dan *davies-bouldin index* (DBI) sebagai indikator kualitas pengelompokan.

Setiap entri dalam tabel dilengkapi dengan tombol lihat detail hasil klasterisasi yang mengarahkan pengguna ke halaman detail hasil klasterisasi untuk peninjauan analisis yang lebih mendalam. Berbeda dengan hak akses admin, halaman bagi tenaga medis ini tidak menyediakan fitur hapus guna menjaga integritas data dan memastikan kendali pengelolaan tetap berada di bawah otoritas administratif. Navigasi paginasi juga tersedia di bagian bawah untuk memudahkan penelusuran jika jumlah laporan melebihi kapasitas tampilan. Dengan adanya fitur-fitur tersebut, pengguna dapat memahami hasil klasterisasi secara lebih sistematis dan komprehensif, sehingga mendukung proses pengambilan keputusan, sebagaimana ditunjukkan pada Gambar 53.

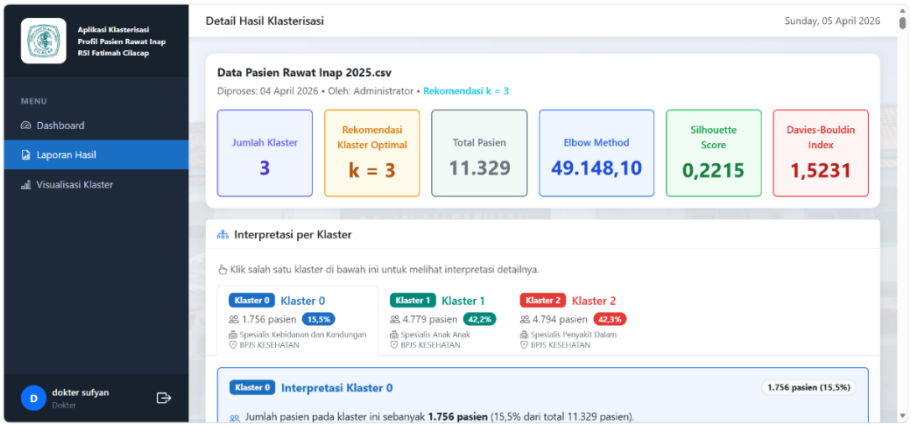


Gambar 53. Halaman Laporan Hasil Tenaga Medis

Halaman detail hasil klasterisasi merupakan antarmuka komprehensif yang menyajikan informasi mendalam mengenai satu proses klasterisasi tertentu guna memberikan transparansi data serta kemudahan peninjauan hasil bagi tenaga medis (dokter/perawat). Halaman ini dapat diakses secara fleksibel melalui dua jalur navigasi utama, yaitu tombol lihat detail hasil klasterisasi pada tabel laporan hasil dan tombol detail lengkap pada kartu laporan terbaru di halaman *dashboard*. Seluruh jalur akses tersebut akan mengarahkan tenaga medis ke halaman yang terbagi menjadi empat bagian utama, yakni informasi umum dan metrik, interpretasi per klaster, metode evaluasi penentuan k optimal (k = 2 - 10), dan data pasien per klaster.

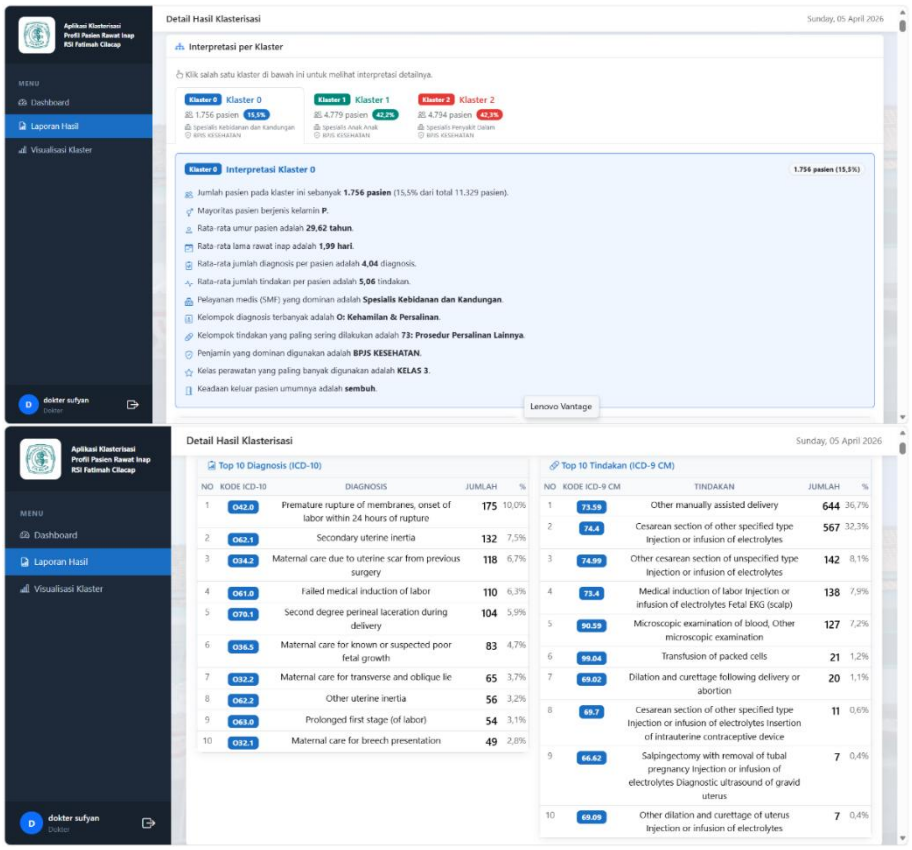
Pada bagian informasi umum dan metrik, terdapat *header card* yang menampilkan metadata proses seperti nama *file dataset*, tanggal pemrosesan, identitas admin, serta rekomendasi jumlah klaster (k) optimal. Di bawah metadata tersebut, ditampilkan enam kartu statistik horizontal yang mencakup jumlah klaster aktif, rekomendasi klaster

terbaik hasil konsensus, total pasien, serta nilai evaluasi *elbow* (WCSS), *silhouette score*, dan *davies-bouldin index* (DBI), sebagaimana ditunjukkan pada Gambar 54.



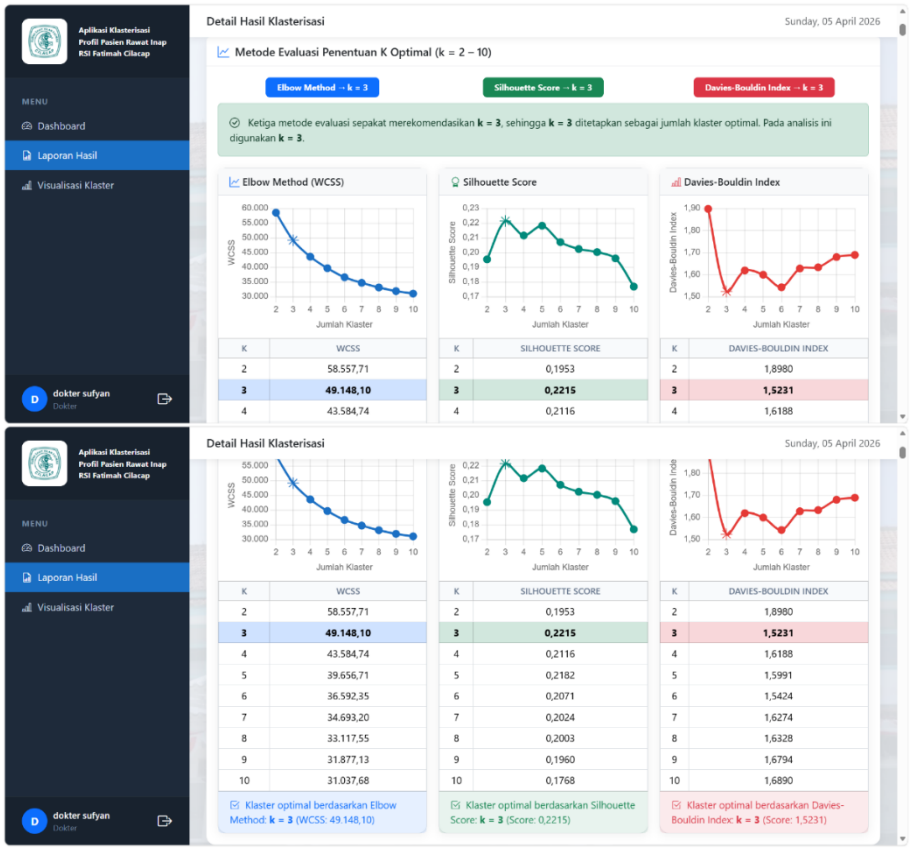
Gambar 54. Halaman Detail Hasil Klasterisasi Tenaga Medis - Informasi

Bagian interpretasi per klaster menggunakan antarmuka tab navigasi untuk merinci karakteristik tiap kelompok melalui label interpretasi, proporsi pasien, SMF dominan, serta penjamin. Saat tab dipilih, sistem menampilkan panel karakteristik mendalam yang mencakup mayoritas jenis kelamin, rata-rata umur, lama rawat, jumlah diagnosis dan tindakan, SMF dominan, kategori diagnosis dan tindakan terbanyak, penjamin, kelas perawatan, hingga keadaan keluar pasien. Analisis ini diperdalam melalui dua tabel berdampingan berisi sepuluh besar kode ICD-10 (Diagnosis) dan ICD-9 CM (Tindakan) guna mengidentifikasi tren medis dominan pada tiap klaster. Dengan adanya tampilan ini, pengguna dapat memahami perbedaan karakteristik antar klaster secara lebih jelas, sehingga memudahkan dalam melakukan interpretasi hasil, sebagaimana ditunjukkan pada Gambar 55.



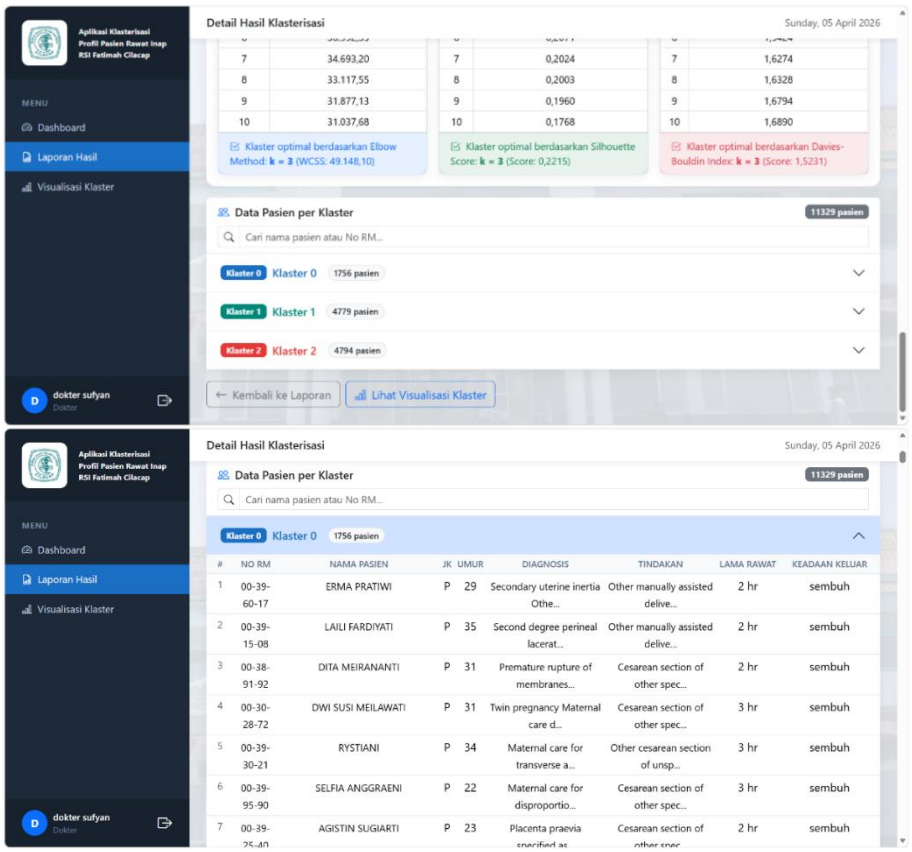
Gambar 55. Halaman Detail Hasil Klasterisasi Tenaga Medis - Interpretasi

Bagian metode evaluasi penentuan k optimal (k=2-10) memberikan justifikasi ilmiah terhadap pemilihan jumlah kelompok melalui kotak *alert* otomatis yang merangkum status konsensus antar-metode secara sistematis. Penjelasan teknis disajikan melalui tiga kartu grafik *line chart* untuk metode *elbow*, *silhouette*, dan DBI dengan penanda ikon bintang pada titik optimal, serta didampingi tabel nilai metrik yang diberi *highlight* pada baris paling optimal. Struktur ini dirancang untuk memberikan transparansi penuh terhadap landasan matematis dalam penentuan jumlah klaster terbaik, sebagaimana ditunjukkan pada Gambar 56.



Gambar 56. Halaman Detail Hasil Klasterisasi Tenaga Medis - Evaluasi

Bagian data pasien per klaster menyediakan akses langsung ke data mentah yang telah terkelompok menggunakan komponen *accordion* yang efisien. Setiap panel klaster dapat diperluas untuk menampilkan detail pasien secara mendalam, serta telah dilengkapi fitur pencarian *real-time* berdasarkan nama atau nomor rekam medis untuk mempermudah verifikasi data tanpa perlu memuat ulang halaman. Halaman ini ditutup dengan dua opsi navigasi strategis, yaitu tombol untuk kembali ke daftar laporan utama atau tombol menuju visualisasi grafis guna melakukan analisis hasil secara spasial, sebagaimana ditunjukkan pada Gambar 57.

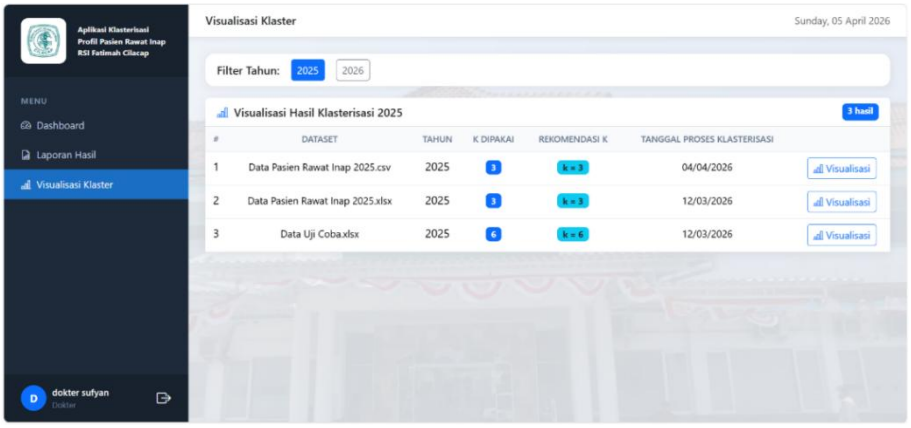


Gambar 57. Halaman Detail Hasil Klasterisasi Tenaga Medis - Data Pasien

d. Halaman Visualisasi Klaster

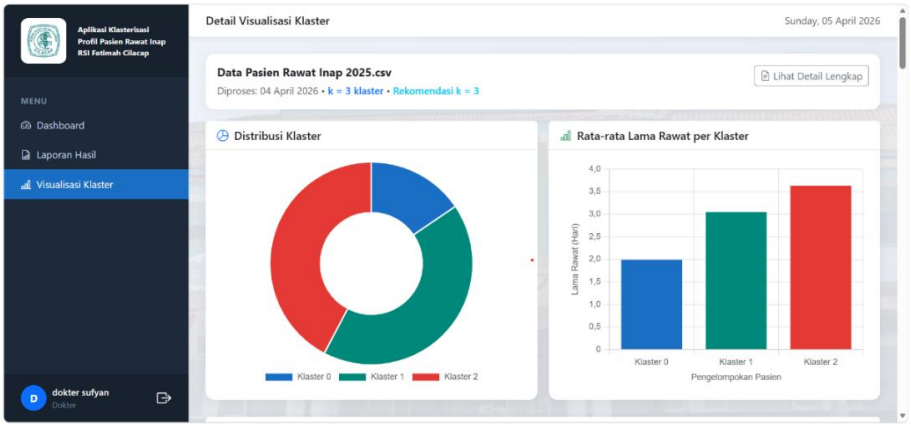
Halaman visualisasi klaster berfungsi sebagai gerbang akses utama bagi tenaga medis (dokter/perawat) untuk meninjau distribusi dan karakteristik pengelompokan data pasien dalam bentuk grafis interaktif. Antarmuka halaman ini dilengkapi fitur filter tahun untuk menyaring daftar hasil klasterisasi berdasarkan periode tertentu, di mana tombol tahun yang aktif ditandai dengan warna biru solid. Tabel utama pada halaman ini menyajikan informasi ringkas yang mencakup nama *dataset*, tahun data, jumlah klaster (k) yang digunakan, rekomendasi k optimal dalam bentuk *badge*, serta tanggal pemrosesan data.

Setiap baris pada tabel dilengkapi tombol visualisasi yang mengarahkan tenaga medis ke halaman detail berisi berbagai grafik interaktif seperti distribusi pasien, *heatmap* sebaran klaster, *box plot*, hingga grafik radar profil karakteristik klaster. Halaman detail tersebut juga menyajikan visualisasi distribusi atribut kategorikal, metrik klinis per kelompok, serta navigasi paginasi untuk memudahkan penelusuran laporan hasil klasterisasi dalam jumlah besar. Selain itu, pada bagian bawah *sidebar* visualisasi klaster terdapat informasi profil pengguna aktif yang dilengkapi tombol *logout* berupa ikon panah keluar. Fitur ini berfungsi untuk mengakhiri sesi secara instan dan mengarahkan kembali ke halaman *login*, yang tersedia secara konsisten di seluruh halaman aplikasi. Penyediaan tabel daftar hasil yang sistematis ini memudahkan tenaga medis dalam membandingkan berbagai hasil eksperimen klasterisasi secara kronologis guna menentukan model pengelompokan yang paling akurat. Tampilan halaman visualisasi klaster bagi tenaga medis sebagaimana ditunjukkan pada Gambar 58.



Gambar 58. Halaman Visualisasi Klaster Tenaga Medis

Halaman detail visualisasi klaster menampilkan representasi data hasil klasterisasi melalui berbagai grafik interaktif guna memudahkan tenaga medis (dokter/perawat) dalam menganalisis distribusi serta karakteristik setiap kelompok secara visual. Halaman ini dapat diakses melalui tombol visualisasi pada daftar utama atau tombol lihat visualisasi klaster di bagian bawah halaman detail hasil klasterisasi. Antarmuka halaman terbagi menjadi delapan bagian grafik utama yang menyajikan perspektif berbeda terhadap pengelompokan data pasien. Pada bagian atas, terdapat *header card* yang memuat metadata seperti nama *file*, tanggal proses, jumlah k yang digunakan, serta rekomendasi k optimal. Selain itu, tersedia tombol lihat detail lengkap yang memungkinkan tenaga medis berpindah secara cepat ke halaman detail hasil untuk meninjau interpretasi naratif dan data pasien secara mendalam. Visualisasi ini, dirancang agar tenaga medis dapat menarik kesimpulan klinis yang akurat. Tampilan halaman detail visualisasi klaster bagi tenaga medis sebagaimana ditunjukkan pada Gambar 59.



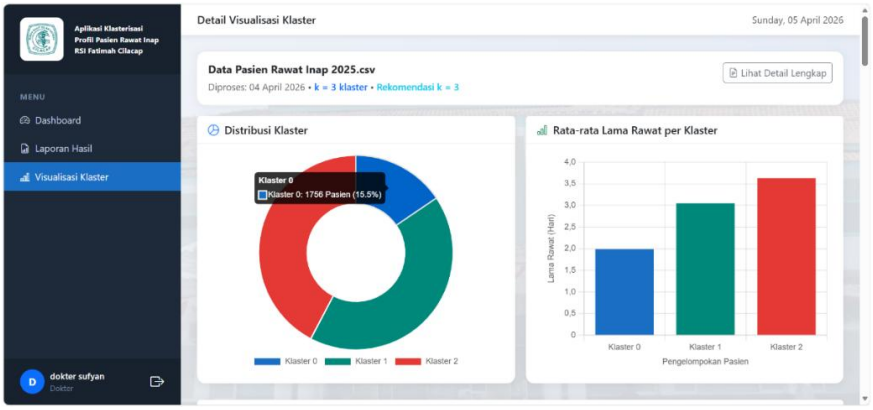
Gambar 59. Halaman Detail Visualisasi Klaster Tenaga Medis

Beberapa jenis visualisasi yang disajikan pada halaman ini guna mendukung analisis data pasien oleh tenaga medis dapat dijelaskan sebagai berikut:

1) Grafik Distribusi Klaster

Grafik distribusi klaster disajikan dalam bentuk grafik donat (*doughnut chart*) untuk memvisualisasikan proporsi jumlah pasien pada setiap klaster terhadap total keseluruhan data secara interaktif. Setiap potongan grafik menggunakan warna yang berbeda untuk merepresentasikan identitas tiap kelompok, lengkap dengan legenda di bagian bawah yang memuat nama beserta indikator warnanya. Visualisasi ini memungkinkan tenaga medis (dokter/perawat) untuk melihat sebaran beban pasien di rumah sakit secara instan dan makroskopis.

Pengguna dapat mengarahkan kursor (*hover*) ke area potongan grafik untuk memunculkan *tooltip* yang menampilkan informasi kuantitatif secara mendetail. Berdasarkan data pada gambar, terlihat klaster 0 mencakup 1.756 pasien (15,5%), klaster 1 mencakup 4.779 pasien (42,2%), serta klaster 2 muncul sebagai kelompok dominan dengan total 4.794 pasien (42,3%). Informasi ini sangat berguna bagi tenaga medis untuk mengidentifikasi kelompok pasien mana yang paling banyak ditangani dalam satu periode *dataset*, sehingga dapat menjadi acuan dalam penentuan prioritas dan peningkatan kualitas pelayanan, sebagaimana ditunjukkan pada Gambar 60.

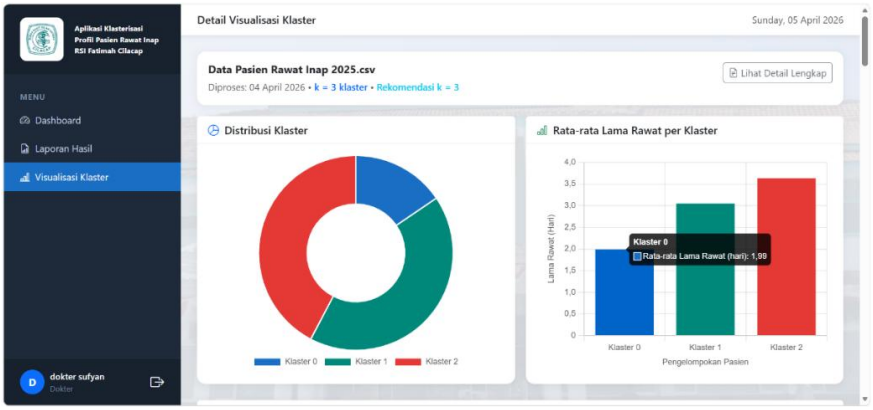


Gambar 60. Grafik Distribusi Klaster Tenaga Medis

2) Grafik Rata-Rata Lama Rawat per Klaster

Di sebelah kanan grafik distribusi, ditampilkan grafik rata-rata lama rawat per klaster dalam bentuk grafik batang vertikal (*bar chart*). Sumbu x pada grafik ini merepresentasikan pengelompokan pasien berdasarkan identitas klaster, sementara sumbu y menunjukkan nilai rata-rata durasi rawat inap dalam satuan hari. Setiap batang menggunakan warna khas klaster untuk memudahkan tenaga medis (dokter/perawat) dalam membandingkan efisiensi durasi perawatan antar-kelompok secara visual dan cepat.

Ketika kursor diarahkan ke setiap batang grafik, sistem akan menampilkan tooltip berisi nilai numerik yang presisi sebagai dasar analisis klinis. Terlihat bahwa klaster 0 memiliki rata-rata lama rawat tersingkat selama 1,99 hari, diikuti klaster 1 selama 3,05 hari, dan klaster 2 memiliki durasi rata-rata tertinggi yaitu 3,63 hari. Data ini memberikan gambaran kepada tenaga medis mengenai karakteristik kelompok pasien yang membutuhkan waktu pemulihan lebih lama di ruang rawat inap, sebagaimana ditunjukkan pada Gambar 61.

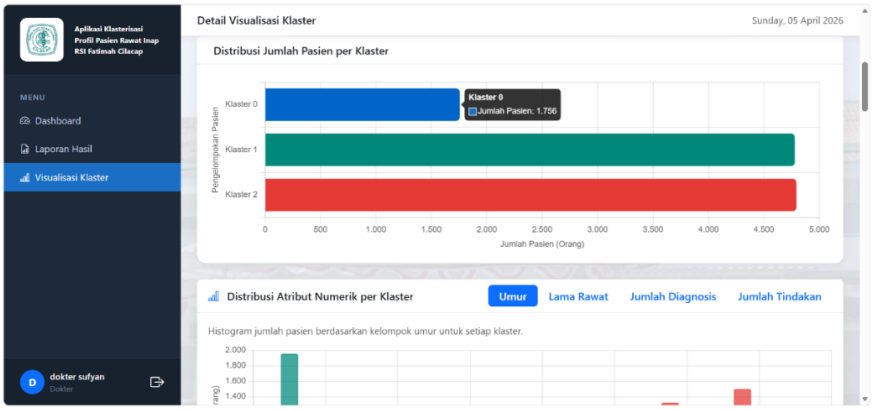


Gambar 61. Grafik Rata-Rata Lama Rawat per Klaster Tenaga Medis

3) Grafik Distribusi Jumlah Pasien per Klaster

Selanjutnya, ditampilkan grafik distribusi jumlah pasien per klaster dalam bentuk grafik batang horizontal (*horizontal bar chart*) yang membentang penuh pada satu baris halaman. Sumbu y pada grafik ini menampilkan nama masing-masing klaster sebagai kategori pengelompokan, sedangkan sumbu x menunjukkan kuantitas pasien dalam satuan orang. Grafik ini dirancang agar tenaga medis (dokter/perawat) dapat melihat perbandingan ukuran serta volume data setiap klaster secara langsung dan proporsional melalui perbedaan panjang batang.

Berdasarkan interaksi pada gambar, sistem menyediakan *tooltip* yang menunjukkan jumlah eksklusif pasien pada tiap kelompok untuk mendukung validasi data. Tercatat klaster 0 sebanyak 1.756 pasien, klaster 1 sebanyak 4.779 pasien, dan klaster 2 sebanyak 4.794 pasien. Visualisasi ini sangat efektif untuk membandingkan kapasitas pelayanan yang telah diberikan pada tiap klaster profil pasien, sebagaimana ditunjukkan pada Gambar 62.



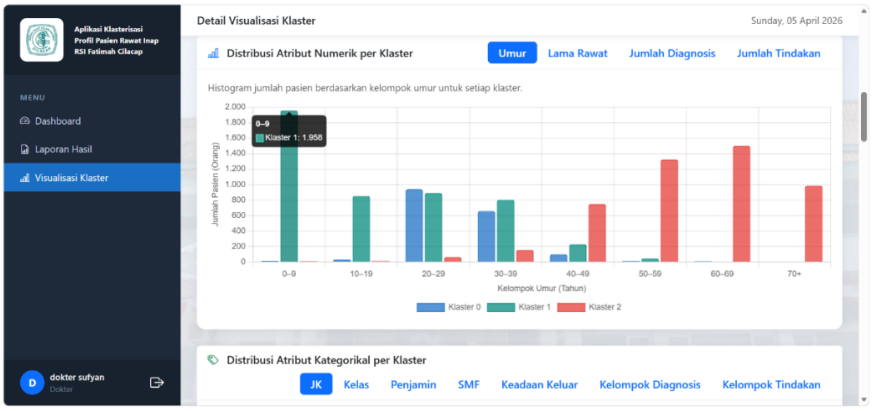
Gambar 62. Grafik Distribusi Jumlah Pasien per Klaster Tenaga Medis

4) Grafik Distribusi Atribut Numerik per Klaster

Bagian ini menyajikan analisis sebaran data melalui empat histogram interaktif yang dapat diakses melalui tab navigasi, yaitu umur, lama rawat, jumlah diagnosis, dan jumlah tindakan. Setiap histogram menggunakan grafik batang berkelompok (*grouped bar chart*) dengan warna identitas klaster untuk memudahkan perbandingan tren data antar-kelompok. Tenaga medis (dokter/perawat) dapat beralih antar tab untuk melihat frekuensi pasien berdasarkan kategori klinis tertentu, seperti tren kelompok usia atau intensitas beban pelayanan medis.

Berdasarkan interaksi pada gambar, sistem menyediakan *tooltip* yang memberikan detail kuantitatif pada kategori spesifik untuk pengamatan lebih mendalam. Sebagai contoh, pada tab umur, terlihat klaster 1 mendominasi kelompok usia anak 0-9 tahun dengan 1.958 pasien, sementara pada tab lama rawat, durasi 2 hari menjadi yang paling umum ditemukan. Analisis pada tab diagnosis dan tindakan menunjukkan bahwa mayoritas pasien di klaster 1 memiliki

1 diagnosis dan 0 tindakan, memberikan indikasi mengenai tingkat keparahan kasus pada kelompok tersebut, Integrasi fitur tab navigasi dan elemen visual yang dinamis ini sangat efektif. Tampilan grafik distribusi atribut numerik per klaster sebagaimana ditunjukkan pada Gambar 63.



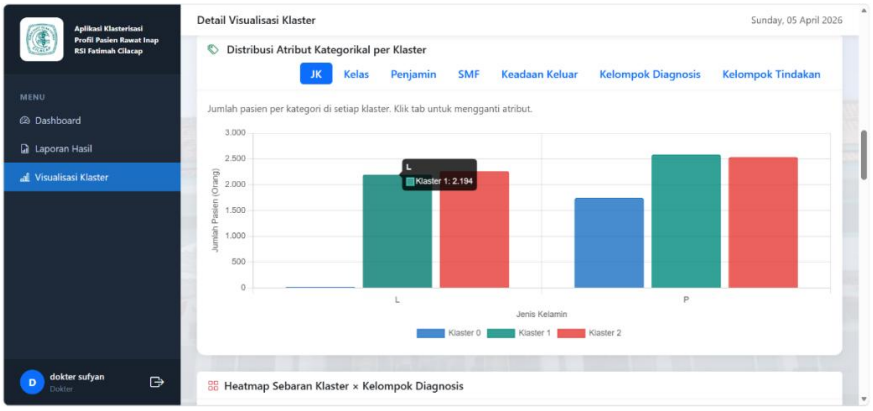
Gambar 63. Grafik Distribusi Atribut Numerik per Klaster Tenaga Medis

5) Grafik Distribusi Atribut Kategorikal per Klaster

Bagian ini menyajikan tujuh grafik batang berkelompok yang dapat diakses melalui tab navigasi untuk menganalisis distribusi atribut kualitatif pada setiap klaster secara mendalam. Tab yang tersedia meliputi JK (Jenis Kelamin), kelas perawatan, penjamin, SMF (Staf Medis Fungsional), keadaan keluar, serta kelompok diagnosis dan tindakan (Top 10). Setiap grafik memvisualisasikan jumlah pasien per kategori dengan pewarnaan yang konsisten, membantu tenaga medis mengenali profil setiap kelompok pasien.

Melalui rangkaian gambar, sistem menampilkan detail data spesifik pada tiap tab guna memudahkan evaluasi layanan. Pada tab JK, klaster 1 tercatat memiliki 2.194 pasien laki-laki (L). Pada tab

kelas, mayoritas pasien klaster 1 berada di kelas 1 (920 pasien), sementara BPJS kesehatan menjadi penanggung dominan dengan 3.680 pasien. Informasi medis juga terlihat pada tab SMF, keadaan keluar, kelompok diagnosis dan tindakan, sebagaimana ditunjukkan pada Gambar 64.

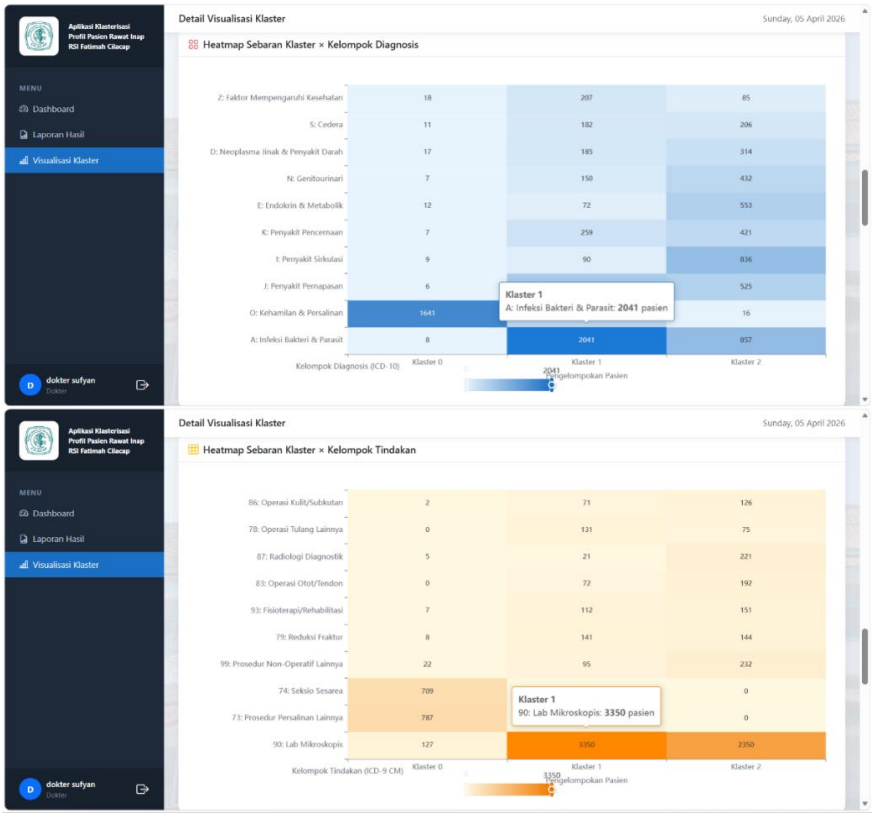


Gambar 64. Grafik Distribusi Atribut Kategorikal per Klaster Tenaga Medis

6) *Heatmap* Sebaran Klaster Kelompok Diagnosis dan Kelompok Tindakan

Bagian ini menyajikan dua grafik *heatmap* interaktif untuk menganalisis kepadatan hubungan antara klaster dengan atribut klinis spesifik menggunakan *library echarts*. *Heatmap* pertama memetakan matriks intensitas antara klaster dengan kategori diagnosis ICD-10, sedangkan *heatmap* kedua menunjukkan korelasi terhadap kategori tindakan ICD-9 CM. Penggunaan gradasi warna dari terang ke gelap berfungsi sebagai indikator visual kuantitas pasien, di mana warna yang lebih pekat menandakan populasi pasien yang terkonsentrasi pada kombinasi medis tersebut.

Berdasarkan interaksi pada gambar, sistem menampilkan *tooltip* berisi informasi presisi saat kursor diarahkan ke sel tertentu untuk membantu tenaga medis (dokter/perawat) mengenali tren penyakit. Pada *heatmap* diagnosis, terlihat klaster 1 memiliki konsentrasi sangat tinggi pada kategori "Infeksi Bakteri dan Parasit" (2.041 pasien). Pada *heatmap* tindakan, Klaster 1 menunjukkan pola dominansi kuat pada prosedur "Lab Mikroskopis" (3.350 pasien), yang sangat efektif untuk mengenali pola hubungan antar-klaster secara spasial. Selain itu, terdapat fitur visual map di bagian bawah setiap grafik untuk pemfilteran intensitas data secara *real-time*, sebagaimana ditunjukkan pada Gambar 65.

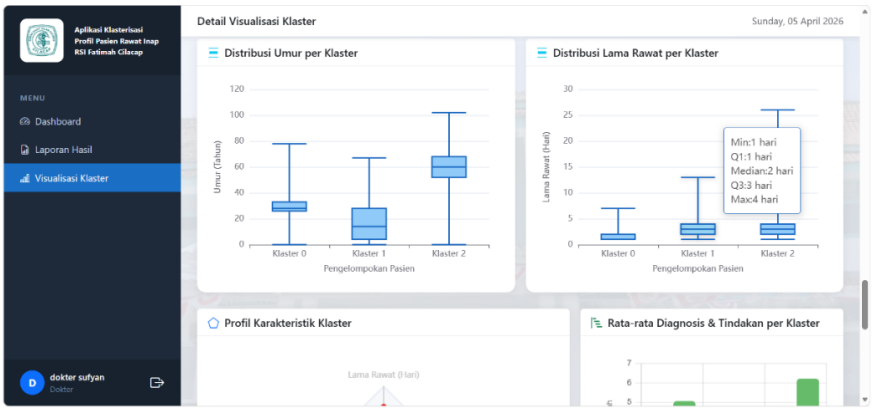


Gambar 65. *Heatmap* Sebaran Kelompok Diagnosis - Tindakan Tenaga Medis

7) *Box Plot* Distribusi Umur dan Lama Rawat per Klaster

Bagian ini menyajikan dua grafik *box plot* yang disusun berdampingan untuk menganalisis sebaran statistik data numerik menggunakan *library echarts*. Grafik pertama memvisualisasikan rentang usia pasien dalam satuan tahun, sedangkan grafik kedua menunjukkan sebaran durasi rawat inap dalam satuan hari. Melalui visualisasi ini, tenaga medis dapat mengidentifikasi nilai median, kuartil (Q1 dan Q3), hingga nilai minimum dan maksimum secara cepat untuk memahami konsistensi data pada tiap klaster.

Selain nilai statistik utama, grafik ini juga membantu dalam mendeteksi keberadaan *outlier* yang mewakili kasus medis luar biasa pada klaster tertentu. Pada grafik umur, klaster 1 menunjukkan profil pasien yang relatif muda dengan median 26 tahun. Sementara pada grafik lama rawat, klaster 1 memiliki distribusi durasi perawatan yang singkat dengan median 2 hari dan batas maksimum hanya 4 hari, sebagaimana ditunjukkan pada Gambar 66.

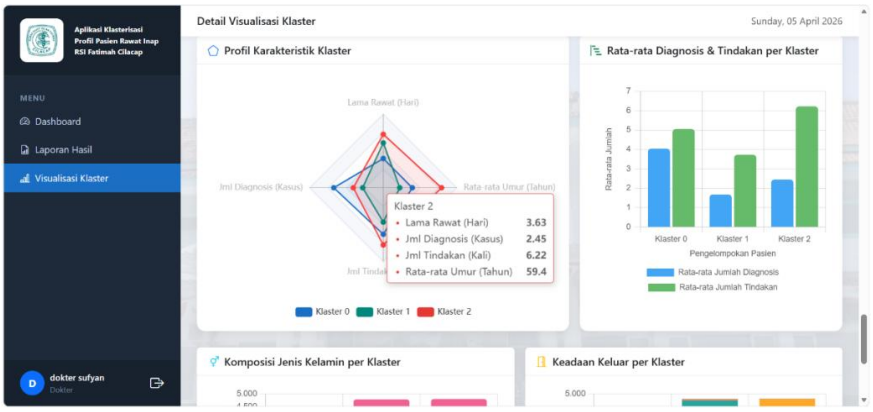


Gambar 66. *Box Plot* Distribusi Umur dan Lama Rawat Tenaga Medis

8) Grafik Profil Karakteristik Klaster dan Rata-Rata Diagnosis serta Tindakan

Bagian ini menyajikan dua grafik komplementer untuk menganalisis profil mendalam setiap kelompok pasien secara holistik. Grafik pertama menggunakan radar (*radar chart*) yang memetakan dimensi rata-rata umur, lama rawat, serta jumlah diagnosis dan tindakan dalam satu kesatuan poligon berwarna. Visualisasi ini sangat memudahkan tenaga medis (dokter/perawat) dalam membandingkan karakter multidimensi antar-klaster, sehingga perbedaan profil klinis antar-kelompok dapat terlihat dengan sangat jelas.

Grafik kedua menyajikan rata-rata jumlah diagnosis dan tindakan dalam bentuk batang berkelompok untuk memberikan perbandingan langsung intensitas layanan medis yang diterima pasien. Teridentifikasi bahwa klaster 2 memiliki karakteristik dengan rata-rata umur tertua (59,4 tahun) dan durasi rawat paling lama. Detail ini diperkuat pada grafik batang yang menunjukkan klaster 2 menerima beban tindakan medis tertinggi (6,22 kali) dibandingkan klaster lainnya, memberikan indikasi mengenai kompleksitas perawatan pada kelompok pasien lansia. Kedua grafik ini secara bersama-sama memberikan landasan analitis yang kuat dalam memahami kebutuhan perawatan yang berbeda-beda pada tiap klaster, sebagaimana ditunjukkan pada Gambar 67.



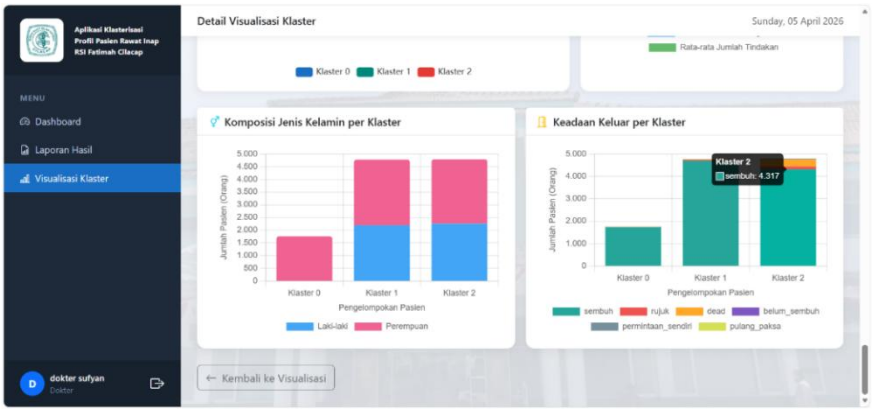
Gambar 67. Grafik Profil dan Rata-Rata Diagnosis serta Tindakan Tenaga Medis

9) Grafik Komposisi Jenis Kelamin dan Keadaan Keluar

Pada bagian terakhir, ditampilkan dua grafik batang bertumpuk (*stacked bar chart*) untuk menganalisis proporsi variabel kategorikal di setiap kelompok secara komparatif. Grafik pertama menunjukkan perbandingan populasi laki-laki dan perempuan dalam satu batang utuh, sedangkan grafik kedua memvisualisasikan distribusi status akhir pasien saat keluar dari rumah sakit. Model *stacked bar* ini sangat membantu tenaga medis (dokter/perawat) dalam mengidentifikasi pola karakteristik yang mendominasi pada masing-masing klaster.

Sistem menyediakan informasi detail melalui *tooltip* untuk setiap segmen warna guna memberikan kepastian data bagi tenaga medis. Pada grafik jenis kelamin, klaster 2 menunjukkan komposisi yang cukup berimbang antara pasien laki-laki dan perempuan. Sementara pada grafik keadaan keluar, terlihat klaster 2 didominasi status "sembuh" (4.317 orang), namun juga mencatat angka kematian (*dead*) sebanyak 325 pasien. Di bagian bawah halaman,

tersedia tombol navigasi untuk memudahkan tenaga medis kembali ke daftar visualisasi, sebagaimana ditunjukkan pada Gambar 68.



Gambar 68. Grafik Jenis Kelamin dan Keadaan Keluar Tenaga Medis

4.5.4. Pengujian

Pada tahap pengujian, seluruh fungsionalitas aplikasi klasterisasi profil pasien rawat inap diverifikasi guna memastikan sistem telah berjalan sesuai dengan spesifikasi kebutuhan yang dirancang. Adapun evaluasi ini menerapkan metode *black box testing* yang berfokus pada kesesuaian antara masukan pengguna dengan respon yang dihasilkan oleh antarmuka aplikasi. Melalui pendekatan ini, pengujian dilakukan murni pada aspek fungsionalitas tanpa melibatkan peninjauan terhadap struktur internal kode program di sisi *back-end*. Hasil dari serangkaian skenario pengujian tersebut akan diuraikan pada Tabel 8.

Tabel 8. Hasil *Black Box Testing*

Aktor	Kebutuhan	Nomor *Requirement*	Hasil Pengujian
Admin	***Login dan Logout***		
	Admin dapat mengakses aplikasi melalui proses *login*	UR.AKPPRI.A.01.001	Sesuai

	menggunakan email dan *password.*		
	Admin dapat melakukan *logout* dari sistem.	UR.AKPPRI.A.01.002	Sesuai
	Dashboard		
	Admin dapat mengakses halaman *dashboard.*	UR.AKPPRI.A.02.001	Sesuai
	Sistem menampilkan menu panduan aplikasi, riwayat klasterisasi per tahun, dan laporan hasil klasterisasi terbaru pada halaman *dashboard.*	UR.AKPPRI.A.02.002	Sesuai
	Upload Dataset		
	Admin dapat mengakses halaman *upload dataset.*	UR.AKPPRI.A.03.001	Sesuai
	Admin dapat meng-*upload* data pasien rawat inap dan memilih tahun data (format CSV / Excel).	UR.AKPPRI.A.03.002	Sesuai
	Sistem memvalidasi format dan isi data yang di-*upload* dan menampilkan pesan kesalahan jika data tidak valid.	UR.AKPPRI.A.03.003	Sesuai
	Sistem menyimpan data ke *database* dan menampilkan hasil *upload dataset.*	UR.AKPPRI.A.03.004	Sesuai
	Daftar *Dataset*		
	Admin dapat mengakses menu daftar *dataset.*	UR.AKPPRI.A.04.001	Sesuai
	Admin dapat melakukan proses lihat, edit baris, hapus baris, tambah kolom, dan hapus	UR.AKPPRI.A.04.002	Sesuai

	kolom data pada menu daftar *dataset.*		
	Admin dapat menghapus *dataset* yang telah di-*upload.*	UR.AKPPRI.A.04.003	Sesuai
	Proses Klasterisasi		
	Admin dapat mengakses halaman proses klasterisasi.	UR.AKPPRI.A.05.001	Sesuai
	Admin dapat memilih *dataset* dan jumlah klaster (k) untuk diproses.	UR.AKPPRI.A.05.002	Sesuai
	Admin dapat menjalankan proses klasterisasi K-Means.	UR.AKPPRI.A.05.003	Sesuai
	Sistem melakukan proses *preprocessing* data dan menghitung nilai *elbow*, *silhouette*, serta DBI untuk setiap klaster.	UR.AKPPRI.A.05.004	Sesuai
	Riwayat Klasterisasi		
	Admin dapat mengakses menu riwayat klasterisasi.	UR.AKPPRI.A.06.001	Sesuai
	Sistem menampilkan hasil klasterisasi pada menu riwayat klasterisasi dan menyimpan hasil klasterisasi ke *database.*	UR.AKPPRI.A.06.002	Sesuai
	Admin dapat melihat dan menghapus hasil klasterisasi pada menu riwayat klasterisasi.	UR.AKPPRI.A.06.003	Sesuai
	Laporan Hasil		
	Admin dapat mengakses halaman laporan hasil.	UR.AKPPRI.A.07.001	Sesuai
	Sistem menampilkan menu hasil klasterisasi dan	UR.AKPPRI.A.07.002	Sesuai

	admin dapat melakukan proses lihat detail dan hapus hasil klasterisasi.		
	Admin dapat memilih dan melihat detail hasil klasterisasi pada menu interpretasi per klaster, metode evaluasi penentuan k optimal k=2-10, dan data pasien per klaster.	UR.AKPPRI.A.07.003	Sesuai
	Admin dapat mencari data pasien per klaster pada halaman detail hasil klasterisasi.	UR.AKPPRI.A.07.004	Sesuai
	Visualisasi Klaster		
	Admin dapat mengakses halaman visualisasi klaster.	UR.AKPPRI.A.08.001	Sesuai
	Sistem menampilkan menu visualisasi hasil klasterisasin dan admin dapat memilih dan melihat grafik visualisasi klaster.	UR.AKPPRI.A.08.002	Sesuai
	Manajemen *User*		
	Admin dapat mengakses halaman manajemen *user.*	UR.AKPPRI.A.09.001	Sesuai
	Sistem menampilkan menu daftar akun pengguna dan admin dapat melakukan proses tambah, edit, dan hapus akun pengguna.	UR.AKPPRI.A.09.002	Sesuai
	Admin dapat menambahkan akun pengguna baru.	UR.AKPPRI.A.09.003	Sesuai

	Admin dapat mengedit akun pengguna.	UR.AKPPRI.A.09.004	Sesuai
	Admin dapat menghapus akun pengguna.	UR.AKPPRI.A.09.005	Sesuai
Tenaga Medis	***Login dan Logout***		
	Tenaga medis dapat mengakses aplikasi melalui proses *login* menggunakan email dan *password.*	UR.AKPPRI.TM.01.001	Sesuai
	Tenaga medis dapat melakukan *logout* dari sistem.	UR.AKPPRI.TM.01.002	Sesuai
	Dashboard		
	Tenaga medis dapat mengakses halaman *dashboard.*	UR.AKPPRI.TM.02.001	Sesuai
	Sistem menampilkan menu buku panduan aplikasi, riwayat klasterisasi per tahun, dan laporan hasil klasterisasi terbaru pada halaman *dashboard.*	UR.AKPPRI.TM.02.002	Sesuai
	Laporan Hasil		
	Tenaga medis dapat mengakses halaman laporan hasil.	UR.AKPPRI.TM.03.001	Sesuai
	Sistem menampilkan menu hasil klasterisasi dan tenaga medis dapat melihat detail hasil klasterisasi.	UR.AKPPRI.TM.03.002	Sesuai
	Tenaga medis dapat memilih dan melihat detail hasil klasterisasi pada menu interpretasi per klaster, metode evaluasi penentuan k optimal k=2-10, dan	UR.AKPPRI.TM.03.003	Sesuai

	data pasien per klaster.		
	Tenaga medis dapat mencari data pasien per klaster pada halaman detail hasil klasterisasi.	UR.AKPPRI.TM.03.004	Sesuai
	Visualisasi Klaster		
	Tenaga medis dapat mengakses halaman visualisasi klaster.	UR.AKPPRI.TM.04.001	Sesuai
	Sistem menampilkan menu visualisasi hasil klasterisasi dan tenaga medis dapat memilih dan melihat grafik visualisasi klaster.	UR.AKPPRI.TM.04.002	Sesuai

4.5.5. Pemeliharaan

Pada tahap pemeliharaan, seluruh fungsionalitas aplikasi klasterisasi profil pasien rawat inap dikelola melalui upaya berkelanjutan guna menjaga relevansi sistem terhadap kebutuhan pengguna. Adapun proses evaluasi ini mencakup peninjauan berkala pada penyajian data serta pembaruan elemen teknis yang meliputi struktur data, logika algoritma, hingga aspek antarmuka pengguna. Selain penanganan terhadap celah kesalahan (*error*), tahap ini juga menitikberatkan pada pengumpulan umpan balik dari tenaga medis maupun admin sebagai landasan dalam pengembangan fitur atau peningkatan performa aplikasi. Hasil dari strategi pemeliharaan sistem tersebut akan diuraikan lebih lanjut guna memastikan keberlanjutan operasional aplikasi.

BAB V
PENUTUP

5.1. Kesimpulan

Berdasarkan hasil penelitian klasterisasi profil pasien rawat inap di Rumah Sakit Islam Fatimah Cilacap menggunakan algoritma K-Means, dapat ditarik kesimpulan bahwa:

1. Algoritma K-Means berhasil diterapkan dalam proses klasterisasi profil pasien rawat inap dengan melalui tahapan pengumpulan data, data *preprocessing*, klasterisasi dengan K-Means, evaluasi, dan perancangan aplikasi berbasis *website*. Hasil klasterisasi menunjukkan terbentuknya tiga klaster. Klaster 0 terdiri dari 1.756 pasien (15,5%) yaitu kelompok pasien usia produktif dengan diagnosis dominan Kehamilan dan Persalinan serta pelayanan medis Spesialis Kebidanan dan Kandungan. Klaster 1 merupakan kelompok terbesar kedua dengan jumlah 4.779 pasien (42,2%) yaitu kelompok pasien usia anak dan remaja dengan diagnosis dominan Infeksi Bakteri dan Parasit serta pelayanan medis Spesialis Anak Anak. Sementara itu, Klaster 2 merupakan kelompok terbesar dengan jumlah 4.794 pasien (42,3%) yaitu kelompok pasien usia lanjut dengan diagnosis dominan Infeksi Bakteri dan Parasit serta pelayanan medis Spesialis Penyakit Dalam. Ketiga klaster memiliki kesamaan pada penjamin dominan BPJS Kesehatan, kelas perawatan Kelas 3, dan keadaan keluar umumnya Sembuh.
2. Tiga metode evaluasi berhasil diterapkan dalam proses penentuan jumlah klaster optimal, yaitu metode *Elbow*, *Silhouette Score*, dan *Davies-Bouldin Index* (DBI).

Masing-masing metode menghitung nilai metrik untuk rentang k = 2 hingga k = 10. Hasil evaluasi menunjukkan bahwa ketiga metode sepakat merekomendasikan k = 3 sebagai jumlah klaster optimal. *Elbow Method* menunjukkan titik *elbow* pada k = 3 dengan nilai WCSS sebesar 49.148,10, *Silhouette Score* tertinggi diperoleh pada k = 3 dengan nilai 0,2215 yang mengindikasikan bahwa pembagian data ke dalam tiga klaster mampu mencerminkan kedekatan antar objek dalam satu klaster dan pemisahan antar klaster yang baik, serta *Davies-Bouldin Index* terendah diperoleh pada k = 3 dengan nilai 1,5231 yang menunjukkan bahwa klaster yang terbentuk memiliki karakteristik yang kompak dan terpisah dengan baik. Konsensus ketiga metode tersebut memperkuat validitas bahwa k = 3 merupakan jumlah klaster yang paling optimal untuk *dataset* pasien rawat inap RSI Fatimah Cilacap.

3. Pengembangan aplikasi berbasis *website* berhasil dilakukan untuk menampilkan hasil klasterisasi profil pasien rawat inap dengan menggunakan metode pengembangan perangkat lunak *Waterfall*. Aplikasi dibangun menggunakan *framework Laravel* sebagai *back-end* utama yang terintegrasi dengan Flask API (*Python*) sebagai mesin komputasi klasterisasi. Aplikasi ini memiliki dua peran pengguna, yaitu Admin yang memiliki akses penuh untuk mengelola *dataset*, menjalankan proses klasterisasi, melihat laporan hasil, visualisasi klaster, dan manajemen *user*, serta Tenaga Medis (Dokter/Perawat) yang dapat melihat *dashboard*, laporan hasil, dan visualisasi klaster tanpa hak untuk mengelola data. Aplikasi menyediakan fitur evaluasi klaster yang komprehensif dengan menampilkan grafik *line chart* untuk metode *Elbow*, *Silhouette Score*, dan

Davies-Bouldin Index, interpretasi per klaster secara detail, serta visualisasi interaktif yang meliputi grafik donat, *bar chart*, histogram, *heatmap*, *box plot*, grafik radar, dan *stacked bar chart* untuk mendukung analisis profil pasien secara mendalam.

5.2. Saran

Berdasarkan hasil penelitian ini, dirumuskan sejumlah rekomendasi strategis yang dapat dijadikan acuan dalam melakukan penelitian dan pengembangan lebih lanjut guna mengoptimalkan performa sistem di masa mendatang, yaitu sebagai berikut:

1. Penelitian selanjutnya disarankan untuk menambahkan atribut lain yang lebih beragam dalam proses klasterisasi, seperti data biaya perawatan, riwayat kunjungan, atau data klinis yang lebih rinci, sehingga tidak hanya terbatas pada 11 atribut yang digunakan saat ini. Penambahan atribut ini dapat membantu menghasilkan pengelompokan profil pasien yang lebih akurat dan memberikan gambaran kondisi pasien rawat inap secara lebih menyeluruh.
2. Integrasi aplikasi dengan Sistem Informasi Manajemen Rumah Sakit (SIMRS) dapat menjadi langkah lanjutan agar proses analisis klasterisasi dapat dilakukan secara *real-time* tanpa perlu mengunggah data secara manual, sehingga hasil klasterisasi dapat langsung dimanfaatkan untuk mendukung pengambilan keputusan yang lebih tepat sasaran berdasarkan karakteristik masing-masing klaster pasien.

DAFTAR PUSTAKA

Anggraini, D., Hutabarat, R. A. N., Sitorus, S. D. L., Nabilah, W. N., & Hutapea, T. A. (2025). Visualisasi Supremum dan Infimum Menggunakan Pemrograman Python. *Jurnal Media Akademik (JMA)*, *3*(4), 3031–5220. https://doi.org/10.62281

Anggreani, S., & Yahfizham. (2024). Pengantar dan Pengenalan Konsep Dasar Algoritma Pemrograman. *Pendekar : Jurnal Pendidikan Berkarakter*, *2*(1), 282–294. https://doi.org/10.51903/pendekar.v2i1.599

Handika, I. G., & Purbasari, A. (2018). *Pemanfaatan Framework Laravel Dalam Pembangunan Aplikasi E-Travel Berbasis Website*.

Hardiansyah, M., Sari, B. N., & Maulana, I. (2025). Perbandingan Algoritma K-Means dan K-Medoids untuk Clustering Penderita Pneumonia di Kabupaten Karawang. *Jurnal Informatika dan Teknik Elektro Terapan*, *13*(3S1). https://doi.org/10.23960/jitet.v13i3S1.7599

Kansha, W. M., Saherih, & Muchlis. (2023). Analisis Perbandingan Struktur dan Performa Framework Codeigniter dan Laravel dalam Pengembangan Web Application. *JURNAL TEKNIK INFORMATIKA STMIK ANTAR BANGSA*, *09*(01), 25–31.

Kristanto, H. Y. W. (2019). Profil pemecahan masalah sistem persamaan linear tiga variabel siswa SMA ditinjau dari perbedaan jenis kelamin. *Jurnal Program Studi Pendidikan Matematika*, *5*(2), 115–122.

Mabrur, A. G., & Lubis, R. (2012). Penerapan Data Mining untuk Memprediksi Kriteria Nasabah Kredit. Dalam *Jurnal Komputer dan Informatika (KOMPUTA) 53 Edisi. I* (Nomor 1).

Maori, N. A. (2023). Metode Elbow dalam Optimasi Jumlah Cluster pada K-Means Clustering. *Jurnal SIMETRIS*, *14*(2).

Ma'rifatin, U. (2020). *Implementasi Algoritma K-Means untuk Pengelompokan Penyakit Pasien Pada Puskesmas Warujayeng*.

Maryati, W., Widyastuti, A., Pinta, A., Rizky, K., Listyorini, P. I., & Aryanti, F. D. (2022). *Analisis Karakteristik Pada Pasien Rawat Inap Kasus Covid-19* (Vol. 12).

Masruriyah, A. F. N., Mardiah, Ananda, M. D., & Malik, K. N. (2025). Pendekatan Unsupervised learning dalam Segmentasi Kesehatan: Perbandingan K-Means dan DBSCAN. *MIND (Multimedia Artificial Intelligent Networking*

Database) Journal, *10*(1), 99–113. https://doi.org/10.26760/mindjournal.v10i1.99-113

Maulana, G. G. (2017). Pembelajaran Dasar Algoritma dan Pemrograman Menggunakan EL-Goritma Berbasis Web. Dalam *Jurnal Teknik Mesin (JTM)* (Vol. 06).

Ningki, C., & Noviyanti.P. (2023). Implementasi Aplikasi Penjualan Produk Tradisional Berbasis Website Menggunakan Metode Waterfall. *JURNAL INFORMATIK*, *19*(2).

Noviana, R. (2022). Pembuatan Aplikasi Penjualan Berbasis Web Monja Store Menggunakan PHP dan MySQL. *JTS (Jurnal Teknik dan Science)*, *1*(2), 112–124.

Nugroho, M. R., Hendrawan, I. E., & Puwantoro. (2022). Penerapan Algoritma K-Means Untuk Klasterisasi Data Obat Pada Rumah Sakit ASRI. *JURNAL NUANSA INFORMATIKA*, *16*(1). https://journal.uniku.ac.id/index.php/ilkom

Putra, A. P., Tshivana, J., & Rilvani, E. (2025). Perbandingan Teoritis dan Eksperimen Algoritma K-Means dan K-Medoids dalam Klasterisasi Data. *Kohesi: Jurnal Multidisiplin Saintek*, *10*(2). https://doi.org/10.8734/Kohesi.v1i2.365

Rasyida, A., Ardhyananta, H., Hidayat, M. I. P., Wicaksono, S. T., Susanti, D., Nurdiansah, H., & Andini, E. F. (2025). Pelatihan Pemrograman Komputer Berbasis Python bagi Siswa SMAIT Al Uswah Surabaya. *SEWAGATI*, *9*(3), 756–765. https://doi.org/10.12962/j26139960.v9i3.2599

Ratman, M. N., Amanda, N. N., Oktapia, S., & Pangestoeti, W. (2025). Program Kelas Rawat Inap Standar (KRIS): Analisis Ekonomi Publik atas Pemerataan Layanan Kesehatan Nasional. *Jurnal Ilmu Komunikasi Dan Sosial Politik*, *02*(04), 1303–1308. https://jurnal.ittc.web.id/index.php/jiksp/index

Risdiansyah, D., & Fitriana, L. A. (2025). Pengembangan Sistem Informasi Pemesanan Makanan (SIMAKAN) Berbasis Web menggunakan Metode Waterfall. *Jurnal Rekayasa Perangkat Lunak*, *6*(1).

Rohmawati, N. W., Defiyanti, S., & Jajuli, M. (2015). Implementasi Algoritma K-Means dalam Pengklasteran Mahasiswa Pelamar Beasiswa. Dalam *Jurnal Ilmiah Teknologi Informasi Terapan: I* (Nomor 2).

Rubiati, N., & Harahap, S. W. (2019). Aplikasi Absensi Siswa Menggunakan QR Code dengan Bahasa Pemrograman PHP di SMKIT Zunurain Aqila Zahra di Pelintung. *Jurnal Informatika, Manajemen dan Komputer*, *11*(1), 62–70.

Rusli, S. (2022). *Implementasi Sistem Informasi Manajemen Rumah Sakit dalam Pengolahan Data Rumah Sakit*.

Sanjaya, G., Rinaldi, A. R., Basysya, F. M., & Fathurrohman. (2024). *Penerapan Algoritma K-Means untuk Mengelompokkan Berbagai Jenis Smartphone Berdasarkan Spesifikasi*. https://ikmi.ac.id/page/18/?lang=de

Sapuan, I., Fauzan, M. H., & Juliane, C. (2022). Implementasi Data Mining untuk Klasterisasi dan Prediksi Kelompok Keluarga. *JTERA (Jurnal Teknologi Rekayasa)*, *7*(1), 149. https://doi.org/10.31544/jtera.v7.i1.2022.149-156

Setyani, T., Heidy, H. N., Sari, K., Indriani, Y., & Sulistiani, H. (2025). Perbandingan Kinerja Algoritma K-Means dan DBSCAN dalam Segmentasi Nasabah Berdasarkan Data Pemasaran Bank. *Prosiding Seminar Nasional Teknologi Komputer dan Sains*, *3*(1), 376–382. https://prosiding.seminars.id/sainteks

Sifa, D., Nikmah, N., & Dinar, D. (2024). Gambaran Penyimpanan Obat di Gudang Obat Instalasi Farmasi Rumah Sakit Islam Fatimah Cilacap. *repository.universitasalirsyad.ac.id*.

Sjamsuddin, I. N., Firmansyah, D. A., & Laferani, Y. (2025). Klasterisasi Pasien Rawat Inap BPJS pada RS Islam Assyifa Sukabumi Menggunakan Metode K-Means. Dalam *Pasien Rawat Inap BPJS pada RS Islam Assyifa Sukabumi menggunakan Metode K-Means* (Vol. 7).

Sophian, S., Tinggi, S., & Kbp, I. E. (2023). Sistem Informasi Pengolahan Data Pasien di Puskesmas. *JEECOM*, *5*(1).

Sucipto, A. (2019). Klasterisasi Calon Mahasiswa Baru Menggunakan Algoritma K-Means. Dalam *Jurnal Science Tech* (Vol. 5, Nomor 2).

Ubaidillah, M. R., Santoso, N. A., & Utami, E. U. S. (2025). Penerapan K-Means Clustering untuk Klasifikasi Jenis Beras Berdasarkan Tren Harga di Pasar Induk Beras Cipinang (PIBC). *RIGGS: Journal of Artificial Intelligence and Digital Business*, *4*(3), 4300–4306. https://doi.org/10.31004/riggs.v4i3.2594

Yolandari, N. A., Butarbutar, L. E., Rajagukguk, G. C. H., Zulfi, M. F., Arnita, & Ramadhani, F. (2025). Analisis Perbandingan K-Means dan DBSCAN dalam Pengelompokan Data Travel Review Ratings Menggunakan Evaluasi Silhouette Index dan Davies-Bouldin Index. *JITET (Jurnal Informatika dan Teknik Elektro Terapan)*, *13*(3). https://doi.org/10.23960/jitet.v13i3.6884

LAMPIRAN

Lampiran 1: Berita Acara Penyerahan dan Pengujian Aplikasi

0282 - 542396
0282 - 541065
rsifc@yahoo.co.id

YAYASAN RUMAH SAKIT ISLAM FATIMAH CILACAP
RUMAH SAKIT ISLAM FATIMAH CILACAP
Jl. Ir. H. Juanda No. 20 Cilacap, Jawa Tengah 53235

بِسْمِ اللَّهِ الرَّحْمَٰنِ الرَّحِيمِ

BERITA ACARA PENYERAHAN DAN PENGUJIAN
APLIKASI KLASTERISASI PROFIL PASIEN RAWAT INAP
MENGGUNAKAN ALGORTIMA K-MEANS
RUMAH SAKIT ISLAM FATIMAH CILACAP

Berita Acara Penyerahan dan Pengujian aplikasi, dibuat pada hari **Sabtu** tanggal **Delapan Belas** bulan **April** tahun **Dua Ribu Dua Puluh Enam**, (18 - 04 - 2026). Yang bertanda tangan di bawah ini :

Nama : Dedi Mulyana
Jabatan : Kepala Instalasi PDE (IT)

Menyatakan bahwa telah dilaksanakan penyerahan dan pengujian (*testing*) terhadap Aplikasi Klasterisasi Profil Pasien Rawat Inap Menggunakan Algoritma K-Means Rumah Sakit Islam Fatimah Cilacap dengan status sebagai admin dalam aplikasi, dengan hasil bahwa aplikasi telah dibuat sesuai dengan kebutuhan dan berjalan sesuai prosedur yang berlaku.

Demikian berita acara penyerahan dan pengujian ini dibuat agar digunakan sebaik-baiknya.

Cilacap, 18 April 2026
Penguji,

Dedi Mulyana
Kepala Instalasi PDE (IT)