PROPOSAL TUGAS AKHIR

IMPLEMENTASI *RETRIEVAL-AUGMENTED GENERATION (RAG)* PADA ASISTEN VIRTUAL UNTUK PENINGKATAN LAYANAN INFORMASI DALAM PENGEMBANGAN WEBSITE SIWUR.ID BERBASIS TALL STACK

SKRIPSI

Diajukan Untuk Memenuhi Persyaratan Memperoleh Gelar
Sarjana Komputer

Disusun Oleh:

Ageng Praba Wijaya

H1D022016

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI

UNIVERSITAS JENDERAL SOEDIRMAN

FAKULTAS TEKNIK

JURUSAN INFORMATIKA

PURWOKERTO

2025

LEMBAR PENGESAHAN

Proposal Tugas Akhir dengan Judul:

IMPLEMENTASI *RETRIEVAL-AUGMENTED GENERATION (RAG)* PADA ASISTEN VIRTUAL UNTUK PENINGKATAN LAYANAN INFORMASI DALAM PENGEMBANGAN WEBSITE SIWUR.ID BERBASIS TALL STACK

Disusun Oleh:

Ageng Praba Wijaya

H1D022016

Diajukan untuk memenuhi salah satu persyaratan memperoleh gelar Sarjana Komputer pada Jurusan Informatika Fakultas Teknik Universitas Jenderal Soedirman

Diterima dan disetujui

Pada tanggal : ……

Pembimbing I	**Pembimbing II**
Ir. SWAHESTI PUSPITA R, S.Kom., M.T.	**AGUS DARMAWAN, S.Kom., M.Cs .**
NIP. 198107052008012024	**NIP. 199008172024061001**

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT atas segala rahmat, karunia, dan hidayah-Nya, sehingga penulis dapat menyelesaikan proposal penelitian dengan judul "Implementasi *Retrieval-Augmented Generation (RAG)* pada Asisten Virtual untuk Peningkatan Layanan Informasi dalam Pengembangan Website siwur.id Berbasis Tall Stack" dengan baik dan tepat waktu. Penyusunan proposal ini merupakan salah satu syarat untuk menyelesaikan pendidikan Strata Satu (S1) di Jurusan Informatika, Fakultas Teknik, Universitas Jenderal Soedirman. Penelitian ini diharapkan dapat memberikan kontribusi dalam pengembangan ilmu pengetahuan khususnya di bidang pemanfaatan teknologi *Retrieval-Augmented Generation (RAG)* untuk asisten virtual pada aplikasi berbasis web modern dengan TALL Stack, serta menjadi referensi bagi penelitian sejenis yang berfokus pada integrasi kecerdasan buatan dalam pengembangan sistem informasi berbasis web..

Penulis menyadari sepenuhnya bahwa selesainya proposal penelitian ini tidak terlepas dari dukungan, doa, serta bantuan berbagai pihak. Oleh karena itu, dengan segala kerendahan hati penulis mengucapkan terima kasih kepada:

1. Allah SWT. yang selalu memberikan kesehatan, kekuatan, dan kesempatan kepada penulis.
2. Kedua orang tua yang senantiasa memberikan doa, kasih sayang, dukungan dan motivasi yang tiada henti.
3. Bapak Prof. Dr. Eng. Agus Maryoto, S.T., M.T. selaku Dekan Fakultas Teknik, Universitas Jenderal Soedirman.
4. Bapak Dr. Lasmedi Afuan, S.T., M.Cs. selaku Ketua Jurusan Informatika Fakultas Teknik Universitas Jenderal Soedirman.
5. Ibu Ir. Swahesti Puspita Rahayu, S.Kom., M.T. selaku Dosen Pembimbing I dan Bapak Agus Darmawan, S.Kom., M.Cs. selaku Dosen Pembimbing II yang telah memberikan arahan dan bimbingan kepada penulis.

6. Bapak Mohammad Irham Akbar, S.Kom., M.Cs. yang telah mengizinkan penulis untuk magang di CV. Jenderal Solusi Digital.
7. Teman-teman seperjuangan di Jurusan Informatika yang selalu memberikan semangat dan dukungan dalam suka maupun duka.
8. Semua pihak yang tidak dapat penulis sebutkan satu per satu, namun telah memberikan bantuan baik secara langsung maupun tidak langsung.

Penulis menyadari bahwa proposal penelitian ini masih jauh dari sempurna. Oleh karena itu, kritik dan saran yang membangun sangat penulis harapkan demi penyempurnaan penelitian ini di masa yang akan datang. Akhir kata, semoga proposal penelitian ini dapat bermanfaat bagi penulis sendiri maupun bagi pihak lain yang tertarik pada bidang penelitian serupa.

Purbalingga, 25 September 2025

Ageng Praba Wijaya

DAFTAR ISI

LEMBAR PENGESAHAN i
KATA PENGANTAR ii
DAFTAR ISI iv
DAFTAR GAMBAR vi
DAFTAR TABEL vii
ABSTRAK viii
ABSTRACT ix
BAB I PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Rumusan Masalah 3
1.3 Pertanyaan Penelitian 3
1.4 Tujuan Penelitian 3
1.5 Batasan Masalah 4
1.6 Manfaat Penelitian 5
BAB II TINJAUAN PUSTAKA 6
2.1 Teori Dasar 6
2.1.1 Kecerdasan Buatan 7
2.1.2 *Natural Language Processing (NLP)* 7
2.1.3 *Asisten Virtual (Virtual Assistant)* 8
2.1.4 *Large Language Models (LLM)* 8
2.1.5 *Retrieval-Augmented Generation (RAG)* 9
2.1.6 *Retrieval-Augmented Generation Assessment (RAGAS)* 11
2.1.7 *Website* Siwur.id 12
2.1.8 Bahasa Pemrograman 13
2.1.9 MySQL 14
2.1.10 TALL *Stack* 14
2.1.11 GeminiAI Flash 2.5 16
2.1.12 ChromaDB 16

2.1.13 *Embedding Sentence Transformer* 16
2.1.14 Metode *Rapid Application Development (RAD)* 17
2.2 Penelitian Sejenis 18
BAB III METODE PENELITIAN 21
3.1 Waktu dan Tempat Penelitian 21
3.2 Data dan Alat Penelitian 21
3.2.1 Data Penelitian 21
3.2.2 Alat Penelitian 22
3.3 Tahapan Penelitian 22
3.3.1 Perencanaan Kebutuhan 23
3.3.2 Desain Sistem 24
3.3.3 Pengembangan Sistem 25
3.4 Jadwal Penelitian 26
DAFTAR PUSTAKA 27

DAFTAR GAMBAR

Gambar 1. Cara Kerja RAG (Gao et all, 2024)..... 10
Gambar 2. Metode Pengembangan RAD (Pressman, 2010)..... 17
Gambar 3. Tahapan Penelitian 23
Gambar 4. Flowchart Asisten Virtual Siwur.id..... 24

DAFTAR TABEL

Tabel 1. Penelitian Sejenis 18
Tabel 2. Jadwal Penelitian..... 26

ABSTRAK

IMPLEMENTASI *RETRIEVAL-AUGMENTED GENERATION (RAG)* PADA ASISTEN VIRTUAL UNTUK PENINGKATAN LAYANAN INFORMASI DALAM PENGEMBANGAN WEBSITE SIWUR.ID BERBASIS TALL STACK

Ageng Praba Wijaya

H1D022016

Di era digital, kebutuhan pengguna terhadap akses informasi yang cepat, relevan, dan terpercaya melalui website semakin meningkat. Namun, metode konvensional seperti *Frequently Asked Questions (FAQ)* statis dan pencarian berbasis kata kunci seringkali belum mampu menjawab pertanyaan kompleks secara efisien. Untuk menjawab tantangan tersebut, penelitian ini mengusulkan implementasi asisten virtual berbasis *Retrieval-Augmented Generation (RAG)* pada website Siwur.id yang dikembangkan menggunakan TALL Stack (Tailwind CSS, Alpine.js, Laravel, Livewire). RAG dipilih karena mampu menggabungkan kekuatan pencarian berbasis basis pengetahuan terkurasi dengan kemampuan generatif *Large Language Model (LLM),* sehingga jawaban yang dihasilkan lebih relevan, kontekstual, dan dapat dipertanggungjawabkan. Sistem kecerdasan buatan dibangun sebagai layanan *backend* terpisah menggunakan FastAPI (Python), dengan Google Gemini API sebagai LLM, ChromaDB sebagai *vector store,* dan Sentence-Transformers untuk *embedding*. Metode penelitian yang digunakan adalah *Rapid Application Development (RAD)* yang menekankan iterasi cepat dan keterlibatan pengguna. Evaluasi kinerja dilakukan menggunakan kerangka kerja RAGAS *(Retrieval-Augmented Generation Assessment)* yang mengukur metrik *faithfulness, answer relevancy, context precision,* dan *context recall*. Hasil penelitian diharapkan mampu menunjukkan bahwa integrasi RAG pada asisten virtual Siwur.id dapat meningkatkan kualitas layanan informasi, mengurangi halusinasi jawaban, serta menjadi acuan praktis dalam pengembangan sistem serupa pada domain lain.

Kata Kunci : *Retrieval-Augmented Generation,* RAGAS, Asisten Virtual, TALL Stack, *Large Language Model (LLM)*

ABSTRACT

IMPLEMENTATION OF RETRIEVAL-AUGMENTED GENERATION (RAG) ON VIRTUAL ASSISTANT TO ENHANCE INFORMATION SERVICES IN THE DEVELOPMENT OF THE SIWUR.ID WEBSITE BASED ON THE TALL STACK

Ageng Praba Wijaya

H1D022016

In the digital era, user expectations for fast, relevant, and reliable access to information through websites are constantly increasing. However, conventional approaches such as static Frequently Asked Questions (FAQ) and keyword-based search often fail to provide efficient answers to complex queries. To address this challenge, this research proposes the implementation of a Retrieval-Augmented Generation (RAG)-based virtual assistant on the Siwur.id website, developed using the TALL Stack (Tailwind CSS, Alpine.js, Laravel, Livewire). RAG is employed to combine the strengths of curated knowledge-base retrieval with the generative capabilities of Large Language Models (LLMs), thus enabling the system to generate more contextually relevant and accountable responses. The AI service is developed as a separate backend using FastAPI (Python), leveraging the Google Gemini API as the LLM, ChromaDB as the vector store, and Sentence-Transformers for embedding. The research adopts the Rapid Application Development (RAD) methodology, which emphasizes rapid iteration and active user involvement. System performance is evaluated using the RAGAS (Retrieval-Augmented Generation Assessment) framework, measuring faithfulness, answer relevancy, context precision, and context recall. The results are expected to demonstrate that integrating RAG into Siwur.id's virtual assistant can improve the quality of information services, reduce hallucinated responses, and provide a practical reference for the development of similar systems in other domains.

Keywords: *Retrieval-Augmented Generation, RAGAS, Virtual Assistant, TALL Stack, Large Language Model (LLM)*

BAB I
PENDAHULUAN

1.1 Latar Belakang

Di era digital saat ini, website telah menjadi garda terdepan dalam penyediaan informasi bagi berbagai institusi, termasuk portal seperti siwur.id. Ekspektasi pengguna terhadap akses informasi yang cepat, tepat, dan relevan semakin meningkat. Namun, metode penyampaian informasi konvensional pada website, seperti halaman *FAQ (Frequently Asked Questions)* yang statis atau fungsi pencarian berbasis kata kunci, seringkali memiliki keterbatasan. Pengguna kerap kali kesulitan menemukan jawaban spesifik untuk pertanyaan mereka yang kompleks dan harus menghabiskan waktu menavigasi berbagai halaman, yang pada akhirnya dapat menimbulkan frustasi dan menurunkan kepuasan pengguna (Nurwanda et al., 2024).

Untuk mengatasi tantangan tersebut, pemanfaatan kecerdasan buatan atau *Artificial Intelligent* (AI) dalam bentuk asisten virtual atau *chatbot* telah menjadi solusi yang populer. Asisten virtual modern ini didukung oleh teknologi yang dikenal sebagai *Large Language Models (LLM),* yaitu model bahasa berukuran sangat besar dan kompleks yang dirancang untuk menganalisis serta menghasilkan teks secara otomatis (Al Faraby et al., 2024). Dibandingkan dengan model bahasa biasa, LLM memiliki keunggulan dalam hal kapasitas dan tingkat akurasi dalam memahami teks. Dengan kemampuan ini, asisten virtual mampu memahami dan merespon pertanyaan pengguna dalam bahasa alami, memberikan pengalaman yang lebih interaktif. Meskipun demikian, LLM memiliki kelemahan, yaitu fenomena halusinasi yang di mana model menghasilkan informasi yang terdengar meyakinkan namun tidak akurat atau tidak bersumber dari data yang valid (Vaswani et al., 2023). Selain itu, pengetahuan LLM terbatas pada data pelatihannya dan seringkali tidak memiliki akses ke informasi yang sangat spesifik, kontekstual, atau terbaru dari suatu domain tertentu, seperti data pada website siwur.id. Siwur.id merupakan *platform multitenant* yang mengintegrasikan sistem *Point of Sale (POS)* dan *Supply*

Chain Management (SCM) untuk mendukung operasional toko kelontong secara efisien dan terpusat yang berfungsi sebagai sistem manajemen internal.

Dalam konteks pengembangan sistem berbasis kecerdasan buatan, arsitektur *Retrieval-Augmented Generation (RAG)* muncul sebagai solusi yang efektif. RAG menggabungkan kekuatan pencarian informasi *(retrieval)* dari basis pengetahuan *(knowledge base)* yang terkurasi dengan kemampuan generasi teks *(generation)* dari LLM (Ram et al., 2023). Dengan RAG, sebelum menghasilkan jawaban, sistem terlebih dahulu akan mencari dokumen atau informasi yang paling relevan dari basis data siwur.id. Informasi faktual inilah yang kemudian dijadikan konteks bagi LLM untuk merumuskan jawaban. Dengan demikian, jawaban yang dihasilkan tidak hanya relevan secara kontekstual tetapi juga dapat dipertanggungjawabkan kebenarannya karena bersumber langsung dari data yang dimiliki (Fanani, 2025). Implementasi asisten virtual ini akan dibangun di atas website siwur.id yang menggunakan TALL Stack (Tailwind CSS, Alpine.js, Laravel, Livewire) menunjukkan integrasi teknologi AI ke dalam kerangka kerja pengembangan web yang modern.

Namun, tantangan signifikan dalam pengembangan sistem RAG adalah evaluasi kinerjanya. Mengukur keberhasilan sebuah sistem generatif tidak cukup hanya dengan metrik akurasi tradisional. Kualitas jawaban harus dinilai secara multidimensional, mencakup apakah jawaban tersebut sesuai dengan sumber informasi (tidak halusinasi), relevan dengan pertanyaan pengguna, dan apakah konteks yang diambil dari basis data sudah tepat dan lengkap. Saat ini, metode evaluasi untuk sistem RAG masih dalam tahap pengembangan aktif dan belum banyak terstandarisasi. Oleh karena itu, penelitian ini juga akan menyoroti pentingnya evaluasi yang andal dengan memanfaatkan kerangka kerja modern seperti *Retrieval-Augmented Generation Assesment (RAGAS)*, yang dirancang khusus untuk mengukur metrik-metrik krusial seperti *faithfulness, answer relevancy, context precision, dan context recall* (Es et al., 2025).

Berdasarkan uraian di atas, penelitian ini diusulkan untuk mengimplementasikan asisten virtual berbasis RAG pada website siwur.id guna meningkatkan kualitas layanan informasi. Lebih lanjut, penelitian ini akan

melakukan evaluasi komprehensif menggunakan kerangka kerja RAGAS untuk memvalidasi efektivitas dan keandalan sistem, sehingga dapat menjadi acuan bagi pengembangan sistem serupa di masa depan.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, maka terdapat beberapa rumusan masalah, yaitu sebagai berikut:

1. Website konvensional dengan penyajian informasi statis dan pencarian berbasis kata kunci sudah tidak relevan lagi untuk memenuhi kebutuhan pengguna yang menginginkan akses informasi cepat, relevan, dan kontekstual, sehingga diperlukan penerapan asisten virtual berbasis *Artificial Intelligent (AI)*.
2. Penggunaan *Large Language Model (LLM)* secara mandiri masih memiliki keterbatasan berupa halusinasi dan tidak dapat mengakses data domain spesifik seperti pada siwur.id, sehingga diperlukan *penerapan Retrieval-Augmented Generation (RAG)* beserta metode evaluasi modern yang tepat menggunakan kerangka kerja RAGAS.

1.3 Pertanyaan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan diatas, maka penulis menuangkan rumusan masalah sebagai berikut:

1. Bagaimana cara mengembangkan asisten virtual menggunakan python dan mengimplementasikannya pada website siwur.id yang dikembangkan menggunakan TALL Stack (Tailwind CSS, Alpine.js, Laravel, Livewire)?
2. Apakah *Retrieval-Augmented Generation (RAG)* dapat diintegrasikan ke dalam asisten virtual untuk memastikan jawaban yang dihasilkan akurat dan relevan dengan basis pengetahuan spesifik milik siwur.id?

1.4 Tujuan Penelitian

Adapun tujuan dari penelitian ini dapat diuraikan sebagai berikut:

1. Mengembangkan asisten virtual menggunakan bahasa pemrograman python dan mengimplementasikannya pada website siwur.id yang dikembangkan dengan TALL Stack.

2. Mengintegrasikan arsitektur *Retrieval-Augmented Generation (RAG)* pada asisten virtual yang memanfaatkan basis pengetahuan *(knowledge base)* dari siwur.id dan mengevaluasi kinerja asisten virtual menggunakan kerangka kerja RAGAS untuk mengukur kualitas jawaban berdasarkan metrik *faithfulness, answer relevancy, context precision,* dan *context recall*.

1.5 Batasan Masalah

Dalam melaksanakan penelitian ini, peneliti menetapkan batasan masalah pada:

1. Penelitian ini menggunakan bahasa pemrograman PHP versi 8.4 dan Python 3.13 serta beberapa framework yang digunakan yaitu Tailwindcss versi 4.1, Alpinejs versi 3, Laravel versi 12, Livewire versi 3, dan Maryui versi 2.
2. Penelitian ini berfokus pada perancangan, implementasi, dan evaluasi asisten virtual berbasis RAG sebagai layanan informasi. Penelitian tidak akan membahas pengembangan fitur-fitur lain di luar fungsionalitas asisten virtual pada website siwur.id.
3. Sistem kecerdasan buatan *(AI Service)* untuk asisten virtual akan dibangun sebagai *backend service* terpisah menggunakan framework FastAPI dengan bahasa pemrograman Python. Interaksi antara *frontend* dan *backend* akan melalui API.
4. Layanan AI menggunakan Google Gemini Flash 2.5 sebagai *Large Language Model (LLM),* ChromaDB sebagai *vector store*, dan *library Sentence-Transformers* untuk proses *embedding*.
5. Model yang digunakan secara spesifik adalah model generatif dari Google Gemini. Penelitian ini tidak akan melakukan perbandingan performa dengan LLM dari penyedia lain seperti OpenAI (GPT) atau model *open-source* lainnya.
6. Sumber data yang digunakan untuk basis pengetahuan RAG terbatas pada konten tekstual yang diekstrak dari halaman-halaman informasi, *database*, dan dokumen pdf pada website siwur.id. Penelitian ini tidak akan memproses data non-tekstual seperti gambar, video, atau audio.
7. Evaluasi performa sistem RAG akan dilakukan secara kuantitatif dan kualitatif dengan menggunakan kerangka kerja *(framework)* RAGAS. Metrik yang diukur terbatas pada yang disediakan oleh RAGAS, seperti *faithfulness, answer*

relevancy, context precision, dan *context recall*. Penelitian ini tidak akan membandingkan RAGAS dengan metode evaluasi lainnya.

8. Penelitian ini mencakup tahap pengembangan dan evaluasi dalam lingkungan lokal atau *development,* dan tidak mencakup aspek *deployment* ke server produksi, skalabilitas sistem untuk beban tinggi, atau keamanan siber tingkat lanjut.

1.6 Manfaat Penelitian

1. Bagi Universitas
   a. Menjadi sumber referensi akademis mengenai implementasi arsitektur RAG dalam studi kasus nyata, terutama yang mengintegrasikan tumpukan teknologi berbeda (PHP dengan Python).
   b. Menyajikan penerapan praktis dari kerangka kerja evaluasi modern Seperti RAGAS, yang masih jarang dibahas dalam penelitian lokal, sehingga memperkaya khazanah ilmu di bidang evaluasi sistem AI generatif.
2. Bagi Pengembang
   a. Sebagai panduan praktis bagi pengembang lain yang ingin mengimplementasikan asisten virtual berbasis RAG.
   b. Memberikan wawasan konkret tentang bagaimana cara mengukur dan memvalidasi kualitas sistem RAG.
3. Bagi Pengguna Akhir
   a. Mendapatkan jawaban yang relevan dan terpercaya yang bersumber langsung dari data siwur.id, sehingga mengurangi frustasi akibat informasi yang sulit ditemukan atau tidak akurat.
   b. Memperoleh layanan bantuan dan informasi melalui asisten virtual, meningkatkan kepuasan dan keterlibatan pengguna terhadap platform siwur.id.

BAB II
TINJAUAN PUSTAKA

2.1 Teori Dasar

Perkembangan teknologi informasi dan komunikasi yang pesat telah mendorong lahirnya berbagai pendekatan baru dalam pengembangan sistem berbasis kecerdasan buatan atau *Artificial Intelligent (AI)*. Konsep AI menjadi landasan penting dalam menciptakan sistem yang mampu meniru kemampuan kognitif manusia, salah satunya melalui pemrosesan bahasa alami atau *Natural Language Processing (NLP)*. Penerapan AI dan NLP kemudian diwujudkan dalam bentuk asisten virtual yang semakin luas penggunaannya, baik untuk layanan pelanggan, pendidikan, maupun sistem informasi. Kehadiran model bahasa berskala besar atau *Large Language Models (LLM)* semakin memperkuat kemampuan asisten virtual dalam memahami konteks dan menghasilkan jawaban yang lebih natural, meskipun tetap menghadapi tantangan seperti halusinasi informasi dan keterbatasan basis pengetahuan. Untuk mengatasi hal tersebut, lahirlah pendekatan *Retrieval-Augmented Generation (RAG)* sebuah arsitektur yang menggabungkan proses pencarian informasi dengan kemampuan generatif LLM, serta RAGAS sebagai kerangka kerja evaluasi khusus yang dapat mengukur kualitas sistem secara lebih komprehensif.

Dalam konteks penelitian ini, teori dasar tidak hanya berfokus pada aspek AI dan turunannya, tetapi juga mencakup fondasi teknis dan lingkungan implementasi sistem. Website Siwur.id dijadikan sebagai studi kasus yang relevan, dengan dukungan teknologi modern seperti TALL Stack (Tailwind CSS, Alpine.js, Laravel, Livewire) yang dipadukan dengan bahasa pemrograman PHP, Python, serta penggunaan MySQL sebagai basis data. Untuk komponen AI, penelitian ini memanfaatkan Gemini AI sebagai model bahasa generatif, ChromaDB sebagai *vector database* untuk pencarian informasi, dan kerangka pengembangan sistem *Rapid Application Development (RAD)* yang menekankan iterasi cepat dengan keterlibatan pengguna secara aktif. Dengan kerangka teori ini, penelitian diharapkan mampu membangun landasan yang kuat untuk merancang,

mengimplementasikan, serta mengevaluasi asisten virtual berbasis RAG pada Siwur.id.

2.1.1 Kecerdasan Buatan

Kecerdasan Buatan atau *Artificial Intelligence (AI)* adalah cabang ilmu komputer yang berfokus pada perancangan dan pembangunan sistem yang mampu melakukan tugas-tugas yang pada umumnya memerlukan kecerdasan manusia. Tujuan utamanya adalah untuk meniru atau menyimulasikan kemampuan kognitif manusia seperti belajar *(learning)*, menalar *(reasoning)*, memecahkan masalah *(problem-solving)*, dan memahami bahasa (Apriliana et al., 2024).

Menurut Russell dan Norvig (2021), AI dapat dipandang dari empat pendekatan, yaitu sistem yang berpikir seperti manusia, sistem yang bertindak seperti manusia, sistem yang berpikir rasional, dan sistem yang bertindak rasional (Russell & Norvig, 2022). Dalam konteks modern, AI seringkali diimplementasikan melalui sub-bidangnya, yaitu *Machine Learning* (Pembelajaran Mesin) dan *Deep Learning* (Pembelajaran Mendalam) yang memungkinkan mesin untuk belajar secara mandiri dari data dalam jumlah besar tanpa diprogram secara eksplisit untuk setiap tugas. Kemampuan inilah yang menjadi fondasi bagi pengembangan teknologi canggih seperti asisten virtual dan sistem pemrosesan bahasa alami.

2.1.2 *Natural Language Processing (NLP)*

Pemrosesan Bahasa Alami atau *Natural Language Processing (NLP)* adalah disiplin ilmu yang merupakan persimpangan antara linguistik, ilmu komputer, dan kecerdasan buatan, yang bertujuan untuk memungkinkan komputer memahami, menafsirkan, dan menghasilkan bahasa manusia secara bermakna (Jurafsky & Martin, 2025). Fokus utama NLP adalah memodelkan bahasa manusia secara komputasional yang mencakup tugas-tugas seperti analisis sentimen, terjemahan mesin, peringkasan teks, serta pengenalan entitas bernama.

Dalam praktiknya, NLP memungkinkan interaksi yang lebih intuitif antara manusia dan mesin, mengubah data teks yang tidak terstruktur menjadi wawasan yang terstruktur dan dapat diolah (Nurwanda et al., 2024). Pada pengembangan

asisten virtual, teknologi NLP menjadi komponen inti yang menangani proses penguraian pertanyaan pengguna *(Natural Language Understanding)* dan penyusunan jawaban yang koheren *(Natural Language Generation)*.

2.1.3 *Asisten Virtual (Virtual Assistant)*

Asisten Virtual atau yang sering disebut juga sebagai *chatbot* adalah program komputer yang dirancang untuk menyimulasikan percakapan manusia melalui antarmuka teks atau suara, dengan tujuan memberikan layanan informasi, otomasi tugas, dan meningkatkan interaksi pengguna (Sujacka Retno et al., 2023). Seiring perkembangannya, teknologi asisten virtual telah berevolusi dari sistem berbasis aturan (*rule-based*) yang kaku dan hanya mampu merespons perintah dengan kata kunci spesifik, menjadi sistem berbasis kecerdasan buatan yang canggih.

Asisten virtual modern memanfaatkan teknologi NLP untuk memahami maksud (*intent*) di balik pertanyaan pengguna yang beragam dan menggunakan model bahasa generatif untuk menyusun jawaban yang lebih relevan, kontekstual, dan dinamis (Garay Gallastegui & Reier Forradellas, 2024). Dalam konteks layanan pelanggan atau penyediaan informasi, asisten virtual berfungsi sebagai garda terdepan yang dapat diakses 24/7, memberikan respon instan, dan meningkatkan efisiensi operasional secara signifikan.

2.1.4 *Large Language Models (LLM)*

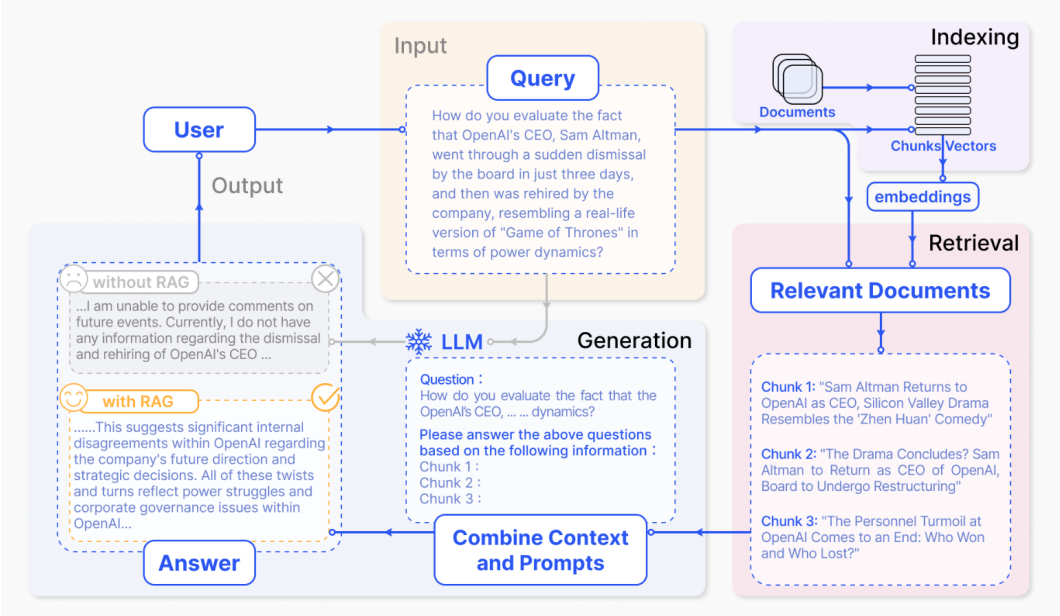
Large Language Models (LLM) adalah model kecerdasan buatan yang dirancang secara khusus untuk memahami, meringkas, menghasilkan, dan memprediksi teks layaknya manusia. Arsitektur yang menjadi tulang punggung bagi hampir semua LLM modern adalah Transformer, yang diperkenalkan pertama kali oleh Tim Google Brain dan Google Research (Vaswani et al., 2023). Keunggulan utama arsitektur ini terletak pada mekanisme *self-attention* yang memungkinkan model untuk menimbang dan mengevaluasi tingkat kepentingan setiap kata dalam sebuah kalimat terhadap kata-kata lainnya, sehingga mampu menangkap konteks yang kompleks, bahkan dalam teks yang sangat panjang. Proses pembentukan kemampuan LLM terjadi melalui tahap pre-training, di mana

model "belajar" dari korpus data teks yang masif—seringkali mencakup sebagian besar isi internet. Selama proses ini, model membangun pemahaman mendalam mengenai pola linguistik, fakta umum, gaya penulisan, hingga kemampuan menalar sederhana.

Skala model yang ditentukan oleh jumlah parameter terbukti menjadi faktor krusial. Seperti yang didemonstrasikan oleh Tim OpenAI dalam penelitian mereka tentang GPT-3, peningkatan jumlah parameter secara eksponensial tidak hanya meningkatkan performa, tetapi juga memunculkan kemampuan baru yang tidak terduga *(emergent abilities)*, seperti kemampuan belajar dalam konteks *(in-context learning)* hanya dengan beberapa contoh *(few-shot learning)* (Brown et al., 2020). Meskipun demikian, di balik kekuatannya LLM memiliki kelemahan yang signifikan. Kelemahan pertama adalah kecenderungan untuk berhalusinasi, yaitu kondisi di mana model menghasilkan informasi yang terdengar sangat meyakinkan namun sepenuhnya salah, tidak faktual, atau tidak didasarkan pada data masukan yang diberikan. Kedua, pengetahuan LLM bersifat statis dan terbatas pada data terakhir yang digunakan dalam pelatihannya *(knowledge cut-off)*. keterbatasan ini membuat LLM rentan memberikan jawaban yang usang atau tidak akurat untuk topik yang berkembang pesat (Al Faraby et al., 2024).

2.1.5 *Retrieval-Augmented Generation (RAG)*

Retrieval-Augmented Generation (RAG) adalah sebuah arsitektur hibrida yang secara fundamental mengubah cara *Large Language Models (LLM)* menghasilkan jawaban dengan mengintegrasikan basis pengetahuan eksternal ke dalam proses generasinya. Diperkenalkan pertama kali oleh Patrick Lewis *(Facebook AI Researcher)* pada tahun 2020, RAG dirancang secara spesifik untuk mengatasi kelemahan utama LLM, seperti halusinasi dan pengetahuan yang usang, dengan memastikan bahwa jawaban yang dihasilkan didasarkan pada informasi yang relevan dan dapat diverifikasi (Lewis et al., 2021).



Gambar 1. Cara Kerja RAG (Gao et all, 2024)

Tahapan *Retrieval-Augmented Generation (RAG)* secara mendasar terdiri dari tiga tahapan utama, yaitu *Indexing, Retrieval*, dan *Generation* yang bertujuan untuk meningkatkan kemampuan *Large Language Models (LLM)* dengan menyertakan pengetahuan dari sumber eksternal (Gao et al., 2024). Hal ini memungkinkan LLM menghasilkan jawaban yang lebih akurat, faktual, dan relevan, terutama untuk pertanyaan mengenai peristiwa terkini atau topik yang sangat spesifik. Proses ini diawali dengan tahap *Indexing* di mana sistem mempersiapkan basis pengetahuan eksternal dengan mengumpulkan dokumen relevan dan memecahnya menjadi potongan-potongan informasi lebih kecil yang disebut *chunks*. Setiap *chunk* kemudian diubah menjadi representasi numerik (vektor) melalui sebuah embedding model dan disimpan dalam vector database sebagai indeks untuk pencarian cepat.

Setelah itu, masuk ke tahap *Retrieval*, di mana pertanyaan *(Query)* dari pengguna juga diubah menjadi vektor menggunakan model yang sama. Vektor pertanyaan ini lalu digunakan untuk mencari dan mengambil *chunks* yang paling relevan dari basis data berdasarkan kemiripan semantik. Tahap puncak dari proses ini adalah *Generation*, di mana *chunks* yang telah diambil tersebut digabungkan dengan pertanyaan asli pengguna menjadi sebuah prompt yang kaya konteks. *Prompt* inilah yang kemudian diberikan kepada LLM untuk menghasilkan jawaban

akhir yang jauh lebih informatif dan mendalam, berbeda dengan respon tanpa RAG yang mungkin bersifat umum.

2.1.6 *Retrieval-Augmented Generation Assessment (RAGAS)*

Evaluasi terhadap sistem *Retrieval-Augmented Generation (RAG)* menghadirkan tantangan karena kualitas jawaban tidak hanya bergantung pada kemampuan generatif model bahasa, tetapi juga pada efektivitas komponen pencariannya. Untuk mengatasi tantangan ini, *RAGAS (Retrieval-Augmented Generation Assessment)* diperkenalkan sebagai sebuah kerangka kerja evaluasi yang komprehensif tanpa memerlukan *ground truth* atau label anotasi manusia (Es et al., 2025). RAGAS memungkinkan pengembang untuk menganalisis kinerja setiap komponen dalam alur kerja RAG secara terpisah, yaitu tahap *retrieval* dan *generation*. Kerangka kerja ini mengukur kualitas sistem melalui serangkaian metrik kunci yang dapat dihitung secara otomatis, diantaranya:

1. *Faithfulness*

   Metrik *faithfulness* mengukur konsistensi faktual dari jawaban yang dihasilkan terhadap konteks yang diambil. Nilai metrik ini berkisar antara 0 hingga 1, di mana nilai yang lebih tinggi menunjukkan konsistensi yang lebih baik. Sebuah jawaban dianggap *"faithful"* jika semua klaim yang dikandungnya dapat didukung oleh konteks yang diambil. Skor *faithfulness* dapat diformulasikan dengan rumus berikut.

   $$faithfulness = \frac{jumlah\ klaim\ respon\ yang\ didukung\ oleh\ konteks\ yang\ diambil}{total\ klaim\ respon} \quad (2.1)$$

2. *Answer Relevancy*

   Metrik *answer relevancy* mengukur sejauh mana relevansi jawaban terhadap *input* pengguna. Skor yang lebih tinggi menunjukkan kesesuaian yang lebih baik dengan input pengguna, sementara skor yang lebih rendah menunjukkan jawaban yang kurang relevan atau tidak lengkap. Skor *answer relevancy* dapat diformulasikan dengan rumus berikut.

   $$answer\ relevancy = \frac{1}{N}\sum_{i=1}^{N} \frac{E_{gi} . E_o}{\|E_{gi}\| . \|E_o\|} \quad (2.2)$$

Keterangan:

E_{gi} : penyematan pertanyaan yang dihasilkan ke-i.

E_o : penyematan masukkan pengguna.

N : jumlah pertanyaan yang dihasilkan (*default 3*).

3. *Context Precision*

Metrik *context precision* mengevaluasi kemampuan pengambil informasi *(retriever)* dalam menempatkan potongan konteks yang relevan di urutan teratas. Metrik ini dihitung sebagai rata-rata dari *precision@k* untuk setiap potongan dalam konteks. *Precision@k* adalah rasio jumlah potongan relevan pada peringkat k terhadap total jumlah potongan pada peringkat k. Skor *context precision* dapat diformulasikan dengan rumus berikut.

$$context\ precision@K = \frac{\sum_{k=1}^{K}(Precision@k \times v_k)}{jumlah\ total\ item\ relevan\ dalam\ hasil\ K\ teratas} \quad (2.3)$$

$$Precision@K = \frac{true\ positives@k}{true\ positives@k + false\ positives@k} \quad (2.4)$$

Keterangan:

K : jumlah potongan dari konteks yang diambil

v_k : indikator relevansi pada peringkat K ($v_k \in \{0,1\}$)

4. *Context Recall*

Metrik *context recall* mengukur sejauh mana konteks yang diambil sesuai dengan jawaban yang dianotasi, yang diperlakukan sebagai kebenaran dasar *(ground truth)*. Metrik ini dihitung menggunakan pertanyaan, jawaban yang dianotasi, dan konteks yang diambil. Nilai metrik ini berkisar antara 0 hingga 1, di mana nilai yang lebih tinggi menunjukkan kinerja yang lebih baik. Skor *context recall* dapat diformulasikan dengan rumus berikut.

$$context\ recall = \frac{jumlah\ klaim\ referensi\ yang\ didukung\ oleh\ konteks\ yang\ diambil}{total\ klaim\ referensi} \quad (2.5)$$

2.1.7 *Website* Siwur.id

Siwur.id (Sistem Wirausaha Terpadu) merupakan *platform* perangkat lunak berbasis *multitenant* yang dirancang untuk mendukung digitalisasi operasional toko kelontong secara terpusat dan efisien. Berbeda dengan *platform e-commerce* konvensional, Siwur.id tidak berfungsi sebagai sarana penjualan daring, melainkan

sebagai sistem manajemen internal yang membantu pengelolaan transaksi dan rantai pasok. *Platform* ini mengintegrasikan dua komponen utama, *yaitu Point of Sale (POS)* untuk pencatatan dan pengelolaan transaksi penjualan, serta *Supply Chain Management (SCM)* untuk mengatur alur pengadaan barang, pengendalian inventaris, hingga proses stock opname. Dalam penerapannya, setiap toko yang menggunakan Siwur.id akan memperoleh instalasi sistem dari pihak pengembang, sementara pengelolaan server dan infrastruktur tetap berada di bawah kendali terpusat pengembang.

2.1.8 Bahasa Pemrograman

Sistem asisten virtual pada penelitian ini dikembangkan menggunakan tiga bahasa pemrograman utama, yaitu JavaScript, PHP, dan Python, yang masing-masing memiliki peran spesifik. JavaScript digunakan pada sisi klien *(client-side)* untuk menciptakan antarmuka pengguna yang dinamis dan interaktif. PHP sebagai inti dari framework Laravel berperan sebagai bahasa pemrograman sisi server *(server-side)* yang menangani logika bisnis utama aplikasi Siwur.id dan komunikasi dengan basis data. Sementara itu, Python digunakan untuk membangun layanan kecerdasan buatan *(AI service)* secara terpisah untuk menangani seluruh proses komputasi pada arsitektur RAG.

1. JavaScript

   JavaScript adalah bahasa pemrograman tingkat tinggi yang menjadi teknologi inti dari World Wide Web bersama dengan HTML dan CSS. Bahasa ini berjalan di sisi klien yang memungkinkan halaman web menjadi interaktif dengan memanipulasi *Document Object Model (DOM)* (Narwal et al., 2025). Fungsi utamanya adalah untuk validasi formulir, mengelola event dari pengguna, membuat animasi, dan melakukan komunikasi asinkron dengan server.

2. PHP (*Hypertext Preprocessor*)

   PHP (Hypertext Preprocessor) adalah bahasa yang berjalan di sisi server yang dirancang khusus untuk pengembangan web. Kode PHP dieksekusi di server dan hasilnya dikirim ke peramban sebagai HTML biasa, sehingga

memungkinkan pembuatan konten halaman yang dinamis dan interaksi dengan basis data seperti MySQL (Hermiati et al., 2021) .

3. Python

   Python adalah bahasa pemrograman tingkat tinggi yang populer karena sintaksisnya yang bersih, mudah dibaca, dan ekosistem pustaka *(library)* yang sangat luas. Keunggulan utama Python terletak pada dukungannya yang kuat untuk pengembangan kecerdasan buatan, pembelajaran mesin, dan analisis data (Santoso, 2022).

2.1.9 MySQL

MySQL adalah sebuah Relational Database Management System (RDBMS) sumber terbuka *(open-source)* yang populer dan banyak digunakan dalam pengembangan aplikasi, terutama aplikasi berbasis web. Sebagai sebuah RDBMS, MySQL mengorganisir data ke dalam tabel-tabel yang terdiri dari baris dan kolom di mana relasi antar tabel dapat didefinisikan menggunakan *keys* untuk menjaga integritas data. MySQL beroperasi dengan model arsitektur *client-server*, di mana server database bertanggung jawab untuk menyimpan, mengelola, dan mengamankan data, sementara klien dapat mengirimkan permintaan untuk memanipulasi data tersebut menggunakan *Structured Query Language (SQL).* SQL merupakan bahasa standar untuk melakukan operasi seperti membuat, membaca, memperbarui, dan menghapus data (CRUD) (Putri, 2022).

2.1.10 TALL *Stack*

TALL *Stack* adalah sebuah akronim yang merujuk pada seperangkat teknologi modern yang digunakan untuk membangun aplikasi *website* yang dinamis tanpa perlu menulis banyak JavaScript secara manual. Pendekatan ini memungkinkan pengembang untuk menciptakan pengalaman pengguna yang dinamis seperti pada aplikasi berbasis JavaScript (seperti Vue atau React), namun tetap dalam ekosistem bahasa PHP. TALL *Stack* terdiri dari empat komponen utama, diantaranya Tailwind CSS, Alpine.js, Laravel, dan Livewire. Dalam penelitian ini, TALL Stack menjadi pondasi utama dalam pengembangan

antarmuka pengguna (UI) website Siwur.id termasuk integrasi jendela percakapan untuk asisten virtual (Nuridza et al., 2025).

1. TailwindCSS

   Tailwind CSS adalah sebuah kerangka kerja *(framework)* CSS yang mengusung pendekatan *utility-first*. Berbeda dengan framework lain seperti Bootstrap yang menyediakan komponen siap pakai (misalnya, .card atau .button), Tailwind menyediakan kelas-kelas utilitas tingkat rendah (misalnya, pt-4 untuk *padding-top*, flex untuk *flexbox*, atau text-lg untuk ukuran teks) yang dapat digabungkan langsung di dalam HTML untuk membangun desain kustom apa pun (Azhariyah & Muhammad Mukhlis, 2024).

2. Alpine.js

   Alpine.js adalah sebuah kerangka kerja JavaScript yang sangat ringan dan minimalis, dirancang untuk menambahkan interaktivitas pada antarmuka pengguna langsung dari HTML. Pada TALL Stack, Alpine.js digunakan untuk menangani interaksi kecil di sisi klien, seperti membuka-tutup menu dropdown, menampilkan atau menyembunyikan elemen, atau mengelola tab, yang semuanya terjadi tanpa perlu memuat ulang halaman (Nuridza et al., 2025).

3. Laravel

   Laravel adalah sebuah kerangka kerja aplikasi web berbasis PHP yang elegan dan ekspresif, mengikuti pola arsitektur *Model-View-Controller* (MVC). Laravel menyediakan berbagai fitur bawaan, seperti sistem *routing*, ORM *(Object-Relational Mapping)* bernama Eloquent, *templating* Blade, serta sistem otentikasi dan otorisasi yang aman (Daru & Adhiwibowo, 2021).

4. Livewire

   Livewire adalah sebuah kerangka kerja *full-stack* untuk Laravel yang memungkinkan pengembang untuk membangun antarmuka dinamis menggunakan PHP, seolah-olah mereka sedang menulis JavaScript.

Livewire menjembatani kesenjangan antara *frontend* dan *backend* dengan membuat permintaan AJAX secara cerdas di latar belakang setiap kali ada interaksi dari pengguna. Server kemudian akan memuat ulang komponen tersebut dan mengirimkan kembali HTML yang sudah diperbarui, lalu Livewire akan dengan cerdas memperbarui DOM di halaman tanpa memuat ulang seluruh halaman (Daru & Adhiwibowo, 2021).

2.1.11 GeminiAI Flash 2.5

GeminiAI Flash 2.5 adalah model generatif AI dari Google DeepMind yang dirancang untuk memberikan kinerja optimal dalam tugas-tugas sehari-hari dengan latensi rendah dan efisiensi biaya tinggi. Model ini mendukung multimodalitas, memungkinkan pemrosesan input berupa teks, gambar, video, dan audio. Dengan kemampuan *"thinking"*, GeminiAI Flash 2.5 dapat menunjukkan proses berpikirnya sebelum menghasilkan respon, meningkatkan transparansi dan akurasi dalam pengambilan keputusan. Model ini juga mendukung penggunaan alat secara *agentic,* memungkinkan eksekusi tugas kompleks secara otomatis (Nazarius et al., 2024).

2.1.12 ChromaDB

ChromaDB adalah basis data vektor sumber terbuka yang dirancang untuk menyimpan dan mengambil *embedding* vektor secara efisien. Dikembangkan dengan tujuan untuk aplikasi *Large Language Model (LLM),* ChromaDB mendukung pencarian berbasis vektor dan penyimpanan metadata, serta kompatibel dengan berbagai *framework* seperti LangChain dan Hugging Face. Penggunaan ChromaDB memungkinkan integrasi yang mulus dalam sistem berbasis AI, seperti dalam penerapan *Retrieval-Augmented Generation (RAG)* (Yatabri et al., 2025).

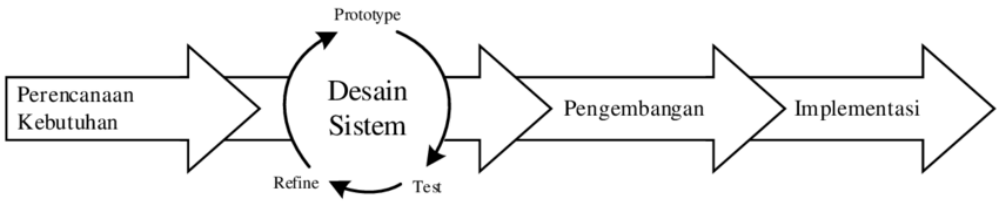
2.1.13 *Embedding Sentence Transformer*

Embedding Sentence Transformer (SBERT) adalah model pembelajaran mesin yang menghasilkan representasi vektor dari kalimat untuk tugas-tugas seperti pencarian semantik dan klasifikasi teks. Berbeda dengan model sebelumnya seperti

BERT yang menghasilkan *embedding* kata, SBERT dirancang untuk menghasilkan *embedding* kalimat secara langsung. Dengan menggunakan arsitektur siamese dan pelatihan berbasis pasangan kalimat, SBERT mampu menangkap kesamaan semantik antar kalimat dengan akurasi tinggi. Model ini telah dioptimalkan untuk berbagai bahasa dan domain, menjadikannya alat yang efektif dalam aplikasi pemrosesan bahasa alami (Galli et al., 2024).

2.1.14 Metode *Rapid Application Development (RAD)*

Dalam penelitian ini, metode pengembangan sistem yang digunakan adalah *Rapid Application Development (RAD)*. RAD adalah sebuah model proses pengembangan perangkat lunak yang berfokus pada siklus pengembangan yang sangat singkat dan cepat. Tujuan utama dari model ini adalah untuk mempercepat penyampaian sistem fungsional dengan melibatkan pengguna secara aktif melalui serangkaian iterasi dan pembuatan *prototype*. Berbeda dengan model air terjun *(waterfall)* yang kaku dan sekuensial, RAD menekankan fleksibilitas dan adaptasi melalui umpan balik yang berkelanjutan, sehingga sangat cocok untuk proyek dengan kebutuhan yang dapat berubah dan memerlukan penyelesaian dalam waktu singkat (Pressman, 2010).



Gambar 2. Metode Pengembangan RAD (Pressman, 2010)

Proses dalam model RAD, seperti yang diilustrasikan pada gambar secara umum terdiri dari beberapa fase utama. Tahapan dimulai dengan Perencanaan Kebutuhan *(Requirements Planning)* di mana kebutuhan bisnis dasar didefinisikan. Selanjutnya, sistem memasuki fase Desain Sistem *(User Design)* yang merupakan inti dari RAD. Pada fase ini, tim secara iteratif membangun, menguji dan menyempurnakan prototipe fungsional bersama pengguna. Umpan balik dari pengguna langsung diintegrasikan untuk perbaikan berkelanjutan. Setelah prototipe disetujui, proyek bergerak ke tahap Pengembangan *(Construction)* di mana kode

program diselesaikan, diuji secara menyeluruh, dan diintegrasikan. Tahap terakhir adalah Implementasi *(Cutover),* yang mencakup proses peluncuran sistem, pelatihan pengguna, dan serah terima akhir.

2.2 Penelitian Sejenis

Hasil dari penelitian terdahulu digunakan sebagai pertimbangan, perbandingan, dan pedoman dasar dalam melakukan penelitian terbaru yang sejenis. Berikut merupakan beberapa penelitian sebelumnya :

Tabel 1. Penelitian Sejenis

	Penelitian 1	**Penelitian 2**	**Penelitian 3**	**Penelitian 4**	**Penelitian 5**	**Penelitian Sekarang**
Judul	Implementasi RAG Multimodal untuk Rekomendasi Teks dan Gambar di E-Commerce	Penerapan Metode *Retrieval-Augmented Generation (RAG)* Pada *Chatbot E-Commerce* Berbasis Gemini AI	*A RAG Chatbot for Precision Medicine of Multiple Myeloma*	Pengembangan *Chatbot* Konsultasi Haji dan Umrah Berbasis RAG dan *Prompt Engineering* Studi Kasus Fillah Guide	*LLM-Based Chatbot for the Indonesia University IT Service Desk: Integrating DeepSeek-v3 API and a RAG Approach*	Implementasi *Retrieval-Augmented Generation (RAG) pada* Asisten Virtual dalam Pengembangan Website Siwur.id Berbasis TALL Stack
Penulis (Tahun)	Bagas Wahyu Herdiansyah dan Mukhammad Andri Setiawan (2025)	Tarisa Ramadhani, Noora Qotrun Nada, Nugroho Dwi S (2025)	Mujahid Ali Quidwai dan Alessandro Lagana (2024)	Rijki Hardiyanti dan Diny Syarifah Sany (2025)	Rahmat Pratami, Muhammad Lutfi Ruhallah, Alfian Akbar Gozali (2025)	Ageng Praba Wijaya (2025)
Model	Google Gemini 2.5 Pro	LLaMA dan Gemini AI	Mistral-7B Instruct	Together AI	DeepSeek-v3	Google Gemini Flash 2.5

Metode Pengembangan	*Incremental*	-	*Incremental*	*Waterfall*	-	*Rapid Application Development (RAD)*
Hasil	RAG Multimodal secara konsisten dipilih oleh semua partisipan (5 dari 5) sebagai pilihan utama dalam skenario pencarian kompleks dan ambigu. Sistem mampu memberikan rekomendasi yang terjustifikasi, adaptif, dan konsultatif, mengubah interaksi dari "mencari" menjadi "berkonsultasi" dan mengurangi beban kognitif pengguna. RAG memberikan nilai tambah paling signifikan dalam skenario yang ditandai oleh ambiguitas	Sistem mencapai *Mean Reciprocal Rank (MRR)* 0.83, *Exact Match (EM)* 100%, *F1 Score* 82.05%, *Semantic Similarity* 97.45%, tingkat kesetiaan 91.67%, dan relevansi jawaban 94.21%. Evaluasi *retrieval* menunjukkan *Top-1 Recall* 80%, *Top-3 Recall* 93.33%, dan *Precision @3* sebesar 88.88%. Integrasi Gemini AI dengan RAG terbukti secara signifikan meningkatkan akurasi, fakta, dan relevansi	Model RAG menunjukkan performa kompetitif dibandingkan GPT-3.5-turbo-16k dan GPT-4-32k dengan biaya 1/10 lebih rendah. Sistem berhasil menguranggi hallucination dengan memberikan respon "Sorry, I could not find relevant information" ketika tidak menemukan dokumen relevan. Benchmarking dashboard menunjukkan akurasi dan relevansi tinggi dengan kemampuan transparent access ke PubMed	*chatbot* mencapai akurasi jawaban 70% dengan rata-rata *semantic similarity* 0.51, dan 100% skenario pengujian fungsional (25 skenario) lulus uji. Pengujian *usability* dengan 14 narasumber menunjukkan tanggapan positif terhadap kecepatan respons dan kemudahan navigasi. Sistem efektif untuk pertanyaan prosedural dan FAQ, namun mengalami kendala pada pertanyaan agama yang memerlukan reasoning kontekstual lintas ayat atau hadist.	*Functional testing* menunjukkan operasi stabil 24/7 dengan akurasi *retrieval* di atas 98%. Performance benchmarking mencatat rata-rata waktu respons 2,1 ± 0,2 detik, 35% lebih cepat dibanding *baseline helpdesk* konvensional. Studi pengguna (26 peserta) menghasilkan skor *UEQ* tinggi 4,5 ± 0,3 (skala 1–5), menandakan kepuasan kuat pada efisiensi dan *novelty.*	Diharapkan sistem meningkatkan kualitas layanan informasi dan mengurangi halusinasi. Integrasi TALL Stack memungkinkan *real-time* data *access* dari MySQL dan ChromaDB.

	, kompleksitas, dan kebutuhan eksplorasi.	konteks dari respon *chatbot* dibanding chatbot konvensional berbasis LLM murni.	papers sebagai sumber.			
Perbedaan	Domain penelitian sistem rekomendasi teks dan gambar pada platform *e-commerce*. Evaluasi menggunakan evaluasi kualitatif berbasis skenario.	Domain penelitian pada E-commerce. Evaluasi menggunakan MRR, EM, F1, Semantic.	Domain penelitian pada *healthcare*. Benchmarking performa vs GPT-3.5-turbo-16k dan GPT-4-32k.	Domain penelitian pada layanan informasi keagamaan (Haji & Umrah). Evaluasi menggunakan *Functional testing* (25 skenario), *usability testing* (14 narasumber), *semantic similarity metrics.*	Domain penelitian pada *IT helpdesk* untuk manajemen layanan TI di lingkungan universitas. Evaluasi menggunakan *Functional testing, hardware benchmarking, performance testing (response time)*, dan *User Experience Questionnaire (UEQ).*	Domain penelitian pada *business management* (POS–SCM). Evaluasi menggunakan kerangka kerja RAGAS.

BAB III
METODE PENELITIAN

3.1 Waktu dan Tempat Penelitian

Penelitian ini akan dilaksanakan di CV. Jenderal Solusi Digital yang beralamat di Jl. Amad I, Dusun II Sokaraja Kidul, Sokaraja Kidul, Kec. Sokaraja, Kabupaten Banyumas, Jawa Tengah 53181. Waktu penelitian dimulai pada bulan Agustus sampai dengan Desember 2025.

3.2 Data dan Alat Penelitian

Penelitian ini memerlukan dukungan berupa data dan seperangkat alat untuk memastikan proses pengembangan serta evaluasi sistem dapat berjalan dengan baik. Data penelitian digunakan sebagai dasar pembentukan basis pengetahuan dan sebagai sumber evaluasi terhadap performa sistem yang dibangun. Sementara itu, alat penelitian berfungsi untuk menunjang kebutuhan teknis mulai dari tahap implementasi, pengujian, hingga penyusunan laporan penelitian.

3.2.1 Data Penelitian

Data yang digunakan dalam penelitian ini terbagi menjadi dua kategori utama, yaitu data sekunder dan data primer. Data sekunder merupakan data input yang menjadi fondasi bagi sistem, yang bersumber dari konten tekstual pada website Siwur.id. Kumpulan data tekstual ini akan melalui tahap pra-pemrosesan untuk kemudian disusun menjadi basis pengetahuan *(knowledge base)* yang akan diindeks ke dalam *vector database* untuk digunakan oleh sistem RAG. Selain itu, data sekunder juga mencakup studi literatur dari jurnal, buku, dan publikasi ilmiah yang relevan.

Sementara itu, data primer adalah data yang dihasilkan secara langsung melalui proses pengujian dan evaluasi sistem yang telah dibangun. Data ini bersifat kuantitatif, berupa skor numerik dari metrik-metrik evaluasi RAGAS—yaitu *faithfulness, answer relevancy, context precision,* dan *context recall*.

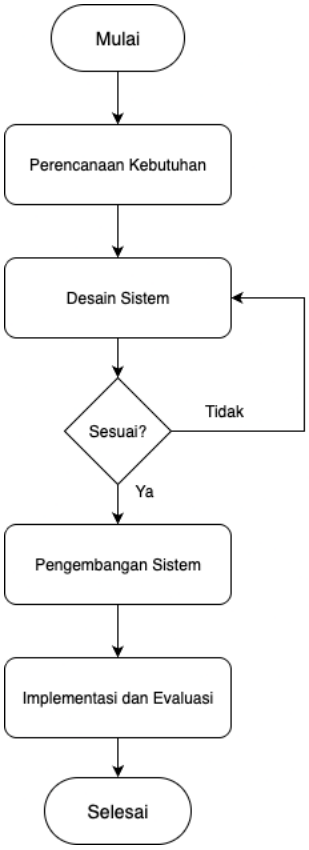
3.2.2 Alat Penelitian

Pada penelitian ini penulis menggunakan alat bantu sebagai berikut:

1. Laptop Macbook Air M2 dengan spesifikasi RAM 16 GB, Sistem Operasi macOS Sequoia 15, dan *processor* Apple M2, untuk pengembangan sistem dan penulisan laporan.
2. Visual Studio Code sebagai IDE untuk menulis kode.
3. Brave sebagai *browser* untuk melakukan pengujian dan *debugging*.
4. Herd untuk menjalankan server Nginx.
5. DBngin untuk menjalankan *database* secara lokal atau *offline*.
6. Microsoft Word untuk penyusunan laporan.
7. MySQL untuk basis data program siwur.id.
8. ChromaDB sebagai basis data vector penyimpanan hasil *embedding.*
9. GeminiAPI sebagai model LLM yang digunakan.
10. DBeaver sebagai alat manajemen basis data.

3.3 Tahapan Penelitian

Tahapan penelitian merupakan penjabaran dari tahapan-tahapan yang akan dilakukan peneliti dalam pelaksanaan penelitian.



Gambar 3. Tahapan Penelitian

Gambar 3 menunjukkan tahapan penelitian yang merupakan penjabaran dari tahapan-tahapan yang dilakukan peneliti dalam pelaksanaan penelitian.

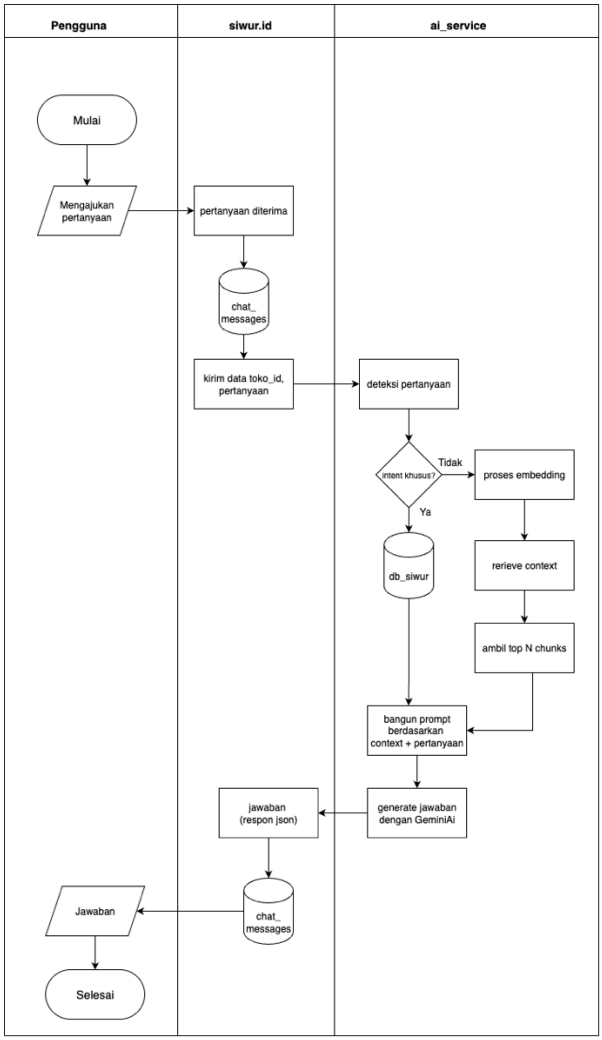
3.3.1 Perencanaan Kebutuhan

Tahap Perencanaan Kebutuhan merupakan fondasi awal dari keseluruhan proses pengembangan sistem asisten virtual ini. Pada fase ini, dilakukan analisis mendalam untuk mendefinisikan tujuan utama, yaitu meningkatkan efisiensi dukungan dan aksesibilitas informasi bagi pengguna *platform* Siwur.id melalui asisten virtual. Fungsi-fungsi dasar sistem diidentifikasi, mencakup kemampuan untuk menjawab pertanyaan terkait data spesifik *tenant* (seperti sisa stok produk, tren penjualan, detail harga) serta memberikan rekomendasi bisnis (misalnya strategi pemasaran) berdasarkan data yang relevan. Lebih lanjut, pada tahap ini juga dilakukan identifikasi dan pemetaan sumber data dari basis data Siwur.id. Data transaksi, inventaris, pelanggan, dan informasi produk yang bersifat *multitenant* akan dianalisis untuk menentukan jenis informasi apa saja yang paling relevan

untuk diekstrak, diproses, dan dijadikan sebagai basis pengetahuan *(knowledge base)* yang akan diindeks ke dalam *vector store* untuk sistem *Retrieval-Augmented Generation (RAG).*

3.3.2 Desain Sistem

Setelah kebutuhan sistem didefinisikan, penelitian memasuki fase Desain Sistem yang bersifat iteratif dan berpusat pada pengguna. Fase ini mewujudkan ide-ide abstrak menjadi model yang konkret dan dapat diuji. Aktivitas utama pada fase ini adalah perancangan arsitektur sistem secara menyeluruh, yang akan menjadi cetak biru bagi tahap pengembangan selanjutnya. Arsitektur yang dirancang, seperti yang divisualisasikan pada Gambar 4.



Gambar 4. *Flowchart* Asisten Virtual Siwur.id

Proses yang digambarkan pada Gambar 4 mengilustrasikan alur kerja sistem *Retrieval-Augmented Generation (RAG)* untuk menangani pertanyaan pengguna dalam platform Siwur.id, yang melibatkan interaksi antara pengguna, aplikasi Siwur.id, dan layanan AI. Alur dimulai ketika pengguna mengajukan pertanyaan melalui antarmuka pengguna. Aplikasi Siwur.id menerima pertanyaan tersebut dan menyimpannya sementara dalam basis data chat_messages untuk pencatatan riwayat. Selanjutnya, Siwur.id mengirimkan data identitas toko (toko_id) beserta pertanyaan ke layanan AI untuk diproses. Di sisi layanan AI, pertanyaan pertama kali dideteksi untuk menentukan apakah termasuk dalam kategori *intent* khusus; jika ya, jawaban langsung dihasilkan tanpa proses tambahan, sedangkan jika tidak, pertanyaan diproses melalui embedding untuk mencari konteks relevan dari basis data db_siwur dan *vector store*. Layanan AI kemudian mengambil *top N chunks* materi yang paling relevan berdasarkan kemiripan, membangun *prompt* yang mencakup konteks tersebut ditambah pertanyaan asli, dan menghasilkan jawaban menggunakan model Gemini AI. Jawaban yang dihasilkan dikembalikan dalam format respon JSON ke aplikasi Siwur.id yang kemudian menyimpannya kembali ke chat_messages dan menampilkan jawaban akhir kepada pengguna. Proses ini berakhir dengan status selesai.

3.3.3 Pengembangan Sistem

Pada tahap Pengembangan, cetak biru dan *prototype* yang telah disetujui pada fase desain diwujudkan menjadi sebuah sistem yang fungsional secara utuh. Fokus dari tahap ini adalah pengkodean *(coding)* final dan integrasi semua komponen teknologi. Pada tahap ini mulai membangun *backend service AI* menggunakan Python, mengimplementasikan logika *pipeline* RAG, mengintegrasikan API Google Gemini, dan mengatur *vector database* ChromaDB. Secara paralel, antarmuka asisten virtual pada sisi *frontend* dikembangkan menggunakan TALL Stack (Laravel, Livewire, Alpine.js, Tailwind CSS) sesuai dengan desain final. Proses terpenting pada tahap ini adalah memastikan komunikasi yang lancar antara *frontend* dan *backend* melalui API yang telah dirancang, sehingga sistem dapat berfungsi dengan baik.

3.3.4 Implementasi dan Evaluasi

Tahap Implementasi adalah fase akhir dari siklus pengembangan, di mana asisten virtual yang telah selesai dibangun diintegrasikan ke dalam lingkungan website Siwur.id versi pengembangan *(development environment)*. Tujuannya adalah untuk menguji sistem dalam lingkungan yang semirip mungkin dengan kondisi nyata, memastikan tidak ada konflik dengan fitur-fitur website yang sudah ada. Pada tahap ini, dilakukan serangkaian pengujian akhir secara menyeluruh *(end-to-end testing)* untuk memvalidasi semua fungsionalitas. Setelah sistem dinyatakan stabil dan berjalan sesuai harapan, sistem disiapkan untuk proses evaluasi kinerja secara formal menggunakan framework RAGAS.

3.4 Jadwal Penelitian

Untuk rincian jadwal kegiatan yang akan dilakukan pada penelitian ini dapat dilihat pada Tabel 2.

Tabel 2. Jadwal Penelitian

Kegiatan	Waktu																			
	Agustus				September				Oktober				November				Desember			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
Perencanaan Kebutuhan Sistem			■	■	■															
Desain Sistem						■	■	■												
Pengembangan Sistem									■	■	■	■								
Implementasi dan Evaluasi Sistem												■	■	■	■	■				
Penyusunan Laporan													■	■	■	■	■	■	■	■

DAFTAR PUSTAKA

Al Faraby, S., Romadhony, A., & Adiwijaya. (2024). Analysis of LLMs for educational question classification and generation. *Computers and Education: Artificial Intelligence*, *7*, 100298. https://doi.org/10.1016/j.caeai.2024.100298

Apriliana, H. K., Kornarius, Y. P., Caroline, A., Gusti, T. E. P., & Gunawan, A. (2024). Perkembangan Penerapan Teknologi Artificial Intelligence di Indonesia. *Jurnal Syntax Admiration*, *5*(10), 3864–3874. https://doi.org/10.46799/jsa.v5i10.1486

Azhariyah, S. & Muhammad Mukhlis. (2024). Framework CSS: Tailwind CSS Untuk Front-End Website Store PT. XYZ. *Jurnal Informatika*, *3*(1), 30–36. https://doi.org/10.57094/ji.v3i1.1601

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., … Amodei, D. (2020). *Language Models are Few-Shot Learners* (No. arXiv:2005.14165). arXiv. https://doi.org/10.48550/arXiv.2005.14165

Daru, A. F., & Adhiwibowo, W. (2021). PENERAPAN METODE RAPID APLICATION DEVELOPMENT UNTUK MENGEMBANGKAN SISTEM INFORMASI STOK BARANG MENGGUNAKAN LIVEWIRE LARAVEL. *JURNAL TEKNOLOGI INFORMASI DAN KOMUNIKASI*, *12*(2), 48–57. https://doi.org/10.51903/jtikp.v12i2.271

Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2025). *Ragas: Automated Evaluation of Retrieval Augmented Generation* (No. arXiv:2309.15217). arXiv. https://doi.org/10.48550/arXiv.2309.15217

Fanani, I. (2025). *IMPLEMENTASI RETRIEVAL AUGMENTED GENERATION UNTUK EVALUASI PROPOSAL TUGAS AKHIR MAHASISWA*. *3*(2).

Galli, C., Donos, N., & Calciolari, E. (2024). Performance of 4 Pre-Trained Sentence Transformer Models in the Semantic Query of a Systematic

Review Dataset on Peri-Implantitis. *Information*, *15*(2), 68. https://doi.org/10.3390/info15020068

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). *Retrieval-Augmented Generation for Large Language Models: A Survey* (No. arXiv:2312.10997). arXiv. https://doi.org/10.48550/arXiv.2312.10997

Garay Gallastegui, L. M., & Reier Forradellas, R. (2024). FASECO: A Framework for Advanced Support of E-Commerce and digital transformation in SMEs with natural language processing-enhanced analysis. *Journal of Open Innovation: Technology, Market, and Complexity*, *10*(4), 100412. https://doi.org/10.1016/j.joitmc.2024.100412

Hermiati, R., Asnawati, A., & Kanedi, I. (2021). PEMBUATAN E-COMMERCE PADA RAJA KOMPUTER MENGGUNAKAN BAHASA PEMROGRAMAN PHP DAN DATABASE MYSQL. *JURNAL MEDIA INFOTAMA*, *17*(1). https://doi.org/10.37676/jmi.v17i1.1317

Jurafsky, D., & Martin, J. H. (2025). *Speech and Language Processing*.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2021). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks* (No. arXiv:2005.11401). arXiv. https://doi.org/10.48550/arXiv.2005.11401

Narwal, N., Nagar, Y., & Rathore, C. (2025). JAVASCRIPT IN MODERN WORLD. *International Journal of Recent Research and Review*.

Nazarius, A., Saputra, F., Noor Kamala Sari, N., & Handrianus Pranatawijaya, V. (2024). PENERAPAN GEMINI AI DALAM PEMBUATAN DESKRIPSI PRODUK E-COMMERCE. *JATI (Jurnal Mahasiswa Teknik Informatika)*, *8*(3), 3721–3725. https://doi.org/10.36040/jati.v8i3.9670

Nuridza, A. B., Fitriastuti, F., & Setiyorini, A. (2025). *IMPLEMENTASI TALL STACK DALAM PENGEMBANGAN SISTEM INFORMASI PEMINJAMAN ALAT DENGAN MENGGUNAKAN RAPID APPLICATION DEVELOPMENT*. *7*(2).

Nurwanda, N., Suarna, N., & Prihartono, W. (2024). PENERAPAN NLP (NATURAL LANGUAGE PROCESSING) DALAM ANALISIS SENTIMEN PENGGUNA TELEGRAM DI PLAYSTORE. *JATI (Jurnal Mahasiswa Teknik Informatika)*, *8*(2), 1841–1846. https://doi.org/10.36040/jati.v8i2.8469

Pressman, R. S. (2010). *Software engineering: A practitioner's approach* (7th ed). McGraw-Hill.

Putri, R. A. (2022). *Buku Ajar Basis Data* (02 ed.). CV. MEDIA SAINS INDONESIA.

Ram, O., Levine, Y., Dalmedigos, I., Muhlgay, D., Shashua, A., Leyton-Brown, K., & Shoham, Y. (2023). *In-Context Retrieval-Augmented Language Models* (No. arXiv:2302.00083). arXiv. https://doi.org/10.48550/arXiv.2302.00083

Russell, S. J., & Norvig, P. (with Chang, M., Devlin, J., Dragan, A., Forsyth, D., Goodfellow, I., Malik, J., Mansinghka, V., Pearl, J., & Wooldridge, M. J.). (2022). *Artificial intelligence: A modern approach* (Fourth edition, global edition). Pearson.

Santoso, J. T. (2022). *PROYEK CODING DENGAN PHYTON*. YAYASAN PRIMA AGUS TEKNIK.

Sujacka Retno, Rozzi Kesuma Dinata, & Novia Hasdyna. (2023). Evaluasi model data chatbot dalam natural language processing menggunakan k-nearest neighbor. *Jurnal CoSciTech (Computer Science and Information Technology)*, *4*(1), 146–153. https://doi.org/10.37859/coscitech.v4i1.4690

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2023). *Attention Is All You Need* (No. arXiv:1706.03762). arXiv. https://doi.org/10.48550/arXiv.1706.03762

Yatabri, B. D. P., Harahap, N. S., Handayani, L., & Candra, M. (2025). Question Answering Al-Qur'an dan Tafsir Menggunakan Generative Pre-Trained Transformer 4 (GPT-4). *Jurnal JUPITER*, *17*(1), 26–38.